

Allineamento delle Componenti nella Decomposizione CP Spettroscopica EEM

Analisi Matematica di align_components ed Utilizzo nel Modulo viz_eem_cp.py

1. Introduzione e Motivazione Teorica

Nello studio della spettroscopia di matrice di eccitazione-emissione (EEM, **Excitation-Emission Matrix**), una miscela chimica contenente R fluorofori viene modellata mediante decomposizione tensoriale non-negativa **Canonical Polyadic** (CP / PARAFAC) di rango R :

$$X_{i,j,k} \approx \sum_{r=1}^R \lambda_r A_{i,r} B_{j,r} C_{k,r}$$

dove:

- $A \in \mathbb{R}_+^{N \times R}$ rappresenta i profili di concentrazione o **loadings** dei campioni (modo 1, campioni $i = 1, \dots, N$),
- $B \in \mathbb{R}_+^{J \times R}$ rappresenta i profili di spettro di emissione (modo 2, lunghezze d'onda di emissione),
- $C \in \mathbb{R}_+^{K \times R}$ rappresenta i profili di spettro di eccitazione (modo 3, lunghezze d'onda di eccitazione).

Ambiguità di Permutazione nei Modelli CP

La decomposizione CP gode dell'unicità essenziale a meno di **riscaldamento** e **permutazione**. Ciò significa che l'ordine delle colonne $r = 1, \dots, R$ estratte dalle matrici fattore A, B, C dall'algoritmo di ottimizzazione (ad es. CP-ALS) è **arbitrario**.

Quando si confrontano i profili di concentrazione stimati A con le concentrazioni reali di riferimento delle sostanze chimiche note $M \in \mathbb{R}_+^{N \times M}$ (ad esempio i fluorofori **Phenylalanine, Tryptophan-Glycine, Valine-Tyrosine-Valine**), la colonna j -esima di A non corrisponde necessariamente alla colonna j -esima della matrice di riferimento M .

La funzione align_components risolve questa ambiguità riordinando le colonne della matrice di riferimento M in modo da farle corrispondere alle componenti stimate nella matrice A .

2. Formulazione Matematica di align_components

La funzione prende in ingresso due matrici:

- $A_{\text{norm}} \in \mathbb{R}^{N \times R}$: matrice fattore stimata (tipicamente normalizzata per colonna),
- $M_{\text{norm}} \in \mathbb{R}^{N \times M}$: matrice delle concentrazioni di riferimento (ground-truth).

Metrica di Similarità Coseno

Per ogni colonna estratta $j \in \{1, \dots, R\}$ di A_{norm} , la funzione calcola la similarità coseno in valore assoluto con ciascuna colonna di riferimento $k \in \{1, \dots, M\}$ di M_{norm} :

$$S(j, k) = | \mathbf{A}_{\text{norm}}[:, j] \cdot \mathbf{M}_{\text{norm}}[:, k] |$$

Se i vettori colonna sono a norma unitaria, $S(j, k)$ coincide esattamente con la similarità coseno.

Regola di Assegnamento Ottimale

L'indice del composto di riferimento che meglio approssima la componente j -esima viene determinato massimizzando la similarità:

$$k^*(j) = \arg \max_{k \in \{1, \dots, M\}} S(j, k)$$

La matrice riordinata finale $M_{\text{matched}} \in \mathbb{R}^{N \times R}$ viene definita colonna per colonna impostando:

$$M_{\text{matched}}[:, j] = M[:, k^*(j)], \quad \forall j = 1, \dots, R$$

3. Codice Sorgente di align_components

La funzione è definita nel modulo experiments/utils/cp/alignment.py:

```
import numpy as np

def align_components(norm_A: np.ndarray, norm_mixtures: np.ndarray) ->
np.ndarray:
    """
    Per ogni colonna calcolata in norm_A, trova la colonna di riferimento
    in norm_mixtures che massimizza la similarità coseno in valore assoluto.
    """
    n_comp = norm_A.shape[1]
    n_mixtures = norm_mixtures.shape[1]
    matched_mixtures = np.zeros_like(norm_A)
    for j in range(n_comp):
        similarities = [
            np.abs(np.dot(norm_A[:, j], norm_mixtures[:, k]))
            for k in range(n_mixtures)
        ]
        best_k = int(np.argmax(similarities))
        matched_mixtures[:, j] = norm_mixtures[:, best_k]
    return matched_mixtures
```

4. Utilizzo all'interno di viz_eem_cp.py

Nel modulo di visualizzazione experiments/tensor_data_eem/plots/viz_eem_cp.py, la funzione visualize_eem_cp() segue una pipeline ben strutturata per la validazione visiva della decomposizione CP di rango 3 su dati EEM18:

4.1 Sequenza Operativa

- Fittaggio ed Estrazione dei Fattori:** Si esegue CP-ALS sul tensore X ottenendo i vettori peso λ e le matrici fattore A, B, C .
- Normalizzazione e Riordinamento:**
 - I fattori vengono normalizzati per colonna $|A_{\{:,r\}}|_2 = 1, |B_{\{:,r\}}|_2 = 1, |C_{\{:,r\}}|_2 = 1$.
 - L'assorbimento delle norme trasferisce l'intensità assoluta al vettore dei pesi λ .
 - Le componenti vengono ordinate in modo decrescente in base al peso λ_r .
- Chiamata a align_components:**

```
norm_mixtures = mixtures / np.linalg.norm(mixtures, axis=0)

matched_mixtures_unscaled = align_components(norm_A, mixtures)
matched_mixtures_norm = align_components(norm_A, norm_mixtures)
```

- `matched_mixtures_unscaled`: allinea le concentrazioni reali non scalate alla sequenza di componenti ordinate in `norm_A`.
- `matched_mixtures_norm`: effettua l'allineamento sulle matrici a norma unitaria.

4. Riscaldamento e Confronto Grafico:

- Per ciascuna delle 3 componenti, le concentrazioni stimate (`scaled_A`) e quelle reali (`scaled_mixtures`) vengono riportate alla stessa scala molecolare (10^6).
- Viene generato un grafico a barre affiancate (**Campione**, colonne di sinistra) che visualizza il confronto campione per campione (da 1 a 18) tra i valori stimati dalla CP e le reali concentrazioni chimiche.

Sintesi dell'Utilità:

Senza l'utilizzo di `align_components`, l'ordine arbitrario restituito dalla decomposizione tensoriale causerebbe l'accoppiamento errato delle barre di concentrazione calcolata rispetto alle sostanze di riferimento chimico (**Phe**, **Trp-Gly**, **Val-Tyr-Val**), falsando il confronto visivo nei grafici pubblicabili.