



UNIVERSITÀ DI PISA

DIPARTIMENTO DI MATEMATICA

Corso di Laurea Triennale in Matematica

Tensor Canonical Polyadic Decomposition and the Complexity of Matrix Multiplication

Tesi di Laurea Triennale

Relatore:

Prof. Leonardo Robol

Candidato:

Alberto Defendi

ANNO ACCADEMICO 2025/2026

SOMMARIO

La decomposizione CP (Canonical Polyadic Decomposition) di rango r di un tensore è la sua scomposizione nella somma di r tensori di rango uno, una generalizzazione naturale della decomposizione di matrici. Oltre ad avere un'importanza teorica nel calcolo tensoriale, è uno strumento utile in molte aree scientifiche: per citarne alcune, spettroscopia, *signal processing*, neurologia e analisi dei dati. In molte di queste applicazioni l'unicità della fattorizzazione è una proprietà fondamentale per rappresentare fedelmente le componenti di sistemi complessi—si pensi al problema di modellare i neuroni di un sistema nervoso tramite un tensore per studiarne gli impulsi, noto come *blind source separation*.

Il primo obiettivo è dimostrare l'unicità della fattorizzazione CP sotto opportune ipotesi. Questo risultato, originariamente dimostrato da Kruskal nel 1977 attraverso il concetto di Kruskal rank, è stato di recente semplificato seguendo la dimostrazione originale, usando strumenti geometrici. Inoltre, osserveremo alcune peculiarità teoriche che distinguono i tensori dalle matrici, ponendo le basi per l'utilizzo del calcolo tensoriale nella teoria della complessità.

Successivamente, applicheremo questi strumenti al problema della complessità della moltiplicazione tra matrici: in quanto mappa bilineare, il prodotto matriciale può essere rappresentato tramite un tensore tre indici, e poi messo in corrispondenza con un algoritmo per valutare il prodotto in funzione delle entrate del tensore. Introduciamo la nozione di complessità aritmetica del prodotto tra matrici per definire l'esponente asintotico ω , che ne misura la complessità ottimale. Tale quantità sarà messa in corrispondenza con il rango CP di un tensore tramite il Teorema di Strassen. Come corollario, ridurre lo studio della complessità ai tensori, anziché all'analisi diretta delle equazioni algebriche, semplifica notevolmente la ricerca di algoritmi più efficienti; una sfida aperta da decenni, dall'algoritmo di Strassen (del 1970), fino alle recenti scoperte guidate dall'intelligenza artificiale.

Infine, l'analisi verrà estesa dagli algoritmi di moltiplicazione esatti agli algoritmi approssimati (APA), introdotti da Bini et al. In questo contesto emerge il fenomeno topologico del border rank, per il quale una successione di tensori di rango inferiore può convergere a un tensore di rango superiore. Dal punto di vista algoritmico, ciò si traduce nella possibilità di approssimare la moltiplicazione esatta tramite una successione di algoritmi con costo computazionale inferiore. Di conseguenza, il rango tensoriale può essere sostituito con il border rank nel calcolo di ω , permettendo di ottenere stime asintotiche più accurate, al prezzo di un errore algoritmico arbitrariamente piccolo.

INDICE

1	LA FATTORIZZAZIONE CP	3
1.1	Tensori	3
1.2	Rango tensoriale	4
1.3	Ordinamenti	5
1.4	La fattorizzazione CP	10
1.5	Slices, fibers e unfoldings	12
1.6	Il problema del rango	16
1.7	Il teorema del rango	21
1.8	Ricostruzione del tensore in formato denso	24
1.9	Calcolo della fattorizzazione CP	24
2	UNICITÀ DELLA FATTORIZZAZIONE CP	27
2.1	Convenzioni	28
2.2	Il Teorema di Kruskal	29
3	APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA	43
3.1	Mappe multilineari e moltiplicazione tra matrici	43
3.2	Decomposizione low-rank di forme bilineari	45
3.3	Rappresentazione del prodotto tra matrici	47
3.4	L'esponente della moltiplicazione tra matrici	47
3.5	Il rango come misura della complessità	51
3.6	Algoritmi di moltiplicazione veloce	56
3.7	Alcune stime sull'esponente	61
3.8	Algoritmi APA	61
3.9	Errore algoritmico	63
4	APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP	67
4.1	Spettroscopia fluorescente	67
4.2	Blind deconvolution di segnali	73
	ACRONIMI	81

Indice

GLOSSARIO 83

BIBLIOGRAFIA 85

INTRODUZIONE

I tensori sono oggetti che modellano molti esperimenti in un numero disparato di aree scientifiche. Decomporli in oggetti più facili da analizzare ... Studieremo la *canonical polyadic decomposition*, nota anche come PARAFAC, per “parallel factor analysis”, CANDECOMP, per “canonical decomposition”, e CP *decomposition*, il quale nome potrebbe o come acronimo della combinazione di CANDECOMP e PARAFAC.

scrivi altro

scrivi altro

Le decomposizioni di tensori occorrono in numerose aree scientifiche. Alcune di queste sono: nell’ambito medico della psicomatria è stata impiegata per studiare gli impulsi cerebrali [311, 71, 158], in particolare nel trovare l’area del cervello di un paziente in cui è in atto una crisi epilettica, o la diagnosi e gestione di ictus.; sempre nella medicina, nell’interpretare le immagini di risonanze magnetiche (MRI); vedi ad esempio e relative reference. Nella geofisica, ad esempio l’interpretazione di data magnetotellurica per strutture regionali a una e due dimensioni, ad esempio in ...e le reference all’interno (wtf?). Nell’analisi numerica. Grazie alla convergenza delle serie di Fourier nello spazio delle funzioni $f : \mathbb{R}^n \rightarrow \mathbb{R}$ misurabili secondo la norma euclidea $L^2(\mathbb{R}^n)$, si ha $L^2(\mathbb{R}^n) = L^2(\mathbb{R}) \otimes \dots \otimes L^2(\mathbb{R})$, e spesso vengono approssimate funzioni di n variabili da una somma finita di prodotti di funzioni in una variabile, generalizzando la separazione di variabili. Si veda ...

questo va o detto a parole, oppure descrivere esempio delle funzioni semiseparabili

Questo elaborato si sviluppa con la seguente struttura:

Nel capitolo 1, introdurremo i tensori e i relativi spazi. Definiremo la fattorizzazione CP e dei relativi metodi di calcolo. Discuteremo alcune loro caratteristiche fondamentali che li differenziano dalle matrici.

Nel capitolo 2 dimostreremo il Teorema di Kruskal, che afferma l’unicità della scrittura della fattorizzazione CP di un tensore sotto opportune ipotesi, discutendo alcuni casi di non unicità.

Nel capitolo 3 sposteremo il focus allo studio della complessità della moltiplicazione matriciale, studiando gli *algoritmi di moltiplicazione veloci* dal punto di vista della decomposizione CP.

Nel capitolo 4 presenteremo alcune applicazioni modellistiche della CP, presentando due esperimenti numerici: il recupero della concentrazione di sostanze chimi-

che in un composto (*spettroscopia fluorescente*) e l'analisi di segnali (*cocktail party problem*).

Le principali fonti di questo lavoro sono TENSORB e LANDSBERG^{1,2}.

cite

Come descritto da Landsberg, nell'ambito del calcolo tensoriale avviene uno “scontro di culture”, dove confluiscono risultati teorici trovati dagli studiosi delle applicazioni scientifiche (e.g., psicometria, chemiometria, neurologia), analisti numerici, teorici della complessità e geometri algebrici.

Credits: cite ballard E Kolda per aver ispirato molte figure. Librerie numeriche.

1 LA FATTORIZZAZIONE CP

1.1 TENSORI

In questo elaborato lavoriamo in $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, e denotiamo gli spazi vettoriali, che assumeremo sempre finiti, con le lettere A, B, C, V, W e A_j , e le dimensioni con le lettere $\mathbf{a}, \mathbf{b}, \mathbf{c}$, etc. Dati dei vettori $v_1, \dots, v_p \in V$, l'insieme $\langle v_1, \dots, v_p \rangle \subseteq V$ denota lo span lineare di $v_1, \dots, v_p$. Indichiamo con $V^* = \{f : V \rightarrow \mathbb{K} \mid f \text{ lineare}\}$ lo *spazio duale* dello spazio V , e per ogni $\alpha \in V^*$, denotiamo con $\alpha^\perp = \{v \in V \mid \alpha(v) = 0\}$ l'*annullatore* di α . Similmente, dato un sottospazio vettoriale $U \subseteq V$, definiamo l'annullatore di U come $U^\perp = \{\alpha \in V^* \mid \alpha(u) = 0, \forall u \in U\}$. Denotiamo con $\mathfrak{S}_n$ il gruppo simmetrico su n elementi, e con $\text{GL}_n(\mathbb{K})$ il gruppo delle matrici $n \times n$ invertibili sul campo $\mathbb{K}$.

Definizione 1.1.1 (Mappe trilineari). Siano U, V, W spazi vettoriali di dimensione finita su un campo $\mathbb{K}$. Una *forma bilineare* è una mappa $\varphi : U \times V \rightarrow W$ lineare in ogni componente, in altre parole tale che $f(u, \cdot)$ e $f(\cdot, v)$ sono lineari per ogni $u \in U$ e $v \in V$. Quando $W = \mathbb{K}$ la chiameremo *forma bilineare*.

In generale, dati degli spazi vettoriali $A_1, \dots, A_n$ di dimensione finita, definiamo le forme n -multilineari come applicazioni $\varphi : A_1 \times \dots \times A_n \rightarrow \mathbb{K}$ lineari in ognuna delle n componenti, e data una forma n -multilineare $\varphi : A_1 \times A_2 \times \dots \times A_n$ è possibile costruire una mappa $n - 1$ lineare $A_1 \times A_2 \times \dots \times A_{n-1} \rightarrow A_n$, e viceversa.

Definizione 1.1.2 (Tensore). Definiamo lo spazio dei *tensori* $A_1 \otimes A_2 \otimes \dots \otimes A_n$ come l'insieme delle forme n -multilineari $\varphi : A_1^* \times A_2^* \times \dots \times A_n^* \rightarrow \mathbb{K}$.

Osservazione 1.1.3 (Spazio standard). Sfruttando l'identificazione canonica $\mathbb{K}^m \otimes \mathbb{K}^n \simeq \mathbb{K}^{m \times n}$ (o più in generale $\mathbb{K}^{n_1} \otimes \mathbb{K}^{n_2} \otimes \dots \otimes \mathbb{K}^{n_d} \simeq \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$) possiamo dare una definizione di tensore operativamente utile in molti contesti del calcolo tensoriale, dove spesso è più conveniente lavorare nello spazio standard $\mathbb{R}^{n_1 \times \dots \times n_d}$.

Usare emph
quando si in-
troduce un ter-
mine nuovo,
inserire tabella
notazione all'i-
nizio

Definizione 1.1.4 (Tensore in coordinate). Un *tensore in coordinate* T di ordine d è un array multidimensionale con entrate definite sul campo $\mathbb{K}$, che denotiamo come $T \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$. Indicizziamo gli elementi di un tensore come $T_{i_1, i_2, \dots, i_d}$.

Osservazione 1.1.5. Per la ragione sopra, spesso chiameremo tensore anche l'oggetto sopra scrivendo semplicemente $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$.

Osservazione 1.1.6. Dato $T \in A \otimes B \otimes C$, possiamo sempre passare da un tensore nello spazio $A \otimes B \otimes C$ a un tensore in $\mathbb{R}^{a \times b \times c}$ così: fissate delle basi $\{e_i\}, \{g_j\}, \{h_k\}$ di A, B, C rispettivamente, possiamo scrivere $T = \sum_{ijk} T_{ijk} e_i \otimes g_j \otimes h_k$. Al variare degli indici, T_{ijk} descrive un array tridimensionale ("a forma di parallelepipedo") in $\mathbb{R}^{a \times b \times c}$, che chiamiamo ancora T .

Osservazione 1.1.7. Siccome per ogni spazio vettoriale V , vale $V \otimes \mathbb{K} \simeq V$, un tensore $T \in \mathbb{K}^{m \times n \times 1}$ è una matrice $m \times n$, e più in generale un tensore $T \in \mathbb{R}^{n_1 \times n_{d-1} \times 1}$ è un tensore di dimensione $n_1 \times n_2 \times \dots \times n_{d-1}$.

Scrivere

Esempio 1.1.8. (Tensori che rappresentano applicazioni multilineari)

ADD: Esempi di tensori. Tra cui il tensore che indica (quello del prodotto di matrici)

Osservazione 1.1.9. L'insieme dei tensori $\mathbb{R}^{n_1 \times \dots \times n_d}$ forma un $\mathbb{R}$ -spazio vettoriale, dotato del prodotto scalare euclideo, con le operazioni

- Addizione: $(T_1 + T_2)(i_1, \dots, i_d) = T_1(i_1, \dots, i_d) + T_2(i_1, \dots, i_d)$.
- Moltiplicazione per scalare: Per ogni $\alpha \in \mathbb{R}$, $\alpha(T(i_1, \dots, i_d)) = (\alpha T)(i_1, \dots, i_d)$.
- Prodotto scalare: $\langle T_1, T_2 \rangle = \text{vec}(T_1)^\top \text{vec}(T_2)$.
- Norma: $\|\text{vec}(T)\| = \sqrt{\sum_{i_1=1}^{n_1} \sum_{i_2=1}^{n_2} \dots \sum_{i_d=1}^{n_d} (T_{i_1, i_2, \dots, i_d})^2}$.

1.2 RANGO TENSORIALE

Definizione 1.2.1 (Tensore di rango uno). Dati $a_1 \in A_1, a_2 \in A_2, \dots, a_d \in A_d$, definiamo un *tensore di rango uno* come un elemento $a_1 \otimes a_2 \otimes \dots \otimes a_n \in A_1 \otimes A_2 \otimes \dots \otimes A_n$ tale che $a_1 \otimes \dots \otimes a_d(\beta_1, \dots, \beta_n) = \beta_1(a_1)\beta_2(a_2) \dots \beta_d(a_d)$.

Operativamente, dati due vettori $u = [u_1, \dots, u_m]^\top \in \mathbb{R}^m$ e $v = [v_1, \dots, v_n]^\top \in \mathbb{R}^n$, possiamo calcolare il prodotto tensore come

$$u \otimes v = uv^\top = \begin{bmatrix} u_1 v_1 & u_1 v_2 & \dots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \dots & u_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ u_m v_1 & u_m v_2 & \dots & u_m v_n \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

In più dimensioni, presi $a_1 \in \mathbb{R}^{n_1}, \dots, a_n \in \mathbb{R}^{n_n}$, il loro prodotto tensore è

$$(1.1) \quad T = a^{(1)} \otimes a^{(2)} \otimes \dots \otimes a^{(d)} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$$

tale che la sua scrittura in componenti è

$$(1.2) \quad T_{i_1, i_2, \dots, i_d} = a_{i_1}^{(1)} v_{i_2}^{(2)} \dots v_{i_d}^{(d)}$$

Questo ci permette di definire la seguente quantità fondamentale:

Definizione 1.2.2 (Rango di un tensore). Il rango di un tensore $T \in A_1 \otimes A_2 \otimes \dots \otimes A_n$ è il minimo intero positivo r tale che T si può scrivere come somma di tensori di rango uno, e scriviamo $\mathbf{R}(T) = r$.

1.3 ORDINAMENTI

Introduciamo alcuni ingredienti utili a definire la fattorizzazione CP.

Sposta sotto
ordinamento

Definizione 1.3.1 (Prodotto di Kroneker). Date due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{p \times q}$, il loro prodotto di Kroneker è la matrice

$$C = A \boxtimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{R}^{mp \times nq}, \text{ dove } c_{kl} = a_{ij}b_{nl},$$

dove $\alpha = \mathbb{L}^*(i, k) = \mathbb{L}(k, i)$ e $\beta = \mathbb{L}^*(j, l) = \mathbb{L}(l, j)$

Osservazione 1.3.2. Dalla definizione di prodotto di Kroneker, segue che

$$\text{rank}(A \boxtimes B) = \text{rank}(A) \text{rank}(B).$$

Un modo per dimostrarlo è considerare le decomposizioni ai valori singolari (SVD) di $A = U \Sigma V^*$ e $B = U' \Sigma' V'^*$, e calcolare

$$\begin{aligned} A \boxtimes B &= (U \Sigma V^*) \boxtimes (U' \Sigma' V'^*) \\ &= (U \boxtimes U') (\Sigma \boxtimes \Sigma') (V^* \boxtimes V'^*), \end{aligned}$$

dove la seconda uguaglianza segue dalla proprietà $(AC \boxtimes BD) = (A \boxtimes B)(C \boxtimes D)$ del prodotto di Kroneker. Siccome le matrici U, U' e V, V' sono ortogonali (e quindi invertibili), anche $U \boxtimes U'$ e $V^* \boxtimes V'^*$ sono ortogonali. Quindi

$$\text{rank}(A \boxtimes B) = \text{rank}(\Sigma \boxtimes \Sigma') = \text{rank}(\Sigma) \text{rank}(\Sigma') = \text{rank}(A) \text{rank}(B).$$

Osservazione 1.3.3 (Prodotto di Kroneker come vettorizzazione del prodotto tensore). Dati due vettori $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$, il loro prodotto di Kroneker si può vedere come vettorizzazione del prodotto vettore, ossia

$$(1.3) \quad \text{vec}(v \otimes u) = \text{vec} \left(\begin{bmatrix} v_1 u_1 & v_1 u_2 & \dots & v_1 u_m \\ v_2 u_1 & v_2 u_2 & \dots & v_2 u_m \\ \vdots & \vdots & \ddots & \vdots \\ v_n u_1 & v_n u_2 & \dots & v_n u_m \end{bmatrix} \right) = [u_1 v \mid u_2 v \mid \dots \mid u_m v] = u \boxtimes v$$

Notiamo che tale operazione scambia l'ordine tra i vettori.

Breve motivazione dell'ordinamento naturale

Definizione 1.3.4 (Ordinamento naturale). *L'ordinamento naturale (o natural ordering) sull'insieme $[n_1] \times \dots \times [n_d]$ è la mappa biunivoca*

$$\mathbb{L}: [n_1] \times \dots \times [n_d] \rightarrow \left[\prod_{j=1}^d n_j \right]$$

$$(i_1, i_2, \dots, i_d) \mapsto 1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1) = 1 + \sum_{j=1}^d s_j(i_j - 1),$$

dove i coefficienti s_j sono chiamati *passi j-esimi* e sono definiti come $s_1 = 1$ e $s_{j+1} = n_1 \dots n_j = \prod_{h=1}^j n_h = s_j n_{j+1}$, per ogni $j = 1, \dots, d-1$. L'inversa di $\mathbb{L}$ è data dalla mappa

$$\mathbb{L}^{-1}: \left[\prod_{j=1}^d n_j \right] \rightarrow [n_1] \times \dots \times [n_d]$$

$$l \mapsto \left(1 + \left\lfloor \frac{(l-1) \pmod{n_1 s_1}}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \pmod{n_d s_d}}{s_d} \right\rfloor \right).$$

Le mappe $\mathbb{L}$ e $\mathbb{L}^{-1}$ sono l'una l'inversa dell'altra, e sono anche dette linearizzazione e tensorizzazione degli indici, rispettivamente, in quanto permettono di passare da un indice tensoriale a uno lineare, e viceversa.

Buona definizione. Segue direttamente dalla definizione di $\mathbb{L}$ e dalle proprietà del modulo. Infatti, detto $\alpha = \mathbb{L}(i_1, i_2, \dots, i_d)$, vale che

$$\mathbb{L}^{-1}(\alpha) = (i_1, i_2, \dots, i_d),$$

in quanto

$$\begin{aligned} (\mathbb{L}^{-1}(\alpha))_h &= 1 + \left\lfloor \frac{\sum_{i=1}^d s_j(i_j - 1) \pmod{n_h s_h}}{s_h} \right\rfloor \\ &= 1 + \left\lfloor \sum_{i=1}^d \frac{s_j}{s_1} (i_j - 1) \pmod{n_h s_h} \right\rfloor \\ &= i_h \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $s_j = n_1 n_2 \cdots n_j$ e il fatto che $\lfloor x \rfloor = 0$ per ogni $x \in [0, 1)$. Viceversa, chiamato $\beta := \mathbb{L}^{-1}(l)$, dove

$$\beta_h = 1 + \left\lfloor \frac{(l - 1) \pmod{n_h s_h}}{s_h} \right\rfloor$$

dimostriamo che

$$\mathbb{L}(\beta) = l.$$

Per comodità prendiamo $k = l - 1$, dove $0 \leq k < \prod_{j=1}^d n_j$. Ricordando che $n_j s_j = s_{j+1}$, per definizione di linearizzazione si ha

$$\begin{aligned} \mathbb{L}(\beta) &= \mathbb{L}(\beta_1, \dots, \beta_d) = \\ (1.4) \quad &= 1 + \sum_{j=1}^d s_j \left(\left\lfloor \frac{k \pmod{s_{j+1}}}{s_j} \right\rfloor \right). \end{aligned}$$

Consideriamo la scrittura in base mista $k = \sum_{h=1}^d c_h s_h$, dove $0 \leq c_h < n_h$, allora vale che $k \pmod{s_{j+1}} = \sum_{h=1}^j c_h s_h$, da cui dividendo per s_j ,

$$\frac{k \pmod{s_{j+1}}}{s_j} = c_j + \sum_{h=1}^{j-1} c_h s_h = c_j + \frac{k \pmod{s_j}}{s_j}.$$

Siccome $k \pmod{s_j} < s_j$ allora $\left\lfloor c_j + \frac{k \pmod{s_j}}{s_j} \right\rfloor = c_j$, per ogni $j = 1, \dots, d$, e sostituendo questi passaggi nell'Equazione (1.4),

$$\mathbb{L}(\beta) = 1 + \sum_{h=1}^d s_h c_h = 1 + k = 1 + (l - 1) = l.$$

□

Esempio 1.3.5. È utile visualizzare il caso 3-dimensionale: fissato un tensore $T \in \mathbb{R}^{m \times n \times p}$ indicizzato con (i, j, k) , abbiamo che $s_1 = 1, s_2 = m$ e $s_3 = mn$, dunque

$$\begin{aligned} \mathbb{L}(i, j, k) &= 1 + (i - 1) + m(j - 1) + mn(k - 1) \\ &= i + m(j - 1) + mn(k - 1), \end{aligned}$$

mentre l'inversa è

$$\begin{aligned} &\mathbb{L}^{-1}(i, j, k) \\ &= \left(\lfloor (l - 1) \pmod{m} \rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mn}}{m} \right\rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mnp}}{mn} \right\rfloor \right). \end{aligned}$$

Definizione 1.3.6 (Reverse ordering). *L'ordinamento inverso* sull'insieme $[n_1] \times \dots \times [n_d]$ è la mappa biunivoca

$$\begin{aligned} \mathbb{L}^*: [n_1] \times \dots \times [n_d] &\rightarrow \left[\prod_{j=1}^d n_j \right] \\ (i_1, i_2, \dots, i_d) &\mapsto 1 + \sum_{j=1}^d s_j^* (i_j - 1), \end{aligned}$$


dove $s_d^* = 1$ e $s_{j-1}^* = \prod_{h=j}^d n_h = s_j^* n_j$, per $j = d, \dots, 2$. La sua inversa è la mappa

$$\begin{aligned} (\mathbb{L}^*)^{-1}: \left[\prod_{j=1}^d n_j \right] &\rightarrow [n_1] \times \dots \times [n_d] \\ l &\mapsto \left(1 + \left\lfloor \frac{(l - 1) \pmod{n_1 s_1^*}}{s_1^*} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l - 1) \pmod{n_d s_d^*}}{s_d^*} \right\rfloor \right). \end{aligned}$$

.

Esempio 1.3.7. Nel caso di un tensore $T \in \mathbb{R}^{m \times n \times p}$, i passi sono $s_3^* = 1, s_2^* = p$ e $s_1^* = np$.

Osservazione 1.3.8. I passi determinano l'ordine di percorrenza del tensore nelle definizioni di $\mathbb{L}$ e $\mathbb{L}^*$.




Analogamente alle matrici, i tensori vengono salvati in memoria come vettori, risulta quindi naturale definire la seguente operazione

Definizione 1.3.9. Dato un tensore T , possiamo definire l'operazione che trasforma un tensore in vettore, tramite la mappa di vettorizzazione

$$\text{vec}: \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d} \rightarrow \mathbb{R}^{\prod_{j=1}^d n_j}$$

$$T \mapsto x$$



dove $x_l = T(\mathbb{L}^{-1}(l; n_1, n_2, \dots, n_d))$.

Osservazione 1.3.10. L'operatore di trasposizione per matrici induce l'ordinamento inverso sulla vettorizzazione. Consideriamo ad esempio il caso 2×2 :

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad A^\top = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix} \implies \text{vec}(A) = \begin{bmatrix} a_{11} \\ a_{21} \\ a_{12} \\ a_{22} \end{bmatrix}, \quad \text{vec}(A^\top) = \begin{bmatrix} a_{11} \\ a_{12} \\ a_{21} \\ a_{22} \end{bmatrix}.$$

Nel caso matriciale si usa riferirsi all'ordine naturale come *column-major* e a quello inverso come *row-major*, specialmente nel contesto dei linguaggi di programmazione.

1.4 LA FATTORIZZAZIONE CP

Introduciamo una scrittura di un tensore in tensori elementari, utile a risolvere i seguenti problemi che affronteremo nei prossimi capitoli.

Il problema inverso del rango: Dato un intero positivo r , nel caso matriciale è, in linea teorica, un problema semplice costruire una matrice di rango r ; mentre dal punto di vista computazionale, esistono algoritmi polinomiali per approssimare il rango. Nel caso dei tensori, il problema è difficile su entrambi i fronti. Nella teoria, trovare un tensore di un certo rango è come trovare un ago in un pagliaio; nella pratica, approssimare il tensore, o il rango, è numericamente difficile. Questo complica la risoluzione di molti problemi che possono essere modellati tramite tensori, come vedremo ad esempio nel Capitolo 3.

Risparmio computazionale: Cerchiamo una decomposizione di rango basso di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ per ridurre il costo di rappresentazione in memoria e delle operazioni algebriche che lo coinvolgono. Nel caso matriciale, data una matrice $X \in \mathbb{R}^{n_1 \times n_2}$ di rango r , possiamo scrivere

$$X = UV^\top = [u_1 | \dots | u_r] [v_1 | \dots | v_r]^\top = u_1 v_1^\top + \dots + u_r v_r^\top = u_1 \otimes v_1 + \dots + u_r \otimes v_r,$$

per certe matrici $U \in \mathbb{R}^{n_1 \times r}$ e $V \in \mathbb{R}^{n_2 \times r}$. Questo tipo di decomposizione è vantaggioso in termini di memoria: infatti

$$\text{vec}(X) = v_1 \boxtimes u_1 + \dots + v_r \boxtimes u_r,$$

quindi memorizzare U e V costa $O((n_1 + n_2)r)$ invece che $O(n_1 n_2)$. Vorremmo quindi riadattare questa decomposizione per memorizzare T con costo $O((n_1 + \dots + n_d)r)$ invece che $O(n_1 \dots n_d)$.

Nel generalizzare questa decomposizione, nota come *Canonical Polyadic Decomposition* (CP) incontreremo alcuni ostacoli, che discuteremo nella § 1.6. Dimostreremo inoltre alcune condizioni necessarie per l'unicità nel Capitolo 2.

Definizione 1.4.1 (Canonical Polyadic Decomposition (CP)). Dati degli spazi vettoriali $A_1 \otimes \dots \otimes A_d$ e dei vettori $\{u_1^t, \dots, u_{n_t}^t\} \subset A_t$, diciamo che un tensore $T \in A_1 \otimes \dots \otimes A_d$ ammette una *decomposizione CP* di rango $r \in \mathbb{N}$ se si può scrivere come

$$T = u_1^1 \otimes u_1^2 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes u_r^2 \otimes \dots \otimes u_r^d.$$

serve ipotesi sui
vettori?

Osservazione 1.4.2. Siccome $A_1 \otimes \cdots \otimes A_n$ è generato da elementi di rango uno, è sempre possibile decomporre un tensore in formato CP.

Osservazione 1.4.3 (Canonical Polyadic Decomposition (CP)). La decomposizione CP in $\mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}$ è data da delle matrici $U_1, \dots, U_d$ tali che $U_t = [u_1^t \mid \dots \mid u_r^t] \in \mathbb{R}^{n_t \times r}$ tali per cui

$$T = u_1^1 \otimes u_1^2 \otimes \cdots \otimes u_1^d + \cdots + u_r^1 \otimes u_r^2 \otimes \cdots \otimes u_r^d \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}.$$

In tal caso, scriveremo $T = \llbracket U_1, \dots, U_d \rrbracket$.

Osservazione 1.4.4. Possiamo riferirci alla CP sia come decomposizione (data dalla somma dei termini di rango uno) oppure come fattorizzazione (data dai fattori $U_1, \dots, U_d$).

Osservazione 1.4.5. Fissando la notazione sopra, la fattorizzazione CP si può scrivere nelle seguenti formulazioni equivalenti:

- (i) $T = \sum_{j=1}^r u_j^1 \otimes \cdots \otimes u_j^d$.
- (ii) $\text{vec}(T) = \sum_{j=1}^r u_j^d \boxtimes \cdots \boxtimes u_j^1$.
- (iii) $T_{i_1, i_2, \dots, i_d} = \sum_{j=1}^r U_1(i_1, j) U_2(i_2, j) \cdots U_d(i_d, j)$.




Figura 1.1: Fattorizzazione CP di un tensore $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{n \times m \times p}$, dove i vettori a_l, b_l, c_l indicano le colonne l -esime di A, B, C .

Osservazione 1.4.6 (Risparmio in memoria della CP). La fattorizzazione CP di un tensore T di rango r permette di ridurre notevolmente il costo di memorizzazione, in quanto richiede $O((n_1 + \dots + n_d)r) \ll O(\prod_{i=1}^d n_i)$.

1.5 SLICES, FIBERS E UNFOLDINGS

Cambiare

Definizione 1.5.1 (Tensor slice). Dato $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ chiamiamo *slice* (o *fetta*) di T ogni matrice ottenuta da T fissando tutti gli indici tranne due. Le slices ottenute fissando gli ultimi $d - 2$ indici sono dette *frontal slices*. Nel caso $d = 3$ si identificano tutte le possibili slices (Figura 1.2):




Figura 1.2: Slices di un tensore di ordine 3: fette orizzontali $X_{i,:}$ (mode-1), laterali $X_{:,j}$ (mode-2) e frontali $X_{::,k}$ (mode-3).

Definizione 1.5.2 (Mode- k fiber). Dato un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ chiamiamo *fibers* i vettori ottenuti fissando tutti gli indici tranne uno. Quando l'indice libero di variare è il k -esimo lo chiamiamo *mode- k fiber*. Nel caso $d = 3$ denotiamo le fibre come fibre colonna $x_{:,jk}$ (mode-1), fibre riga $x_{i:,k}$ (mode-2) e fibre tubo $x_{ij,:}$ (mode-3), come illustrato in Figura 1.3.





Figura 1.3: Fibre di un tensore di ordine 3: fibre colonna $x_{:,jk}$ (mode-1), riga $x_{i:,k}$ (mode-2) e tubo $x_{ij,:}$ (mode-3).

In molte situazioni risulta comodo disporre gli elementi di un tensore in una matrice. Uno dei modi per farlo è utilizzare le matricizzazioni, anche dette *unfoldings*.


Definizione 1.5.3 (Mode- k unfolding). Il *mode- k unfolding* di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ è la matrice $\mathbf{T}_{(k)} \in \mathbb{R}^{n_k \times \prod_{j \neq k} n_j}$ le cui colonne sono mode- k fibers ordinate seguendo l'ordine naturale su $\underline{n}_1 \times \dots \times \underline{n}_{k-1} \times \underline{n}_{k+1} \times \dots \times \underline{n}_d$. In particolare si ha

$$(\mathbf{T}_{(k)})_{i,j} = T_{i_1, \dots, i_{k-1}, i, i_{k+1}, \dots, i_d}, \text{ con } j = \mathbb{L}(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d).$$


Osservazione 1.5.4. Possiamo pensare all'unfolding nel modo k come a rimappare l'indice i_k sulle righe e l'indice $(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d)$ sulle colonne.




(a) Mode-1 fibers.




(b) Mode-1 unfolding.




(c) Mode-2 fibers.



(d) Mode-2 unfolding.



(e) Mode-3 fibers.



(f) Mode-3 unfolding.

Figura 1.4: Fibre e matricizzazioni nei tre modi per un tensore del terzo ordine.

Esempio 1.5.5 (De Lathauwer [22]). Consideriamo il tensore T di taglia $2 \times 2 \times 2$ definito da

$$a_{111} = -a_{121} = 3, \quad a_{211} = -a_{221} = 6, \quad a_{112} = -a_{122} = 1, \quad a_{212} = -a_{222} = 2.$$

I vettori dei modi 1, 2 e 3 sono le colonne delle matrici

$$\mathbf{T}_{(1)} = \begin{bmatrix} 3 & -3 & 1 & -1 \\ 6 & -6 & 2 & -2 \end{bmatrix}, \quad \mathbf{T}_{(2)} = \begin{bmatrix} 3 & 6 & 1 & 2 \\ -3 & -6 & -1 & -2 \end{bmatrix}, \quad \mathbf{T}_{(3)} = \begin{bmatrix} 3 & 6 & -3 & -6 \\ 1 & 2 & -1 & -2 \end{bmatrix},$$

rispettivamente. Il tensore ha rango uno perché si può decomporre come

$$T = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -1 \end{bmatrix} \otimes \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Pensando la terza dimensione nel verso entrante al foglio, possiamo riassumere i passaggi svolti per fattorizzare T , dove è stata applicata più volte la definizione di

c'è un typo!

prodotto tensore:

$$\begin{bmatrix} 1 & -1 \\ 3 & 2 \\ 6 & -6 \end{bmatrix} = {}_3 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix} \circ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right) = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \circ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \circ \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$




Figura 1.5: Schema delle matricizzazioni e vettorizzazione di un tensore.

L'operazione di unfolding permette anche di catturare il suo rango (matriciale) lungo ogni direzione:

anche def land-
sberg

Definizione 1.5.6 (Rango multilineare). Il *rango multilineare* o *multirank* di un tensore $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è la d -upla $(r_1, r_2, \dots, r_d)$, dove $r_k = \text{rank } \mathbf{T}_{(k)}$, per ogni $k \in \{1, \dots, d\}$. Lo denotiamo con $\mathbf{R}_{\text{multilin}}(T)$.

refrasare un po-
co per renderla
più leggibile

Dal punto di vista computazionale è utile introdurre la seguente operazione

Definizione 1.5.7 (Reshape). Definiamo l'operatore di *reshape* come l'operazione riarrangia il tensore senza alterarne le dimensioni e mantenendo l'ordine delle entrate. Formalmente, fissati $d, d' \in \mathbb{N}$ e un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$, per ogni $m_1, \dots, m_{d'}$ tali che $\prod_{i=1}^{d'} m_i = \prod_{j=1}^d n_j$, il tensore $\mathbf{Y} = \text{RESHAPE}(T, m_1 \times \dots \times m_{d'}) \in \mathbb{R}^{m_1 \times \dots \times m_{d'}}$ è definito come

$$\mathbf{Y}(i_1, \dots, i_{d'}) = T(j_1, \dots, j_d),$$

per ogni $(i_1, \dots, i_{d'}, (j_1, \dots, j_d))$ tali che $\mathbb{L}(i_1, \dots, i_{d'}; m_1 \times \dots \times m_{d'}) = \mathbb{L}(j_1, \dots, j_d; n_1 \times \dots \times n_d)$.

Osservazione 1.5.8. Un reshape ha costo nullo perché non si spostano celle di memoria, ma si eseguono solo operazioni di indici. Questa proprietà vale in particolare per tutte le strutture dati (vettori, matrici, tensori) $\tilde{T}$ tali che $\text{vec}(\tilde{T}) = \text{vec}(T)$.

Osservazione 1.5.9. L'unfolding sul primo modo ha costo nullo, in quanto $\mathbf{T}_{(1)} = \text{RESHAPE}(T, n_1 \times \prod_{j=2}^d n_j)$, cioè

$$\mathbf{T}_{(1)} = \left[T_{:, \dots, :, 1} \mid \dots \mid T_{:, \dots, :, n_d} \right] \in \mathbb{R}^{n_1 \times \prod_{j=2}^d n_j}.$$

Osservazione 1.5.10. Per $k > 1$, formare l'unfolding $\mathbf{T}_{(k)}$ ha un costo non banale, in particolare $\text{vec}(\mathbf{T}_{(k)}) \neq \text{vec}(T)$.

Se $k = d$, l'unfolding $\mathbf{T}_{(d)} = \begin{bmatrix} \text{vec}(T_{:, \dots, :, 1})^\top \\ \vdots \\ \text{vec}(T_{:, \dots, :, n_d})^\top \end{bmatrix}$, e in particolare vale $\text{vec}(\mathbf{T}_{(d)}^\top) =$

$\text{vec}(T)$. Quindi calcolare la trasposta dell'ultimo unfolding non costa nulla.

Lemma 1.5.11 (Vettorizzazione e unfolding di un tensore di rango uno). *Dato un tensore $T = v^1 \otimes \dots \otimes v^d$, allora*

$$(i) \text{ vec}(T) = v^d \boxtimes \dots \boxtimes v^1.$$

$$(ii) \mathbf{T}_{(k)} = v^k (v^d \boxtimes \dots \boxtimes v^{k-1} \boxtimes v^{k+1} \boxtimes \dots \boxtimes v^1)^\top.$$

In particolare, tutte le matricizzazioni di un prodotto esterno hanno rango 1.

Dimostrazione. La (i) segue applicando più volte l'Osservazione 1.3.3. Dimostriamo la (ii). Per definizione di tensore di rango uno (1.2) la scrittura in componenti di T è

$$T_{i_1, \dots, i_d} = v_{i_1}^1 \dots v_{i_d}^d = v_{i_k}^k \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right).$$

Preso $u = v^d \boxtimes \dots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \dots \boxtimes v^1$, osserviamo che la sua componente j -esima è il prodotto fra parentesi, ovvero $u_j = \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right)$. A questo punto, per definizione di unfolding abbiamo $(\mathbf{T}_{(k)})_{i_k, j} = v_{i_k}^k u_j$, da cui

$$\mathbf{T}_{(k)} = v^k u^\top = v^k (v^d \boxtimes \dots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \dots \boxtimes v^1)^\top.$$

□

In molte situazioni è utile moltiplicare un tensore con una matrice. La seguente definizione risolve il problema facendo agire la matrice la matrice lungo il modo k -esimo di un tensore, e si chiama.

Definizione 1.5.12 (Prodotto nel modo k). Il *prodotto nel modo k* di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ con una matrice $U \in \mathbb{R}^{r \times n_k}$ descrive l'azione di U sulla k -esima coordinata di T . Formalmente, è un tensore

$$Y = T \times_k U \in \mathbb{R}^{n_1 \times \dots \times n_{k-1} \times r \times n_{k+1} \times \dots \times n_d} \text{ con } \mathbf{Y}_{(k)} = U \mathbf{T}_{(k)}.$$

Esempio polinomio semisep + altro es

In componenti, $Y_{i_1, \dots, i_{k-1}, \alpha, i_{k+1}, \dots, i_d} = \sum_{i_k=1}^d T(i_1, i_2, \dots, i_d) U_{\alpha, i_k}$.

1.6 IL PROBLEMA DEL RANGO

non mi piace

In più dimensioni il problema di calcolare il rango, e una fattorizzazione CP di un tensore si complicano notevolmente rispetto al caso matriciale. Ci sono molte domande aperte riguardo al rango, ad esempio non si ha una risposta generale (a differenza del caso matriciale) a domande del tipo:

1. Qual'è il massimo rango possibile per un tensore di dimensione $n_1 \times \dots \times n_d$?
2. Quali sono i ranghi *tipici*, ovvero quelli ottenuti con probabilità non nulla quando si genera un tensore di entrate casuali?

Per capire il motivo, discutiamo alcune caratteristiche dei tensori che rendono complesso il “problema del rango”.

BORDER RANK

Nel caso delle matrici, una successione di matrici di rango r converge sempre a una matrice di rango $\leq r$. Per i tensori possono accadere dei “salti”, in altre parole, la varietà dei tensori di un rango fissato r non è chiusa¹, ad esempio, un tensore di rango 2 può convergere ad uno di rango 3, come mostra il prossimo esempio. Questo inconveniente teorico ha risvolti interessanti che vedremo nella § 3.8.

Esempio 1.6.1. Consideriamo dei vettori $a_1, a_2 \in \mathbb{R}^m$, $b_1, b_2 \in \mathbb{R}^n$ e $c_1, c_2 \in \mathbb{R}^p$ vettori linearmente indipendenti. Definiamo il tensore

$$(1.5) \quad T = a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1,$$

¹Non precisiamo la topologia, per una discussione formale si vedano [35, 36].

e notiamo che $\mathbf{R}(T) = 3$ dato che non può essere scomposto come somma di tensori più semplici. Consideriamo la successioni di tensori

$$(1.6) \quad T_\varepsilon = \frac{1}{\varepsilon}(a_1 + \varepsilon a_2) \otimes (b_1 + \varepsilon b_2) \otimes (c_1 + \varepsilon c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1, \text{ con } \varepsilon \in \mathbb{R},$$

che essendo combinazione lineare di due tensori di rango uno, ha rango 2. Vediamo che $\lim_{\varepsilon \rightarrow 0} T_\varepsilon = T$, da cui segue che l'insieme dei tensori di rango 3 non è chiuso. Espandendo i termini dell'Equazione (1.6) tramite la proprietà distributiva del prodotto esterno,

$$(1.7) \quad \begin{aligned} \mathbf{y}_\varepsilon &= \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1 \\ &\quad + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1 \\ &= T + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) \end{aligned}$$

Quindi $T_\varepsilon - T \rightarrow 0$.

Questo motiva la seguente definizione:

Definizione 1.6.2 (Border rank). Un tensore T ha *border rank* r se è limite di una successione di tensori di rango r , ma non è limite di una successione di tensori di rango s , per ogni $s < r$. Lo denoteremo con il simbolo $\underline{\mathbf{R}}(T)$.

Osservazione 1.6.3. $\mathbf{R}(T) \geq \underline{\mathbf{R}}(T)$.

Osservazione 1.6.4. In altri termini, se $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$, il suo border rank è la quantità

$$\underline{\mathbf{R}}(T) = \min \{r \in \mathbb{N} \mid \exists T' \in \mathbb{R}^{n_1 \times \dots \times n_d} \text{ tale che } \mathbf{R}(T') = r, \|T - T'\| < \varepsilon\}.$$

Il border rank ammette anche la seguente interpretazione geometrica:

COSTO COMPUTAZIONALE

Il costo di calcolare una fattorizzazione CP usando un algoritmo esatto è NP-Hard [28]. Non solo; il problema di trovare un tensore approssimante di un certo rango è computazionalmente difficile. In altre parole, la miglior approssimazione di rango r è data da dei vettori $x_i \in \mathbb{R}^{n_1}, y_i \in \mathbb{R}^{n_2}, \dots, z_i \in \mathbb{R}^{n_d}$, per $i = 1, \dots, r$ che minimizzano

$$\|A - x_1 \otimes y_1 \otimes \dots \otimes z_1 - \dots - x_r \otimes y_r \otimes \dots \otimes z_r\|$$

Disegno interpretazione geometrica (Landsberg pg 38)

oppure, in altre parole un tensore B dato da una fattorizzazione CP, che realizza

$$\min_{\text{rank}(B) \leq r} \|A - B\|.$$

Qui $\|\cdot\|$ denota una norma fissata su $\mathbb{R}^{n_1 \times \dots \times n_d}$. Quando $d = 2$, il problema è risolto per norme invarianti per trasformazioni unitarie su $\mathbb{R}^{m \times n}$ dal teorema di Eckart-Young-Mirsky [24]: se

$$A = U\Sigma V^* = \sum_{i=1}^{\text{rank}(A)} \sigma_i u_i \otimes v_i, \quad \sigma_i \geq \sigma_{i+1},$$

è la decomposizione ai valori singolari di A (anche detta SVD), allora la migliore approssimazione di rango r è data dai primi r termini della somma. Sfortunatamente, generalizzare questo risultato in più dimensioni è ritenuto molto difficile (o impossibile) [43].

Nella pratica esistono diverse euristiche per calcolare il rango. Una di queste è scegliere come rango il più piccolo r che minimizza l'errore relativo rispetto al rango $r - 1$. Per un tensore a 3 indici, l'*errore relativo* è definito in questo modo:

$$(1.8) \quad \varepsilon_{\text{rel}} = \frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} = \frac{\left(\sum_{i,j,k} (t_{ijk} - \sum_{l=1}^r a_{il} b_{jl} c_{kl})^2\right)^{\frac{1}{2}}}{\left(\sum_{i,j,k} t_{ijk}^2\right)^{\frac{1}{2}}}.$$

RANGO MASSIMO

Nel caso di una matrice $m \times n$, il suo rango massimo è $\min\{m, n\}$. Per un tensore, il *rango massimo* è definito come il massimo dei ranghi realizzabili per dei tensori $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ di una certa taglia fissata. In altre parole,

$$\mathbf{R}_{\max}(\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}) = \max\{\mathbf{R}(T) \mid T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}\}.$$

Sfortunatamente, ad eccezione di alcuni casi speciali, i ranghi massimi per la maggior parte dei tensori di ordine superiore sono sconosciuti. I casi speciali in cui il rango massimo è noto sono elencati nella Tabella 1.1. Il primo risultato per tensori di dimensione $2 \times m \times n$ implica, ad esempio, che un tensore di taglia $2 \times 2 \times 2$ ha un rango massimo pari a 3.

È inoltre possibile derivare un limite superiore debole per il rango massimo:

se lasci verifica-
lo

Tabella 1.1: Ranghi massimi tensoriali noti. L'ordine delle dimensioni non modifica il rango, quindi le taglie sono ordinate dalla più piccola alla più grande (tratta da Ballard e Kolda [6, Tabella 16.1]).

Taglia tensore	Rango massimo	Fonte
$2 \times m \times n$ ($m \leq n$)	$m + \min\{m, \lfloor n/2 \rfloor\}$	JáJá [30]; Kruskal [32]
$3 \times 3 \times 3$	5	Kruskal [32]
$3 \times 7 \times 7$	8	Atkinson e Stephens [4]
$2 \times 4 \times 4$	6	ten Berge [9]

$$(1.9) \quad \mathbf{R}_{\max}(\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}) \leq \min_k \prod_{\substack{\ell=1 \\ \ell \neq k}}^d n_\ell = \frac{\prod_{k=1}^d n_k}{\max_k n_k}.$$

RANGO TIPICO

Mentre le matrici random hanno rango massimo con probabilità uno², per un tensore di un formato fissato potrebbe esserci più di un rango con probabilità positiva. Questo fenomeno è noto come *rango tipico*.

Sia $\mathcal{D}(n_1, n_2, \dots, n_d)$ una distribuzione di probabilità continua sullo spazio dei tensori $\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ (un esempio sono i tensori a entrate gaussiane).

Definizione 1.6.5. Il *rango tipico* (o *rango generico*) di un tensore $T \in \mathbb{K}^{n_1 \times \dots \times n_d}$ è l'insieme dei ranghi che occorrono con probabilità non nulla, rispetto ad ogni distribuzione continua $\mathcal{D}(n_1, n_2, \dots, n_d)$ sull'insieme di tali tensori. In formule,

$$\mathbf{R}_{\text{typical}} = \{r \mid P(\mathbf{R}(T) = r, T \sim \mathcal{D}(n_1, \dots, n_d)) > 0\}.$$

Per le matrici il rango tipico è unico e coincide con il massimo rango possibile, per i tensori di ordine superiore a due non è così: su $\mathbb{R}$ possono coesistere più ranghi tipici, mentre su $\mathbb{C}$ il rango tipico è sempre unico. La Tabella 1.2 riassume i principali risultati noti in letteratura, tratti da Ballard e Kolda [6, p. 276, Tabella 16.2]. Per verificare questi risultati, abbiamo implementato un esperimento numerico. Selezionando alcuni formati, abbiamo generato dei tensori casuali con entrate estratte indipendentemente sia da una distribuzione normale standard $\mathcal{N}(0, 1)$ sia da una distribuzione uniforme $\mathcal{U}(-1, 1)$. Il rango di ciascun tensore è stato stimato usando l'algoritmo ALS (che introdurremo in § 1) su un campione di 200 tensori, facendo 120

²L'idea è presa una matrice con entrate estratte da una distribuzione di probabilità continua, il determinante è un polinomio le cui indeterminate sono le entrate della matrice. Il luogo di zeri di questo polinomio ha misura di Lebesgue nulla, quindi integrando la densità di probabilità sul luogo di zeri dà probabilità nulla. La tesi si ha passando al complementare.

1 La fattorizzazione CP

restarts e un numero massimo di 500 iterazioni, interrompendo una volta raggiunto un errore relativo inferiore a 10^{-5} . La distribuzione empirica dei ranghi riportata in Figura 1.6 mostra che la distribuzione delle entrate (normale o uniforme) non altera l'insieme dei ranghi tipici e produce frequenze empiriche analoghe.




Figura 1.6: Distribuzione empirica dei ranghi per tensori casuali reali di formato $2 \times 2 \times 2$, $3 \times 3 \times 2$, $3 \times 3 \times 3$ e $3 \times 3 \times 5$ con entrate estratte da distribuzioni Normali $\mathcal{N}(0,1)$ ed Uniformi $\mathcal{U}(-1,1)$ (istogrammi affiancati).

Tabella 1.2: Ranghi tipici noti sul campo reale $\mathbb{R}$ per tensori di dimensione $m \times n \times p$ con $2 \leq m \leq n \leq p$ (adattata da Ballard e Kolda [6, Tabella 16.2]).

Formato ($m \times n \times p$)	Rango tipico	Fonte
$2 \times n \times n$	$\{n, n+1\}$	ten Berge, Kiers [10]
$3 \times 3 \times 3$	5	ten Berge, Stegeman [12]
$3 \times 3 \times 5$	$\{5, 6\}$	ten Berge, Sidiropoulos, Rocci [11]
$3 \times 4 \times 8$	$\{8, 9\}$	Sumi et al. [49]
$3 \times 5 \times 9$	$\{9, 10\}$	Choulakian [18]; ten Berge [8]
$4 \times 4 \times 12$	$\{12, 13\}$	Friedland [26]
$m \times n \times n(m-1)$ ($m > 2$, n dispari)	$n(m-1)$	ten Berge [9]
$m \times n \times p$ ($n(m-1) < p < mn$)	p	ten Berge, Kiers [10]; ten Berge [9]
$m \times n \times p$ ($p \geq mn$)	mn	ten Berge, Kiers [10]; ten Berge [9]

DIPENDENZA DAL CAMPO BASE

Nel caso matriciale ogni matrice $m \times n$ reale ha lo stesso rango se visto come elemento di $\mathbb{R}^{m \times n}$ o di $\mathbb{C}^{m \times n}$, ma per i tensori questo è falso. Consideriamo il seguente esempio:

Esempio 1.6.6 (De Silva e Lim [43]). Scriviamo $z_k = x_k + iy_k$ e $\bar{z}_k = x_k - iy_k$, allora

$$(1.10) \quad \begin{aligned} & \frac{1}{2}(\bar{z}_1 \otimes z_2 \otimes \bar{z}_3 + z_1 \otimes \bar{z}_2 \otimes z_3) \\ &= x_1 \otimes x_2 \otimes x_3 + x_1 \otimes y_2 \otimes y_3 - y_1 \otimes x_2 \otimes y_3 + y_1 \otimes y_2 \otimes x_3. \end{aligned}$$

Chiamando $I = \bar{z}_1 \otimes z_2 \otimes \bar{z}_3$ e $II = z_1 \otimes \bar{z}_2 \otimes z_3$, usando la proprietà distributiva e la trilinearità del prodotto tensore,

$$\begin{aligned} I &= (x_1 - iy_1) \otimes (x_2 + iy_2) \otimes (x_3 - iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 - ix_1 \otimes x_2 \otimes y_3 + ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 - iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 - iy_1 \otimes y_2 \otimes y_3, \\ II &= (x_1 + iy_1) \otimes (x_2 - iy_2) \otimes (x_3 + iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 + ix_1 \otimes x_2 \otimes y_3 - ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 + iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 + iy_1 \otimes y_2 \otimes y_3. \end{aligned}$$

L'espressione sopra segue calcolando $\frac{1}{2}(I + II)$.

1.7 IL TEOREMA DEL RANGO

Data la complessità del problema del rango possiamo stimarlo rango con la seguente proposizione, dalla quale intuimmo che non sarà semplice trovare stime del rango di un tensore—queste spesso coinvolgono tecniche algebrico-combinatorie avanzate. Vedremo alcuni esempi di queste stime nella Sezione 3.7.

Definiamo un'operazione utile tra le colonne di due matrici, che sarà utile a dimostrare il risultato di questa sezione.

Definizione 1.7.1 (Prodotto Khatri-Rao). Date due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$, il loro *prodotto Khatri-Rao* è dato da

$$(1.11) \quad C = A \odot B = [a_1 \boxtimes b_1 \mid \dots \mid a_r \boxtimes b_r] \in \mathbb{R}^{(mn) \times r},$$

dove a_j e b_j indicano la j -esima colonna di A e B , rispettivamente, e la matrice C si lascia scrivere in componenti come $C_{kl} = A_{il}B_{jl}$, dove $\mathbb{L}^*(i, j) = \mathbb{L}(j, i) = k$.

Osservazione 1.7.2. Il prodotto $A \odot B$ è sottomatrice di $A \boxtimes B$, in quanto una colonna k -esima della prima è del tipo $a_k \boxtimes b_k$, mentre per la seconda è $[a_{1k}B, \dots, a_{mk}B]^\top$; quindi possiamo ottenere la prima matrice selezionando alcune colonne della seconda.

Osservazione 1.7.3. Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$, il prodotto Khatri-Rao

$$U_d \odot U_{d-1} \odot \dots \odot U_1$$

ha come colonna r -esima $u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$, in altre parole, è la rappresentazione matriciale dell'insieme $\{u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1\}_{r=1, \dots, d}$ formato dagli addendi della decomposizione $\text{vec}(T) = \sum_{r=1}^R u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$. In particolare, vale

$$\begin{aligned} \text{vec}(T) &= \sum_{h=1}^r u_h^d \boxtimes \dots \boxtimes u_h^1 = \left[u_1^d \boxtimes \dots \boxtimes u_1^1 \mid \dots \mid u_r^d \boxtimes \dots \boxtimes u_r^1 \right]^\top \mathbf{1}_r \\ &= (U_d \odot U_{d-1} \odot \dots \odot U_1) \mathbf{1}_r. \end{aligned}$$

Osservazione 1.7.4. Calcolare il prodotto di Khatri-Rao di due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$ ha un costo in memoria di $O(mnr)$.

Lemma 1.7.5. *Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket \in \mathbb{R}^{n_1 \times \dots \times n_d}$, essa ha come unfoldings*

$$\mathbf{T}_{(j)} = U_j (U_d \odot U_{d-1} \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)^\top,$$

per ogni $j = 1, \dots, d$.

Dimostrazione. Scrivendo le matricizzazioni di $T = \sum_{h=1}^r u_h^1 \otimes \dots \otimes u_h^d$, dove i vettori $u_1^j, \dots, u_r^j$ rappresentano le colonne della matrice U_j , troviamo che

$$\begin{aligned} \mathbf{T}_{(j)} &= \sum_{h=1}^r u_h^j \left(u_h^d \boxtimes \dots \boxtimes u_h^{j+1} \boxtimes u_h^{j-1} \boxtimes \dots \boxtimes u_h^1 \right)^\top \\ &= U_j \left[u_1^d \boxtimes \dots \boxtimes u_1^1 \mid \dots \mid u_r^d \boxtimes \dots \boxtimes u_r^1 \right]^\top \\ &= U_j (U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)^\top, \end{aligned}$$

dove nel primo passaggio abbiamo applicato la Proposizione 1.5.11 su ogni addendo di rango uno. $\square$

Esempio 1.7.6. Se $T = \llbracket A, B, C \rrbracket$, allora segue che $\mathbf{T}_{(1)} = A(C \odot B)^\top$.

Proposizione 1.7.7 (Teorema del rango). *Sia $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ un tensore che ammette fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$, e sia $r_j = \text{rank}(\mathbf{T}_{(j)})$ il rango dell'unfolding $\mathbf{T}_{(j)}$ con $j = 1, \dots, d$. Allora vale che*

$$(1.12) \quad \max_{j=1, \dots, d} (r_j) \leq \mathbf{R}(T) \leq \min_{j=1, \dots, d} \left(\prod_{i \neq j} r_i \right)$$

Dimostrazione. Fissato $r = \mathbf{R}(T)$, la minorazione segue direttamente dal fatto che ogni unfolding $\mathbf{T}_{(j)}$ è una matrice di taglia $n_j \times r$. Mostriamo la maggiorazione, assumendo senza perdita di generalità che $\mathbf{R}(T) \leq \prod_{i=2}^d r_i$. Consideriamo la vettorizzazione

$$(1.13) \quad \text{vec}(T) = \sum_{k=1}^r u_k^d \boxtimes \dots \boxtimes u_k^2 \boxtimes u_k^1.$$

Allora l'insieme

$$\left\{ u_k^d \boxtimes \dots \boxtimes u_k^2 \right\}_{k=1, \dots, r}$$

è formato da vettori linearmente indipendenti. Se così non fosse, esisterebbe un indice k_0 , che possiamo supporre $k_0 = 1$ a meno di riordinamento degli indici k , tale per cui

$$(1.14) \quad u_1^d \boxtimes \dots \boxtimes u_1^2 = \sum_{h=2}^r c_h (u_h^d \boxtimes \dots \boxtimes u_h^2),$$

che sostituita nella Equazione (1.13) porta alla seguente decomposizione:

$$\begin{aligned} \text{vec}(T) &= \sum_{k=2}^r u_k^d \boxtimes \dots \boxtimes u_k^2 \boxtimes u_k^1 + \left(\sum_{k=2}^r c_k (u_k^d \boxtimes \dots \boxtimes u_k^2) \right) \boxtimes u_1^1 \\ &= \sum_{k=2}^r \left(u_k^d \boxtimes \dots \boxtimes u_k^2 \right) \boxtimes (u_k^1 + c_k u_1^1), \end{aligned}$$

che ha rango $r - 1$, contraddicendo la minimalità di r . Dal Lemma 1.7.5 possiamo scrivere

$$\mathbf{T}_{(1)} = U_1(U_d \odot \dots \odot U_2)^\top.$$

Dalla lineare indipendenza appena dimostrata, e dall'Osservazione 1.7.3 segue che $\mathbf{R}(U_d \odot \dots \odot U_2) = r$. Applicando l'Osservazione 1.7.2 a più fattori, $U_d \odot \dots \odot$

U_r è sottomatrice di $U_d \boxtimes \cdots \boxtimes U_2$. Siccome il rango del prodotto di Kroneker è moltiplicativo (Osservazione 1.3.2) troviamo

$$r \leq \text{rank}(U_d \boxtimes \cdots \boxtimes U_2) = r_2 \cdots r_d.$$

Ripetendo l'argomento per gli altri unfoldings si ha la tesi. $\square$

Osservazione 1.7.8. Una conseguenza immediata di questo teorema è che T ha rango uno se e solo se $\mathbf{R}_{\text{multilin}}(T) = 1$, cioè se e solo se $\mathbf{R}(\mathbf{T}_{(j)}) = 1$ per ogni j . In generale vale che, se $\mathbf{R}(T) = r$, allora $\mathbf{R}_{\text{multilin}}(T) \leq r$, ma non il viceversa.

1.8 RICOSTRUZIONE DEL TENSORE IN FORMATO DENSO

In alcune situazioni è utile scrivere il tensore fattorizzato in modo esplicito, ad esempio per valutare l'errore di approssimazione (1.8) o generare numericamente un tensore. Un modo conveniente di farlo è il seguente. Data una fattorizzazione $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{m \times n \times p}$ di rango r , dato che $\text{vec}(T) = (C \odot B \odot A)\mathbf{1}_r$, saremmo tentati di formare la matrice $C \odot B \odot A$ e moltiplicarla per il vettore di tutti uni $\mathbf{1}_r$, ma questa matrice ha più entrate del risultato finale. L'approccio vincente è considerare $\mathbf{T}_{(1)} = A(C \odot B)^\top$ dato dalla Proposizione 1.7.5, e studiare il sistema

$$\begin{cases} R = C \odot B, \\ Y = AR^\top, \\ T = \text{RESHAPE}(Y, m \times n \times p). \end{cases}$$

Il risultato intermedio $R \in \mathbb{R}^{np \times r}$ ha costo $O(npr)$, mentre formare Y costa $O(mnpr)$. Dato che l'unfolding è sul modo uno, non abbiamo bisogno di permutazioni.

1.9 CALCOLO DELLA FATTORIZZAZIONE CP

Trattiamo il problema di trovare la migliore approssimazione con rango r di un dato tensore. Studiamo il caso $d = 3$ per semplicità di notazione. Dato $T \in \mathbb{R}^{m \times n \times p}$ cerchiamo una fattorizzazione $\llbracket A, B, C \rrbracket$ con $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ e $C \in \mathbb{R}^{p \times r}$ cercando di risolvere il problema ai minimi quadrati

$$(\mathcal{P}) \quad \min_{A, B, C} \|T - \llbracket A, B, C \rrbracket\|^2.$$

Tale problema può essere mal posto per quanto detto sul border rank. Inoltre si tratta di un problema non convesso (esistono molti minimi locali); inoltre un tensore può avere fattorizzazioni CP multiple.

Definizione 1.9.1 (Prodotto di Hadamard). Date due matrici $A, B \in \mathbb{R}^{m \times n}$, il loro *prodotto di Hadamard* è il loro prodotto elemento per elemento, e si indica con la matrice $C = A * B$ con entrate $C_{ij} = a_{ij}b_{ij}$.

Lemma 1.9.2. Date delle matrici $A \in \mathbb{R}^{m \times r}, B \in \mathbb{R}^{n \times r}, C \in \mathbb{R}^{m \times s}, D \in \mathbb{R}^{n \times s}$, vale

$$(A \odot B)^\top (C \odot D) = (A^\top C) * (B^\top D).$$

Dimostrazione. Basta osservare che la matrice

$$(A \odot B)^\top (C \odot D) = \begin{bmatrix} a_1^\top \boxtimes b_1^\top \\ \vdots \\ a_r^\top \boxtimes b_r^\top \end{bmatrix} \left[c_1 \boxtimes d_1 \mid \dots \mid c_s \boxtimes d_s \right].$$

array ticker
brackets $\boxtimes$

ha come entrata (i, j) l'elemento $(a_i^\top c_j)(b_i^\top d_j)$, che corrisponde all'entrata (i, j) di $(A^\top C) * (B^\top D)$. $\square$

ALTERNATING LEAST-SQUARES

Nonostante la funzione obbiettivo dell'Equazione (P) non sia convessa, essa è convessa nelle singole variabili. Ovvero, fissando B e C , ottimizzare solo su A significa risolvere un problema ai minimi quadrati lineare

$$(1.15) \quad \|T - \llbracket A, B, C \rrbracket\|^2 = \|\mathbf{T}_{(1)} - A(C \odot B)^\top\|_F^2 = \|(C \odot B)A^\top - \mathbf{T}_{(1)}^\top\|_F^2,$$

dove l'incognita è una matrice. Nel primo passaggio abbiamo applicato la Proposizione 1.7.5 per ridurci a un problema ai minimi quadrati matriciale. La soluzione può essere espressa in termini delle equazioni normali

why?

$$(C \odot B)^\top (C \odot B)A^\top = (C \odot B)^\top \mathbf{T}_{(1)}^\top,$$

se e solo se, usando il Lemma 1.9.2

$$(1.16) \quad (C^\top C * B^\top B)A^\top = (C \odot B)^\top \mathbf{T}_{(1)}^\top$$

Sia $Z := C^\top C * B^\top B \in \mathbb{R}^{r \times r}$. Osserviamo che calcolare Z ha costo $O((n+p)r^2)$.

motiva

Inoltre Z è semidefinita positiva, e quando $C \odot B$ è full-rank è positiva definita: in tal caso possiamo risolvere con la fattorizzazione di Cholesky il sistema

$$(1.17) \quad AZ = \mathbf{T}_{(1)}(C \odot B) = M,$$

verifica

con costo $O(r^2m + r^3)$

verificare (aggiungerebbe un paragrafetto)

L'idea dell'algoritmo ALS è di minimizzare ciclicamente la funzione obiettivo dell'Equazione (1.15), prima al variare di A , poi B e poi C . Ognuno dei problemi dati dall'Equazione ha costo $O(mnpr)$. Riassumiamo questo schema nell'Algoritmo 1, dove in ogni passaggio riscaldiamo la fattorizzazione CP come $\llbracket AD_A, BD_B, CD_C \rrbracket$ con delle matrici tali che $D_A D_B D_C = I_r$ per riscaldare le colonne dei due fattori fissati in modo che abbiano norma unitaria.

Algorithm 1 Schema dell'algoritmo ALS.

Input: Tensore T di rango r , tolleranza ε .

- 1: Generiamo B e C in modo casuale.
 - 2: Normalizziamo le colonne di B .
 - 3: **repeat**
 - 4: Normalizziamo le colonne di C .
 - 5: $A \leftarrow \arg \min_A \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 6: Normalizziamo le colonne di A .
 - 7: $B \leftarrow \arg \min_B \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 8: Normalizziamo le colonne di B .
 - 9: $C \leftarrow \arg \min_C \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 10: **until** $\frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} > \varepsilon$.
-

Osservazione 1.9.3. Dato che in genere non si sa il valore ottimo del problema ($\mathcal{P}$), arrestiamo l'algoritmo quando sta “stagnando”, ovvero quando l'errore relativo fra due iterazioni successive diminuisce meno di un dato fattore.

Osservazione 1.9.4. Nel caso di T matrice, il fattore $C = I$ e nel caso T ha rango $r = 1$, l'algoritmo diventa il metodo delle potenze, in quanto l'Equazione (1.16) degenera in $a \leftarrow T \frac{b}{\|b\|^2}$ e $b \leftarrow T^\top \frac{a}{\|a\|^2}$, mentre per T di rango $r > 1$ diventa il metodo dei sottospazi: $A \leftarrow TB(B^\top B)^{-1}$ e $B \leftarrow T^\top A(A^\top A)^{-1}$.

ref

Osservazione 1.9.5. L'espressione sopra si può anche scrivere come

$$\|T - \sum_{r=1}^R a_r \otimes b_r \otimes c_r\|^2 = \sum_{i,j,k} |t_{ijk} - \sum_{r=1}^R a_{ir} b_{jr} c_{kr}|^2.$$

2 UNICITÀ DELLA FATTORIZZAZIONE CP

Data una matrice $M \in \mathbb{C}^{n \times n}$ di rango r , possiamo scriverla come somma di matrici di rango uno come

$$M = a_1 \otimes b_1 + \dots + a_r \otimes b_r = \begin{bmatrix} a_1 & \dots & a_r \end{bmatrix} \begin{bmatrix} b_1 & \dots & b_r \end{bmatrix}^\top = AB^\top.$$

Questa decomposizione non è mai unica a meno che $r = 1$, in quanto

$$M = AB^\top = APP^{-1}B^\top = (AP)(BP^{-T})^\top,$$

dove P è invertibile ma non necessariamente prodotto di matrici diagonali. Siccome $\text{GL}_n(\mathbb{C})$ contiene infiniti elementi, esistono infinite decomposizioni per M . Sorprendentemente, per i tensori è possibile ottenere l'unicità, sotto opportune ipotesi d'indipendenza delle componenti. Ma cosa intendiamo per unicità e indipendenza?

Possiamo definire l'unicità nel caso 3-dimensionale così: dato un tensore

$$T = a_1 \otimes b_1 \otimes c_1 + \dots + a_r \otimes b_r \otimes c_r \in A \otimes B \otimes C,$$

sotto opportune ipotesi T differisce da un'altra fattorizzazione CP a meno di permutazione dei tensori elementari e riscalamento dei fattori. Più precisamente: esistono degli scalari $\alpha_1, \dots, \alpha_r, \beta_1, \dots, \beta_r, \gamma_1, \dots, \gamma_r$ tali che $\alpha_j \beta_j \gamma_j = 1$ per ogni $j \in \{1, \dots, r\}$, ed esiste una permutazione $\sigma \in \mathfrak{S}_r$ tale che

$$T = \alpha_1 a_{\sigma(1)} \otimes \beta_1 b_{\sigma(1)} \otimes \gamma_1 c_{\sigma(1)} + \dots + \alpha_r a_{\sigma(r)} \otimes \beta_r b_{\sigma(r)} \otimes \gamma_r c_{\sigma(r)}.$$

Diamo una definizione più generale.

Definizione 2.0.1 (Essenziale unicità). Una fattorizzazione CP di rango r di un tensore $T \in A_1 \otimes \dots \otimes A_d$,

$$T = u_1^1 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes \dots \otimes u_r^d$$

2 Unicità della fattorizzazione CP

è *essenzialmente unica* se differisce a meno di permutazioni dei tensori di rango uno e di scalari il cui prodotto fa uno. Formalmente, se esistono degli scalari $\lambda_1^{(t)}, \dots, \lambda_r^{(t)}$ con $t \in \{1, \dots, d\}$ tali che $\lambda_j^{(1)} \lambda_j^{(2)} \dots \lambda_j^{(d)} = 1$ per ogni $j \in \{1, \dots, r\}$, ed esiste una permutazione $\sigma \in \mathfrak{S}_r$ tale che

$$T = \lambda_1^{(1)} u_{\sigma(1)}^1 \otimes \dots \otimes \lambda_1^{(d)} u_{\sigma(1)}^d + \dots + \lambda_r^{(1)} u_{\sigma(r)}^1 \otimes \dots \otimes \lambda_r^{(d)} u_{\sigma(r)}^d.$$

Notiamo che il tensore permutato appartiene ancora allo spazio di partenza. In realtà, la formulazione originale in coordinate è la seguente.

Definizione 2.0.2 (Essenziale unicità). Una fattorizzazione CP di rango r di un tensore $T = \llbracket U_1, \dots, U_d \rrbracket$ è essenzialmente unica se, per ogni altra fattorizzazione $T = \llbracket \tilde{U}_1, \dots, \tilde{U}_d \rrbracket$ di rango r , esiste una matrice di permutazione $P \in \mathbb{R}^{r \times r}$ e delle matrici diagonali $D_1, \dots, D_d \in \mathbb{R}^{r \times r}$ che soddisfano $D_1 D_2 \dots D_d = I$ e $U_j = \tilde{U}_j D_j P$, per ogni $j = 1, \dots, d$.

Osservazione 2.0.3. È facile vedere che questa definizione è una specializzazione di quella generale. Nel caso 3-dimensionale, ad esempio scriviamo in coordinate

$$A = \left[\begin{array}{c|c|c} a_1 & \dots & a_r \end{array} \right], \quad B = \left[\begin{array}{c|c|c} b_1 & \dots & b_r \end{array} \right], \quad C = \left[\begin{array}{c|c|c} c_1 & \dots & c_r \end{array} \right].$$

Rappresentiamo $\sigma \in \mathfrak{S}_r$ tramite una matrice P^{-1} di permutazione, e dette

$$D_A^{-1} := \text{diag}(\alpha_1, \dots, \alpha_r), \quad D_B^{-1} := \text{diag}(\beta_1, \dots, \beta_r), \quad D_C^{-1} := \text{diag}(\gamma_1, \dots, \gamma_r),$$

possiamo prendere

$$\tilde{A} := AP^{-1}D_A^{-1} = \left[\begin{array}{c|c|c} \alpha_1 a_{\sigma(1)} & \dots & \alpha_r a_{\sigma(r)} \end{array} \right],$$

e definire in maniera analoga $\tilde{B} := BP^{-1}D_B^{-1}$ e $\tilde{C} := CP^{-1}D_C^{-1}$. Moltiplicando a destra per le matrici inverse troviamo la definizione.

2.1 CONVENZIONI

Dato uno spazio vettoriale V su un campo $\mathbb{K}$, lo spazio proiettivo $\mathbb{P}(V)$ è dato da $\pi: V \setminus \{0\} \rightarrow \mathbb{P}(V): v \mapsto [v]$, dove per ogni $v \in V \setminus \{0\}$, il punto $[v]$ denota $\pi(v)$. Poniamo $\pi(V \setminus \{0\} / \sim) =: \mathbb{P}(V)$, dove $v \sim w$ se e solo se esiste $\lambda \in \mathbb{K} \setminus \{0\}$ tale che $v = \lambda w$. Se $V = \mathbb{K}^{n+1}$ indichiamo lo spazio proiettivo standard sul campo $\mathbb{K}$ come $\mathbb{P}^n = \mathbb{P}^n(\mathbb{K}) = \mathbb{P}(\mathbb{K}^{n+1})$. Dato un sottospazio $X \subset \mathbb{P}(V)$, il suo cono vettoriale è

$\hat{X} = \pi^{-1}(X \cup \{0\}) \subset V$. Lo span lineare di un sottoinsieme $X \subset \mathbb{P}(V)$ è denotato con $\langle X \rangle \subseteq V$.

2.2 IL TEOREMA DI KRUSKAL

Dato un tensore $T \in A \otimes B \otimes C$, vogliamo mostrare che la scrittura

$$(2.1) \quad T = a_1 \otimes b_1 \otimes c_1 + \dots + a_r \otimes b_r \otimes c_r,$$

è essenzialmente unica, sotto opportune condizioni.

Osservazione 2.2.1. Una condizione semplice per l'unicità è che T non possa essere ricondotto a una somma di matrici di rango uno. Consideriamo ad esempio

$$\begin{aligned} T &= a_1 \otimes b_1 \otimes c_1 + a_1 \otimes b_2 \otimes c_2 + a_3 \otimes b_3 \otimes c_3 + \dots + a_r \otimes b_r \otimes c_r \\ &= a_1 \otimes (b_1 \otimes c_1 + b_2 \otimes c_2) + a_3 \otimes b_3 \otimes c_3 + \dots + a_r \otimes b_r \otimes c_r, \end{aligned}$$

dove ognuno degli insiemi $\{a_i\}$, $\{b_j\}$ e $\{c_k\}$ è formato da elementi linearmente indipendenti. Questa scrittura non è unica a causa del termine

$$a_1 \otimes (b_1 \otimes c_1 + b_2 \otimes c_2)$$

Inoltre, se consideriamo per l'Equazione (2.1) gli insiemi $\mathcal{S}_A = \{[a_i]\} \subset \mathbb{P}A$, $\mathcal{S}_B = \{[b_i]\} \subset \mathbb{P}B$ e $\mathcal{S}_C = \{[c_i]\} \subset \mathbb{P}C$, allora l'unicità implica che siano formati da r punti distinti.

Definizione 2.2.2 (Posizione generale). Sia W uno spazio vettoriale finito dimensionale e $\mathcal{S} = \{x_1, \dots, x_p\} \subset \mathbb{P}W$ un insieme di punti. Diciamo che i punti di $\mathcal{S}$ sono in 2-posizione generale se nessuna coppia di punti coincide; sono in 3-posizione generale se nessuna terna di punti giace su una retta, e in generale, diremo che sono in r -posizione generale se nessuna r -upla giace su un sottospazio proiettivo di dimensione $r - 2$ (talvolta detto $(r - 2)$ -piano).

Definizione 2.2.3 (Kruskal rank). Il *Kruskal rank* di $\mathcal{S}$, indicato con $\mathbf{k}_{\mathcal{S}}$, è il massimo r tale per cui i punti di $\mathcal{S}$ sono in r -posizione generale.

Osservazione 2.2.4. Fissata una base per W tale per cui i punti di $\mathcal{S}$ possono essere scritti come colonne di una matrice M (è ben definito a meno di riscalamento), allora $\mathbf{k}_{\mathcal{S}}$ è il massimo intero positivo r tale per cui ogni sottoinsieme di r colonne




Figura 2.1: Rappresentazione di punti in 3-posizione e 4-posizione generale in uno spazio proiettivo.

di M sono vettori linearmente indipendenti. Questa era la definizione originale di Kruskal.

Osservazione 2.2.5. Dalla definizione segue che $\mathbf{k}_A \leq \text{rank}(A) \leq \min\{m, n\}$ per ogni matrice $A \in \mathbb{R}^{m \times n}$. In particolare, se A è full-rank, $\mathbf{k}_A = \text{rank}(A)$; se invece A ha due colonne linearmente dipendenti, $\mathbf{k}_A \leq 1$.

Possiamo enunciare il Teorema di Kruskal.

Teorema 2.2.6 (Kruskal [33]). *Sia $T \in A \otimes B \otimes C$ che ammette decomposizione $T = \sum_{i=1}^r u_i \otimes v_i \otimes w_i$. Siano $\mathcal{S}_A = \{[u_i]\}$, $\mathcal{S}_B = \{[v_i]\}$ e $\mathcal{S}_C = \{[w_i]\}$. Se vale*

$$(2.2) \quad r \leq \frac{1}{2}(\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} + \mathbf{k}_{\mathcal{S}_C}) - 1,$$

allora T ha rango r , e la sua espressione come tensore di rango r è essenzialmente unica.

Osservazione 2.2.7. Osserviamo che nel caso delle matrici l'unicità è verificata solo per $r = 1$ (in quanto $T = u \otimes v \in A \otimes B$) ma le ipotesi del teorema non sono rispettate perché $\mathcal{S}_A = \{[u]\}$, $\mathcal{S}_B = \{[v]\}$ e i due insiemi hanno k -rango uno, e varrebbe

$$\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} = 1 + 1 = 2 \geq 2r + 2 - 1 = 2 + 2 - 1 = 3.$$

Più in generale vale il seguente teorema:

Teorema 2.2.8 ([41]). *Sia $T \in A_1 \otimes A_2 \otimes \cdots \otimes A_n$ che ammette una decomposizione $T = \sum_{i=1}^r u_{1i} \otimes \cdots \otimes u_{ni}$. Sia $\mathcal{S}_{A_k} = \{[u_{ki}]\}$. Se*

$$(2.3) \quad \sum_{k=1}^r \mathbf{k}_{\mathcal{S}_{A_k}} \geq 2r + n - 1,$$

allora T ha rango r , e la sua espressione come tensore di rango r è essenzialmente unica.

Osservazione 2.2.9. Se vale l'Equazione (2.2), segue che $\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}, \mathbf{k}_{\mathcal{S}_C} \geq 2$. Dimostriamolo per $\mathcal{S}_A$, gli altri casi sono analoghi. L'Equazione (2.2) si può riscrivere come

$$2 + 2r \leq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} + \mathbf{k}_{\mathcal{S}_C}.$$

Siccome $\mathbf{k}_{\mathcal{S}}$ è limitato dall'alto dalla cardinalità dell'insieme $\mathcal{S}$, in questo caso abbiamo $\mathbf{k}_{\mathcal{S}_B}, \mathbf{k}_{\mathcal{S}_C} \leq r$, e applicando questa disequazione all'equazione sopra otteniamo,

$$2 + 2r \leq \mathbf{k}_{\mathcal{S}_A} + r + r,$$

cioè $\mathbf{k}_{\mathcal{S}_A} \geq 2$.

Proposizione 2.2.10 (Landsberg [36], §12.5). *Dati degli spazi vettoriali A, B, C tali che $\mathbf{a} = \mathbf{b} = \mathbf{c}$ e un tensore $T \in A \otimes B \otimes C$ di rango multilineare $(\mathbf{a}, \mathbf{a}, \mathbf{a})$. Se T ha rango $\mathbf{a}$, allora la fattorizzazione è unica. In particolare, quando $\mathbf{k}_{\mathcal{S}_A} = \mathbf{k}_{\mathcal{S}_B} = \mathbf{k}_{\mathcal{S}_C} = \mathbf{a}$, la condizione di unicità del teorema di Kruskal si estende a*

$$\mathbf{a} \leq r \leq \frac{1}{2}(\mathbf{a} + \mathbf{a} + \mathbf{a}) - 1 = \frac{3}{2}\mathbf{a} - 1$$

Dimostrazione. Se $r = \mathbf{a}$, consideriamo la decomposizione

$$T = a_1 \otimes b_1 \otimes c_1 + \cdots + a_{\mathbf{a}} \otimes b_{\mathbf{a}} \otimes c_{\mathbf{a}}$$

migliorare la
scrittura

Contraiamo T lungo la terza componente, cioè per ogni funzionale $\gamma_j \in C^*$

$$T(\gamma_j) = \sum_{i=1}^{\mathbf{a}} \gamma_j(c_i) a_i \otimes b_i = U D_j V^T,$$

dove

$$U = \left[\begin{array}{c|c|c} a_1 & \cdots & a_{\mathbf{a}} \end{array} \right], \quad D_j = \text{diag}(\gamma_j(c_1), \dots, \gamma_j(c_{\mathbf{a}})), \quad V = \left[\begin{array}{c|c|c} b_1 & \cdots & b_{\mathbf{a}} \end{array} \right].$$

2 Unicità della fattorizzazione CP

Consideriamo due funzionali $\gamma_1, \gamma_2 \in C^*$ tali che

(i) Per ogni $j \in \{1, 2\}$, $\gamma_j(c_i) \neq 0$ per ogni $i \in \{1, \dots, \mathbf{a}\}$, da cui $T(\gamma_j)$ è invertibile.

(ii) I rapporti $\lambda_i = \frac{\gamma_1(c_i)}{\gamma_2(c_i)}$ sono a due a due distinti.

La (i) segue perché, fissato $\gamma = \gamma_j$, siccome $\{c_1, \dots, c_{\mathbf{a}}\}$ è una base per C , nessuno dei vettori c_i è nullo. Per ogni c_i , consideriamo l'insieme dei funzionali che si annullano con c_i :

$$H_i = \{\gamma \in C^* \mid \gamma(c_i) = 0\},$$

che forma un iperpiano in C^* . Siccome su un campo infinito, lo spazio C^* non è unione finita di sottospazi propri, possiamo trovare un $\gamma \in C^* \setminus \bigcup_{i=1}^{\mathbf{a}} H_i$. Per questa scelta, si ha che $\gamma(c_i) \neq 0$ per ogni i . Siccome T ha rango multilineare $(\mathbf{a}, \mathbf{a}, \mathbf{a})$, allora le matrici U, D_j, V sono invertibili, in particolare, anche $T(\gamma_j)$ è invertibile, per ogni $j \in \{1, 2\}$. Da cui,

$$\begin{aligned} T(\gamma_1)T(\gamma_2)^{-1} &= (UD_1V^T)(UD_2V^T)^{-1} = UD_1V^TV^{-T}D_2^{-1}U^{-1} \\ &= UD_1D_2^{-1}U^{-1}, \end{aligned}$$

in altre parole, $T(\gamma_1)T(\gamma_2)^{-1}$ è diagonalizzabile, con autovettori, dati dalla matrice U , univocamente determinati a meno di permutazione e riscalamento. Inoltre, i rapporti $\frac{\gamma_1(c_i)}{\gamma_2(c_i)}$ sono distinti: se fosse $\frac{\gamma_1(c_i)}{\gamma_2(c_i)} = \frac{\gamma_1(c_k)}{\gamma_2(c_k)}$ per certi $i, k \in \{1, \dots, \mathbf{a}\}$, si avrebbe che

$$\gamma_1(c_i)\gamma_2(c_k) = \gamma_1(c_k)\gamma_2(c_i).$$

Sfruttando la linearità di γ_1 , troviamo

$$\gamma_1(c_i\gamma_2(c_k) - c_k\gamma_2(c_i)) = 0.$$

Siccome γ_1 e γ_2 non si annullano sui vettori c_i e c_k , allora $c_i\gamma_2(c_k) - c_k\gamma_2(c_i) \notin \gamma_1^\perp$, quindi necessariamente $c_i\gamma_2(c_k) - c_k\gamma_2(c_i) = 0$, ma essendo c_i e c_k linearmente indipendenti, le costanti $\gamma_2(c_k), \gamma_2(c_i)$ sarebbero nulle, assurdo.

Ripetendo questo ragionamento contraendo su A e poi su B otteniamo l'unicità. $\square$

Enunciamo il permutation lemma, dimostrato da Kruskal nell'articolo originale, e di centrale importanza nella dimostrazione del teorema.

Lemma 2.2.11 (Permutation lemma). *Siano $\mathcal{S} = \{p_1, \dots, p_r\}$ e $\tilde{\mathcal{S}} = \{q_1, \dots, q_r\}$ due insiemi di punti in $\mathbb{P}W$ a due a due distinti (i.e. tali che $\mathbf{k}_S \geq 2$) e supponiamo*

che $\langle \tilde{S} \rangle = W$. Se ogni iperpiano $H \subset \mathbb{P}W$ che contiene almeno $\dim(H) + 1$ punti di $\tilde{S}$ è tale che $\#(\mathcal{S} \cap H) \geq \#(\tilde{S} \cap H)$, allora $\mathcal{S} = \tilde{S}$.

Osservazione 2.2.12. Fissata una base per W e rappresentati i punti di $\mathcal{S}$ e $\tilde{S}$ con due matrici M e $\tilde{M}$, l'ipotesi si può rifrasare con la formulazione originale, ovvero che per ogni $x \in \mathbb{R}^w$ tale $\text{nnz}(\tilde{M}^\top x) < r - \text{rank}(\tilde{M}) + 1$ hanno la proprietà che $\text{nnz}(\tilde{M}x) \geq \text{nnz}(M^\top x)$. Per vedere questa corrispondenza, bisogna pensare al vettore x come un punto in W^* che dà un'equazione di H , e gli elementi nulli del vettore $\tilde{M}^\top$ corrispondono alle colonne che fanno zero quando accoppiate con x , cioè che soddisfano a un'equazione di H , ovvero a punti contenuti in H . Inoltre, l'ipotesi $\langle S \rangle = W$, che motiveremo meglio a breve, implica che $\text{rank}(\tilde{M}) = w$.

ha senso rifrasare la versione originale in forma di enunciato?

perché serve nella proof originale?

Definizione 2.2.13 (Concise tensor). Un tensore $T \in A_1 \otimes A_2 \otimes \cdots \otimes A_n$ si dice *1-concise* se non esiste un sottospazio proprio $A'_1 \subseteq A_1$ tale che $T \in A'_1 \otimes A_2 \otimes \cdots \otimes A_n$. Similmente, definiamo la i -conciseness per $i \in \{2, \dots, n\}$. Un tensore è detto *concise* se è i -concise per ogni i .

Osservazione 2.2.14. In altre parole T è concise se non è contenuto in nessun sottospazio proprio $A'_1 \otimes A'_2 \otimes \cdots \otimes A'_n \subset A_1 \otimes A_2 \otimes \cdots \otimes A_n$. Possiamo pensare a i tensori concise come tensori che usano tutte le dimensioni degli spazi A_i .

teniamo questa come definizione?

Osservazione 2.2.15. Tale proprietà giocherà un ruolo chiave nella dimostrazione del Teorema di Kruskal, dove supporremo che $\langle \mathcal{S}_{A_k} \rangle = A_k$; a questo scopo abbiamo indebolito il permutation lemma con l'ipotesi $\langle S \rangle = W$. La prossima proposizione afferma che tale restrizione è ben posta, ed esclude casi banali dalla dimostrazione del teorema di Kruskal.

Proposizione 2.2.16 (Tensori concise e rango). Sia $n > 2$. Sia $T \in A_1 \otimes \cdots \otimes A_n$ di rango r . Diciamo che $T \in A'_1 \otimes \cdots \otimes A'_n$, dove $A'_j \subseteq A_j$ con almeno un'inclusione propria. Allora ogni espressione $T = \sum_{i=1}^\rho u_{1i} \otimes \cdots \otimes u_{ni}$ con qualche $u_{sj} \notin A'_s$ ha $\rho > r$.

Osservazione 2.2.17. In altre parole, se T non è concise, allora $\rho > r$.

Dimostrazione. Scegliamo dei complementari A''_t tali che $A_t = A'_t \oplus A''_t$. Assumiamo per assurdo che $\rho = r$ e scriviamo $u_{tj} = u'_{tj} + u''_{tj}$, dove $u'_{tj} \in A'_t$ e $u''_{tj} \in A''_t$. Allora

$$T = \sum_{i=1}^\rho (u'_{1i} + u''_{1i}) \otimes \cdots \otimes (u'_{ni} + u''_{ni}) = \sum_{i=1}^\rho u'_{1i} \otimes \cdots \otimes u'_{ni} + R,$$

dove R è il tensore che contiene i termini “misti” dati dai prodotti tra i fattori u'_{sj} e u''_{tj} oppure u''_{sj} e u'_{tj} , appartenenti ai rispettivi sottospazi $A'_s \otimes A''_t$ e $A''_s \otimes A'_t$, cioè

$$(2.4) \quad R = \sum_{j=1}^{\rho} u''_{1j} \otimes (u'_{2j} \otimes \cdots \otimes u'_{nj}) + \dots + \sum_{j=1}^{\rho} u'_{1j} \otimes \cdots \otimes u''_{nj}.$$

Ma siccome $T \in A'_1 \otimes \cdots \otimes A'_n$, si deve avere che $R = 0$, ovvero i termini di R si proiettano nel vettore nullo. Assumiamo senza perdita di generalità che $A'_1 \subsetneq A_1$ sia propria, dunque $u''_{1j_0} \neq 0$ per un certo j_0 . Osserviamo che in R è presente l'espressione $\sum_{j=1}^r u''_{1j} \otimes (u'_{2j} \otimes \cdots \otimes u'_{nj}) = 0$, ma tutti i termini $u'_{2j} \otimes \cdots \otimes u'_{nj}$ sono linearmente indipendenti nel sottospazio $A'_2 \otimes \cdots \otimes A'_n$ (altrimenti T si potrebbe scrivere con meno di r termini, che contraddirebbe la minimalità di r). Allora gli u_{1j} sono tutti nulli, che è assurdo. $\square$

why?

potrebbe non bastare

Per dimostrare il Lemma 2.2.11 abbiamo bisogno di un piccolo risultato insiemistico

Lemma 2.2.18. *Dati tre insiemi A, B e C di cardinalità finita tali che $C \subseteq B$, si ha*

$$\#(A \cap (B \setminus C)) = \#(A \cap B) - \#(A \cap B \cap C).$$

Dimostrazione. Sviluppando

$$A \cap (B \setminus C) = A \cap (B \cap C^c) = (A \cap B) \cap C^c = (A \cap B) \setminus C,$$

da cui

$$\#((A \cap B) \setminus C) = \#(A \cap B) - \#(A \cap B \cap C),$$

dove abbiamo usato che $\#(X \setminus Y) = \#X - \#(X \cap Y)$. $\square$

Dimostrazione del permutation lemma. Osserviamo prima che sostituendo nell'ipotesi “iperpiani” con “punti”, la tesi segue immediatamente: per ogni punto $P \in \tilde{\mathcal{S}}$ tale che $1 = \#(\mathcal{S} \cap \{P\}) = \#(\tilde{\mathcal{S}} \cap \{P\})$, allora $\mathcal{S} \cap \{P\} = \tilde{\mathcal{S}} \cap \{P\}$, ovvero $\mathcal{S} = \tilde{\mathcal{S}}$, poiché i punti di $\mathcal{S}$ sono distinti. Consideriamo la seguente proprietà $(\mathcal{P}_{k+1})$: i $(k+1)$ -piani M che contengono almeno $k+2$ punti di $\tilde{\mathcal{S}}$, soddisfano $\#(\mathcal{S} \cap M) \geq \#(\tilde{\mathcal{S}} \cap M)$. Vediamo che lo stesso vale per i k -piani $(\mathcal{P}_k)$. Una volta dimostrato ciò, sapendo per ipotesi che la proprietà sopra valga per gli iperpiani (ovvero piani di dimensione $\dim(\mathbb{P}W) - 1 = w - 2$), possiamo costruire una catena di implicazioni dagli iperpiani fino ai punti, e ottenere la tesi:

sto pensando a un modo di riscrivere questo

$$\mathcal{P}_{w-2} \implies \mathcal{P}_{w-3} \implies \mathcal{P}_{w-4} \implies \cdots \implies \mathcal{P}_1 \implies \mathcal{P}_0 \implies \mathcal{S} = \tilde{\mathcal{S}},$$

dove la proprietà $\mathcal{P}_0$ corrisponde a quella detta inizialmente per i punti.

Fissiamo un k -piano L contenente $\mu \geq k+1$ punti di $\tilde{\mathcal{S}}$, e denotiamo con $\{M_\alpha\}$ l'insieme dei piani di dimensione $k+1$ che contengono L e almeno $\mu+1$ elementi di $\tilde{\mathcal{S}}$. È possibile costruire un tale piano M_α prendendo il sottospazio generato da L e un punto di $\tilde{\mathcal{S}}$ non appartenente a L . Osserviamo che $\#\{M_\alpha\} \geq 2$, cioè ci sono almeno due piani distinti contenenti L : se fosse $\#\{M_\alpha\} = 0$, non esisterebbero punti di $\tilde{\mathcal{S}}$ fuori da L , cioè $\mathcal{S} \subset L$, mentre se $\#\{M_\alpha\} = 1$, $\tilde{\mathcal{S}}$ sarebbe contenuto interamente nell'unico k -piano M_α . In ogni caso, $\tilde{\mathcal{S}}$ sarebbe contenuto in un sottospazio di dimensione al più $w-2$, ma ciò è impossibile perché $\langle \tilde{\mathcal{S}} \rangle = W$, quindi $\mathbb{P}W$, che ha dimensione $w-1$, è generato dai punti di $\tilde{\mathcal{S}}$. Dalla costruzione segue inoltre che ogni $(k+1)$ -piano M_α contiene almeno $\mu+1 \geq k+2$ punti di $\tilde{\mathcal{S}}$, quindi applicando l'ipotesi induttiva troviamo

$$(2.5) \quad \#(\tilde{\mathcal{S}} \cap M_\alpha) \leq \#(\mathcal{S} \cap M_\alpha).$$

Osserviamo che

$$(2.6) \quad \#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap (M_\alpha \setminus L)) = r,$$

$$(2.7) \quad \#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap (M_\alpha \setminus L)) \leq r.$$

La prima segue perché ogni punto di $\tilde{\mathcal{S}}$ che non appartiene a L sta esattamente in un piano M_α , mentre la seconda segue perché ogni punto di $\mathcal{S}$ non in L sta in al più un piano M_α . Dal Lemma 2.2.18 otteniamo l'identità (che vale anche per $\tilde{\mathcal{S}}$),

$$\#(\tilde{\mathcal{S}} \cap (M_\alpha \setminus L)) = \#(\tilde{\mathcal{S}} \cap M_\alpha) - \#(\tilde{\mathcal{S}} \cap M_\alpha \cap L) = \#(\tilde{\mathcal{S}} \cap M_\alpha) - \#(\tilde{\mathcal{S}} \cap L),$$

dove nell'ultimo passaggio abbiamo il contenimento $L \subseteq M_\alpha$. Sostituendola nelle Equazioni (2.6) e (2.7) troviamo

$$(1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap M_\alpha) = r,$$

$$(1 - \#\{M_\alpha\})\#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha) \leq r.$$




Figura 2.2: Interpretazione geometrica della costruzione nel caso $k = 1$ (L è una retta, e gli M_α sono piani). In questo caso L contiene almeno $\mu \geq k + 1 = 2$ punti di $\tilde{\mathcal{S}}$, e M_α contiene almeno $\mu + 1 \geq k + 2 = 3$ di $\tilde{\mathcal{S}}$; per ipotesi induttiva, $3 \leq \#(\tilde{\mathcal{S}} \cap M_\alpha) \leq \#(\mathcal{S} \cap M_\alpha)$. A priori i punti di $\mathcal{S}$ potrebbero non intersecare L , ma attraverso un conteggio troviamo che $2 \leq \#(\tilde{\mathcal{S}} \cap L) \leq \#(\mathcal{S} \cap L)$.

Mettendole insieme e applicando l'Equazione (2.5) otteniamo

$$\begin{aligned} (1 - \#\{M_\alpha\})\#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha) &\leq (1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap M_\alpha) \\ &\leq (1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha), \end{aligned}$$

semplificando le sommatorie, e usando che $(1 - \#\{M_\alpha\}) < 0$, troviamo

$$\#(\tilde{\mathcal{S}} \cap L) \leq \#(\mathcal{S} \cap L).$$

□

Introduciamo un ultimo lemma valido in generale:

Lemma 2.2.19. *Sia $T \in A \otimes B$ un tensore di rango r che ammette due espressioni $T = a_1 \otimes b_1 + \dots + a_r \otimes b_r$ e $T = a_1 \otimes b_{\sigma(1)} + \dots + a_r \otimes b_{\sigma(r)}$, dove $\sigma \in \mathfrak{S}_r$ è una permutazione. Allora $\sigma = \text{Id}$.*

Dimostrazione. Riscriviamo T come

$$T = u_1 \otimes b_1 + \dots + u_r \otimes b_r = u_1 \otimes b_{\sigma(1)} + \dots + u_r \otimes b_{\sigma(r)},$$

se e solo se

$$u_1 \otimes (b_{\sigma(1)} - b_1) + \dots + u_r \otimes (b_{\sigma(r)} - b_r) = 0.$$

Da cui, $b_{\sigma(j)} = b_j$ per ogni $j \in \{1, \dots, r\}$, allora $\sigma = \text{Id}$. $\square$

Siamo ora pronti a dimostrare il Teorema 2.2.6.

Dimostrazione del Teorema di Kruskal. Dalla Proposizione 2.2.16 possiamo supporre che T sia conciso, ovvero che A, B, C coincidano con i sottospazi generati da $\tilde{\mathcal{S}}_A, \tilde{\mathcal{S}}_B, \tilde{\mathcal{S}}_C$, rispettivamente. Date quindi due decomposizioni

$$(2.8) \quad T = \sum_{j=1}^r u_j \otimes v_j \otimes w_j = \sum_{j=1}^r \tilde{u}_j \otimes \tilde{v}_j \otimes \tilde{w}_j$$

di lunghezza r , con la prima decomposizione che soddisfa le ipotesi del teorema, vogliamo mostrare che sono uguali. Notiamo che, quando l'unicità della decomposizione di lunghezza r è verificata, il rango di T è r ; infatti, se sopra apparisse una decomposizione di lunghezza $r-1$, potremmo ricostruirne una di lunghezza r rimpiazzando $\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1$ con $\frac{1}{2}\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1 + \frac{1}{2}\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1$. Mostriamo prima che $\mathcal{S}_A = \tilde{\mathcal{S}}_A$, $\mathcal{S}_B = \tilde{\mathcal{S}}_B$ e $\mathcal{S}_C = \tilde{\mathcal{S}}_C$. Per simmetria basta mostrare l'ultima affermazione, sfruttando il permutation lemma. Consideriamo un iperpiano $H \subset \mathbb{P}C$ tale che $\#(\tilde{\mathcal{S}}_C \cap H) \geq c-1$, allora

$$(2.9) \quad \#(\mathcal{S}_C \cap H) \geq \#(\tilde{\mathcal{S}}_C \cap H),$$

le ipotesi sono garantite dall'Osservazione 2.2.9 e dal fatto che $\langle \tilde{\mathcal{S}}_C \rangle = C$. Definiamo il numero $S := \#(\mathcal{S}_C \not\subset H)$ dei punti di $\mathcal{S}_C$ non contenuti in H , e scomponiamo

$$T = \sum_{j=1}^r u_j \otimes v_j \otimes w_j = \sum_{\sigma=1}^S u_\sigma \otimes v_\sigma \otimes w_\sigma + \sum_{\mu=S+1}^r u_\mu \otimes v_\mu \otimes w_\mu,$$

dove abbiamo riordinato gli indici j affinché i primi S dei $[w_j]$ non stiano in H . L'Equazione (2.9) si può riformulare nel modo seguente

$$\#(\tilde{\mathcal{S}}_C \not\subset H) \geq \#(\mathcal{S}_C \not\subset H) = S,$$

sostituendo $\#(\mathcal{S}_C \cap H) = r - \#(\mathcal{S}_C \not\subset H)$ e $\#(\tilde{\mathcal{S}}_C \cap H) = r - \#(\tilde{\mathcal{S}}_C \not\subset H)$. Sia $h \in \hat{H}^\perp$ non nullo. Valutando in h abbiamo

$$T(h) = \sum_{\sigma=1}^S u_\sigma \otimes v_\sigma h(w_\sigma) \in A \otimes B \simeq \mathbb{R}^{a \times b},$$

dove nessuno dei $h(w_\sigma)$   nullo. In particolare,

$$\#(\tilde{\mathcal{S}}_C \not\subset H) \geq \text{rank}(T(h)).$$

Rappresentando $T(h) \in A \times B$ in $\mathbb{R}^{a \times b}$ tramite il passaggio alle coordinate, troviamo

$$T(h) = U_S D V_S^*,$$

dove $U_S = [u_1 | \dots | u_S] \in \mathbb{R}^{a \times S}$, $V_S = [v_1 | \dots | v_S] \in \mathbb{R}^{b \times S}$ e $D = \text{diag}(h(w_1), \dots, h(w_S))$   di taglia $S \times S$ ed invertibile. Per la disuguaglianza di Sylvester [29, Pag. 12]

$$\begin{aligned} \text{rank}(T(h)) &= \text{rank}(U_S D V_S^*) = \text{rank}(U_S D) + \text{rank}(V_S^*) - S \\ &\geq \dim\langle u_\sigma \rangle_{\sigma=1}^S + \dim\langle v_\sigma \rangle_{\sigma=1}^S - S. \end{aligned}$$

Per definizione di k -rango, valgono $\dim\langle u_\sigma \rangle \geq \min\{S, \mathbf{k}_{\mathcal{S}_A}\}$ e $\dim\langle v_\sigma \rangle \geq \min\{S, \mathbf{k}_{\mathcal{S}_B}\}$. Mettendo insieme queste ultime stime,

$$(2.10) \quad \#(\tilde{\mathcal{S}}_C \not\subset H) \geq \min\{S, \mathbf{k}_{\mathcal{S}_A}\} + \min\{S, \mathbf{k}_{\mathcal{S}_B}\} - S.$$

Questo concluderebbe se sapessimo che $S \leq \min\{\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}\}$. Riscrivendo l'Equazione (2.2) dell'ipotesi, troviamo

$$(2.11) \quad r - \mathbf{k}_{\mathcal{S}_C} + 1 \leq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1.$$

Siccome $\#(\tilde{\mathcal{S}}_C \cap H) \geq c - 1$, dall'equazione sopra otteniamo

$$\begin{aligned} \#(\tilde{\mathcal{S}}_C \not\subset H) &= r - \#(\tilde{\mathcal{S}}_C \cap H) \\ &\leq r - (c - 1) \\ (2.12) \quad &\leq r - (\mathbf{k}_{\mathcal{S}_C} - 1) \quad \text{dato che } c - 1 \geq \mathbf{k}_{\mathcal{S}_C} - 1, \\ &\leq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1. \end{aligned}$$

Mettendo insieme le stime trovate nell'Equazione (2.10) e (2.12), troviamo

$$(2.13) \quad \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1 \geq \#(\tilde{\mathcal{S}}_C \not\subset H) \geq \min\{S, \mathbf{k}_{\mathcal{S}_A}\} + \min\{S, \mathbf{k}_{\mathcal{S}_B}\} - S.$$

Se fosse $S \geq \min\{\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}\}$, avremmo

$$\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1 \geq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - S$$

ovvero $-r - 1 \geq -S$ cioè $r + 1 \leq S$, assurdo. Quindi $S \leq \min\{\mathbf{k}_{S_A}, \mathbf{k}_{S_B}\}$, e dal permutation lemma segue l'uguaglianza $\mathcal{S}_C = \tilde{\mathcal{S}}_C$.

Supponiamo ora di avere due scritture di T che differiscono da due permutazioni degli indici tramite $\sigma, \tau \in \mathfrak{S}_r$:

$$\begin{aligned} T &= u_1 \otimes v_1 \otimes w_1 + \dots + u_r \otimes v_r \otimes w_r \\ &= u_1 \otimes v_{\sigma(1)} \otimes w_{\tau(1)} + \dots + u_r \otimes v_{\sigma(r)} \otimes w_{\tau(r)}. \end{aligned}$$

Se $\sigma = \tau$, possiamo porre $a_j = u_j$, $b_j = v_j \otimes w_j$ e applicare il Lemma 2.2.19.

Se $\sigma \neq \tau$, allora esiste il più piccolo indice $j_0 \in \{1, \dots, r\}$ tale che $\sigma(j_0) =: s_0 \neq t_0 := \tau(j_0)$. Affermiamo che esistano due sottoinsiemi $S, T \subset \{1, \dots, r\}$ con le seguenti proprietà:

- (i) $s_0 \in S, t_0 \in T$,
- (ii) $S \cap T = \emptyset$,
- (iii) $\#S \leq r - \mathbf{k}_{S_B} + 1$, $\#T \leq r - \mathbf{k}_{S_C} + 1$, e
- (iv) Esistono due iperpiani $\hat{H}_S \subset B$ e $\hat{H}_T \subset C$ tali che
 - $s_0 \notin \hat{H}_S$ e $t_0 \notin \hat{H}_T$.
 - I sottospazi $\langle v_j \mid j \in S^c \rangle$ e $\langle w_j \mid j \in T^c \rangle$ sono contenuti negli iperpiani $\hat{H}_S$ e $\hat{H}_T$ rispettivamente.

Qui, $S^c = \{1, \dots, r\} \setminus S$. L'idea è costruire due iperpiani $\hat{H}_S$ e $\hat{H}_T$ che separino v_{s_0} da v_{t_0} e w_{s_0} da w_{t_0} come in Figura 2.3, per trovare un funzionale che annulli T , da cui poi trovare un assurdo violando l'ipotesi di Kruskal.

Partiamo da costruire un iperpiano $\hat{H}_T$ che soddisfi la (iv). Fissiamo una base $\mathcal{C}$ di C tale che $\{w_{t_0}, w_{s_0}\} \subset \mathcal{C}$, e definiamo il sottospazio $\hat{H}_T := \langle \mathcal{C} \setminus \{w_{t_0}\} \rangle$ di dimensione $\mathbf{c} - 1$. Possiamo riscrivere $\hat{H}_T = \langle w_j \mid j \in T^c \rangle$, dove T^c è l'insieme dei $\mathbf{c} - 1$ indici di supporto tali che $t_0 \notin T$. Dalla definizione di k-rango, vale $\mathbf{c} \geq \mathbf{k}_{S_C}$, dunque $\#T^c \geq \mathbf{k}_{S_C} - 1$. Questo assicura che $\#T$ sia strettamente limitata da $\mathbf{k}_{S_B}$, in quanto

$$\#T = r - \#T^c \leq r - \mathbf{k}_{S_C} + 1 \leq \mathbf{k}_{S_A} + \mathbf{k}_{S_B} - r - 1 \leq \mathbf{k}_{S_B} - 1.$$

La penultima disuguaglianza segue dall'Equazione (2.11), mentre l'ultima segue da $\mathbf{k}_{S_A} \leq r$. Procediamo ora a costruire $\hat{H}_S$. Consideriamo il sottospazio $V_T := \langle v_j \mid j \in T \rangle$, che dalla stima su $\#T$ ha dimensione al più $\mathbf{k}_{S_B} - 1$. Osserviamo che $v_{s_0} \notin V_T$;

se così non fosse, l'insieme $\{s_0\} \cup T$ conterrebbe al più $\mathbf{k}_{\mathcal{S}_B}$ vettori, ma il vettore v_{s_0} sarebbe linearmente dipendente rispetto ai vettori $\{v_j \mid j \in T\}$, che contraddirebbe la definizione di k -rango. Da cui, completando il sottospazio $\langle v_j \mid j \in T \rangle$ ad altri vettori in $\pi^{-1}(\mathcal{S}_B)$, possiamo trovare un iperpiano $\hat{H}_S \subset B$ contenente $\langle v_t \mid t \in T \rangle$ ma non v_{s_0} . Sia ora $S^c := \{j \mid v_j \in \hat{H}_S\}$. Similmente a quanto visto per T , valgono $\#S^c \geq \mathbf{k}_{\mathcal{S}_B} - 1$, dunque $\#S \leq r - \mathbf{k}_{\mathcal{S}_B} + 1$. Dalla costruzione segue che $T \subseteq S^c$, da cui $S \cap T = \emptyset$. Allora S e T hanno le proprietà desiderate.

la figura va sistemata, lo farò alla fine




Figura 2.3: Rappresentazione della costruzione degli iperpiani $\hat{H}_T \subset C$ e $\hat{H}_S \subset B$ e della separazione degli indici nella dimostrazione del Teorema di Kruskal.

La formula delle dimensioni dell'ortogonale assicura che esista un elemento non banale in $\hat{H}_S^\perp \times \hat{H}_T^\perp$, infatti

$$\dim(\hat{H}_S^\perp \times \hat{H}_T^\perp) = \dim(\hat{H}_S^\perp) \dim(\hat{H}_T^\perp) = (\mathbf{b} - (\mathbf{b} - 1))(\mathbf{c} - (\mathbf{c} - 1)) = 1.$$

Notiamo che per costruzione $T|_{\hat{H}_S^\perp \times \hat{H}_T^\perp} = 0$: preso l'unico elemento non zero $(\beta, \gamma) \in \hat{H}_S^\perp \times \hat{H}_T^\perp$, si ha

$$\begin{aligned} 0 = T(\beta, \gamma) &= \sum_{j=1}^r u_j \beta(v_j) \gamma(w_j) \\ &= \sum_{j=1}^r u_j \beta(v_{\sigma(j)}) \gamma(w_{\tau(j)}) = \sum_{j \in \mathcal{J}} u_j \beta(v_{\sigma(j)}) \gamma(w_{\tau(j)}), \end{aligned}$$

dove $\mathcal{J} = \{j \mid \sigma(j) \in S, \tau(j) \in T\} \supseteq \{j \mid \sigma(j) \neq \tau(j)\}$ è non vuoto, in quanto contiene almeno j_0 , e ha cardinalità limitata da $\#S$ e $\#T$. Analizziamo meglio l'espressione sopra. Nel caso della prima sommatoria tutti i termini $\beta(v_j) \gamma(w_j)$ sono

nulli. Se così non fosse, esisterebbe un indice j tale per cui $\beta(v_j) \neq 0$ e $\gamma(w_j) \neq 0$, ma ciò accadrebbe, per definizione di annullatore, se e solo se $v_j \notin \hat{H}_S$ (cioè $j \in S$) e $w_j \notin \hat{H}_T$ (cioè $j \in T$), ma ciò accade se e solo se $j \in S \cap T = \emptyset$. Nella seconda riga, similmente, un addendo è non nullo se $v_{\sigma(j)} \notin \hat{H}_S$ e $w_{\tau(j)} \notin \hat{H}_T$, cioè $j \in \mathcal{J}$. Allora esiste una combinazione lineare non banale tra gli elementi u_j per gli indici $j \in \mathcal{J}$, ma $\#\mathcal{J} \leq \min\{\#S, \#T\} \leq \min\{r - \mathbf{k}_{S_B} + 1, r - \mathbf{k}_{S_C} + 1\}$, che è minore di $\mathbf{k}_{S_A}$, che produce l'assurdo, perché per lineare indipendenza e definizione di k -rango, questi dovrebbero essere almeno $\mathbf{k}_{S_A}$. Infatti, se fosse $\mathbf{k}_{S_A} \geq \min\{r - \mathbf{k}_{S_B} + 1, r - \mathbf{k}_{S_C} + 1\}$, si avrebbero

$$\begin{aligned} r - \mathbf{k}_{S_B} + 1 &\geq \mathbf{k}_{S_A}, \\ r - \mathbf{k}_{S_C} + 1 &\geq \mathbf{k}_{S_A}. \end{aligned}$$

Sommando le disequazioni troveremmo $2r + 2 \geq \mathbf{k}_{S_A} + \mathbf{k}_{S_B} + \mathbf{k}_{S_A}$, che violerebbe l'ipotesi. Da cui $\sigma = \tau$, che completa la dimostrazione. $\square$

La condizione di Kruskal è sufficiente ma non necessaria. Il seguente risultato fornisce una condizione necessaria ma non sufficiente:

Teorema 2.2.20. *Dato un tensore $T = \llbracket U_1, \dots, U_d \rrbracket$ tale per cui*

$$\min_j \{ \mathbf{R}(U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1) \} < r,$$

allora la fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$ non è essenzialmente unica.

Osservazione 2.2.21. Nel 1977 Kruskal dimostra l'unicità della fattorizzazione CP nel caso 3-dimensionale con un argomento di 40 pagine [33], di non semplice lettura. La sua idea è stata riadattata da diversi matematici, e attualmente abbiamo due dimostrazioni brevi che sfruttano il permutation lemma, ma che seguono idee diverse. La prima riscrittura, ad opera di Stegeman e Sidiropoulos [45] era 16 pagine, ed è stata di seguito riadattata da Landsberg [36] in un argomento geometrico di poche pagine, che abbiamo presentato in questo elaborato. La seconda rielaborazione, ad opera di Rhodes (circa 9 pagine) in [39] utilizza un approccio diverso, che non discuteremo. Il caso generale, dimostrato da Sidiropoulos e Bro [41] si ottiene (in maniera non ovvia) riconducendosi al caso 3-dimensionale, abbiamo ritenuto più interessante trattare solamente il caso in dimensione bassa.

forse è semplice da dimostrare, se avanza tempo fare

3

APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA

In questo capitolo introdurremo l'esponente asintotico della moltiplicazione matriciale ω e alcuni fondamenti teorici per calcolare la complessità del prodotto tra matrici. Formuleremo tale prodotto come una mappa bilineare, e quindi come un tensore. Osserveremo che il rango della forma bilineare dà il numero di moltiplicazioni di un algoritmo, e viceversa. In questo contesto, introdurremo gli *algoritmi di moltiplicazione veloce*, cioè gli algoritmi di moltiplicazione matriciale che impiegano asintoticamente un numero minore di operazioni aritmetiche rispetto all'algoritmo classico, ottenendo un esponente di complessità asintotica minore di 3 per le matrici quadrate. Presenteremo alcuni algoritmi di moltiplicazione veloci esatti e approssimati, e concluderemo discutendo dell'errore algoritmico.

3.1 MAPPE MULTILINEARI E MOLTIPLICAZIONE TRA MATRICI

Definizione 3.1.1 (Moltiplicazione matriciale). Fissati degli interi positivi m, n, p , la moltiplicazione tra due matrici $m \times n$ e $n \times p$ è una mappa bilineare

$$\langle m, n, p \rangle: \mathbb{C}^{m \times n} \times \mathbb{C}^{n \times p} \rightarrow \mathbb{C}^{m \times p}$$

$$(A, B) \mapsto C = AB.$$

Spesso ci riferiremo a $\langle m, n, p \rangle$ chiamandolo “algoritmo”, ad esempio nel contesto degli algoritmi di moltiplicazione veloce.

Osservazione 3.1.2. La bilinearità della mappa sopra segue immediatamente dalla definizione del prodotto matriciale:

$$(3.1) \quad (AB)_{ij} = \sum_{k=1}^n a_{ik} b_{kj},$$

dove $i = 1, \dots, m$ e $j = 1, \dots, p$.

Controlla che non ci sia ambiguità nel riferirti a mappe/forme bilineari: $\psi: U \times V \rightarrow W$ è una forma bilineare se $W = \mathbb{K}$, altrimenti chiamala mappa bilineare

Osservazione 3.1.3. Possiamo vedere la moltiplicazione tra matrici anche come una forma trilineare

$$\begin{aligned} \mathbb{C}^{m \times n} \times \mathbb{C}^{n \times p} \times \mathbb{C}^{m \times p} &\rightarrow \mathbb{C} \\ (A, B, C) &\mapsto \text{trace}(ABC) \end{aligned}$$

RAPPRESENTAZIONE IN COORDINATE DI UNA FORMA BILINEARE

Un modo semplice di rappresentare una forma bilineare $\varphi: U \times V \rightarrow W$ come un tensore è farlo partendo dalle fette. Fissato $k \in \{1, \dots, p\}$ e considerata la sua componente k -esima $\varphi_k: U \times V \rightarrow \mathbb{R}$, esiste una matrice $M \in \mathbb{R}^{m \times n}$ tale che $\varphi_k(u, v) = u^\top M v$ per ogni $(u, v) \in \mathbb{R}^m \times \mathbb{R}^n$. Scrivendo ogni componente di

$$\varphi = \begin{bmatrix} \varphi_1 \\ \vdots \\ \varphi_p \end{bmatrix}$$

in questa forma, otteniamo un tensore $T \in \mathbb{R}^{m \times n \times p}$ tale che le sue fette frontali rappresentino ognuna delle p forme bilineari φ_k , ossia che

$$(3.2) \quad \varphi_k(u, v) = u^\top T_{:, :, k} v = \sum_{i=1}^m \sum_{j=1}^n T_{i,j,k} u_i v_j, \text{ per ogni } k = 1, \dots, p.$$

In forma tensoriale,

$$(3.3) \quad \varphi(u, v) = \begin{bmatrix} \varphi_1(u, v) \\ \vdots \\ \varphi_p(u, v) \end{bmatrix} = \begin{bmatrix} u^\top T_{:, :, 1} v \\ \vdots \\ u^\top T_{:, :, p} v \end{bmatrix} = T \times_1 u^\top \times_2 v^\top.$$

Osservazione 3.1.4. L'algebra multilineare garantisce l'esistenza e l'unicità di T .

Osservazione 3.1.5. Questa procedura si estende (passando alle coordinate) anche al caso in cui le entrate di u e v siano oggetti algebrici più complessi di scalari, ad esempio vettori o matrici.

Ricordando che $U^* \otimes V^* \otimes W$ è l'insieme delle forme trilineari da $U \times V \times W^* \rightarrow \mathbb{K}$, possiamo dare un nome all'oggetto sopra.

Definizione 3.1.6 (Tensore strutturale). L'unico tensore $T \in U^* \otimes V^* \otimes W$ associato alla mappa bilineare $\varphi: U \times V \rightarrow W$ è detto *tensore strutturale* di φ .

Osservazione 3.1.7. Con un abuso di notazione tipicamente usato in letteratura [17, 35, 36], nel seguito identificheremo l'algoritmo di moltiplicazione matriciale (come mappa bilineare) con il suo tensore strutturale, denotando entrambi dello stesso

simbolo $\langle m, n, p \rangle$, e specificheremo l'oggetto in questione laddove creerà ambiguità. Più avanti questa notazione sarà giustificata dalla Proposizione 3.2.3.

3.2 DECOMPOSIZIONE LOW-RANK DI FORME BILINEARI

In § 1.4 abbiamo osservato che le fattorizzazioni low-rank riducono il costo in memoria. Aggiungiamo che questa rappresentazione è anche vantaggiosa per ridurre il calcolo delle operazioni aritmetiche. Nel caso delle matrici, se $M \in \mathbb{R}^{m \times n}$ ha rango uno, possiamo scrivere $M = u \otimes v = uv^\top$ per certi $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$; valutare $Mx = (uv^\top)x = u(v^\top x)$ ha costo $O(n)$, contro il costo $O(mn)$ del prodotto classico matrice vettore. In generale, se M ha rango R , possiamo scriverla come somma di R matrici di rango uno e per linearità ottenere un costo $O(Rn)$ per Mx . È possibile generalizzare quest'idea per mappe bilineari.

Calcolare la valutazione di una mappa bilineare φ come nell'Equazione (3.2) senza alcuna fattorizzazione di T ha un costo $O(mnp)$, data dal numero di moltiplicazioni necessarie fra gli elementi di u e v con le entrate non nulle di T . Osserveremo che queste operazioni si chiameranno *active multiplications*, in quanto saranno legate alla misura di complessità $L(\varphi)$. In particolare, sarà possibile ridurre le *active multiplications* trovando fattorizzazioni di rango più basso di T .

Definizione 3.2.1 (Bilinear algorithm). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali. Per ogni $i \in \{1, \dots, r\}$, siano $f_i \in U^*$, $g_i \in V^*$, $w_i \in W$ tali che

$$\varphi(u, v) = \sum_{i=1}^r f_i(u)g_i(v)w_i,$$

per ogni $u \in U, v \in V$. Allora la r -upla $(f_1, g_1, w_1; \dots; f_r, g_r, w_r)$ viene detta *bilinear computation (algorithm) di lunghezza r per φ* , e la lunghezza di più breve algoritmo di calcolo per φ è chiamata *bilinear complexity* o rango di φ , che indichiamo ancora con $R(\varphi)$.

La prossima proposizione assicura che il rango di una forma bilineare sia dato dal rango CP.

Proposizione 3.2.2. Fissata una forma bilineare φ , e detto T il tensore che la rappresenta. Allora, dalla fattorizzazione CP di un tensore T si ottiene una *bilinear computation*, e in particolare $R(\varphi) = R(T)$.

lasciamo in inglese o meglio tradurre?

si può definire direttamente come bilinear algorithm la scrittura sopra invece che la r -upla? (nel testo non la uso mai come r -upla)

Dimostrazione. Data una decomposizione $T = \llbracket U, V, W \rrbracket$ di rango r , dalla Definizione 1.4.1 abbiamo che $T = \sum_{l=1}^r u_l \otimes v_l \otimes w_l$, o in componenti, $T_{i,j,k} = \sum_{l=1}^r u_{il} v_{jl} w_{kl}$. Inserendo questa relazione nell'Equazione (3.2) troviamo,

$$\begin{aligned}
 (3.4) \quad \varphi_k(x, y) &= \left(\left(\sum_{l=1}^r u_l \otimes v_l \otimes w_l \right) \times_1 x^\top \times_2 y^\top \right)_k = \left(\sum_{l=1}^r (u_l \otimes v_l \otimes w_l) \times_1 x^\top \times_2 y^\top \right)_k \\
 &= \sum_{i=1}^m \sum_{j=1}^n \sum_{l=1}^r u_{il} v_{jl} w_{kl} x_i y_j = \sum_{l=1}^r \left(\sum_{i=1}^m u_{il} x_i \right) \cdot \left(\sum_{j=1}^n v_{jl} y_j \right) w_{kl} \\
 &= \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_{kl},
 \end{aligned}$$

per ogni $k = 1, \dots, p$. Mettendo insieme le Equazioni (3.3) e (3.4) troviamo

$$(3.5) \quad \varphi(x, y) = \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_l.$$

Considerando i funzionali $f_l(x) := u_l^\top x$ e $g_l(y) := v_l^\top y$ indotti dal prodotto scalare standard si ha la tesi. $\square$

Quindi valutare φ richiede esattamente $r = \mathbf{R}(T)$ active multiplications (e $O(r)$ addizioni), che sopra evidenziamo con $(\cdot)$. In particolare, il seguente risultato algebrico ci dice che la rappresentazione di una forma bilineare come tensore o come bilinear computation sono identiche, ed è utile per riscrivere un algoritmo tramite un tensore.

Proposizione 3.2.3 (Si veda [17], Cap. 14). *Siano U, V e W dei $\mathbb{K}$ -spazi vettoriali. Allora esiste un unico isomorfismo $U^* \otimes V^* \otimes W \rightarrow \{\varphi : U \times V \rightarrow W, \text{ bilineare} \}$ che manda $f \otimes g \otimes w$ nella mappa bilineare $(u, v) \mapsto f(u)g(v)w$.*

Osservazione 3.2.4. Grazie a questo isomorfismo, possiamo passare da una bilinear computation

$$\varphi(u, v) = \sum_{i=1}^r f_i(u) g_i(v) w_i,$$

al suo tensore

$$T = \sum_{i=1}^r f_i \otimes g_i \otimes w_i,$$

e viceversa.

3.3 RAPPRESENTAZIONE DEL PRODOTTO TRA MATRICI

Torniamo al nostro focus iniziale, cioè valutare la forma bilineare del prodotto tra matrici con un numero ottimale di operazioni.

Consideriamo due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times p}$ e il loro prodotto $C \in \mathbb{R}^{m \times p}$. Ponendo $x = \text{vec}(A)$ e $y = \text{vec}(B)$, l'Equazione (3.3) diventa

$$(3.6) \quad \text{vec}(C^\top) = \varphi(x, y) = T \times_1 \text{vec}(A)^\top \times_2 \text{vec}(B)^\top,$$

dove tramite le trasposizioni abbiamo fissato l'ordinamento naturale sulle entrate di $\text{vec}(A)$ e $\text{vec}(B)$, e quello inverso su $\text{vec}(C^\top)$. Per costruzione, il tensore $T \in \mathbb{R}^{mn \times np \times mp}$ rappresenta l'algoritmo $\langle m, n, p \rangle$. Scrivendo T tramite la sua decomposizione CP di rango r , l'Equazione (3.5) ci permette di riscrivere l'espressione sopra come una bilinear computation

$$(3.7) \quad \text{vec}(C^\top) = \sum_{l=1}^r (u_l^\top \text{vec}(A)) \cdot (v_l^\top \text{vec}(B)) w_l = \sum_{l=1}^r (s_l \cdot t_l) w_l = \sum_{l=1}^r m_l w_l,$$

Dove abbiamo posto $s_l := s_l(A) := u_l^\top \text{vec}(A)$, $t_l := t_l(B) := v_l^\top \text{vec}(B)$ e $m_l := s_l t_l$.

Questa formula definisce un algoritmo di moltiplicazione veloce $\langle m, n, p \rangle$; spesso nella pratica m, n, p sono più piccoli delle matrici da moltiplicare; in questo caso è possibile dividerle a blocchi e applicare l'algoritmo in maniera ricorsiva. Nella prossima sezione giustificheremo meglio questa procedura.

ha senso usare f_l e t_l invece che s_l e t_l ?

3.4 L'ESPONENTE DELLA MOLTIPLICAZIONE TRA MATRICI

In questo capitolo useremo il seguente modello computazionale per il calcolo della complessità, per calcolare costi computazionali anche su campi infiniti, e semplificare il calcolo dei costi eliminando branching (e.g. `if-then-else` o `while`).

Definizione 3.4.1 (Circuito aritmetico). Un *circuito aritmetico* Γ su $\mathbb{K}$ è un grafo diretto, aciclico, finito con vertici di grado entrante 0 o 2 ed esattamente un vertice di grado uscente 0. I vertici di grado entrante 0 sono etichettati con gli elementi di $\mathbb{K} \cup \{x_1, \dots, x_n\}$ e sono detti *inputs*. Quelli di grado entrante 2 sono etichettati con $+$ oppure $*$ e sono chiamati *gates*. Se il grado uscente di un vertice v è 0, allora v è chiamato un *output gate*. La dimensione di Γ è il numero di archi.




Figura 3.1: Esempio di circuito aritmetico per il polinomio $\varphi(x_1, x_2) = (x_1 + x_2)x_2(x_2 + 1)$.

specifichiamo a che spazio appartengono i risultati intermedi?

Definizione 3.4.2 (Funzione costo). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali di dimensione finita. Definiamo la *funzione costo* associata a un circuito aritmetico Γ come

$C_\Gamma(\varphi) :=$ numero di moltiplicazioni per calcolare φ sul circuito Γ , oppure

$C_\Gamma^{\text{tot}}(\varphi) :=$ numero di addizioni e moltiplicazioni per calcolare φ sul circuito Γ .

Denotiamo con $\mathcal{C}_\varphi$ come l'insieme dei circuiti aritmetici Γ che calcolano φ .

Definizione 3.4.3 (Funzione di complessità aritmetica). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali di dimensione finita. Definiamo

$L(\varphi) := \inf_{\Gamma \in \mathcal{C}_\varphi} \{C_\Gamma(\varphi)\}$ la *complessità moltiplicativa* di φ , e

$L^{\text{tot}}(\varphi) := \inf_{\Gamma \in \mathcal{C}_\varphi} \{C_\Gamma^{\text{tot}}(\varphi)\}$ la *complessità totale* di φ .

Osservazione 3.4.4. In altre parole, $L(\varphi)$ è il minimo numero di moltiplicazioni non scalari sufficienti a calcolare φ , anche dette *active multiplications*. In maniera analoga, L^{tot} è il minimo numero di moltiplicazioni non scalari e di addizioni sufficienti a calcolare φ .

Consideriamo la forma bilineare $\varphi = \langle n, n, n \rangle$ data dall'Equazione (3.1). Fissato un campo $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, e delle matrici $A, B \in \mathbb{R}^{n \times n}$, denotiamo con

$$(3.8) \quad M_{\mathbb{K}}(n) := L^{\text{tot}}(\langle n, n, n \rangle) = L^{\text{tot}}\left(\left\{\sum_{k=1}^n a_{ik} b_{kj} \mid i, j \in \{1, \dots, n\}\right\}\right)$$

il numero totale di moltiplicazioni aritmetiche sufficienti a calcolare la moltiplicazione di due matrici $n \times n$. Determinare una formula per $M_{\mathbb{K}}(n)$ è lontano dagli strumenti attualmente disponibili. Invece, il problema di approssimare la crescita asintotica della funzione $n \mapsto M_{\mathbb{K}}(n)$ è fattibile; definiamo

Definizione 3.4.5. L'esponente $\omega_{\mathbb{K}}$ di una moltiplicazione matriciale è il numero

$$\omega_{\mathbb{K}} := \inf_{n \in \mathbb{N}} \{\tau \in \mathbb{R} \mid \text{la moltiplicazione tra due matrici in } \mathbb{K}^{n \times n} \text{ ha costo } o(n^{\tau}) \text{ operazioni aritmetiche}\}.$$

In altre parole, $\omega_{\mathbb{K}} = \inf_{n \in \mathbb{N}} \{\tau \in \mathbb{R} \mid M_{\mathbb{K}}(n) = o(n^{\tau})\}$.

Osservazione 3.4.6. La notazione $M_{\mathbb{K}}(h)$ e $\omega_{\mathbb{K}}$ è dovuta alla dipendenza dal campo $\mathbb{K}$. Dato che tratteremo solo $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, spesso scriveremo ω per $\omega_{\mathbb{K}}$.

Teorema 3.4.7 (Schönhage [40]). *L'esponente della moltiplicazione tra matrici è invariante rispetto alle estensioni scalari: se $\mathbb{K} \subset \mathbb{L}$ è un'estensione di campo, allora*

$$\omega_{\mathbb{K}} = \omega_{\mathbb{L}}$$

STIMARE L'ESPONENTE

Un modo elementare di trovare una nuova stima su ω è trovare una scrittura più breve della forma bilineare (o del tensore). La seguente proposizione ci fornisce una prima stima della misura di complessità con il rango di una forma bilineare.

Proposizione 3.4.8 (Strassen, si veda [17], Capitolo 14).

Siano U, V e W dei $\mathbb{K}$ -spazi vettoriali di dimensione finita, e $\varphi : U \times V \rightarrow W$ una mappa bilineare. Allora

$$L(\varphi) = \text{Lunghezza della più breve bilinear computation per } \varphi.$$

Osservazione 3.4.9. Da questa proposizione segue direttamente che

$$(3.9) \quad L(\varphi) \leq \mathbf{R}(\varphi) \leq 2L(\varphi).$$

in realtà è un corollario semplice di un teorema formulato da Strassen, che ho deciso di attribuire a Strassen (non aveva nome)

Osserviamo che $M_{\mathbb{K}}(n) \leq n^2(2n-1)$. Siccome il costo computazionale dev'essere almeno pari al numero di entrate della matrice, vale $M_{\mathbb{K}}(n) \geq n^2$, da cui $\omega \in [2, 3]$. Trovare ω è un problema centrale nella teoria della complessità, e si congettura che $\omega = 2$, cioè che il costo delle moltiplicazioni possa essere asintoticamente pari a quello delle addizioni. L'algoritmo naive ha $\omega = 3$, mentre il primo miglioramento, dovuto all'algoritmo di Strassen [48] mostra che $\omega \leq \log_2(7) < 2.81$. Il record attuale è $\omega \leq 2.371177$ [3]. Dopo Strassen, nel 1978 i miglioramenti significativi sono stati $\omega \leq 2.7962$ ad opera di [38], poi $\omega \leq 2.7799$ [13] nel 1979, poi $\omega \leq 2.55$ [40], poi $\omega \leq 2.48$ nel 1987 [47], e poi $\omega \leq 2.38$ [19] nel 1989, che potrebbe aver fatto pensare che nel 1990 si sarebbe trovato il bound. Dopo tale miglioramento, l'approssimazione è scesa molto lentamente, fino a scendere sotto $\omega < 2.372$ solo recentemente [2, 27, 46, 50]. Tuttavia, l'avvento dell'Intelligenza Artificiale sta dando un nuovo impulso a questa ricerca (si veda ad esempio AlphaTensor [25]); di recente (agosto 2026) l'utilizzo di strumenti di IA come AlphaEvolve ha stabilito il nuovo record di $\omega \leq 2.371177$ [3]. Sottolineiamo che da un punto di vista pratico, non è detto che le stime ottimali si traducano in algoritmi più veloci o stabili di quello classico, ad esempio l'algoritmo di Strassen, che presenteremo, risulta migliore di algoritmi con esponente più basso in molte situazioni [7, 21].




Figura 3.2: Miglioramenti del limite superiore dell'esponente della moltiplicazione matriciale ω dal 1969 ad oggi. La linea tratteggiata rappresenta il limite superiore $\omega \leq 3$.

3.5 IL RANGO COME MISURA DELLA COMPLESSITÀ

STIMARE LA COMPLESSITÀ NEL CASO GENERALE

Precedentemente abbiamo introdotto gli algoritmi di moltiplicazione dal caso base e.g. $\langle n, n, n \rangle$, senza giustificare come cambia la complessità quando l'algoritmo viene eseguito ricorsivamente. Date due matrici $n^i \times n^i$, possiamo vedere la loro moltiplicazione come il prodotto di matrici $n \times n$ sull'algebra delle matrici $n^{i-1} \times n^{i-1}$, suddividendole in blocchi. Questo dice anche che, se $\mathbf{R}(\langle n, n, n \rangle) \leq r$, allora $\mathbf{R}(\langle n^i, n^i, n^i \rangle) \leq r^i$; infatti, combinando le prossime Proposizioni 3.5.3 e 3.5.4, e usando che il rango è invariante per isomorfismo, troviamo

$$\mathbf{R}(\langle n^i, n^i, n^i \rangle) = \mathbf{R}(\langle n, n, n \rangle^{\otimes i}) \leq \mathbf{R}(\langle n, n, n \rangle)^i \leq r^i,$$

dove

$$\langle n, n, n \rangle^{\otimes i} = \underbrace{\langle n, n, n \rangle \otimes \cdots \otimes \langle n, n, n \rangle}_{i\text{-volte}}.$$

In altre parole, possiamo applicare ricorsivamente l'algoritmo di moltiplicazione veloce, che è disegnato per matrici $n \times n$, per ottenere la moltiplicazione di matrici $n^i \times n^i$ impiegando solo r^i moltiplicazioni (senza dover fattorizzare il tensore di $\langle n^i, n^i, n^i \rangle$, che sarebbe del modesto formato $(n^i)^2 \times (n^i)^2 \times (n^i)^2$).

Se invece $n > n_0$ sono due interi positivi (nei passaggi può essere utile pensare al caso $n_0 = 2$) dato un algoritmo con un caso base fissato $\langle n_0, n_0, n_0 \rangle$ è possibile ottenerne uno per $\langle n, n, n \rangle$ con $n > n_0$, allargando la matrice di taglia $n \times n$ aggiungendo zeri fino a raggiungere la dimensione $n_0^{\lceil \log_{n_0} n \rceil}$, in modo tale che le matrici da moltiplicare siano partizionate in blocchi di taglia divisibile dal caso base. La complessità dipenderà comunque da n_0 e da r , in quanto

$$\begin{aligned} \mathbf{R}(\langle n, n, n \rangle) &\leq \mathbf{R}(\langle n_0^{\lceil \log_{n_0} n \rceil}, n_0^{\lceil \log_{n_0} n \rceil}, n_0^{\lceil \log_{n_0} n \rceil} \rangle) && \text{dalla 3.5.2,} \\ &\leq \mathbf{R}(\langle n_0, n_0, n_0 \rangle)^{\lceil \log_{n_0} n \rceil} && \text{dalle 3.5.3 e 3.5.4,} \\ &\leq r^{\lceil \log_{n_0} n \rceil} && \text{per ipotesi } \mathbf{R}(\langle n, n, n \rangle) \leq r, \\ &\leq r \cdot n^{\log_{n_0} r} && \text{usando che } \lceil x \rceil \leq x + 1. \end{aligned}$$

Riassumendo, $\mathbf{R}(\langle n, n, n \rangle) \leq r \cdot n^{\log_{n_0} r}$. Dunque ignorando la costante e applicando l'Equazione (3.14), segue che $\omega \leq \log_{n_0} r$. Questa stima si rivelerà utile per calcolare la complessità degli algoritmi veloci, evitando di passare per il Master Theorem [20].

spiegare cosa significa fare $\langle n \rangle^{\otimes i}$. C'è ambiguità, non è chiaro se sia un prodotto di Kroneker o prodotto tensoriale (forse vanno bene entrambi)

Abbiamo dimostrato la seguente:

Proposizione 3.5.1. *Se $R(\langle n, n, n \rangle) \leq r$ per degli interi positivi n, r , allora $n^\omega \leq r$.*

Questo risultato tornerà utile per calcolare l'esponente quando scopriremo una nuova fattorizzazione tensoriale di un algoritmo, in quanto $\omega \leq \log_n r$.

Nei passaggi sopra abbiamo anche osservato che se $n \leq n'$ e dato un algoritmo per n' , possiamo ottenerne uno per n allargando la matrice. Possiamo racchiudere questa proprietà nel seguente risultato:

Proposizione 3.5.2 (Monotonia del rango di un algoritmo). *Il rango di un algoritmo per la moltiplicazione di matrici è monotono crescente rispetto alle loro taglie, ovvero dati due interi positivi $n \leq n'$, allora $R(\langle n, n, n \rangle) \leq R(\langle n', n', n' \rangle)$.*

Riportiamo le proposizioni utilizzate per dimostrare la proposizione sopra, dimostrate in [17, Capitoli 14 e 15].

Proposizione 3.5.3. *Siano e, e', h, h', l, l' degli interi positivi. Allora abbiamo*

$$\langle e, h, l \rangle \otimes \langle e', h', l' \rangle \simeq \langle ee', hh', ll' \rangle,$$

cioè le due forme bilineari sono isomorfe.

Proposizione 3.5.4. *Siano φ_1, φ_2 due mappe bilineari. Allora $R(\varphi_1 \otimes \varphi_2) \leq R(\varphi_1)R(\varphi_2)$.*

Dimostrazione. Scriviamo φ_1, φ_2 come bilinear computation:

$$\begin{aligned}\varphi_1(u_1, v_1) &= \sum_{i=1}^{r_1} \alpha_i(u_1) \beta_i(v_1) w_i, \\ \varphi_2(u_2, v_2) &= \sum_{j=1}^{r_2} \gamma_j(u_2) \beta_j(v_2) z_j.\end{aligned}$$

Calcolando il loro prodotto tensoriale,

$$\begin{aligned}(\varphi_1 \otimes \varphi_2)(u_1 \otimes u_2, v_1 \otimes v_2) &= \varphi_1(u_1, v_1) \otimes \varphi_2(u_2, v_2) \\ &= \left(\sum_{i=1}^{r_1} \alpha_i(u_1) \beta_i(v_1) w_i \right) \otimes \left(\sum_{j=1}^{r_2} \gamma_j(u_2) \beta_j(v_2) z_j \right) \\ &= \sum_{i=1}^{r_1} \sum_{j=1}^{r_2} \alpha_i(u_1) \beta_i(v_1) \gamma_j(u_2) \beta_j(v_2) (w_i \otimes z_j),\end{aligned}$$

da quello che ho capito quindi potremmo usare questa proposizione invece che il master theorem per calcolare la complessità?

warning! Potrebbe essere il kroneker product di mappe bilineari

che è un'espressione di $\varphi_1 \otimes \varphi_2$ come somma di mappe bilineari di rango uno. Per minimalità del rango, segue

$$\mathbf{R}(\varphi_1 \otimes \varphi_2) \leq r_1 r_2 = \mathbf{R}(\varphi_1) \mathbf{R}(\varphi_2).$$

□

IL TEOREMA DI STRASSEN

Dato un algoritmo con r moltiplicazioni, abbiamo mostrato che è possibile costruire la sua bilinear computation (e rappresentarla con il suo circuito aritmetico) e poi dedurre che il rango del tensore è r . Esiste anche il problema inverso: quali interi positivi r realizzano un algoritmo con r moltiplicazioni? La prossima proposizione risponde a questa domanda.

può andare bene qui questa figura o la mettiamo dopo?




Figura 3.3: Circuito aritmetico per la moltiplicazione di matrici 2×2 .

Teorema 3.5.5 (Strassen [48], vedi anche [17] §15.1).

non capisco come sia collegata alla prop 3.5.1

$$\omega = \inf_n \{ \tau \in \mathbb{R} \mid \mathbf{R}(\langle n, n, n \rangle) = O(n^\tau) \}.$$

Ovvero, è possibile moltiplicare due matrici $n \times n$ usando $O(n^{\omega+\varepsilon})$ operazioni aritmetiche se e solo se il rango tensoriale di $\langle n, n, n \rangle$ è $O(n^{\omega+\varepsilon})$.

Introduciamo alcuni strumenti utili a dimostrare questo risultato.

Definizione 3.5.6 (Mappa bilineare concise). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare. Diremo che φ è *concise* se valgono tutte e tre le condizioni sotto:

1. $\text{Ker}_L(\varphi) = \{u \in U \mid \varphi(u, \cdot) = 0\} = \{0\}$,
2. $\text{Ker}_R(\varphi) = \{v \in V \mid \varphi(\cdot, v) = 0\} = \{0\}$,
3. $\text{Im}(\varphi) = \{\varphi(u, v) \mid u \in U, v \in V\} = W$.

change to roman and to i -concise per matchare quella dei tensori

Osservazione 3.5.7.

Esempio 3.5.8. La mappa bilineare $\langle n, n, n \rangle$ è concise.

Lemma 3.5.9. Sia $x = (x_0, x_1, x_2, \dots)$ una successione di numeri reali che soddisfa la ricorsione $x_s = ax_{s-1} + cb^s$, per certi numeri reali a, b, c . Allora per ogni $s \geq 0$, vale

$$x_s = \begin{cases} a^s x_0 + (a^s - b^s) \frac{bc}{a-b} & \text{se } a \neq b, \\ (cs + x_0) a^s & \text{se } a = b. \end{cases}$$

Dimostrazione. Mostriamo la formula per induzione su s . Per $s = 0$ la formula è verificata.

$$\begin{aligned} x_1 &= ax_0 + bc, \\ x_2 &= a(ax_0 + bc) + b^2c \\ &= a^2x_0 + (a+b)bc \\ &= \begin{cases} a^2x_0 + (a^2 - b^2) \frac{bc}{a-b} & \text{se } a \neq b, \\ (2c + x_0)a^2 & \text{se } a = b. \end{cases} \end{aligned}$$

Assumiamo la proprietà vera per $n-1$ e mostriamola per n .

Se $a \neq b$,

$$\begin{aligned} x_s &= a \left(a^{s-1} x_0 + (a^{s-1} - b^{s-1}) \frac{bc}{a-b} \right) + b^s c \\ &= a^s x_0 + ((a^{s-1} - b^{s-1})a + b^{s-1}(a-b)) \frac{bc}{a-b} \\ &= a^s x_0 + (a^s - b^s) \frac{bc}{a-b} \end{aligned}$$

Similmente, se $a = b$

$$\begin{aligned} x_s &= (c(s-1) + x_0 + c)a^s \\ &= (cs + x_0)a^s. \end{aligned}$$

□

osservare che combacia con la def data per i tensori

Dimostrazione del Teorema di Strassen. Dimostriamo che

$$\omega = \inf\{\tau \in \mathbb{R} \mid \mathbf{R}(\langle n, n, n \rangle) = O(n^\tau)\}.$$

Sia θ il lato destro dell'equazione sopra, e per semplicità scriviamo $M(n) := M_{\mathbb{K}}(n)$ e $\omega := \omega_{\mathbb{K}}$. Dall'Equazione (3.9) abbiamo

$$\frac{1}{2}R(\langle n, n, n \rangle) \leq L(\langle n, n, n \rangle) \leq M(n),$$

e dalla Definizione 3.4.5 segue $\theta \leq \omega$.

Mostriamo che $\omega \leq \theta$. Per definizione di θ , per ogni $\varepsilon > 0$ esiste un $n > 1$ tale che

$$(3.10) \quad r := \mathbf{R}(\langle n, n, n \rangle) \leq n^{\theta+\varepsilon}.$$

Dall'Equazione (3.7) esistono dei funzionali $f_\rho, g_\rho \in (\mathbb{K}^{n \times n})^*$ e delle matrici $w_\rho \in \mathbb{K}^{n \times n}$ per $\rho \in \{1, \dots, r\}$ tali che, per ogni $A, B \in \mathbb{K}^{n \times n}$

$$AB = \sum_{\rho=1}^r f_\rho(A)g_\rho(B)w_\rho.$$

matrix product, ma TODO verifica, e controlla se è così davvero(io ho i vec)

Vedendo $\mathcal{A} = \mathbb{K}^{n^i \times n^i}$ come l'algebra delle matrici $n^i \times n^i$, notiamo che i funzionali $f_\rho, g_\rho : \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ si estendono a funzionali $f_\rho, g_\rho : \mathcal{A}^{n \times n} \rightarrow \mathcal{A}$, sostituendo le entrate scalari con delle matrici. In particolare vale, per ogni $A, B \in \mathcal{A}^{n \times n}$

$$(3.11) \quad AB = \sum_{\rho=1}^r f_\rho(A)g_\rho(B)w_\rho.$$

L'Equazione sopra rappresenta l'algoritmo di moltiplicazione a blocchi tra A e B : infatti abbiamo $\mathcal{A}^{n \times n} = (\mathbb{K}^{n^i \times n^i})^{n \times n} \simeq \mathbb{K}^{n^{i+1} \times n^{i+1}}$, dove l'isomorfismo può essere pensato come la suddivisione di matrici più grandi in matrici a blocchi. Da questo fatto, unito all'Equazione (3.11), si ottiene che

$$(3.12) \quad M(n^{i+1}) \leq rM(n^i) + cn^{2i},$$

dove $c := c(n, r)$ è una costante che dipende sia da n che da r . Questo perché nella formula il prodotto AB , sviluppato come prodotto tra blocchi $n^i \times n^i$ (formalmente, visto come prododotto a coefficienti in $\mathcal{A}$), coinvolge r prodotti e un numero costante di addizioni. Siccome $\langle n, n, n \rangle$ è concise, abbiamo che $r \geq n^2$. Fissando n (e

quindi r), risolviamo la ricorsione dell'Equazione (3.12) in funzione di i usando il Lemma 3.5.9 con $a = r$ e $b = n^2$, analizzando due casi.

Se $r > n^2$, abbiamo che

$$\begin{aligned} M(n^i) &= r^i M(1) + (r^i - n^{2i}) \frac{n^2 c}{r - n^2} \\ &= (M(1) + n^2 c) r^i - n^{2i} \frac{n^2 c}{r - n^2}, \end{aligned}$$

da cui,

$$M(n^i) \leq \alpha r^i + \beta n^{2i},$$

dove abbiamo posto $\alpha := M(1) + n^2 c$ e $\beta := -\frac{n^2 c}{r - n^2}$.

Se $r = n^2$, dal Lemma (3.12) abbiamo

$$M(n^i) \leq (cs + M(1))r^i,$$

In entrambi i casi troviamo,

$$(3.13) \quad M(n^i) = O(r^i).$$

non chiaro se
anche l'equazio-
ne sopra garan-
tisca monotonia

capire se questo
passaggio è cor-
retto

Dalla proposizione 3.5.2 segue che M è una successione monotona, per ogni $h \in \mathbb{N} \setminus \{0\}$,

$$M(h) \leq M(n^{\lceil \log_n h \rceil}) = O(r^{\log_n h}) = O(h^{\log_n r}) = O(h^{\theta + \varepsilon}),$$

dove la prima uguaglianza segue dall'Equazione 3.5.2, la seconda da una proprietà del logaritmo, e la terza applicando la stima dell'Equazione (3.10). Quindi passando all'inf, $\omega_{\mathbb{K}} \leq \theta$, che completa la dimostrazione. $\square$

Osservazione 3.5.10. Riassumendo, il teorema sopra mette in corrispondenza $\mathbf{R}(\langle n, n, n \rangle)$, ovvero il rango del tensore che rappresenta $\langle n, n, n \rangle$ e numero di active multiplications, con l'esponente asintotico ottimale. Possiamo quindi scrivere

$$(3.14) \quad \omega = \lim_{n \rightarrow +\infty} \log_n(\mathbf{R}(\langle n, n, n \rangle)).$$

3.6 ALGORITMI DI MOLTIPLICAZIONE VELOCE

Osservazione 3.6.1. Di seguito ci limiteremo a studiare prodotti fra matrici quadrate; per il caso rettangolare, si possono estendere i ragionamenti sopra considerando una rappresentazione di rango r del tensore $\langle m, n, p \rangle$ e scrivendo, attraverso una serie di

permutazioni cicliche, la fattorizzazione di $\langle mnp, mnp, mnp \rangle$ di rango r^3 , che produce un algoritmo di complessità $O(n^{\log_{abc} r^3}) = O(n^{3 \log_{abc} r})$. Questo si può vedere tramite la scrittura della moltiplicazione tra matrici come forma trilineare dell'Osservazione 3.1.3, che ci permette di dire che il tensore è invariante per trasformazioni cicliche, in quanto

$$(3.15) \quad \text{trace}(ABC) = \text{trace}(CAB) = \text{trace}(BAC).$$

IL CASO NAIVE

Trattiamo il caso di matrici quadrate con taglie potenze di due (possiamo farlo a meno di passare a una sottomatrice di taglia pari). In questo caso possiamo partizionare le matrici in delle sottomatrici a blocchi 2×2 ¹:

$$\begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix}.$$

L'algoritmo naive procede combinando un insieme di otto moltiplicazioni matriciali con quattro addizioni:

$$(3.16) \quad \begin{aligned} m_1 &= a_{11} \cdot b_{11} = s_1 t_1 & m_2 &= a_{12} \cdot b_{21} = s_2 t_2 & m_3 &= a_{11} \cdot b_{12} = s_3 t_3 \\ m_4 &= a_{12} \cdot b_{22} = s_4 t_4 & m_5 &= a_{21} \cdot b_{11} = s_5 t_5 & m_6 &= a_{22} \cdot b_{21} = s_6 t_6 \\ m_7 &= a_{21} \cdot b_{12} = s_7 t_7 & m_8 &= a_{22} \cdot b_{22} = s_8 t_8 \end{aligned}$$

$$\begin{aligned} c_{11} &= m_1 + m_2 = a_{11}b_{11} + a_{12}b_{21}, & c_{12} &= m_3 + m_4 = a_{11}b_{12} + a_{12}b_{22}, \\ c_{21} &= m_5 + m_6 = a_{21}b_{11} + a_{22}b_{21}, & c_{22} &= m_7 + m_8 = a_{21}b_{12} + a_{22}b_{22}. \end{aligned}$$

Proviamo a scriverlo in forma tensoriale. La sua bilinear computation è

$$C = \sum_{i=1}^8 m_i w_i,$$

a noi resta solo da assegnare i termini w_i , che in questo caso saranno matrici. Fissiamo la base standard $\{E_{11}, E_{12}, E_{21}, E_{22}\}$ dello spazio delle matrici 2×2 . Scriviamo

¹possiamo pensare alle entrate sia come scalari, che come matrici.

Dire se la derivazione del tensore è chiara, ho provato a giustificarla meglio che potessi

$$\begin{array}{c} A \end{array} \begin{bmatrix} \boxed{a_{11}} & \boxed{a_{12}} \\ \boxed{a_{21}} & \boxed{a_{22}} \end{bmatrix} \times \begin{array}{c} B \end{array} \begin{bmatrix} \boxed{b_{11}} & \boxed{b_{12}} \\ \boxed{b_{21}} & \boxed{b_{22}} \end{bmatrix} = \begin{array}{c} C \end{array} \begin{bmatrix} \boxed{c_{11}} & \boxed{c_{12}} \\ \boxed{c_{21}} & \boxed{c_{22}} \end{bmatrix}$$

$$c_{ij} = \sum_{k=1}^2 a_{ik}b_{kj} = a_{i1}b_{1j} + a_{i2}b_{2j}$$

Figura 3.4: Rappresentazione della moltiplicazione di due matrici 2×2 .

$$\begin{aligned} C &= c_{11}E_{11} + c_{12}E_{12} + c_{21}E_{21} + c_{22}E_{22} \\ &= (m_1 + m_2)E_{11} + (m_3 + m_4)E_{12} + (m_5 + m_6)E_{21} + (m_7 + m_8)E_{22} \\ &= \sum_{i=1}^8 m_i w_i, \end{aligned}$$

dove i termini w_i sono determinati dalla scrittura sopra.

Tramite l'isomorfismo della Proposizione 3.2.3, possiamo mappare ogni termine $s_r t_r w_r$ dell'equazione sopra in $s_r \otimes t_r \otimes w_r$ e scrivere il tensore strutturale di $\langle 2, 2, 2 \rangle$ in formato CP (si veda anche la Figura 3.5). Per farlo, identifichiamo i funzionali s_r e t_r con i loro primali a_{ij} e b_{ij} e le matrici w_r con gli elementi c_{ij} .

può andare bene scritto così?

$$\begin{aligned} \langle 2, 2, 2 \rangle &= a_{11} \otimes b_{11} \otimes c_{11} + a_{12} \otimes b_{21} \otimes c_{11} \\ &\quad + a_{21} \otimes b_{11} \otimes c_{21} + a_{22} \otimes b_{21} \otimes c_{21} \\ &\quad + a_{11} \otimes b_{12} \otimes c_{12} + a_{12} \otimes b_{22} \otimes c_{12} \\ &\quad + a_{21} \otimes b_{12} \otimes c_{22} + a_{22} \otimes b_{22} \otimes c_{22}. \end{aligned} \tag{3.17}$$

non mi convince molto

mst

Osserviamo che questo caso base dà luogo a un algoritmo ricorsivo per $n > 2$. Riperkorrendo il ragionamento dell'Equazione del Teorema di Strassen, troviamo che $M(n) = O(n^{\log_2 8}) = O(n^3)$.

Nel 1969 Strassen² tentò di mostrare che non esistesse un algoritmo più veloce di quello classico. Tramite una serie di riduzioni manuali riuscì a mostrare l'ottimalità su $\mathbb{Z}/2\mathbb{Z}$, ma per $\mathbb{R}$ o $\mathbb{C}$ il suo progetto si rivelò un fallimento spettacolare.

²in una comunicazione riportata da Landsberg in [36].




Figura 3.5: Decomposizione CP del tensore di moltiplicazione di matrici $\langle 2, 2, 2 \rangle$ come somma di 8 tensori di rango uno.

L'ALGORITMO DI STRASSEN

L'algoritmo di Strassen è probabilmente l'algoritmo di moltiplicazione veloce più celebre e segue la stessa struttura a blocchi $\langle 2, 2, 2 \rangle$.

$$\begin{array}{lll}
 s_1 = a_{11} + a_{22} & s_2 = a_{21} + a_{22} & s_3 = a_{11} \\
 s_4 = a_{22} & s_5 = a_{11} + a_{12} & s_6 = a_{21} - a_{11} \\
 s_7 = a_{12} - a_{22} & & \\
 t_1 = b_{11} + b_{22} & t_2 = b_{11} & t_3 = b_{12} - b_{22} \\
 t_4 = b_{21} - b_{11} & t_5 = b_{22} & t_6 = b_{11} + b_{12} \\
 t_7 = b_{21} + b_{22} & &
 \end{array}$$

$$\begin{array}{ll}
 m_r = s_r t_r, & 1 \leq r \leq 7 \\
 (3.18) \quad c_{11} = m_1 + m_4 - m_5 + m_7 & c_{12} = m_3 + m_5 \\
 c_{21} = m_2 + m_4 & c_{22} = m_1 - m_2 + m_3 + m_6
 \end{array}$$

3 Applicazioni della CP alla complessità aritmetica

Nella base canonica, la matrice C si scrive come

$$\begin{aligned}
C &= c_{11}E_{11} + c_{12}E_{12} + c_{21}E_{21} + c_{22}E_{22} \\
&= (m_1 + m_4 - m_5 + m_7)E_{11} + (m_3 + m_5)E_{12} \\
&\quad + (m_2 + m_4)E_{21} + (m_1 - m_2 + m_3 + m_6)E_{22} \\
&= m_1(E_{11} + E_{22}) + m_2(E_{21} - E_{22}) + m_3(E_{12} + E_{22}) \\
&\quad + m_4(E_{11} + E_{21}) + m_5(-E_{11} + E_{12}) + m_6E_{22} + m_7E_{11} \\
&= \sum_{r=1}^7 m_r w_r.
\end{aligned}$$

Possiamo anche calcolare gli m_r :

$$\begin{aligned}
m_1 &= (a_{11} + a_{22})(b_{11} + b_{22}) \\
m_2 &= (a_{21} + a_{22})b_{11} \\
m_3 &= a_{11}(b_{12} - b_{22}) \\
m_4 &= a_{22}(b_{21} - b_{11}) \\
m_5 &= (a_{11} + a_{12})b_{22} \\
m_6 &= (a_{21} - a_{11})(b_{11} + b_{12}) \\
m_7 &= (a_{12} - a_{22})(b_{21} + b_{22})
\end{aligned}$$

Passando all'isomorfismo, e usando l'identificazione fatta sopra, la bilinear computation si può riscrivere in forma tensoriale come

$$\begin{aligned}
\langle 2, 2, 2 \rangle &= (a_{11} + a_{22}) \otimes (b_{11} + b_{22}) \otimes (c_{11} + c_{22}) \\
&\quad + (a_{21} + a_{22}) \otimes b_{11} \otimes (c_{21} - c_{22}) \\
&\quad + a_{11} \otimes (b_{12} - b_{22}) \otimes (c_{12} + c_{22}) \\
&\quad + a_{22} \otimes (-b_{11} + b_{21}) \otimes (c_{21} + c_{11}) \\
&\quad + (a_{11} + a_{12}) \otimes b_{22} \otimes (-c_{11} + c_{12}) \\
&\quad + (-a_{11} + a_{21}) \otimes (b_{11} + b_{12}) \otimes c_{22} \\
&\quad + (a_{12} - a_{22}) \otimes (b_{21} + b_{22}) \otimes c_{11}.
\end{aligned}$$

Espandendo i prodotto tensoriali e facendo opportune semplificazioni, possiamo ritrovare il tensore dell'algoritmo classico riportato nell'Equazione (3.17).

Osservazione 3.6.2 (Costo computazionale). Similmente a quanto svolto sopra, troviamo che $M(n) = O(n^{\log_2 7}) = O(n^{2.81})$. Inoltre, dalla Proposizione 3.5.1 troviamo

che $\omega \leq \log_2 7 < 2.81$.

Osservazione 3.6.3. L'algoritmo di Strassen non è unico: è possibile riscrivere il tensore sopra in funzione di un parametro $t \in \mathbb{R}$. Si veda [36, Pag. 37].

3.7 ALCUNE STIME SULL'ESPONENTE

Ad esempio, l'algoritmo di Strassen [48] mostra che $\mathbf{R}(\langle 2, 2, 2 \rangle) \leq 7$, e come dimostrato da Winograd [51], $\mathbf{R}(\langle 2, 2, 2 \rangle) = 7$, ovvero non è possibile moltiplicare due matrici 2×2 con meno di sette moltiplicazioni. Nei casi diversi da $\langle 2, 2, 2 \rangle$ il problema si complica, e attualmente abbiamo alcune stime più lasche: già per matrici 3×3 , sappiamo solo che $19 \leq \mathbf{R}(\langle 3, 3, 3 \rangle) \leq 23$ [16, 34]; questo caso è ritenuto molto curioso perché esiste un'espressione nota per il tensore, ma è difficile dimostrarne il rango. Mentre la migliore stima asintotica dal basso per il caso di matrici $n \times n$ è $\frac{5}{2}n^2 - 3n \leq \mathbf{R}(\langle n, n, n \rangle)$ [15]. Si veda [36, Capitolo 11] per una discussione più ampia.

3.8 ALGORITMI APA

Dopo il tentativo di Strassen di dimostrare che l'algoritmo di moltiplicazione standard fosse ottimale, Bini et. Al [13] considerano il seguente algoritmo di moltiplicazione ridotto ottenuto ponendo a zero l'entrata a_{22} di $\langle 2, 2, 2 \rangle$:

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & 0 \end{bmatrix} \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} & a_{21}b_{12} \end{bmatrix}.$$

Facendo alcuni raccoglimenti e sostituendo $a_{22} = 0$, il tensore dell'Equazione (3.17) si riscrive come

$$\begin{aligned} \langle 2, 2, 2 \rangle^{\text{red}} &:= a_{11} \otimes (b_{11} \otimes c_{11} + b_{12} \otimes c_{12}) \\ &\quad + a_{12} \otimes (b_{21} \otimes c_{11} + b_{22} \otimes c_{12}) \\ &\quad + a_{21} \otimes (b_{11} \otimes c_{21} + b_{12} \otimes c_{22}). \end{aligned}$$

Che è somma di sei tensori elementari distinti, quindi $\mathbf{R}\langle 2, 2, 2 \rangle^{\text{red}} \leq 6$. Bini et. al. provarono a cercare un'espressione di rango cinque per $\langle 2, 2, 2 \rangle^{\text{red}}$ numericamente, calcolando

$$\min_{\substack{T \in \mathbb{R}^{n \times n \times n} \\ \mathbf{R}(T)=5}} \|\langle 2, 2, 2 \rangle^{\text{red}} - T\|$$

norma di $\langle 2, 2, 2 \rangle^{\text{red}}$. Il loro computer continuava a produrre tensori T di rango cinque con la norma della differenza che diventava sempre più piccola, ma con coef-

ficienti sempre più grandi. Questo è andato avanti per un po' di tempo, fino a che realizzarono che il codice era giusto, ma quello che sembrava un problema era in realtà una manifestazione del border rank. L'espressione del tensore che stavano cercando era il seguente tensore di rango 5:

$$\langle n, n, n \rangle_t^{\text{red}} = \frac{1}{t}[(I) + (II) - (III) - (IV) + (V)],$$

qui va sistemato con la notazione a_{ij} invece che a_j^i , lo farò a breve

dove

$$\begin{aligned} (I) &= (a_2^1 + ta_1^1) \otimes (b_2^1 + tb_2^2 \otimes c_2^1) \\ &= a_2^1 \otimes b_2^1 \otimes c_2^1 + t[a_2^1 \otimes b_2^2 \otimes c_2^1 + a_1^1 \otimes b_2^1 \otimes c_2^1] + O(t^2) \\ (II) &= (a_1^2 + ta_1^1) \otimes b_1^1 \otimes (c_1^1 + tc_1^2) \\ &= a_1^2 \otimes b_1^1 \otimes c_1^1 + t[a_1^2 \otimes b_1^1 \otimes c_1^2 + a_1^1 \otimes b_1^1 \otimes c_1^1] + O(t^2) \\ (III) &= a_2^1 \otimes b_2^1 \otimes ((c_1^1 + c_2^1) + tz_2^2) \\ &= a_2^1 \otimes b_2^1 \otimes c_1^1 + a_2^1 \otimes b_2^1 \otimes c_2^1 + t[a_2^1 \otimes b_2^1 \otimes c_2^2] \\ (IV) &= a_1^2 \otimes ((b_1^1 + b_2^1) + tb_1^2) \otimes c_1^1 \\ &= a_1^2 \otimes b_1^1 \otimes c_1^1 + a_1^2 \otimes b_2^1 \otimes c_1^1 + t[a_1^2 \otimes b_1^2 \otimes c_1^1] \\ (V) &= (a_2^1 + a_1^2) \otimes (b_2^1 + tb_1^2) \otimes (c_1^1 + tc_2^2) \\ &= a_2^1 \otimes b_2^1 \otimes c_1^1 + a_1^2 \otimes b_2^1 \otimes c_1^1 \\ &\quad + t[a_2^1 \otimes (b_2^1 + c_2^2 + b_1^2 \otimes c_1^1) + a_1^2 \otimes (b_2^1 \otimes c_2^2 + b_1^2 \otimes c_1^1)] + O(t^2) \end{aligned}$$

In ogni passaggio abbiamo applicato più volte la proprietà distributiva del prodotto tensoriale. Osserviamo che i termini di grado costante in t si cancellano:

$$\begin{aligned} &a_2^1 \otimes (b_2^1 \otimes c_2^1 - b_2^1 \otimes c_1^1 - b_2^1 \otimes c_2^1 + b_2^1 \otimes c_1^1) \\ &+ a_1^2 \otimes (b_1^1 \otimes c_1^1 - b_1^1 \otimes c_1^1 + b_2^1 \otimes c_1^1 - b_2^1 \otimes c_1^1) = 0 \end{aligned}$$

Sommando e raggruppando i termini di grado uno in t troviamo

$$\begin{aligned} \langle n, n, n \rangle^{\text{red}} &= a_1^1 \otimes (b_1^1 \otimes c_1^1 + b_2^1 \otimes c_2^1) + \\ &\quad a_2^1 \otimes (b_1^2 \otimes c_1^1 + b_2^2 \otimes c_2^1) + \\ &\quad a_1^2 \otimes (b_1^1 \otimes c_1^2 + b_2^1 \otimes c_2^2), \end{aligned}$$

ovvero il tensore di partenza. Da cui,

$$\begin{aligned}\langle n, n, n \rangle_t^{\text{red}} - \langle n, n, n \rangle^{\text{red}} &= \frac{1}{t} \left(t \langle n, n, n \rangle^{\text{red}} + O(t^2) \right) - \langle n, n, n \rangle^{\text{red}} \\ &= O(t) \xrightarrow{t \rightarrow 0} 0\end{aligned}$$

Abbiamo dimostrato che i tensori approssimanti $\langle n, n, n \rangle_t^{\text{red}}$, di rango 5 convergono ad un tensore di rango 6. Nella pratica, è possibile calcolare il prodotto di due matrici usando il tensore $\langle n, n, n \rangle_t^{\text{red}}$ per una scelta di t maggiore della precisione di macchina, riducendo il numero di moltiplicazioni (in questo caso di una moltiplicazione), a costo di un errore algoritmico che accenneremo in § 3.9.

Il border rank si rivela utilissimo nello studio dell'esponente ω , cioè possiamo sostituire il rango con il border rank nel Teorema 3.5.5:

Teorema 3.8.1 (Bini [13], vedi §3.2).

$$\omega = \inf\{\tau \in \mathbb{R} \mid \underline{\mathbf{R}}(\langle n, n, n \rangle) = O(n^\tau)\}.$$

Possiamo inoltre generalizzare la Proposizione 3.5.1.

Proposizione 3.8.2. *Se $\underline{\mathbf{R}}(\langle n, n, n \rangle) \leq r$ per degli interi positivi n, r , allora $n^\omega \leq r$.*

Anche se potremmo avere $\underline{\mathbf{R}}(\langle n, n, n \rangle) < \mathbf{R}(\langle n, n, n \rangle)$, non sono abbastanza diversi da avere un impatto sull'esponente.

Riportiamo alcune stime sul border rank riportate in [35, §1]. Per $n = 2$, Winograd dimostra che $\underline{\mathbf{R}}(\langle 2, 2, 2 \rangle) = \mathbf{R}(\langle 2, 2, 2 \rangle) = 7$. Ci aspetteremmo che per $n > 2$, $\underline{\mathbf{R}}(\langle n, n, n \rangle) < \mathbf{R}(\langle n, n, n \rangle)$, ma la risposta non è così semplice. Per $n = 3$, sappiamo solo che $15 \leq \underline{\mathbf{R}}(\langle 3, 3, 3 \rangle) \leq 20$, mentre per il rango vale $19 \leq \mathbf{R}(\langle 3, 3, 3 \rangle) \leq 23$. In generale, sappiamo che $\mathbf{R}(\langle n, n, n \rangle) \geq 3n^2 - o(n)$ e $\underline{\mathbf{R}}(\langle n, n, n \rangle) \geq 2n^2 - \lceil \log_2(n) \rceil - 1$.

l'ho trovato
anche in forma
 $\underline{\mathbf{R}}\langle n, n, n \rangle \geq n^\omega$
per ogni intero
positivo n

why?

ref

3.9 ERRORE ALGORITMICO

Discutiamo brevemente l'errore algoritmico degli algoritmi di moltiplicazione veloci, rimandando a [5] per ulteriori dettagli. Gli algoritmi di moltiplicazione veloci producono errori numerici più grandi rispetto all'algoritmo classico, dove l'errore in avanti è dato componente per componente, e dipende solo dal prodotto scalare della riga e colonna corrispondente. Gli algoritmi veloci, invece, eseguono calcoli che coinvolgono altre entrate della matrice che non appaiono nel prodotto scalare (eventualmente questi contributi si cancellano), dunque gli errori dipendono da proprietà globali

delle matrici di input. In gergo, gli algoritmi veloci ³ sono detti *stabili rispetto alla norma* [14, 37], mentre quello classico gode di una proprietà più forte, ovvero è *stabile rispetto alle componenti*, caratteristica irraggiungibile per gli algoritmi veloci [37]. Definiamo la stabilità rispetto alla norma per il prodotto $C = AB$ dove $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times k}$ come

$$\|\hat{C} - C\| \leq f_{\text{alg}}(n)\|A\|\|B\| + O(\varepsilon^2),$$


dove $\|\cdot\|$ è la norma del massimo, ε è la precisione di macchina, e f_{alg} è una costante polinomiale che dipende dall'algoritmo. Ad esempio, $f_{\text{alg}}(n) = n^2$ per l'algoritmo di moltiplicazione classico, senza alcuna ipotesi sull'ordinamento dei calcoli svolti dal prodotto scalare. Osserviamo che f_{alg} è indipendente dalle matrici di input, e $\|A\|\|B\|$ è indipendente dall'algoritmo.

ANDAMENTO DELL'ERRORE


Per analizzare il comportamento dell'errore algoritmico abbiamo confrontato l'algoritmo $\langle 2, 2, 2 \rangle^{\text{red}}$ con l'algoritmo di Strassen e con la routine di moltiplicazione standard fornita da Intel MKL DGEMM (Math Kernel Library, Double-precision General Matrix Multiply). Gli esperimenti sono stati condotti per dimensioni delle matrici $N = 2^1, \dots, 2^{13} = 8192$ e livelli di ricorsione $L \in \{1, 2, 3\}$. I risultati sono riportati in Figura 3.6.

Come mostrato in Figura 3.6a l'algoritmo $\langle 2, 2, 2 \rangle^{\text{red}}$ raggiunge prestazioni elevate grazie all'impiego di sole 5 moltiplicazioni. Tuttavia, come evidenziato in Figura 3.6b, l'accumulo degli errori di arrotondamento, dovuti al parametro ε , porta ad una crescita dell'errore relativo all'aumentare della profondità di ricorsione ($L = 2, 3$).

³senza ulteriori modifiche, come manipolazione algoritmica per ridurre l'errore di arrotondamento



(a) Prestazioni computazionali (GFLOPS effettivi)



(b) Errore relativo in norma di Frobenius

Figura 3.6: Confronto delle prestazioni computazionali (in GFLOPS effettivi) e dell'errore relativo in norma di Frobenius tra gli algoritmi al variare della dimensione della matrice $N = 2, 4, 8, \dots, 8192$.

4

APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP

In questo capitolo esploreremo due applicazioni della decomposizione CP di un tensore a tre indici in due ambiti modellistici, dove avremo modo di applicare il Teorema di Kruskal 2.2.6 e l'algoritmo Alternating Least Squares. Nel primo esperimento il rango non sarà noto a priori e dovremo prima approssimarlo, per poi trovare una decomposizione. Nel secondo conosceremo il rango a priori. In entrambi gli esperimenti sarà fondamentale l'essenziale unicità data dal teorema di Kruskal 2.2.6. Inoltre, osserveremo che nella pratica la fattorizzazione CP soffre l'ambiguità del riscalamento e della permutazione dei fattori.

cambia titolo

why excitation-emission matrices have rank 1?

improve

4.1 SPETTROSCOPIA FLUORESCENTE

Nella *spettroscopia fluorescente*, un campione chimico è eccitato (e.g. tramite una luce), e la luce che viene emessa viene misurata a diverse lunghezze d'onda, risultando in una matrice di *eccitazione-emissione* (EEM) di intensità fluorescenti (si veda Figura 4.1). Quando i dati EEM vengono raccolti da diversi campioni, otteniamo un tensore a tre indici. Questi dati si possono utilizzare nella chimica analitica per stimare le concentrazioni e gli spettri dei composti chimici a partire da più miscele.

Nel dettaglio, vengono dati I campioni di soluzioni chimiche, ognuno dei quali contiene diverse sostanze diluite in diverse concentrazioni. Il primo obiettivo è determinare il numero r delle diverse sostanze presenti. Il dataset che analizziamo [1, 31] è composto da una serie di esperimenti riportati da [44], nel quale sono presenti ci sono tre sostanze chimiche disciolte nelle soluzioni:

- *Valine-Tyrosine-Valine* (Val-Tyr-Val) - peptide,
- *Tryptophan-Glycine* (Trp-Gly) - peptide,
- *Phenylalanine* (Phe) - amino acid.




Figura 4.1: Rappresentazione schematica di uno spettrofotometro per spettroscopia di fluorescenza.

Segnaliamo che i dati sono stati preprocessati dagli autori per riempire i dati mancanti e sostituire le entrate negative, come spiegato in [31].

Ogni campione, diciamo il numero i -esimo è successivamente eccitato da una luce in J diverse lunghezze d'onda. Per ogni lunghezza d'onda di eccitazione, viene misurato lo spettro emesso. Diciamo che l'intensità della luce fluorescente emessa è misurata da K diverse lunghezze d'onda. Allora per ogni i otteniamo una matrice $J \times K$ di eccitazione-emissione.

Quindi i dati possono essere rappresentati come un array $I \times J \times K$, scrivibile come

$$T = \sum_{f=1}^r a_f \otimes b_f \otimes c_f,$$

in componenti,

$$T_{ijk} = \sum_{f=1}^r a_{if} b_{jf} c_{kf},$$

dove $a_{i,f}$ è la concentrazione della f -esima sostanza nell' i -esimo campione, $c_{k,f}$ è la frazione di protoni che la f -esima sostanza emette nella lunghezza d'onda k e $b_{j,f}$ è l'intensità della luce incidente alla lunghezza d'onda j moltiplicata per l'assorbimento alla lunghezza d'onda j . Il primo obiettivo è trovare un r tale che ogni f rappresenti una sostanza.

Il dataset analizzato contiene le misurazioni di matrici di eccitazione-emissione (EEM) per 18 campioni, ognuno dei quali consiste in una miscela dei tre composti chimici sopra (Val-Tyr-Val, Trp-Gly e Phe). I dati sono organizzati in un tensore tridimensionale di dimensioni $I \times J \times K = 18 \times 251 \times 21$, corrispondenti rispetti-

vamente ai campioni, alle lunghezze d'onda di emissione (da 250 a 500 nm) e alle lunghezze d'onda di eccitazione (da 210 a 310 nm). Una rappresentazione tridimensionale del tensore è mostrata in Figura 4.2, mentre alcune sezioni di matrici di eccitazione-emissione sono visualizzate in Figura 4.3.




Figura 4.2: Rappresentazione tridimensionale del tensore EEM di dimensioni $18 \times 251 \times 21$.

Cerchiamo una fattorizzazione approssimata di $\hat{T}$ con le tecniche descritte nella § 1.9. Fissata una tolleranza ε piccola, applichiamo il procedimento dell'Algoritmo 2. La ricerca di $\hat{T}$ viene ripetuta attraverso una serie di restarts per evitare minimi locali, al termine dei quali viene restituito il tensore che minimizza l'errore relativo ε_{rel} . Nell'articolo originale [44] vengono anche esclusi i tensori che non sono ragionevoli da un punto di vista fisico per rimuovere valori di r troppo piccoli. Per i nostri scopi ci limitiamo a imporre che le quantità fisiche coinvolte (concentrazioni, intensità di emissione ed eccitazione) siano non negative, per cui si scartano le decomposizioni che presentano fattori negativi.

Algorithm 2 Algoritmo di approssimazione del tensore originale.

```

1: for  $i = 1 \dots r$  do
2:   repeat
3:      $\hat{T} \leftarrow \arg \min_{A,B,C} \|T - \llbracket A, B, C \rrbracket\|$  ▷ CP ALS con restarts.
4:   until  $\|T - \hat{T}\| < \varepsilon$ 
5: end for
```

Assumiamo ora che il rango ottimale r sia stato determinato attraverso l'euristica discussa in § 1.6. Siccome i valori di r sono relativamente piccoli, a meno di piccole perturbazioni, l'espressione di $\hat{T}$ come somma di elementi di rango uno sarà unica grazie al Teorema di Kruskal 2.2.6. Quindi, decomponendo $\hat{T}$, possiamo recuperare la concentrazione di ognuna delle r sostanze in ogni soluzione, determinando i vettori a_f così come lo spettro delle eccitazioni ed emissioni determinando i vettori b_f . La Figura 4.5 mostra i fattori calcolati e il confronto con le concentrazioni reali delle tre sostanze, arrestando CP ALS quando la differenza dell'errore relativo tra due iterazioni susseguenti è minore di 10^{-4} . Nel grafico sono tracciati i fattori a_f, b_f, c_f




Figura 4.3: Profili d'intensità di emissione-eccitazione del tensore EEM. I profili corrispondono alle fette orizzontali del tensore, ordinate dall'alto ($T_{1,:,:}$) al basso ($T_{18,:,:}$). Visualizzazione di alcune matrici di eccitazione-emissione (EEM) per diversi campioni. Ogni profilo è etichettato a destra con le concentrazioni dei tre composti chimici (Val-Tyr-Val/Trp-Gly/Phe). Ogni profilo copre 21 lunghezze d'onda d'eccitazione (210, 215, ..., 310 nm) da 251 lunghezze d'onda di emissione (250, 251, ..., 500nm).




Figura 4.4: Errore relativo al variare del rango della decomposizione approssimante. Il rango ottimale selezionato è $r = 3$, corrispondente al superamento della tolleranza target $\varepsilon = 0.05$. Osserviamo che la precisione non varia di molto all'aumentare di r .

della decomposizione CP, dove ogni riga $f = 1, 2, 3$ rappresenta una sostanza diversa (scritta in sottoimpresione). Ad esempio, la componente a_1 sono le barre blu nella prima sottofigura in alto a sinistra, dove notiamo che i primi due fattori di a_1 sono nulli, che significa che la componente non è presente nei primi due campioni. Nella colonna centrale in alto denotiamo le componenti individuali di b_1 , che sono 256, con dei punti. Il terzo fattore c_1 è rappresentato nella figura in alto a destra.




Figura 4.5: Fattori della decomposizione CP non negativa a rango $r = 3$ del tensore EEM. I diagrammi a barre a sinistra confrontano i profili di concentrazione calcolati con le concentrazioni effettive delle tre sostanze (Val-Tyr-Val, Trp-Gly, Phe).

4.2 BLIND DECONVOLUTION DI SEGNALI

Nel *problema del cocktail party* un insieme di persone si trova in una stanza a parlare. Ci sono diversi ricevitori impostati che registrano le conversazioni: non singolarmente ma tutte insieme, sovrapposte. L'obiettivo è recuperare cosa ogni persona sta dicendo. Questo “unmixing” si può ottenere usando la decomposizione CP. Questo problema è noto nell'analisi di segnali come *blind deconvolution*, utilizzata nel campo delle telecomunicazioni nel modello wireless *direct-sequence code-division multiple access* (DS-CDMA) [23, 36, 42] che riadattiamo in questa sezione.

Per semplicità supponiamo che R utenti mandino dei messaggi a I antenne. I messaggi arrivano mischiati, e l'obiettivo è recuperare i segnali individuali e le posizioni di utenti e antenne.




Figura 4.6: $R = 3$ sorgenti inviano segnali a $I = 2$ antenne.

L'utente r -esimo trasmette il messaggio in un vettore di $s_r = [s_{1r}, \dots, s_{Kr}]^T \in \mathbb{R}^K$, dove le entrate sono numeri reali random. Ci sono I antenne che ricevono i segnali. Quando i segnali arrivano all' i -esima antenna, il segnale è stato soggetto a distorsione nell'intensità e fase (anche detta *fading/gain*), quindi ciò che viene ricevuto dall'antenna i -esima sono le IK quantità $a_{ir}s_{kr}$, dove a_{ir} è il fading/gain tra l'utente r e l'antenna i .

In questo scenario si riceve un tensore (matrice) $T \in \mathbb{C}^{I \times K}$ di rango R di entrate

$$T_{ik} = \sum_{r=1}^R a_{ir}s_{kr}.$$

L'obiettivo sarebbe recuperare i segnali s_r , per $1 \leq r \leq R$ da questa matrice decomponendola come somma di matrici di rango uno. Sfortunatamente, questa decomposizione non è mai unica quando $R > 1$. Per aggirare il problema, vengono introdotti

dei “codici” per “diffondere” il segnale che ogni utente invia per ottenere un tensore a tre indici che avrà generalmente una decomposizione unica.¹

Facciamo le seguenti ipotesi sulla trasmissione dei segnali: la trasmissione avviene in linea d’aria, seguendo la strada più breve (secondo la distanza euclidea) senza incontrare ostacoli; i simboli inviati arrivano in maniera ordinata senza sovrapposizione (esempio $s_{k,r}$ allo stesso tempo di $s_{k+1,r}$). Questi comportamenti sono noti in letteratura come ICI (*interchip interference*) e ISI (*intersignal interference*). Inoltre i segnali non subiscono rumore e non vengono memorizzati.

Per recuperare s_r e a_{ir} , l’ r -esimo utente introduce una ridondanza in termini di codice chiamata *spreading sequence* che è fissata per ogni utente, diciamo $c_r = [c_{1r}, \dots, c_{Jr}]^\top$. Il simbolo s_{kr} è trasmesso su molteplici frequenze; come risultato, vengono trasmesse simultaneamente J quantità $[s_{kr}c_{1r}, \dots, s_{kr}c_{Jr}]$, chiamate *chips* al tempo k . La trasmissione totale sopra JK unità di tempo dell’utente r -esimo sono le JK chips $c_{jr}s_{kr}$, $1 \leq j \leq J$, $1 \leq k \leq K$ (qui J è anche detto *spreading gain*). L’antenna i -esima riceve le JK quantità $\sum_r a_{ir}c_{jr}s_{kr}$, per $1 \leq j \leq J$, $1 \leq k \leq K$, dove, come sopra, a_{ir} sono i fading/gain tra l’utente r e l’antenna i . In totale, viene ricevuto un tensore $T \in \mathbb{C}^{I \times J \times K}$ di rango R scrivibile in componenti come

$$(4.1) \quad T_{ijk} = \sum_{r=1}^R a_{ir}c_{jr}s_{kr},$$

o in generale,

$$T = \sum_{r=1}^R a_r \otimes c_r \otimes s_r.$$

In altre parole, $T = \llbracket S, C, A \rrbracket$. L’obiettivo è recuperare i segnali s_r , per $1 \leq r \leq R$ da questo tensore, cioè la matrice S . Per farlo abbiamo bisogno che la scrittura sia essenzialmente unica. Per il Teorema di Kruskal 2.2.6 questa decomposizione è unica se

$$\mathbf{k}_A + \mathbf{k}_B + \mathbf{k}_C \geq 2(R + 1).$$

Per costruzione [23] le matrici A e C sono di k -rango pieno con probabilità 1, mentre se i simboli trasmessi s_{Kr} appartengono ad un alfabeto finito, c’è possibilità che S non sia di k -rango pieno—c’è una possibilità che le sequenze di utenti diversi possano essere uguali, ma questo è poco probabile per dataset più grandi. Quindi nella pratica assumiamo che S sia di k -rango pieno. Questo significa che il numero

¹Tale spreading è comune nelle telecomunicazioni, e.g. della ridondanza è introdotta per compensare gli errori causati dalla corruzione dei segnali durante la trasmissione.

di utenti che possono essere processati simultaneamente si può considerare limitato come

$$(4.2) \quad \min\{I, R\} + \min\{J, R\} + \min\{K, R\} \geq 2(R + 1).$$

Il recupero di T avviene con l'algoritmo ALS

ref

Osservazione 4.2.1. Una limitazione di questo modello è che in ambito industriale spesso ci sono poche antenne e meno utenti, quindi si perde l'unicità.

ESPERIMENTO NUMERICO

Consideriamo lo scenario dove $R = 4$ utenti vogliono inviare messaggi di $K = 100$ simboli a $I = 5$ antenne, con un fattore di spreading $J = 16$. Generiamo dei tensori

$$T_\sigma = T_{\text{clean}} + W_\sigma \in \mathbb{R}^{I \times J \times K}$$

dove W_σ è un tensore di rumore gaussiano con entrate in $\mathcal{N}(0, \sigma)$ e T_{clean} è un tensore generato in formato denso a partire dalla decomposizione $T_{\text{clean}} = \llbracket A, C, S \rrbracket$. L'esperimento consiste in recuperare la posizione degli r utenti conoscendo la posizione delle antenne (la matrice A). Per farlo dobbiamo calcolare le matrici S e C , sfruttando la decomposizione CP al variare del rumore σ nella Tabella 4.1.

Tabella 4.1: Livelli di rumore gaussiano applicati al tensore $T_\sigma = T_{\text{clean}} + W_\sigma$, con relativo rapporto segnale-rumore (SNR) e corrispondente scenario fisico di trasmissione.

Rumore	σ	SNR _{dB}	Scenario fisico
σ_0	0,0000	∞ dB	Assenza di rumore
σ_1	0,0173	16,5 dB	Segnale ottimo
σ_2	0,0403	9,1 dB	Segnale buono
σ_3	0,0691	4,4 dB	Segnale debole
σ_4	0,1037	0,9 dB	Segnale quasi assente
σ_5	0,1382	-1,6 dB	Fortissime interferenze

- Matrice delle antenne $A \in \mathbb{R}^{I \times R}$: generiamo le posizioni delle antenne p_i e degli utenti u_r nel quadrato $[0, L]^2$, dove L è un generico intero positivo, per $i = 1, \dots, I$ e $r = 1, \dots, R$. Le entrate di A sono $a_{ir} := \frac{1}{\|p_i - u_r\|_2}$, dove assumiamo che $\|p_i - u_r\|_2 > 0$ (gli utenti non si trovano sulle antenne).
- Matrice dei simboli $S \in \mathbb{R}^{K \times R}$ con entrate s_{kr} secondo la distribuzione gaussiana standard $\mathcal{N}(0, 1)$.

- Matrice delle sequenze di spreading $C \in \{-1, 1\}^{J \times R}$: contiene i codici casuali assegnati a ciascuna delle R sorgenti, dove $c_{jr} = -1$ o $c_{jr} = 1$ con uguale probabilità.

ref

L'algoritmo ALS produce un tensore approssimante $\hat{T} = \llbracket \hat{A}, \hat{C}, \hat{S} \rrbracket$ unico a meno di permutazione e riscalamento dei fattori: per costruzione, l'Equazione 4.2 è verificata in senso stretto. In questa applicazione è importante recuperare l'ordine dei fattori—altrimenti un utente finirebbe per trovarsi sulla posizione di un altro utente. Descriviamo brevemente il procedimento. Indichiamo con (a_r, c_r, s_r) i fattori di T e con $(\hat{a}_r, \hat{c}_r, \hat{s}_r)$ i fattori di $\hat{T}$.

1. Calcoliamo correlazione tra ogni colonna $\hat{a}_k$ e a_r tramite $\rho_{kr} := \frac{\hat{a}_k^\top a_r}{\|\hat{a}_k\|_2 \|a_r\|_2}$.
2. Costruiamo la matrice dei costi $M \in \mathbb{R}^{R \times R}$ di entrate $M_{kr} = 1 - |\rho_{kr}|$.
3. Troviamo una permutazione ottima $\pi^* \in \mathfrak{S}_R$ che realizza

$$\min_{\pi \in \mathfrak{S}_R} \sum_{r=1}^R M_{\pi(r), r}.$$

4. Calcoliamo il cambio di segno tramite $\xi_r := \text{sign}(\hat{a}_{\pi^*(r)}^\top a_r) \in \{-1, 1\}$.
5. Permutiamo e riscaliamo $\hat{A}$ e $\hat{S}$ applicando $\xi_r \hat{A}_{:, \pi^*(r)}$ e $\xi_r \hat{S}_{:, \pi^*(r)}$, rispettivamente.

RISULTATI

Nel contesto definito sopra, denotiamo gli utenti reali $r \in \{1, \dots, R\}$ con dei quadrati e gli utenti recuperati con degli omini dello stesso colore. Inizialmente verifichiamo che in assenza di rumore l'utente recuperato combaci con l'utente reale, come illustrato in Figura 4.7. Inoltre verifichiamo che ciò funzioni per diverse disposizioni degli utenti e delle antenne in Figura 4.8. Di seguito, generiamo più tensori T_σ al variare di σ nella Tabella 4.1 e osserviamo quanto gli utenti recuperati si discostano dall'utente originale. In Figura 4.9 osserviamo i comportamenti tipici di deriva al crescere del rumore. Infine, la Figura 4.10 mostra ulteriori esecuzioni dell'algoritmo su sei configurazioni spaziali differenti.

Cosa ne pensa di queste figure?




Figura 4.7: Stima della posizione degli utenti e delle antenne in assenza di rumore. I quadrati trasparenti indicano le posizioni reali degli utenti U_r , gli omini indicano le posizioni stimate $\hat{U}_r$, i triangoli scuri indicano le antenne a_i , e le circonferenze tratteggiate indicano le distanze stimate dalle antenne.




Figura 4.8: Stima della posizione degli utenti e delle antenne in sei esperimenti indipendenti con diverse disposizioni spaziali di antenne e sorgenti in assenza di rumore.


Deriva della Localizzazione degli Utenti sotto Rumore Gaussiano ($R=4$, $I=5$)

Figura 4.9: Deriva della localizzazione degli utenti sotto sei livelli crescenti di rumore gaussiano $(\sigma_0, \dots, \sigma_5)$ per un singolo esperimento. Gli omini numerati da 1 a 5 indicano le posizioni stimate al crescere del livello di rumore.



Figura 4.10: Deriva della localizzazione degli utenti sotto rumore gaussiano per sei esperimenti indipendenti (disposizioni spaziali differenti), mostrando i comportamenti tipici di deriva al crescere del livello di rumore σ_l .

ACRONIMI

ALS	Alternating Least Squares
APA	Arbitrary Precision Approximating
CP	Canonical Polyadic Decomposition
SVD	Singular Value Decomposition

GLOSSARIO

$\text{\LaTeX}$	A document preparation system
$\mathbb{R}$	The set of real numbers

BIBLIOGRAFIA

1. E. Acar, E. E. Papalexakis, G. Gürdeniz, M. A. Rasmussen, A. J. Lawaetz, M. Nilsson, e R. Bro. «Structure-Revealing Data Fusion». *BMC Bioinformatics* 15:1, 2014, p. 239. DOI: [10.1186/1471-2105-15-239](https://doi.org/10.1186/1471-2105-15-239).
2. J. Alman, R. Duan, V. V. Williams, Y. Xu, Z. Xu, e R. Zhou. «More asymmetry yields faster matrix multiplication». *Computing Research Repository (arXiv)*, 2024. arXiv:2404.16349.
3. J. Alman, V. Vassilevska Williams et al. «Improving the matrix multiplication exponent with modern optimization and AlphaEvolve». *arXiv preprint*, 2026.
4. M. Atkinson e N. Stephens. «On the maximal multiplicative complexity of a family of bilinear forms». *Linear Algebra and its applications* 27, 1979, pp. 1–8.
5. G. Ballard, A. R. Benson, A. Druinsky, B. Lipshitz, e O. Schwartz. «Improving the numerical stability of fast matrix multiplication». *SIAM Journal on Matrix Analysis and Applications* 37:4, 2016, pp. 1382–1418.
6. G. Ballard e T. G. Kolda. *Tensor Decompositions for Data Science*. Cambridge University Press, 2025. URL: <https://tensortextbook.com>.
7. A. R. Benson e G. Ballard. «A Framework for Practical Parallel Fast Matrix Multiplication». *CoRR* abs/1409.2908, 2014. arXiv: [1409.2908](https://arxiv.org/abs/1409.2908). URL: <http://arxiv.org/abs/1409.2908>.
8. J. M. F. ten Berge. «Simplicity and typical rank results for three-way arrays». *Psychometrika* 76:1, 2011, pp. 3–12. DOI: [10.1007/s11336-010-9193-1](https://doi.org/10.1007/s11336-010-9193-1).
9. J. M. F. ten Berge. «The typical rank of tall three-way arrays». *Psychometrika* 65:4, 2000, pp. 525–532. DOI: [10.1007/BF02296342](https://doi.org/10.1007/BF02296342).
10. J. M. F. ten Berge e H. A. L. Kiers. «Simplicity of core arrays in three-way principal component analysis and the typical rank of $p \times q \times 2$ arrays». *Linear Algebra and its Applications* 294:1–3, 1999, pp. 169–179. DOI: [10.1016/S0024-3795\(99\)00057-9](https://doi.org/10.1016/S0024-3795(99)00057-9).

11. J. M. F. ten Berge, N. D. Sidiropoulos, e R. Rocci. «Typical rank and INDSCAL dimensionality for symmetric three-way arrays of order $I \times 2 \times 2$ or $I \times 3 \times 3$ ». *Linear Algebra and its Applications* 388, 2004, pp. 363–377. DOI: [10.1016/j.laa.2004.03.009](https://doi.org/10.1016/j.laa.2004.03.009).
12. J. M. F. ten Berge e A. Stegeman. «Symmetry transformations for square sliced three-way arrays, with applications to their typical rank». *Linear Algebra and its Applications* 418:1, 2006, pp. 215–224. DOI: [10.1016/j.laa.2006.02.002](https://doi.org/10.1016/j.laa.2006.02.002).
13. D. Bini. «Relations between exact and approximate bilinear algorithms. Applications». *Calcolo* 17:1, 1980, pp. 87–97. DOI: [10.1007/bf02575865](https://doi.org/10.1007/bf02575865). URL: <https://doi.org/10.1007/bf02575865>.
14. D. Bini e G. Lotti. «Stability of fast algorithms for matrix multiplication». *Numerische Mathematik* 36:1, 1980, pp. 63–72.
15. M. Bläser. «A $(5/2)n^2$ -Lower Bound for the Multiplicative Complexity of $n \times n$ -Matrix Multiplication». In: *Proceedings of the 18th Annual Symposium on Theoretical Aspects of Computer Science*. STACS '01. Springer-Verlag, Berlin, Heidelberg, 2001, pp. 99–109. ISBN: 3540416951.
16. M. Bläser. «On the complexity of the multiplication of matrices of small formats». *Journal of Complexity* 19:1, 2003, pp. 43–60. ISSN: 0885-064X. DOI: [https://doi.org/10.1016/S0885-064X\(02\)00007-9](https://doi.org/10.1016/S0885-064X(02)00007-9). URL: <https://www.sciencedirect.com/science/article/pii/S0885064X02000079>.
17. P. Bürgisser, M. Clausen, e M. A. Shokrollahi. *Algebraic complexity theory*. Vol. 315. Springer Science & Business Media, 2013.
18. V. Choulakian. «Some properties of the PARAFAC model». *Journal of Chemometrics* 24:7–8, 2010, pp. 483–490. DOI: [10.1002/cem.1310](https://doi.org/10.1002/cem.1310).
19. D. Coppersmith e S. Winograd. «Matrix multiplication via arithmetic progressions». *Journal of Symbolic Computation* 9:3, 1990. Computational algebraic complexity editorial, pp. 251–280. ISSN: 0747-7171. DOI: [https://doi.org/10.1016/S0747-7171\(08\)80013-2](https://doi.org/10.1016/S0747-7171(08)80013-2). URL: <https://www.sciencedirect.com/science/article/pii/S0747717108800132>.
20. T. H. Cormen, C. E. Leiserson, R. L. Rivest, e C. Stein. *Introduction to algorithms*. MIT press, 2022.

21. P. D’Alberto. *Strassen’s Matrix Multiplication Algorithm Is Still Faster*. 2023. arXiv: [2312.12732](https://arxiv.org/abs/2312.12732) [cs.MS]. URL: <https://arxiv.org/abs/2312.12732>.
22. L. DeLathauwer. «A Link between the Canonical Decomposition in Multilinear Algebra and Simultaneous Matrix Diagonalization». *SIAM Journal on Matrix Analysis and Applications* 28:3, 2006, pp. 642–666. DOI: [10.1137/040608830](https://doi.org/10.1137/040608830). eprint: <https://doi.org/10.1137/040608830>. URL: <https://doi.org/10.1137/040608830>.
23. L. DeLathauwer e A. de Baynast. «Blind deconvolution of DS-CDMA signals by means of decomposition in rank-(1, L, L) terms». *IEEE Transactions on Signal Processing* 56:4, 2008, pp. 1562–1571.
24. C. Eckart e G. Young. «The approximation of one matrix by another of lower rank». *Psychometrika* 1:3, 1936, pp. 211–218.
25. A. Fawzi, M. Balog, A. Huang, T. Hubert, B. Romera-Paredes, M. Barekatain, A. Novikov, F.J. R. Ruiz, J. Schrittwieser, G. Swirszcz et al. «Discovering faster matrix multiplication algorithms with reinforcement learning». *Nature* 610:7930, 2022, pp. 47–53.
26. S. Friedland. «On the generic rank of 3-tensors». *Linear Algebra and its Applications* 436:3, 2012, pp. 478–497. DOI: [10.1016/j.laa.2011.08.031](https://doi.org/10.1016/j.laa.2011.08.031).
27. F.L. Gall. «Powers of Tensors and Fast Matrix Multiplication». *CoRR* abs/1401.7714, 2014. arXiv: [1401.7714](https://arxiv.org/abs/1401.7714). URL: <http://arxiv.org/abs/1401.7714>.
28. J. Håstad. «Tensor rank is NP-complete». In: *International colloquium on automata, languages, and programming*. Springer. 1989, pp. 451–460.
29. R. A. Horn e C. R. Johnson. *Matrix analysis*. Cambridge university press, 2012.
30. J. JáJá. «Optimal evaluation of pairs of bilinear forms». *SIAM Journal on Computing* 8:3, 1979, pp. 443–462. DOI: [10.1137/0208037](https://doi.org/10.1137/0208037).
31. T.G. Kolda. *EEM Tensor Dataset*. https://gitlab.com/tensors/tensor_data_eem. Accesso: 25 agosto 2026. 2021.
32. J.B. Kruskal. «Rank, decomposition, and uniqueness for 3-way and N -way arrays». In: *Multiway and Random Data Analysis*. A cura di R. Coppi e S. Bolasco. North-Holland, 1989, pp. 7–18.

33. J. B. Kruskal. «Three-way arrays: rank and uniqueness of trilinear decompositions, with application to arithmetic complexity and statistics». *Linear Algebra and its Applications* 18:2, 1977, pp. 95–138. ISSN: 0024-3795. DOI: [https://doi.org/10.1016/0024-3795\(77\)90069-6](https://doi.org/10.1016/0024-3795(77)90069-6). URL: <https://www.sciencedirect.com/science/article/pii/0024379577900696>.
34. J. D. Laderman. «A noncommutative algorithm for multiplying 3×3 matrices using 23 multiplications». *Bulletin of the American Mathematical Society* 82:1, 1976, pp. 126–128.
35. J. M. Landsberg. «Geometry and complexity theory». *NSF Award Number 1405348. Directorate for Mathematical and Physical Sciences* 14:1405348, 2015, p. 5348.
36. J. M. Landsberg. *Tensors: geometry and applications*. Vol. 128. American Mathematical Soc., 2011.
37. W. Miller. «Computational complexity and numerical stability». In: *Proceedings of the sixth annual ACM symposium on Theory of computing*. 1974, pp. 317–322.
38. V. Y. Pan. «Strassen’s algorithm is not optimal trilinear technique of aggregating, uniting and canceling for constructing fast algorithms for matrix operations». In: *19th Annual Symposium on Foundations of Computer Science (sfcs 1978)*. 1978, pp. 166–176. DOI: [10.1109/SFCS.1978.34](https://doi.org/10.1109/SFCS.1978.34).
39. J. A. Rhodes. *A concise proof of Kruskal’s theorem on tensor decomposition*. 2009. arXiv: [0901.1796](https://arxiv.org/abs/0901.1796) [math.RA]. URL: <https://arxiv.org/abs/0901.1796>.
40. A. Schönhage. «Partial and Total Matrix Multiplication». *SIAM Journal on Computing* 10:3, 1981, pp. 434–455. DOI: [10.1137/0210032](https://doi.org/10.1137/0210032). eprint: <https://doi.org/10.1137/0210032>. URL: <https://doi.org/10.1137/0210032>.
41. N. D. Sidiropoulos e R. Bro. «On the uniqueness of multilinear decomposition of N-way arrays». *Journal of Chemometrics: A Journal of the Chemometrics Society* 14:3, 2000, pp. 229–239.
42. N. D. Sidiropoulos, G. B. Giannakis, e R. Bro. «Blind PARAFAC receivers for DS-CDMA systems». *IEEE Transactions on Signal Processing* 48:3, 2000, pp. 810–823.

43. V. de Silva e L.-H. Lim. *Tensor rank and the ill-posedness of the best low-rank approximation problem*. 2008. arXiv: [math/0607647](https://arxiv.org/abs/math/0607647) [math.NA]. URL: <https://arxiv.org/abs/math/0607647>.
44. A.K. Smilde, R. Bro, P. Geladi et al. *Multi-way analysis with applications in the chemical sciences*. Vol. 396. Wiley Chichester, 2004.
45. A. Stegeman e N.D. Sidiropoulos. «On Kruskal's uniqueness condition for the Candecomp/Parafac decomposition». *Linear Algebra and its Applications* 420:2, 2007, pp. 540–552. ISSN: 0024-3795. DOI: <https://doi.org/10.1016/j.laa.2006.08.010>. URL: <https://www.sciencedirect.com/science/article/pii/S0024379506003855>.
46. A. Stothers. «On the complexity of matrix multiplication». Tesi di dott. Edinburgh, UK: University of Edinburgh, 2010. URL: <https://ed.ac.uk>.
47. V. STRASSEN. «Relative bilinear complexity and matrix multiplication.» *Journal für die reine und angewandte Mathematik* 1987:375-376, 1987, pp. 406–443. DOI: [doi:10.1515/crll.1987.375-376.406](https://doi.org/10.1515/crll.1987.375-376.406). URL: <https://doi.org/10.1515/crll.1987.375-376.406>.
48. V. Strassen. «Gaussian elimination is not optimal». *Numer. Math.* 13:4, 1969, pp. 354–356. ISSN: 0029-599X. DOI: [10.1007/BF02165411](https://doi.org/10.1007/BF02165411). URL: <https://doi.org/10.1007/BF02165411>.
49. T. Sumi, T. Sakata, e M. Miyazaki. «Typical ranks for $m \times n \times (m-1)n$ tensors with $m \leq n$ ». *Linear Algebra and its Applications* 438:2, 2013, pp. 953–958. DOI: [10.1016/j.laa.2011.08.009](https://doi.org/10.1016/j.laa.2011.08.009).
50. V. V. Williams. *Breaking the Coppersmith-Winograd barrier*. Manuscript available at <http://theory.stanford.edu/~virgi/matrixmult-f.pdf>. 2011.
51. S. Winograd. «On multiplication of 2×2 matrices». *Linear Algebra and its Applications* 4:4, 1971, pp. 381–388. ISSN: 0024-3795. DOI: [https://doi.org/10.1016/0024-3795\(71\)90009-7](https://doi.org/10.1016/0024-3795(71)90009-7). URL: <https://www.sciencedirect.com/science/article/pii/0024379571900097>.