



UNIVERSITÀ DI PISA

DIPARTIMENTO DI MATEMATICA

Corso di Laurea Triennale in Matematica

Tensor Canonical Polyadic Decomposition and the Complexity of Matrix Multiplication

Tesi di Laurea Triennale

Relatore:

Prof. Leonardo Robol

Candidato:

Alberto Defendi

ANNO ACCADEMICO 2025/2026

SOMMARIO

La decomposizione CP (Canonical Polyadic Decomposition) di rango r di un tensore è la sua scomposizione nella somma di r tensori di rango uno, una generalizzazione naturale della decomposizione di matrici. Oltre ad avere un'importanza teorica nel calcolo tensoriale, è uno strumento utile in molte aree scientifiche: per citarne alcune, spettroscopia, *signal processing*, neurologia e analisi dei dati. In molte di queste applicazioni l'unicità della fattorizzazione è una proprietà fondamentale per rappresentare fedelmente le componenti di sistemi complessi—si pensi al problema di modellare i neuroni di un sistema nervoso tramite un tensore per studiarne gli impulsi, noto come *blind source separation*.

Il primo obiettivo è dimostrare l'unicità della fattorizzazione CP sotto opportune ipotesi. Questo risultato, originariamente dimostrato da Kruskal nel 1977 attraverso il concetto di Kruskal rank, è stato di recente semplificato seguendo la dimostrazione originale, usando strumenti geometrici. Inoltre, osserveremo alcune peculiarità teoriche che distinguono i tensori dalle matrici, ponendo le basi per l'utilizzo del calcolo tensoriale nella teoria della complessità.

Successivamente, applicheremo questi strumenti al problema della complessità della moltiplicazione tra matrici: in quanto mappa bilineare, il prodotto matriciale può essere rappresentato tramite un tensore tre indici, e poi messo in corrispondenza con un algoritmo per valutare il prodotto in funzione delle entrate del tensore. Introduciamo la nozione di complessità aritmetica del prodotto tra matrici per definire l'esponente asintotico ω , che ne misura la complessità ottimale. Tale quantità sarà messa in corrispondenza con il rango CP di un tensore tramite il Teorema di Strassen. Come corollario, ridurre lo studio della complessità ai tensori, anziché all'analisi diretta delle equazioni algebriche, semplifica notevolmente la ricerca di algoritmi più efficienti; una sfida aperta da decenni, dall'algoritmo di Strassen (del 1970), fino alle recenti scoperte guidate dall'intelligenza artificiale.

Infine, l'analisi verrà estesa dagli algoritmi di moltiplicazione esatti agli algoritmi approssimati (APA), introdotti da Bini et al. In questo contesto emerge il fenomeno topologico del border rank, per il quale una successione di tensori di rango inferiore può convergere a un tensore di rango superiore. Dal punto di vista algoritmico, ciò si traduce nella possibilità di approssimare la moltiplicazione esatta tramite una successione di algoritmi con costo computazionale inferiore. Di conseguenza, il rango tensoriale può essere sostituito con il border rank nel calcolo di ω , permettendo di ottenere stime asintotiche più accurate, al prezzo di un errore algoritmico arbitrariamente piccolo.

INDICE

1	LA FATTORIZZAZIONE CP	5
1.1	Tensori	5
1.2	Rango tensoriale	7
1.3	Ordinamenti	8
1.4	Il prodotto di Kroneker	11
1.5	La fattorizzazione CP	12
1.6	Slices, fibers e unfoldings	14
1.7	Il problema del rango	18
1.8	Il teorema del rango	24
1.9	Ricostruzione del tensore in formato denso	27
1.10	Calcolo della fattorizzazione CP	28
2	UNICITÀ DELLA FATTORIZZAZIONE CP	31
2.1	Convenzioni	33
2.2	Il Teorema di Kruskal	33
3	APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA	49
3.1	Mappe multilineari e moltiplicazione tra matrici	49
3.2	Decomposizione low-rank di forme bilineari	51
3.3	Rappresentazione low-rank del prodotto tra matrici	53
3.4	L'esponente della moltiplicazione tra matrici	54
3.5	Il rango come misura della complessità	57
3.6	Algoritmi di moltiplicazione veloce	63
3.7	Alcune stime sull'esponente	67
3.8	Algoritmi APA	68
3.9	Errore algoritmico	70
4	APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP	73
4.1	Spettroscopia fluorescente	73
4.2	Blind source separation	79

Indice

ACRONIMI	87
GLOSSARIO	89
BIBLIOGRAFIA	91

INTRODUZIONE

In questo elaborato studiamo la decomposizione di un tensore di rango r come somma di r tensori di rango uno, dal nome Canonical Polyadic Decomposition (abbreviata, decomposizione CP), anche nota come PARAFAC (da “parallel factor analysis”) o CANDECOMP (da “canonical decomposition”). Dimostreremo l’unicità di una decomposizione sotto opportune ipotesi di indipendenza dei fattori, risultato noto come il Teorema di Kruskal. Per farlo, introdurremo il concetto di unicità di una decomposizione e di indipendenza dei fattori (detto k -rango). Questo risultato fornisce una condizione sufficiente sul rango e k -rango per garantire l’unicità; sarà molto rilevante nelle applicazioni, per identificare univocamente le componenti di un modello reale. Esploreremo due di queste applicazioni modellistiche. La prima è la spettroscopia fluorescente (dalla chemiometria) dove la decomposizione di un tensore che rappresenta una serie di misurazioni su un campione permette di recuperare la concentrazione delle sostanze chimiche. La seconda, la blind deconvolution (dall’analisi di segnali), dove la decomposizione consente di localizzare la posizione di utenti che trasmettono messaggi a delle antenne. Successivamente passeremo allo studio della complessità aritmetica della moltiplicazione tra matrici, modellando l’algoritmo di moltiplicazione tramite la decomposizione CP di rango r . Dimostriamo la corrispondenza tra il rango della decomposizione e la complessità ottima del prodotto matriciale. Per fornire stime più accurate di tale complessità, analizzeremo gli algoritmi di moltiplicazione approssimati, che richiedono un numero inferiore di moltiplicazioni al costo di un maggiore errore algoritmico.

Le decomposizioni di tensori occorrono in numerose aree scientifiche in cui è necessario modellare elementi di sistemi complessi tramite fattori semplici. In molte di queste applicazioni è cruciale garantire l’unicità. Nell’ambito medico della psicomedia, ad esempio, sono state impiegate per studiare gli impulsi cerebrali [20, 34, 63], in particolare per individuare l’area del cervello di un paziente in cui è in atto una crisi epilettica [19, 53], o la diagnosi e gestione di ictus; sempre in medicina, trovano applicazione nell’interpretare le immagini di risonanza magnetica; vedi ad esempio e relative reference. Sono inoltre utilizzate nell’elaborazione di immagini per alcu-

ne tecniche di compressione, o anche nell'analisi di dati [4, 46] e in la geologia [48]. Nell'analisi numerica, infine, sono utilizzate per approssimare funzioni di n variabili tramite una somma finita di prodotti di funzioni in una variabile [33].

Questo elaborato è strutturato come segue:

Nel Capitolo 1 introdurremo i tensori e i relativi spazi. Introdurremo il rango di un tensore, e discuteremo alcune caratteristiche dei tensori che li differenziano dalle matrici, come border rank, rango tipico e rango massimo. Definiremo la fattorizzazione CP e un metodo per calcolarla, chiamato algoritmo Alternating Least Squares (ALS). La trattazione è riadattata da Ballard e Kolda [7].

Nel Capitolo 2 definiremo l'unicità di una fattorizzazione e il Kruskal rank per dimostrare il Teorema di Kruskal, che afferma l'unicità della scrittura della fattorizzazione CP di un tensore a tre indici quando viene rispettata una relazione tra il rango e k -rango. Enunceremo il risultato per tensori n -dimensionali, e osserveremo che esso non è valido per il caso delle matrici. Presenteremo una versione modernizzata, a cura di Landsberg [45], della dimostrazione originale di Kruskal [41] in dimensione tre

Nel Capitolo 3 sposteremo il focus sulla complessità della moltiplicazione matriciale attraverso gli algoritmi di moltiplicazione veloci. Introdurremo l'esponente ottimo ω della moltiplicazione e un modello computazionale per calcolarlo. Osserveremo che la moltiplicazione tra matrici vista come mappa bilineare, può essere rappresentata come un tensore, il quale verrà poi messo in corrispondenza con un algoritmo per valutare il prodotto in funzione delle entrate del tensore stesso (detto bilinear computation). Dimosteremo la corrispondenza tra il rango di un tensore, il numero di moltiplicazioni di un algoritmo e l'esponente ottimo, fornendo alcune stime su quest'ultimo. Deriveremo un esempio di algoritmo di moltiplicazione approssimato partendo da quello classico, dove potremo osservare il fenomeno del border rank. Al termine accenneremo l'errore algoritmico degli algoritmi veloci, e confronteremo numericamente l'andamento dell'errore degli algoritmi esatti rispetto a quelli approssimati. Le fonti di questo capitolo si trovano all'intersezione dei campi dell'analisi numerica [7], teoria della complessità algebrica [18] e geometria algebrica [22, 44, 45].

Nel Capitolo 4 illustreremo alcune applicazioni modellistiche della CP attraverso due esperimenti numerici: il recupero della concentrazione di sostanze chimiche in un composto (spettroscopia fluorescente) e la ricostruzione di segnali (cocktail party problem). In entrambe le applicazioni l'unicità avrà un ruolo fondamentale.

Come evidenziato da Landsberg [45, §0.3], nell'ambito del calcolo tensoriale avvie-

ne uno “scontro di culture”, dove confluiscono risultati teorici trovati dagli studiosi delle applicazioni scientifiche (e.g., psicometria, chemiometria, neurologia), analisti numerici, informatici, teorici della complessità e geometri algebrici. Poiché le in questi settori le notazioni differiscono in modo sostanziale, abbiamo cercato di mantenere il punto di vista dell’analisi numerica, senza appesantire troppo con la notazione tipica dell’algebra multilineare.

Le sperimentazioni dei Capitoli 1 e 4 sono state sviluppate in Python con le librerie Numpy, Scipy, Tensorly, il codice sorgente si trova in [27]. L’esperimento del Capitolo 3 è stato scritto in Rust, ed è parte di un progetto svolto durante il corso di laurea per il corso “laboratorio computazionale”, il codice e il report si trovano in [28].

Molte figure sono state ispirate dal libro di Ballard e Kolda [7] e riprodotte tramite Tikz. I grafici sono stati generati con Matplotlib con la libreria Scienceplots.

1 LA FATTORIZZAZIONE CP

1.1 TENSORI

In questo elaborato lavoriamo in $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, e denotiamo gli spazi vettoriali, che assumeremo sempre finiti, con le lettere A, B, C, V, W e A_j , e le dimensioni con le lettere $\mathbf{a}, \mathbf{b}, \mathbf{c}$, etc. Dati dei vettori $v_1, \dots, v_p \in V$, l'insieme $\langle v_1, \dots, v_p \rangle \subseteq V$ denota lo span lineare di $v_1, \dots, v_p$. Indichiamo con $V^* = \{f : V \rightarrow \mathbb{K} \mid f \text{ lineare}\}$ lo *spazio duale* dello spazio V , e per ogni $\alpha \in V^*$, denotiamo con $\alpha^\perp = \{v \in V \mid \alpha(v) = 0\}$ l'*annullatore* di α . Similmente, dato un sottospazio vettoriale $U \subseteq V$, definiamo l'annullatore di U come $U^\perp = \{\alpha \in V^* \mid \alpha(u) = 0, \forall u \in U\}$. Denotiamo con $\mathfrak{S}_n$ il gruppo simmetrico su n elementi, e con $\text{GL}_n(\mathbb{K})$ il gruppo delle matrici $n \times n$ invertibili sul campo $\mathbb{K}$. Dato un intero positivo n , indichiamo l'insieme dei numeri $\{1, 2, \dots, n\}$ con $[n]$.

Definizione 1.1.1 (Mappe bilineari). Siano U, V, W spazi vettoriali di dimensione finita su un campo $\mathbb{K}$. Una *mappa bilineare* è un'applicazione $\varphi : U \times V \rightarrow W$ lineare in ogni componente, in altre parole tale che $\varphi(u, \cdot)$ e $\varphi(\cdot, v)$ sono lineari per ogni $u \in U$ e $v \in V$. Quando $W = \mathbb{K}$ la chiameremo *forma bilineare*.

In generale, dati degli spazi vettoriali $A_1, \dots, A_n$ di dimensione finita, definiamo le forme n -multilineari come applicazioni $\varphi : A_1 \times \dots \times A_n \rightarrow \mathbb{K}$ lineari in ognuna delle n componenti. Data una forma n -multilineare $\varphi : A_1 \times A_2 \times \dots \times A_n$ è possibile costruire una mappa $n - 1$ lineare $A_1 \times A_2 \times \dots \times A_{n-1} \rightarrow A_n$, e viceversa.

Definizione 1.1.2 (Tensore). Definiamo lo spazio dei *tensori* $A_1 \otimes A_2 \otimes \dots \otimes A_n$ come l'insieme delle forme n -multilineari $\varphi : A_1^* \times A_2^* \times \dots \times A_n^* \rightarrow \mathbb{K}$.

Osservazione 1.1.3 (Spazio standard). Sfruttando l'identificazione canonica $\mathbb{K}^m \otimes \mathbb{K}^n \simeq \mathbb{K}^{m \times n}$ (o più in generale $\mathbb{K}^{n_1} \otimes \mathbb{K}^{n_2} \otimes \dots \otimes \mathbb{K}^{n_d} \simeq \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$) possiamo dare una definizione di tensore operativamente utile in molti contesti del calcolo tensoriale, dove spesso è più conveniente lavorare nello spazio standard $\mathbb{K}^{n_1 \times \dots \times n_d}$.

Definizione 1.1.4 (Tensore in coordinate). Un *tensore in coordinate* T di ordine d è un array multidimensionale con entrate definite sul campo $\mathbb{K}$, che denotiamo come $T \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$. Indicizziamo gli elementi di un tensore come $T_{i_1, i_2, \dots, i_d}$.

Osservazione 1.1.5. Per la ragione sopra, spesso chiameremo tensore anche l'oggetto sopra scrivendo semplicemente $T \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$.

Osservazione 1.1.6. Dato $T \in A \otimes B \otimes C$, possiamo sempre passare da un tensore nello spazio $A \otimes B \otimes C$ a un tensore in $\mathbb{K}^{a \times b \times c}$ così: fissate delle basi $\{e_i\}, \{g_j\}, \{h_k\}$ di A, B, C rispettivamente, possiamo scrivere $T = \sum_{ijk} T_{ijk} e_i \otimes g_j \otimes h_k$. Al variare degli indici, T_{ijk} descrive un array tridimensionale ("a forma di parallelepipedo") in $\mathbb{K}^{a \times b \times c}$, che chiamiamo ancora T . Questo ragionamento si può estendere per i tensori di ordine d generico (anche per le matrici).

Osservazione 1.1.7. Siccome per ogni spazio vettoriale V , vale $V \otimes \mathbb{K} \simeq V$, un tensore $T \in \mathbb{K}^{m \times n \times 1}$ è una matrice $m \times n$, e più in generale un tensore $T \in \mathbb{K}^{n_1 \times n_{d-1} \times 1}$ è un tensore di dimensione $n_1 \times n_2 \times \dots \times n_{d-1}$.

aggiunto esempio, si può tenere? Non saprei però motivare meglio perché il tensore sia così

Esempio 1.1.8 (Tensore della matrix multiplication [44]). Nel Capitolo 3 studieremo il tensore della moltiplicazione tra due matrici di taglia $m \times n$ e $n \times p$ come mappa bilineare $\mathbb{K}^{m \times n} \times \mathbb{K}^{n \times p} \rightarrow \mathbb{K}^{m \times p}$ che può essere vista come un tensore tridimensionale nello spazio $(\mathbb{K}^{m \times n})^* \otimes (\mathbb{K}^{n \times p})^* \otimes \mathbb{K}^{m \times p}$. Indicando con E_{rc} la base canonica dello spazio delle matrici, il *tensore della matrix multiplication* ha coordinate date da

$$T_{ijk} = \begin{cases} 1 & \text{se } E_{ij} E_{jk} = E_{ik}, \\ 0 & \text{altrimenti.} \end{cases}$$

Di conseguenza, il tensore può essere scritto nella forma

$$T = \sum_{i=1}^m \sum_{j=1}^n \sum_{k=1}^p E_{ij}^* \otimes E_{jk}^* \otimes E_{ik}.$$

Esempio 1.1.9. Un esempio di tensori sono gli array di dati multidimensionali che codificano più caratteristiche. Ad esempio un video di 600 frames e risoluzione 1920×1080 pixels può essere visto come un tensore a tre indici di formato $600 \times 1920 \times 1080$ in cui ogni entrata contiene l'intensità di ogni pixel ad ogni istante di tempo. Esploreremo questo tipo di tensori nel Capitolo 4.

Riscritto

Osservazione 1.1.10. L'insieme dei tensori $\mathbb{K}^{n_1 \times \dots \times n_d}$ forma un $\mathbb{K}$ -spazio vettoriale con le operazioni di addizione e moltiplicazione per scalare

$$(T_1 + T_2)(i_1, \dots, i_d) = T_1(i_1, \dots, i_d) + T_2(i_1, \dots, i_d)$$

$$\alpha(T(i_1, \dots, i_d)) = (\alpha T)(i_1, \dots, i_d), \text{ per ogni } \alpha \in \mathbb{K}$$

Possiamo dotare questo spazio di un prodotto scalare $\langle T_1, T_2 \rangle = \text{vec}(T_1)^\top \text{vec}(T_2)$, che induce una norma $\|\text{vec}(T)\| = \sqrt{\sum_{i_1=1}^{n_1} \sum_{i_2=1}^{n_2} \dots \sum_{i_d=1}^{n_d} (T_{i_1, i_2, \dots, i_d})^2}$. Osserviamo che $\|\cdot\|$ è la norma Frobenius sullo spazio $\mathbb{K}^{n_1 \times \dots \times n_d}$, che è indotta dal prodotto scalare sopra, che a sua volta è indotto dal prodotto scalare euclideo di $\mathbb{K}^{n_1 n_2 \dots n_d}$.

1.2 RANGO TENSORIALE

Definizione 1.2.1 (Tensore di rango uno). Dati $a_1 \in A_1, a_2 \in A_2, \dots, a_d \in A_d$, definiamo un *tensore di rango uno* come un elemento $a_1 \otimes a_2 \otimes \dots \otimes a_n \in A_1 \otimes A_2 \otimes \dots \otimes A_n$ tale che $a_1 \otimes \dots \otimes a_d(\beta_1, \dots, \beta_n) = \beta_1(a_1)\beta_2(a_2) \dots \beta_d(a_d)$.

Operativamente, dati due vettori $a = [a_1, \dots, a_m]^\top \in \mathbb{K}^m$ e $b = [b_1, \dots, b_n]^\top \in \mathbb{K}^n$, possiamo calcolare il prodotto tensore come

$$a \otimes b = ab^\top = \begin{bmatrix} a_1 b_1 & a_1 b_2 & \dots & a_1 b_n \\ a_2 b_1 & a_2 b_2 & \dots & a_2 b_n \\ \vdots & \vdots & \ddots & \vdots \\ a_m b_1 & a_m b_2 & \dots & a_m b_n \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

Questo segue dalla valutazione di $T = a \otimes b \in \mathbb{K}^{m \times n}$ sulla base canonica e_i^* :

$$T_{i,j} = T(e_i^*, e_j^*) = (a \otimes b)(e_i^*, e_j^*) = e_i^*(a)e_j^*(b) = a_i b_j.$$

Analogamente, in più dimensioni, presi $a_1 \in \mathbb{K}^{n_1}, \dots, a_n \in \mathbb{K}^{n_n}$, il loro prodotto tensore è

$$(1.1) \quad T = a^{(1)} \otimes a^{(2)} \otimes \dots \otimes a^{(d)} \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$$

tale che la sua scrittura in componenti è

$$(1.2) \quad T_{i_1, i_2, \dots, i_d} = a_{i_1}^{(1)} a_{i_2}^{(2)} \dots a_{i_d}^{(d)}$$

Questo ci permette di definire la seguente quantità fondamentale:

Definizione 1.2.2 (Rango di un tensore). Il rango di un tensore $T \in A_1 \otimes A_2 \otimes \cdots \otimes A_n$ è il minimo intero positivo r tale che T si può scrivere come somma di tensori di rango uno. Lo indicheremo con $\mathbf{R}(T) = r$.

1.3 ORDINAMENTI

In molte situazioni è utile passare da una d -upla di indici a un indice lineare, e viceversa, per vettorizzare un tensore o appiattirlo su un tensore di formato più basso (come un tensore su una matrice, o un tensore di ordine 4 su uno di ordine 3).

Definizione 1.3.1 (Ordinamento naturale). *L'ordinamento naturale (o natural ordering)* sull'insieme $[n_1] \times \cdots \times [n_d]$ è la mappa biunivoca

$$\mathbb{L}: [n_1] \times \cdots \times [n_d] \rightarrow \left[\prod_{j=1}^d n_j \right]$$

$$(i_1, i_2, \dots, i_d) \mapsto 1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1) = 1 + \sum_{j=1}^d s_j(i_j - 1),$$

dove i coefficienti s_j sono chiamati *passi j -esimi* e sono definiti come $s_1 = 1$ e $s_{j+1} = n_1 \cdots n_j = \prod_{h=1}^j n_h = s_j n_j$, per ogni $j = 1, \dots, d-1$. L'inversa di $\mathbb{L}$ è data dalla mappa

$$\mathbb{L}^{-1}: \left[\prod_{j=1}^d n_j \right] \rightarrow [n_1] \times \cdots \times [n_d]$$

$$l \mapsto \left(1 + \left\lfloor \frac{(l-1) \pmod{n_1 s_1}}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \pmod{n_d s_d}}{s_d} \right\rfloor \right).$$

Le mappe $\mathbb{L}$ e $\mathbb{L}^{-1}$ sono l'una l'inversa dell'altra, e sono anche dette linearizzazione e tensorizzazione degli indici, rispettivamente, in quanto permettono di passare da un indice tensoriale a uno lineare, e viceversa.

Buona definizione. Segue direttamente dalla definizione di $\mathbb{L}$ e dalle proprietà del modulo. Infatti, detto $\alpha = \mathbb{L}(i_1, i_2, \dots, i_d)$, vale che

$$\mathbb{L}^{-1}(\alpha) = (i_1, i_2, \dots, i_d),$$

in quanto

$$\begin{aligned} (\mathbb{L}^{-1}(\alpha))_h &= 1 + \left\lfloor \frac{\sum_{i=1}^d s_j(i_j - 1) \pmod{n_h s_h}}{s_h} \right\rfloor \\ &= 1 + \left\lfloor \sum_{i=1}^d \frac{s_j}{s_1} (i_j - 1) \pmod{n_h s_h} \right\rfloor \\ &= i_h \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $s_j = n_1 n_2 \cdots n_j$ e il fatto che $\lfloor x \rfloor = 0$ per ogni $x \in [0, 1)$. Viceversa, chiamato $\beta := \mathbb{L}^{-1}(l)$, dove

$$\beta_h = 1 + \left\lfloor \frac{(l-1) \pmod{n_h s_h}}{s_h} \right\rfloor$$

dimostriamo che

$$\mathbb{L}(\beta) = l.$$

Per comodità prendiamo $k = l - 1$, dove $0 \leq k < \prod_{j=1}^d n_j$. Ricordando che $n_j s_j = s_{j+1}$, per definizione di linearizzazione si ha

$$\begin{aligned} \mathbb{L}(\beta) &= \mathbb{L}(\beta_1, \dots, \beta_d) = \\ (1.3) \quad &= 1 + \sum_{j=1}^d s_j \left(\left\lfloor \frac{k \pmod{s_{j+1}}}{s_j} \right\rfloor \right). \end{aligned}$$

Consideriamo la scrittura in base mista $k = \sum_{h=1}^d c_h s_h$, dove $0 \leq c_h < n_h$, allora vale che $k \pmod{s_{j+1}} = \sum_{h=1}^j c_h s_h$, da cui dividendo per s_j ,

$$\frac{k \pmod{s_{j+1}}}{s_j} = c_j + \sum_{h=1}^{j-1} c_h s_h = c_j + \frac{k \pmod{s_j}}{s_j}.$$

Siccome $k \pmod{s_j} < s_j$ allora $\left\lfloor c_j + \frac{k \pmod{s_j}}{s_j} \right\rfloor = c_j$, per ogni $j = 1, \dots, d$, e sostituendo questi passaggi nell'Equazione (1.3),

$$\mathbb{L}(\beta) = 1 + \sum_{h=1}^d s_h c_h = 1 + k = 1 + (l - 1) = l.$$

□

Esempio 1.3.2. È utile visualizzare il caso 3-dimensionale: fissato un tensore

1 La fattorizzazione CP

$T \in \mathbb{R}^{m \times n \times p}$ indicizzato con (i, j, k) , abbiamo che $s_1 = 1, s_2 = m$ e $s_3 = mn$, dunque

$$\begin{aligned}\mathbb{L}(i, j, k) &= 1 + (i - 1) + m(j - 1) + mn(k - 1) \\ &= i + m(j - 1) + mn(k - 1),\end{aligned}$$

mentre l'inversa è

$$\begin{aligned}\mathbb{L}^{-1}(i, j, k) \\ = \left(\lfloor (l - 1) \pmod{m} \rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mn}}{m} \right\rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mnp}}{mn} \right\rfloor \right).\end{aligned}$$

Definizione 1.3.3 (Reverse ordering). *L'ordinamento inverso* sull'insieme $[n_1] \times \cdots \times [n_d]$ è la mappa biunivoca

$$\begin{aligned}\mathbb{L}^*: [n_1] \times \cdots \times [n_d] &\rightarrow \left[\prod_{j=1}^d n_j \right] \\ (i_1, i_2, \dots, i_d) &\mapsto 1 + \sum_{j=1}^d s_j^*(i_j - 1),\end{aligned}$$

dove $s_d^* = 1$ e $s_{j-1}^* = \prod_{h=j}^d n_h = s_j^* n_j$, per $j = d, \dots, 2$. La sua inversa è la mappa

$$\begin{aligned}(\mathbb{L}^*)^{-1}: \left[\prod_{j=1}^d n_j \right] &\rightarrow [n_1] \times \cdots \times [n_d] \\ l &\mapsto \left(1 + \left\lfloor \frac{(l - 1) \pmod{n_1 s_1^*}}{s_1^*} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l - 1) \pmod{n_d s_d^*}}{s_d^*} \right\rfloor \right).\end{aligned}$$

.

Esempio 1.3.4. Nel caso di un tensore $T \in \mathbb{R}^{m \times n \times p}$, i passi sono $s_3^* = 1, s_2^* = p$ e $s_1^* = np$.


Osservazione 1.3.5. I passi determinano l'ordine di percorrenza del tensore nelle definizioni di $\mathbb{L}$ e $\mathbb{L}^*$.

Analogamente alle matrici, i tensori vengono salvati in memoria come vettori, risulta quindi naturale definire la seguente operazione

Definizione 1.3.6. Dato un tensore T , possiamo definire l'operazione che trasforma un tensore in vettore, tramite la mappa di vettorizzazione

$$\text{vec}: \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d} \rightarrow \mathbb{K}^{\prod_{j=1}^d n_j}$$

$$T \mapsto x$$



dove $x_l = T(\mathbb{L}^{-1}(l; n_1, n_2, \dots, n_d))$.

Osservazione 1.3.7. L'operatore di trasposizione per matrici induce l'ordinamento inverso sulla vettorizzazione. Consideriamo ad esempio il caso 2×2 :

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad A^\top = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix} \implies \text{vec}(A) = \begin{bmatrix} a_{11} \\ a_{21} \\ a_{12} \\ a_{22} \end{bmatrix}, \quad \text{vec}(A^\top) = \begin{bmatrix} a_{11} \\ a_{12} \\ a_{21} \\ a_{22} \end{bmatrix}.$$

Nel caso matriciale si usa riferirsi all'ordine naturale come *column-major* e a quello inverso come *row-major*, specialmente nel contesto dei linguaggi di programmazione.

1.4 IL PRODOTTO DI KRONEKER

Definizione 1.4.1 (Prodotto di Kroneker). Date due matrici $A \in \mathbb{K}^{m \times n}$ e $B \in \mathbb{K}^{p \times q}$, il loro prodotto di Kroneker è la matrice

$$C = A \boxtimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{K}^{mp \times nq}, \text{ dove } c_{\alpha\beta} = a_{ij}b_{kl},$$

dove $\alpha = \mathbb{L}^*(i, k) = \mathbb{L}(k, i)$ e $\beta = \mathbb{L}^*(j, l) = \mathbb{L}(l, j)$.

Osservazione 1.4.2. Dalla definizione di prodotto di Kroneker, segue che

$$\text{rank}(A \boxtimes B) = \text{rank}(A) \text{rank}(B).$$

1 La fattorizzazione CP

Un modo per dimostrarlo è considerare le decomposizioni ai valori singolari (SVD) di $A = U\Sigma V^*$ e $B = U'\Sigma'V'^*$, e calcolare

$$\begin{aligned} A \boxtimes B &= (U\Sigma V^*) \boxtimes (U'\Sigma'V'^*) \\ &= (U \boxtimes U')(\Sigma \boxtimes \Sigma')(V^* \boxtimes V'^*), \end{aligned}$$

dove la seconda uguaglianza segue dalla proprietà $(AC \boxtimes BD) = (A \boxtimes B)(C \boxtimes D)$ del prodotto di Kroneker. Siccome le matrici U, U' e V, V' sono ortogonali (e quindi invertibili), anche $U \boxtimes U'$ e $V^* \boxtimes V'^*$ sono ortogonali. Quindi

$$\text{rank}(A \boxtimes B) = \text{rank}(\Sigma \boxtimes \Sigma') = \text{rank}(\Sigma) \text{rank}(\Sigma') = \text{rank}(A) \text{rank}(B).$$

Osservazione 1.4.3 (Prodotto di Kroneker come vettorizzazione del prodotto tensore). Dati due vettori $u \in \mathbb{K}^m$ e $v \in \mathbb{K}^n$, il loro prodotto di Kroneker si può vedere come vettorizzazione del prodotto vettore, ossia

$$(1.4) \quad \text{vec}(v \otimes u) = \text{vec} \left(\begin{bmatrix} v_1 u_1 & v_1 u_2 & \dots & v_1 u_m \\ v_2 u_1 & v_2 u_2 & \dots & v_2 u_m \\ \vdots & \vdots & \ddots & \vdots \\ v_n u_1 & v_n u_2 & \dots & v_n u_m \end{bmatrix} \right) = [u_1 v \mid u_2 v \mid \dots \mid u_m v] = u \boxtimes v$$

Notiamo che tale operazione scambia l'ordine tra i vettori.

1.5 LA FATTORIZZAZIONE CP

Introduciamo una scrittura di un tensore in tensori elementari, utile a risolvere alcuni problemi che affronteremo nei prossimi capitoli.

Il problema inverso del rango: Dato un intero positivo r , nel caso matriciale è semplice costruire una matrice di rango r ; mentre dal punto di vista computazionale, esistono algoritmi polinomiali per approssimare il rango. Nel caso dei tensori, il problema è difficile su entrambi i fronti. Nella teoria, trovare un tensore di un certo rango è come trovare un ago in un pagliaio; nella pratica, approssimare il tensore, o il rango, è numericamente difficile. Questo complica la risoluzione di molti problemi che possono essere modellati tramite tensori, come vedremo ad esempio nel Capitolo 3.

Risparmio computazionale: Cerchiamo una decomposizione di rango basso di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ per ridurre il costo di rappresentazione in memoria e delle

operazioni algebriche che lo convolgono. Nel caso matriciale, data una matrice $X \in \mathbb{R}^{n_1 \times n_2}$ di rango r , possiamo scrivere

$$X = UV^\top = [u_1 | \dots | u_r] [v_1 | \dots | v_r]^\top = u_1 v_1^\top + \dots + u_r v_r^\top = u_1 \otimes v_1 + \dots + u_r \otimes v_r,$$

per certe matrici $U \in \mathbb{R}^{n_1 \times r}$ e $V \in \mathbb{R}^{n_2 \times r}$. Questo tipo di decomposizione è vantaggioso in termini di memoria: infatti

$$\text{vec}(X) = v_1 \boxtimes u_1 + \dots + v_r \boxtimes u_r,$$

quindi memorizzare U e V costa $O((n_1 + n_2)r)$ invece che $O(n_1 n_2)$. Vorremmo quindi riadattare questa decomposizione per memorizzare T con costo $O((n_1 + \dots + n_d)r)$ invece che $O(n_1 \dots n_d)$. Nel farlo incontreremo alcuni ostacoli, che discuteremo nella § 1.7. Dimosteremo inoltre alcune condizioni necessarie per l'unicità nel Capitolo 2.

Definizione 1.5.1 (Canonical Polyadic Decomposition (CP)). Dati degli spazi vettoriali $A_1 \otimes \dots \otimes A_d$ e dei vettori $\{u_1^t, \dots, u_{n_t}^t\} \subset A_t$, diciamo che un tensore $T \in A_1 \otimes \dots \otimes A_d$ ammette una *Canonical Polyadic Decomposition* (abbreviata, *decomposizione CP*) di rango $r \in \mathbb{N}$ se si può scrivere come somma di r tensori di rango uno

$$T = u_1^1 \otimes u_1^2 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes u_r^2 \otimes \dots \otimes u_r^d.$$

Osservazione 1.5.2. Siccome $A_1 \otimes \dots \otimes A_n$ è generato da elementi di rango uno, è sempre possibile decomporre un tensore in formato CP.

Osservazione 1.5.3. Possiamo rifrasedare il rango $r = \mathbf{R}(T)$ come il minimo r tale per cui T ammette una fattorizzazione CP.

Osservazione 1.5.4 (Canonical Polyadic Decomposition (CP)). La decomposizione CP in $\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è data da delle matrici $U_1, \dots, U_d$ tali che $U_t = [u_1^t | \dots | u_r^t] \in \mathbb{R}^{n_t \times r}$ tali per cui

$$T = u_1^1 \otimes u_1^2 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes u_r^2 \otimes \dots \otimes u_r^d \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}.$$

In tal caso, scriveremo $T = \llbracket U_1, \dots, U_d \rrbracket$.

Osservazione 1.5.5. Possiamo riferirci alla CP sia come decomposizione (data dalla somma dei termini di rango uno) oppure come fattorizzazione (data dai fattori $U_1, \dots, U_d$).

Osservazione 1.5.6. Tramite la notazione sopra, la fattorizzazione CP si può scrivere nelle seguenti formulazioni equivalenti:

1 La fattorizzazione CP

- (i) $T = \sum_{l=1}^r u_l^1 \otimes \cdots \otimes u_l^d.$
- (ii) $\text{vec}(T) = \sum_{l=1}^r u_l^d \boxtimes \cdots \boxtimes u_l^1.$
- (iii) $T_{i_1, i_2, \dots, i_d} = \sum_{l=1}^r U_1(i_1, l) U_2(i_2, l) \cdots U_d(i_d, l).$




Figura 1.1: Fattorizzazione CP di un tensore $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{n \times m \times p}$, dove i vettori a_l, b_l, c_l indicano le colonne l -esime di A, B, C .

Osservazione 1.5.7 (Risparmio in memoria della CP). La fattorizzazione CP di un tensore T di rango r permette di ridurre notevolmente il costo di memorizzazione, in quanto richiede $O((n_1 + \dots + n_d)r) \ll O(\prod_{i=1}^d n_i)$.

1.6 SLICES, FIBERS E UNFOLDINGS

Introduciamo alcuni modi per manipolare più agilmente i tensori.

Definizione 1.6.1 (Tensor slice). Dato $T \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}$ chiamiamo *slice* (o *fetta*) di T ogni matrice ottenuta da T fissando tutti gli indici tranne due. Le slices ottenute fissando gli ultimi $d-2$ indici sono dette *frontal slices*. Nel caso $d=3$ si identificano tutte le possibili slices (Figura 1.2):




Figura 1.2: Slices di un tensore di ordine 3.

Definizione 1.6.2 (Mode- k fiber). Dato un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ chiamiamo *fibers* i vettori ottenuti fissando tutti gli indici tranne uno. Quando l'indice libero di variare è il k -esimo lo chiamiamo *mode- k fiber*. Nel caso $d = 3$ denotiamo le fibre come fibre colonna $x_{:jk}$ (mode-1), fibre riga $x_{i:k}$ (mode-2) e fibre tubo $x_{ij:}$ (mode-3), come illustrato in Figura 1.3.




Figura 1.3: Fibre di un tensore di ordine 3.

In molte situazioni risulta comodo disporre gli elementi di un tensore in una matrice. Uno dei modi per farlo è utilizzare le matricizzazioni, anche dette *unfoldings*.

Definizione 1.6.3 (Mode- k unfolding). Il *mode- k unfolding* di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ è la matrice $T_{(k)} \in \mathbb{R}^{n_k \times \prod_{j \neq k} n_j}$ le cui colonne sono mode- k fibers ordinate seguendo l'ordine naturale su $[n_1] \times \dots \times [n_{k-1}] \times [n_{k+1}] \times \dots \times [n_d]$. In particolare si ha

$$(T_{(k)})_{i,j} = T_{i_1, \dots, i_{k-1}, i, i_{k+1}, \dots, i_d}, \text{ con } j = \mathbb{L}(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d).$$

Osservazione 1.6.4. Possiamo pensare all'unfolding nel modo k come a rimappare l'indice i_k sulle righe e l'indice $(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d)$ sulle colonne. Le Figure 1.4 e 1.5 mostrano alcuni esempi di unfolding nel caso 3-dimensionale.

Esempio 1.6.5 (De Lathauwer [25]). Consideriamo il tensore T di taglia $2 \times 2 \times 2$ definito da

$$a_{111} = -a_{121} = 3, \quad a_{211} = -a_{221} = 6, \quad a_{112} = -a_{122} = 1, \quad a_{212} = -a_{222} = 2.$$

I vettori dei modi 1, 2 e 3 sono le colonne delle matrici

$$T_{(1)} = \begin{bmatrix} 3 & -3 & 1 & -1 \\ 6 & -6 & 2 & -2 \end{bmatrix}, \quad T_{(2)} = \begin{bmatrix} 3 & 6 & 1 & 2 \\ -3 & -6 & -1 & -2 \end{bmatrix}, \quad T_{(3)} = \begin{bmatrix} 3 & 6 & -3 & -6 \\ 1 & 2 & -1 & -2 \end{bmatrix},$$




Figura 1.4: Fibre e matricizzazioni nei tre modi per un tensore del terzo ordine.

rispettivamente. Il tensore ha rango uno perché si può decomporre come

$$T = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -1 \end{bmatrix} \otimes \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$




Figura 1.5: Schema delle matricizzazioni e vettorizzazione di un tensore.

L'operazione di unfolding permette anche di catturare il suo rango (matriciale) lungo ogni direzione:

Definizione 1.6.6 (Rango multilineare). Il *rango multilineare* o *multirank* di un tensore $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è la d -upla $(r_1, r_2, \dots, r_d)$, dove $r_k = \text{rank } T_{(k)}$, per ogni

$k \in \{1, \dots, d\}$. Lo denotiamo con $\mathbf{R}_{\text{multilin}}(T)$.

In alcune situazioni è utile cambiare il formato del tensore.

Definizione 1.6.7 (Reshape). Definiamo l'operatore di *reshape* come l'operazione riarrangia il tensore senza alterarne le dimensioni e mantenendo l'ordine delle entrate. Formalmente, fissati $d, d' \in \mathbb{N}$ e un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$, per ogni $m_1, \dots, m_{d'}$ tali che $\prod_{i=1}^{d'} m_i = \prod_{j=1}^d n_j$, il tensore

$$Y = \text{RESHAPE}(T, m_1 \times \dots \times m_{d'}) \in \mathbb{R}^{m_1 \times \dots \times m_{d'}}$$

è definito come

$$Y_{i_1, \dots, i_{d'}} = T_{j_1, \dots, j_d},$$

per ogni $(i_1, \dots, i_{d'}), (j_1, \dots, j_d)$ tali che

$$\mathbb{L}(i_1, \dots, i_{d'}; m_1 \times \dots \times m_{d'}) = \mathbb{L}(j_1, \dots, j_d; n_1 \times \dots \times n_d).$$

Osservazione 1.6.8. Un reshape ha costo nullo perché non si spostano celle di memoria, ma si eseguono solo operazioni di indici. Questa proprietà vale in particolare per tutte le strutture dati (vettori, matrici, tensori) $\tilde{T}$ tali che $\text{vec}(\tilde{T}) = \text{vec}(T)$.

Osservazione 1.6.9. L'unfolding sul primo modo ha costo nullo, in quanto $T_{(1)} = \text{RESHAPE}(T, n_1 \times \prod_{j=2}^d n_j)$, cioè

$$T_{(1)} = \left[T_{:, \dots, :, 1} \mid \dots \mid T_{:, \dots, :, n_d} \right] \in \mathbb{R}^{n_1 \times \prod_{j=2}^d n_j}.$$

Osservazione 1.6.10. Per $k > 1$, formare l'unfolding $T_{(k)}$ ha un costo non banale, in particolare $\text{vec}(T_{(k)}) \neq \text{vec}(T)$.

Se $k = d$, l'unfolding $T_{(d)} = \begin{bmatrix} \text{vec}(T_{:, \dots, :, 1})^\top \\ \vdots \\ \text{vec}(T_{:, \dots, :, n_d})^\top \end{bmatrix}$, e in particolare vale $\text{vec}(T_{(d)}^\top) =$

$\text{vec}(T)$. Quindi calcolare la trasposta dell'ultimo unfolding non costa nulla.

Lemma 1.6.11 (Vettorizzazione e unfolding di un tensore di rango uno). *Dato un tensore $T = v^1 \otimes \dots \otimes v^d$, allora*

$$(i) \text{ vec}(T) = v^d \boxtimes \dots \boxtimes v^1.$$

$$(ii) T_{(k)} = v^k (v^d \boxtimes \dots \boxtimes v^{k-1} \boxtimes v^{k+1} \boxtimes \dots \boxtimes v^1)^\top.$$

In particolare, tutte le matricizzazioni di un prodotto esterno hanno rango 1.

Dimostrazione. La (i) segue applicando più volte l'Osservazione 1.4.3. Dimostriamo la (ii). Per definizione di tensore di rango uno la scrittura in componenti di T è

$$T_{i_1, \dots, i_d} = v_{i_1}^1 \cdots v_{i_d}^d = v_{i_k}^k \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right).$$

Preso $u = v^d \boxtimes \cdots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \cdots \boxtimes v^1$, osserviamo che la sua componente j -esima è il prodotto fra parentesi, ovvero $u_j = \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right)$. A questo punto, per definizione di unfolding abbiamo $(T_{(k)})_{i_k, j} = v_{i_k}^k u_j$, da cui

$$T_{(k)} = v^k u^\top = v^k \left(v^d \boxtimes \cdots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \cdots \boxtimes v^1 \right)^\top.$$

□

In molte situazioni è utile moltiplicare un tensore con una matrice. La seguente definizione risolve il problema facendo agire la matrice lungo il modo k -esimo di un tensore, e si chiama.

Definizione 1.6.12 (Prodotto nel modo k). Il *prodotto nel modo k* di un tensore $T \in \mathbb{R}^{n_1 \times \cdots \times n_d}$ con una matrice $U \in \mathbb{R}^{r \times n_k}$ descrive l'azione di U sulla k -esima coordinata di T . Formalmente, è un tensore

$$Y = T \times_k U \in \mathbb{R}^{n_1 \times \cdots \times n_{k-1} \times r \times n_{k+1} \times \cdots \times n_d} \text{ con } Y_{(k)} = U T_{(k)}.$$

In componenti, $Y_{i_1, \dots, i_{k-1}, \alpha, i_{k+1}, \dots, i_d} = \sum_{i_k=1}^d T(i_1, i_2, \dots, i_d) U_{\alpha, i_k}$.

1.7 IL PROBLEMA DEL RANGO

Rispetto al caso matriciale, il problema di calcolare il rango e una fattorizzazione CP di un tensore si complicano notevolmente. Ci sono molte domande aperte riguardo al rango, ad esempio non si ha una risposta generale a domande pienamente risolte per le matrici:

1. Qual è il massimo rango possibile per un tensore di dimensione $n_1 \times \cdots \times n_d$?
2. Quali sono i ranghi *tipici*, ovvero quelli ottenuti con probabilità non nulla quando si genera un tensore di entrate casuali?

3. Qual è il rango di una successione di tensori al limite?

Per capire il motivo, discutiamo alcune caratteristiche dei tensori che rendono complesso il “problema del rango”.

BORDER RANK

Nel caso delle matrici, una successione di matrici di rango r converge sempre a una matrice di rango $\leq r$. Per i tensori possono accadere dei “salti”, in altre parole, la varietà dei tensori di un rango fissato r non è chiusa¹, ad esempio, un tensore di rango 2 può convergere ad uno di rango 3, come mostra il prossimo esempio. Questo inconveniente teorico ha risvolti interessanti che vedremo nella § 3.8.

Esempio 1.7.1. Consideriamo dei vettori $a_1, a_2 \in \mathbb{R}^m$, $b_1, b_2 \in \mathbb{R}^n$ e $c_1, c_2 \in \mathbb{R}^p$ vettori linearmente indipendenti. Definiamo il tensore

$$(1.5) \quad T = a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1,$$

e notiamo che $\mathbf{R}(T) = 3$ dato che non può essere scomposto come somma di tensori più semplici. Consideriamo la successioni di tensori

$$(1.6) \quad T_\varepsilon = \frac{1}{\varepsilon}(a_1 + \varepsilon a_2) \otimes (b_1 + \varepsilon b_2) \otimes (c_1 + \varepsilon c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1, \text{ con } \varepsilon \in \mathbb{R},$$

che essendo combinazione di due tensori di rango uno, ha rango 2. Vediamo che $\lim_{\varepsilon \rightarrow 0} T_\varepsilon = T$, da cui segue che l'insieme dei tensori di rango 3 non è chiuso. Espandendo i termini dell'Equazione (1.6) tramite la proprietà distributiva del prodotto esterno,

$$(1.7) \quad \begin{aligned} T_\varepsilon &= \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1 \\ &\quad + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1 \\ &= T + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) \end{aligned}$$

Quindi $T_\varepsilon - T \xrightarrow{\varepsilon \rightarrow 0} 0$.

Questo motiva la seguente definizione:

¹Non ne precisiamo la topologia, per una discussione formale si vedano [44, 45].

Definizione 1.7.2 (Border rank). Un tensore T ha *border rank* r se è limite di una successione di tensori di rango r , ma non è limite di una successione di tensori di rango s , per ogni $s < r$. Lo denoteremo con il simbolo $\underline{R}(T)$.

Osservazione 1.7.3. $\underline{R}(T) \geq \underline{R}(T)$.

Osservazione 1.7.4. In altri termini, se $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$, il suo border rank è la quantità

$$\underline{R}(T) = \min\{r \in \mathbb{N} \mid \exists T' \in \mathbb{R}^{n_1 \times \dots \times n_d} \text{ tale che } \underline{R}(T') = r, \|T - T'\| < \varepsilon\}.$$

Osservazione 1.7.5. Nell'esempio sopra, $\underline{R}(T) \leq 2$.

Il border rank ammette anche la seguente interpretazione geometrica:




Figura 1.6: Nella varietà dei tensori $2 \times 2 \times 2$ una successione di tensori di rango 2 può convergere a un tensore di rango 3 al bordo tra i tensori di rango due e quelli di rango 3.

DIFFICOLTÀ DI CALCOLO

Il costo di calcolare una fattorizzazione CP usando un algoritmo esatto è NP-Hard [35]. Non solo; il problema di trovare un tensore approssimante di un certo rango è computazionalmente difficile. In altre parole, la miglior approssimazione di rango r è data da dei vettori $u_i \in \mathbb{R}^{n_1}, v_i \in \mathbb{R}^{n_2}, \dots, w_i \in \mathbb{R}^{n_d}$, per $i = 1, \dots, r$ che minimizzano

$$\|A - u_1 \otimes v_1 \otimes \dots \otimes w_1 - \dots - u_r \otimes v_r \otimes \dots \otimes w_r\|$$

oppure, in altre parole un tensore B dato da una fattorizzazione CP, che realizza

$$\min_{\text{rank}(B) \leq r} \|A - B\|.$$

Qui $\|\cdot\|$ denota una norma fissata su $\mathbb{R}^{n_1 \times \dots \times n_d}$. Quando $d = 2$, il problema è risolto per norme invarianti per trasformazioni unitarie su $\mathbb{R}^{m \times n}$ dal teorema di Eckart-Young-Mirsky [29]: se

$$A = U\Sigma V^* = \sum_{i=1}^{\text{rank}(A)} \sigma_i u_i \otimes v_i, \quad \sigma_i \geq \sigma_{i+1},$$

è la decomposizione ai valori singolari di A (anche detta SVD), allora la migliore approssimazione di rango r è data dai primi r termini della somma. Sfortunatamente, generalizzare questo risultato in più dimensioni è ritenuto infattibile [56].

Nella pratica esistono diverse euristiche per calcolare il rango. Una di queste è scegliere come rango il più piccolo r che minimizza l'errore relativo rispetto al rango $r - 1$. Possiamo definire l'*errore relativo* per un tensore T a tre indici come

$$(1.8) \quad \varepsilon_{\text{rel}} = \frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} = \frac{\left(\sum_{i,j,k} (t_{ijk} - \sum_{l=1}^r a_{il} b_{jl} c_{kl})^2\right)^{\frac{1}{2}}}{\left(\sum_{i,j,k} t_{ijk}^2\right)^{\frac{1}{2}}}.$$

RANGO MASSIMO

Nel caso di una matrice $m \times n$, il suo rango massimo è $\min\{m, n\}$. Per un tensore, il *rango massimo* è definito come il massimo dei ranghi realizzabili per dei tensori $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ di una certa taglia fissata. In altre parole,

$$\mathbf{R}_{\max}(\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}) = \max\{\mathbf{R}(T) \mid T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}\}.$$

Sfortunatamente, i ranghi massimi per la maggior parte dei tensori di ordine superiore sono sconosciuti. I casi speciali in cui il rango massimo è noto sono elencati nella Tabella 1.1. Il primo risultato per tensori di dimensione $2 \times m \times n$ implica, ad esempio, che un tensore di taglia $2 \times 2 \times 2$ ha un rango massimo pari a 3.

Tabella 1.1: Ranghi massimi tensoriali noti. L'ordine delle dimensioni non modifica il rango, quindi le taglie sono ordinate dalla più piccola alla più grande (tratta da Ballard e Kolda [7, Tabella 16.1]).

Taglia tensore	Rango massimo	Fonte
$2 \times m \times n$ ($m \leq n$)	$m + \min\{m, \lfloor n/2 \rfloor\}$	JáJá [38]; Kruskal [40]
$3 \times 3 \times 3$	5	Kruskal [40]
$3 \times 7 \times 7$	8	Atkinson e Stephens [5]
$2 \times 4 \times 4$	6	ten Berge [10]

È inoltre possibile derivare un limite superiore debole per il rango massimo [7, Pag. 275],

$$(1.9) \quad \mathbf{R}_{\max}(\mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}) \leq \min_k \prod_{\substack{\ell=1 \\ \ell \neq k}}^d n_\ell = \frac{\prod_{k=1}^d n_k}{\max_k n_k}.$$

RANGO TIPICO

Mentre le matrici random hanno rango massimo con probabilità uno², per un tensore di un formato fissato potrebbe esserci più di un rango con probabilità positiva. Questo fenomeno è noto come rango tipico.

Fissiamo una misura di probabilità P , e sia $\mathcal{D}(n_1, n_2, \dots, n_d)$ una distribuzione di probabilità continua sullo spazio dei tensori $\mathbb{K}^{n_1 \times n_2 \times \cdots \times n_d}$ (un esempio sono i tensori a entrate gaussiane).

Definizione 1.7.6. Il *rango tipico* (o *rango generico*) di un tensore $T \in \mathbb{K}^{n_1 \times \cdots \times n_d}$ è l'insieme dei ranghi che occorrono con probabilità non nulla, rispetto ad ogni distribuzione continua $\mathcal{D}(n_1, n_2, \dots, n_d)$ sull'insieme di tali tensori. In formule,

$$\mathbf{R}_{\text{typical}} = \{r \mid P(\mathbf{R}(T) = r, T \sim \mathcal{D}(n_1, \dots, n_d)) > 0 \text{ per ogni } \mathcal{D}(n_1, \dots, n_d)\}.$$

Per le matrici il rango tipico è unico e coincide con il massimo rango possibile, per i tensori di ordine superiore a due non è così: su $\mathbb{R}$ possono coesistere più ranghi tipici, mentre su $\mathbb{C}$ il rango tipico è sempre unico. La Tabella 1.2 riassume i principali risultati noti in letteratura, tratti da Ballard e Kolda [7, p. 276, Tabella 16.2]. Per verificare

²L'idea alla base è che, presa una matrice con entrate estratte da una distribuzione di probabilità continua, il determinante è un polinomio le cui indeterminate sono le entrate della matrice. Il luogo di zeri di questo polinomio ha misura di Lebesgue nulla, quindi integrando la densità di probabilità sul luogo di zeri dà probabilità nulla. La tesi si ha passando al complementare.

questi risultati, abbiamo implementato un esperimento numerico. Selezioniamo alcuni formati e generiamo dei tensori casuali con entrate estratte indipendentemente sia da una distribuzione normale standard $\mathcal{N}(0, 1)$ sia da una distribuzione uniforme $\mathcal{U}(-1, 1)$. Il rango di ciascun tensore è stato stimato usando l'algoritmo ALS (che introdurremo in § 1) su un campione di 200 tensori, facendo 120 restarts e un numero massimo di 500 iterazioni, interrompendo una volta raggiunto un errore relativo inferiore a 10^{-5} . La distribuzione empirica dei ranghi riportata in Figura 1.7 mostra che la distribuzione delle entrate (normale o uniforme) non altera l'insieme dei ranghi tipici e produce frequenze empiriche analoghe.




Figura 1.7: Distribuzione empirica dei ranghi per tensori casuali reali di formato $2 \times 2 \times 2$, $3 \times 3 \times 2$, $3 \times 3 \times 3$ e $3 \times 3 \times 5$ con entrate estratte da distribuzioni Normali $\mathcal{N}(0, 1)$ ed Uniformi $\mathcal{U}(-1, 1)$ (istogrammi affiancati).

Tabella 1.2: Ranghi tipici noti su $\mathbb{R}$ per tensori di dimensione $m \times n \times p$ con $2 \leq m \leq n \leq p$ (da Ballard e Kolda [7, Tabella 16.2]).

Formato ($m \times n \times p$)	Rango tipico	Fonte
$2 \times n \times n$	$\{n, n + 1\}$	ten Berge, Kiers [11]
$3 \times 3 \times 3$	5	ten Berge, Stegeman [13]
$3 \times 3 \times 5$	$\{5, 6\}$	ten Berge, Sidiropoulos, Rocci [12]
$3 \times 4 \times 8$	$\{8, 9\}$	Sumi et al. [62]
$3 \times 5 \times 9$	$\{9, 10\}$	Choulakian [21]; ten Berge [9]
$4 \times 4 \times 12$	$\{12, 13\}$	Friedland [31]
$m \times n \times n(m - 1)$ ($m > 2$, n dispari)	$n(m - 1)$	ten Berge [10]
$m \times n \times p$ ($n(m - 1) < p < mn$)	p	ten Berge, Kiers [11]; ten Berge [10]
$m \times n \times p$ ($p \geq mn$)	mn	ten Berge, Kiers [11]; ten Berge [10]

DIPENDENZA DAL CAMPO BASE

Nel caso matriciale ogni matrice $m \times n$ reale ha lo stesso rango se visto come elemento di $\mathbb{R}^{m \times n}$ o di $\mathbb{C}^{m \times n}$, ma per i tensori questo è falso. Consideriamo il seguente esempio:

Esempio 1.7.7 (De Silva e Lim [56]). Scriviamo $z_k = x_k + iy_k$ e $\bar{z}_k = x_k - iy_k$, allora

$$(1.10) \quad \begin{aligned} & \frac{1}{2}(\bar{z}_1 \otimes z_2 \otimes \bar{z}_3 + z_1 \otimes \bar{z}_2 \otimes z_3) \\ &= x_1 \otimes x_2 \otimes x_3 + x_1 \otimes y_2 \otimes y_3 - y_1 \otimes x_2 \otimes y_3 + y_1 \otimes y_2 \otimes x_3. \end{aligned}$$

Chiamando $I = \bar{z}_1 \otimes z_2 \otimes \bar{z}_3$ e $II = z_1 \otimes \bar{z}_2 \otimes z_3$, usando la proprietà distributiva e la trilinearità del prodotto tensore,

$$\begin{aligned} I &= (x_1 - iy_1) \otimes (x_2 + iy_2) \otimes (x_3 - iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 - ix_1 \otimes x_2 \otimes y_3 + ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 - iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 - iy_1 \otimes y_2 \otimes y_3, \\ II &= (x_1 + iy_1) \otimes (x_2 - iy_2) \otimes (x_3 + iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 + ix_1 \otimes x_2 \otimes y_3 - ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 + iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 + iy_1 \otimes y_2 \otimes y_3. \end{aligned}$$

L'espressione sopra segue calcolando $\frac{1}{2}(I + II)$.

1.8 IL TEOREMA DEL RANGO

Data la complessità del problema del rango possiamo stimarlo con la seguente proposizione, dalla quale intuiamo che non sarà semplice trovare stime generali più precise—queste spesso coinvolgono tecniche algebrico-combinatorie avanzate. Vedremo alcuni esempi di queste stime nella Sezione 3.7.

Definiamo un'operazione utile tra le colonne di due matrici, che sarà utile a dimostrare il risultato di questa sezione.

Definizione 1.8.1 (Prodotto Khatri-Rao). Date due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$, il loro *prodotto Khatri-Rao* è dato da

$$(1.11) \quad C = A \odot B = [a_1 \boxtimes b_1 \mid \dots \mid a_r \boxtimes b_r] \in \mathbb{R}^{(mn) \times r},$$

dove a_j e b_j indicano la j -esima colonna di A e B , rispettivamente, e la matrice C si lascia scrivere in componenti come $C_{kl} = A_{il}B_{jl}$, dove $\mathbb{L}^*(i, j) = \mathbb{L}(j, i) = k$.

Osservazione 1.8.2. Il prodotto $A \odot B$ è sottomatrice di $A \boxtimes B$, in quanto una colonna k -esima della prima è del tipo $a_k \boxtimes b_k$, mentre per la seconda è $[a_{1k}B, \dots, a_{mk}B]^\top$; quindi possiamo ottenere la prima matrice selezionando alcune colonne della seconda.

Osservazione 1.8.3. Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$, il prodotto Khatri-Rao

$$U_d \odot U_{d-1} \odot \dots \odot U_1$$

ha come colonna r -esima $u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$, in altre parole, è la rappresentazione matriciale dell'insieme $\{u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1\}_{r=1, \dots, d}$ formato dagli addendi della decomposizione $\text{vec}(T) = \sum_{r=1}^R u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$. In particolare, vale

$$\begin{aligned} \text{vec}(T) &= \sum_{h=1}^r u_h^d \boxtimes \dots \boxtimes u_h^1 = \left[u_1^d \boxtimes \dots \boxtimes u_1^1 \mid \dots \mid u_r^d \boxtimes \dots \boxtimes u_r^1 \right]^\top \mathbf{1}_r \\ &= (U_d \odot U_{d-1} \odot \dots \odot U_1) \mathbf{1}_r. \end{aligned}$$

Osservazione 1.8.4. Calcolare il prodotto di Khatri-Rao di due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$ ha un costo in memoria di $O(mnr)$.

Lemma 1.8.5. Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket \in \mathbb{R}^{n_1 \times \dots \times n_d}$, essa ha come *unfoldings*

$$T_{(j)} = U_j (U_d \odot U_{d-1} \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)^\top,$$

per ogni $j = 1, \dots, d$.

Dimostrazione. Scrivendo le matricizzazioni di $T = \sum_{h=1}^r u_h^1 \otimes \cdots \otimes u_h^d$, dove i vettori $u_1^j, \dots, u_r^j$ rappresentano le colonne della matrice U_j , troviamo che

$$\begin{aligned} T_{(j)} &= \sum_{h=1}^r u_h^j \left(u_h^d \boxtimes \cdots \boxtimes u_h^{j+1} \boxtimes u_h^{j-1} \boxtimes \cdots \boxtimes u_h^1 \right)^\top \\ &= U_j \left[u_1^d \boxtimes \cdots \boxtimes u_1^1 \mid \cdots \mid u_r^d \boxtimes \cdots \boxtimes u_r^1 \right]^\top \\ &= U_j (U_d \odot \cdots \odot U_{j+1} \odot U_{j-1} \odot \cdots \odot U_1)^\top, \end{aligned}$$

dove nel primo passaggio abbiamo applicato la Proposizione 1.6.11 su ogni addendo di rango uno. $\square$

Esempio 1.8.6. Se $T = \llbracket A, B, C \rrbracket$, allora segue che $T_{(1)} = A(C \odot B)^\top$.

Proposizione 1.8.7 (Teorema del rango). *Sia $T \in \mathbb{R}^{n_1 \times \cdots \times n_d}$ un tensore che ammette una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$ di rango r , e sia $r_j = \text{rank}(T_{(j)})$ il rango dell'unfolding $T_{(j)}$ con $j = 1, \dots, d$. Allora vale che*

$$(1.12) \quad \max_{j=1, \dots, d} (r_j) \leq \mathbf{R}(T) \leq \min_{j=1, \dots, d} \left(\prod_{i \neq j} r_i \right)$$

Dimostrazione. Fissato $r = \mathbf{R}(T)$, la minorazione segue direttamente dal fatto che ogni unfolding $T_{(j)}$ è una matrice di taglia $n_j \times r$ di rango r_j . Mostriamo la maggiorazione, assumendo senza perdita di generalità che $\mathbf{R}(T) \leq \prod_{i=2}^d r_i$. Consideriamo la vettorizzazione

$$(1.13) \quad \text{vec}(T) = \sum_{k=1}^r u_k^d \boxtimes \cdots \boxtimes u_k^2 \boxtimes u_k^1.$$

Allora l'insieme

$$\left\{ u_k^d \boxtimes \cdots \boxtimes u_k^2 \right\}_{k=1, \dots, r}$$

è formato da vettori linearmente indipendenti. Se così non fosse, esisterebbe un indice k_0 , che possiamo supporre $k_0 = 1$ a meno di riordinamento degli indici k , tale per cui

$$(1.14) \quad u_1^d \boxtimes \cdots \boxtimes u_1^2 = \sum_{h=2}^r c_h (u_h^d \boxtimes \cdots \boxtimes u_h^2),$$

che sostituita nella Equazione (1.13) porta alla seguente decomposizione:

$$\begin{aligned} \text{vec}(T) &= \sum_{k=2}^r u_k^d \boxtimes \cdots \boxtimes u_k^2 \boxtimes u_k^1 + \left(\sum_{k=2}^r c_k (u_k^d \boxtimes \cdots \boxtimes u_k^2) \right) \boxtimes u_1^1 \\ &= \sum_{k=2}^r (u_k^d \boxtimes \cdots \boxtimes u_k^2) \boxtimes (u_k^1 + c_k u_1^1) \end{aligned}$$

che ha rango $r - 1$, contraddicendo la minimalità di r . Dal Lemma 1.8.5 possiamo scrivere

$$T_{(1)} = U_1(U_d \odot \cdots \odot U_2)^\top.$$

Dalla lineare indipendenza appena dimostrata, e dall'Osservazione 1.8.3 segue che $\text{rank}(U_d \odot \cdots \odot U_2) = r$. Applicando l'Osservazione 1.8.2 a più fattori troviamo che $U_d \odot \cdots \odot U_r$ è sottomatrice di $U_d \boxtimes \cdots \boxtimes U_2$. Notiamo che i fattori U_j hanno rango r_j in quanto

Aggiunta questa giustificazione

$$\begin{aligned} r_j &= \text{rank}(T_{(j)}) = \text{rank}(U_j(U_d \odot U_{d-1} \odot \cdots \odot U_{d+1} \odot U_{j-1} \odot \cdots \odot U_1)^\top) \\ &\leq \min\{\text{rank}(U_j), \text{rank}((U_d \odot U_{d-1} \odot \cdots \odot U_{d+1} \odot U_{j-1} \odot \cdots \odot U_1)^\top)\} \\ &\leq \text{rank}(U_j) \leq r_j, \end{aligned}$$

per ogni $j = 1, \dots, d$. Siccome il rango del prodotto di Kroneker è moltiplicativo (Osservazione 1.4.2) troviamo

$$r \leq \text{rank}(U_d \boxtimes \cdots \boxtimes U_2) = \text{rank}(U_d) \cdots \text{rank}(U_2) = r_2 \cdots r_d.$$

Ripetendo l'argomento per gli altri unfoldings si ha la tesi. $\square$

Osservazione 1.8.8. Una conseguenza immediata di questo teorema è che T ha rango uno se e solo se $\mathbf{R}_{\text{multilin}}(T) = 1$, cioè se e solo se $\mathbf{R}(T_{(j)}) = 1$ per ogni j . In generale vale che, se $\mathbf{R}(T) = r$, allora $\mathbf{R}_{\text{multilin}}(T) \leq r$, ma non il viceversa.

1.9 RICOSTRUZIONE DEL TENSORE IN FORMATO DENSO

In alcune situazioni è utile scrivere il tensore fattorizzato in modo esplicito, ad esempio per valutare l'errore di approssimazione dell'Equazione (1.8) o generare numericamente un tensore. Un modo conveniente di farlo è il seguente. Data una fattorizzazione $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{m \times n \times p}$ di rango r , poiché $\text{vec}(T) = (C \odot B \odot A)\mathbf{1}_r$, saremmo tentati di formare la matrice $C \odot B \odot A$ e moltiplicarla per il vettore di tutti

uni $\mathbf{1}_r$, ma questa matrice ha più entrate del risultato finale. L'approccio vincente è considerare l'unfolding $T_{(1)} = A(C \odot B)^\top$ della Proposizione 1.8.5, e studiare il sistema

$$\begin{cases} R = C \odot B, \\ Y = AR^\top, \\ T = \text{RESHAPE}(Y, m \times n \times p). \end{cases}$$

Il risultato intermedio $R \in \mathbb{R}^{np \times r}$ ha costo $O(npr)$, mentre formare Y costa $O(mnpr)$. Essendo un unfolding sul modo uno, non paghiamo il costo di permutazioni.

1.10 CALCOLO DELLA FATTORIZZAZIONE CP

Trattiamo il problema di trovare la migliore approssimazione con rango r di un dato tensore. Studiamo il caso $d = 3$ per semplicità di notazione. Dato $T \in \mathbb{R}^{m \times n \times p}$ cerchiamo una fattorizzazione $\llbracket A, B, C \rrbracket$ con $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ e $C \in \mathbb{R}^{p \times r}$ cercando di risolvere il problema ai minimi quadrati

$$(\mathcal{P}) \quad \min_{A, B, C} \|T - \llbracket A, B, C \rrbracket\|^2.$$

Tale problema può essere mal posto per quanto detto sul border rank. Inoltre si tratta di un problema non convesso (esistono molti minimi locali). Ricordiamo anche che in generale un tensore può avere fattorizzazioni CP multiple.

Definizione 1.10.1 (Prodotto di Hadamard). Date due matrici $A, B \in \mathbb{R}^{m \times n}$, il loro *prodotto di Hadamard* è il loro prodotto elemento per elemento, e si indica con la matrice $C = A * B$ con entrate $C_{ij} = a_{ij}b_{ij}$.

Lemma 1.10.2. Date delle matrici $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$, $C \in \mathbb{R}^{m \times s}$, $D \in \mathbb{R}^{n \times s}$, vale

$$(A \odot B)^\top (C \odot D) = (A^\top C) * (B^\top D).$$

Dimostrazione. Basta osservare che la matrice

$$(A \odot B)^\top (C \odot D) = \begin{bmatrix} a_1^\top \boxtimes b_1^\top \\ \vdots \\ a_r^\top \boxtimes b_r^\top \end{bmatrix} \left[\begin{array}{c|c|c} c_1 \boxtimes d_1 & \dots & c_s \boxtimes d_s \end{array} \right].$$

ha come entrata (i, j) l'elemento $(a_i^\top c_j)(b_i^\top d_j)$, che corrisponde all'entrata (i, j) di $(A^\top C) * (B^\top D)$. $\square$

ALTERNATING LEAST-SQUARES

Nonostante la funzione obiettivo dell'Equazione (P) non sia convessa, essa è convessa nelle singole variabili. Ovvero, fissate B e C , ottimizzare solo su A significa risolvere un problema ai minimi quadrati lineare

$$(1.15) \quad \|T - \llbracket A, B, C \rrbracket\|^2 = \|T_{(1)} - A(C \odot B)^\top\|_F^2 = \|(C \odot B)A^\top - T_{(1)}^\top\|_F^2,$$

dove l'incognita è una matrice. Nel primo passaggio abbiamo applicato la Proposizione 1.8.5 per ridurci a un problema ai minimi quadrati matriciale. La soluzione può essere espressa in termini delle equazioni normali

$$(C \odot B)^\top (C \odot B) A^\top = (C \odot B)^\top T_{(1)}^\top,$$

se e solo se, usando il Lemma 1.10.2

$$(1.16) \quad (C^\top C * B^\top B) A^\top = (C \odot B)^\top T_{(1)}^\top$$

Sia $Z := (C \odot B) = C^\top C * B^\top B \in \mathbb{R}^{r \times r}$. Osserviamo che Z soddisfa

$$x^\top Z x = x^\top (C \odot B)^\top (C \odot B) x = ((C \odot B) x)^\top ((C \odot B) x) = \|(C \odot B) x\|_2^2 \geq 0$$

per ogni $x \in \mathbb{R}^r$, ossia è semidefinita positiva. In particolare dall'equazione sopra segue che quando $C \odot B$ è full-rank Z è positiva definita: in tal caso possiamo risolvere con la fattorizzazione di Cholesky il sistema

$$(1.17) \quad AZ = T_{(1)}(C \odot B) = M,$$

con costo $O(r^2 m + r^3)$.

Aggiunto

Osservazione 1.10.3. Scomponiamo i costi per risolvere il sistema sopra:

- Calcolare $T_{(1)}(C \odot B)$ costa $O(mnpr)$, in quanto calcolare $C * B$ costa $O(mpr)$; essendo $C * B$ una matrice $np \times r$ e $T_{(1)}$ una matrice $m \times np$, il loro prodotto costa $O(mnpr)$.
- Calcolare $(C^\top C * B^\top B)$ costa $O(r^2 n + r^2 p + r^2)$ in quanto $C^\top C$ costa $r^2 n$, $B^\top B$ costa $r^2 p$ ed essendo entrambe due matrici $r \times r$, il loro prodotto di Katri-Rao costa $O(r^2)$.
- La risoluzione con Cholesky costa $O(r^3)$, e ricavare A costa $O(r^2 m)$.

Siccome in generale il rango è molto più piccolo delle dimensioni del tensore, il costo asintotico è $O(mnpr)$.

Algorithm 1 Schema dell'algoritmo ALS.

Input: Tensore T di rango r , tolleranza ε .

- 1: Generiamo B e C in modo casuale.
 - 2: Normalizziamo le colonne di B .
 - 3: **repeat**
 - 4: Normalizziamo le colonne di C .
 - 5: $A \leftarrow \arg \min_A \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 6: Normalizziamo le colonne di A .
 - 7: $B \leftarrow \arg \min_B \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 8: Normalizziamo le colonne di B .
 - 9: $C \leftarrow \arg \min_C \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 10: **until** $\frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} > \varepsilon$.
-

L'idea dell'algoritmo ALS è di minimizzare ciclicamente la funzione obiettivo dell'Equazione (1.15), prima al variare di A , poi B e poi C . Alla luce dei calcoli sopra, risolvere i problemi dati dall'Equazione ha costo $O(mnpr)$, che quindi è anche il costo dell'algoritmo ALS. Riassumiamo questo schema nell'Algoritmo 1, dove in ogni passaggio riscaliamo la fattorizzazione CP come $\llbracket AD_A, BD_B, CD_C \rrbracket$ con delle matrici tali che $D_A D_B D_C = I_r$ per riscalare le colonne dei due fattori fissati in modo che abbiano norma unitaria.

Osservazione 1.10.4. Dato che in genere non si sa il valore ottimo del problema ($\mathcal{P}$), arrestiamo l'algoritmo quando sta “stagnando”, ovvero quando l'errore relativo fra due iterazioni successive diminuisce meno di un dato fattore.

Osservazione 1.10.5. Nel caso di T matrice, il fattore $C = I$ e nel caso T ha rango $r = 1$, l'algoritmo diventa il metodo delle potenze, in quanto l'Equazione (1.16) degenera in $a \leftarrow T \frac{b}{\|b\|^2}$ e $b \leftarrow T^\top \frac{a}{\|a\|^2}$, mentre per T di rango $r > 1$ diventa il metodo dei sottospazi: $A \leftarrow TB(B^\top B)^{-1}$ e $B \leftarrow T^\top A(A^\top A)^{-1}$.

2 UNICITÀ DELLA FATTORIZZAZIONE CP

Data una matrice $M \in \mathbb{C}^{n \times n}$ di rango r , possiamo scriverla come somma di matrici di rango uno come

$$M = a_1 \otimes b_1 + \dots + a_r \otimes b_r = \begin{bmatrix} a_1 & \dots & a_r \end{bmatrix} \begin{bmatrix} b_1 & \dots & b_r \end{bmatrix}^\top = AB^\top.$$

Questa decomposizione non è mai unica a meno che $r = 1$, in quanto

$$(2.1) \quad M = AB^\top = APP^{-1}B^\top = (AP)(BP^{-T})^\top,$$

dove $P \in \text{GL}_n(\mathbb{C})$ è invertibile ma non necessariamente prodotto di matrici diagonali. Siccome $\text{GL}_n(\mathbb{C})$ contiene infiniti elementi, esistono infinite decomposizioni per M . Sorprendentemente, per i tensori è possibile ottenere l'unicità, sotto opportune ipotesi d'indipendenza delle componenti. Ma cosa intendiamo per unicità e indipendenza?

Possiamo definire l'unicità nel caso 3-dimensionale così: dato un tensore

$$T = a_1 \otimes b_1 \otimes c_1 + \dots + a_r \otimes b_r \otimes c_r \in A \otimes B \otimes C,$$

sotto opportune ipotesi T differisce da un'altra fattorizzazione CP a meno di permutazione dei tensori elementari e riscalamento dei fattori. Più precisamente, se esistono degli scalari $\alpha_1, \dots, \alpha_r, \beta_1, \dots, \beta_r, \gamma_1, \dots, \gamma_r$ tali che $\alpha_j \beta_j \gamma_j = 1$ per ogni $j \in \{1, \dots, r\}$ ed esiste una permutazione $\sigma \in \mathfrak{S}_r$ tale che

$$T = \alpha_1 a_{\sigma(1)} \otimes \beta_1 b_{\sigma(1)} \otimes \gamma_1 c_{\sigma(1)} + \dots + \alpha_r a_{\sigma(r)} \otimes \beta_r b_{\sigma(r)} \otimes \gamma_r c_{\sigma(r)},$$

diremo che la fattorizzazione CP è *essenzialmente unica*. Diamo una definizione più generale.

Definizione 2.0.1 (Essenziale unicità). Sia $T \in A_1 \otimes \cdots \otimes A_d$ un tensore che ammette una decomposizione CP di rango r

$$T = u_1^1 \otimes \cdots \otimes u_1^d + \cdots + u_r^1 \otimes \cdots \otimes u_r^d.$$

Diremo che tale decomposizione è *essenzialmente unica* se esistono degli scalari $\lambda_1^{(t)}, \dots, \lambda_r^{(t)}$ con $t \in \{1, \dots, d\}$ tali che $\lambda_j^{(1)} \lambda_j^{(2)} \cdots \lambda_j^{(d)} = 1$ per ogni $j \in \{1, \dots, r\}$ e una permutazione $\sigma \in \mathfrak{S}_r$ tale che

$$T = \lambda_1^{(1)} u_{\sigma(1)}^1 \otimes \cdots \otimes \lambda_1^{(d)} u_{\sigma(1)}^d + \cdots + \lambda_r^{(1)} u_{\sigma(r)}^1 \otimes \cdots \otimes \lambda_r^{(d)} u_{\sigma(r)}^d.$$

Notiamo che il tensore permutato appartiene ancora allo spazio di partenza. In realtà, la formulazione originale in coordinate è la seguente.

Definizione 2.0.2 (Essenziale unicità). Una fattorizzazione CP di rango r di un tensore $T = \llbracket U_1, \dots, U_d \rrbracket$ è essenzialmente unica se, per ogni altra fattorizzazione $T = \llbracket \tilde{U}_1, \dots, \tilde{U}_d \rrbracket$ di rango r , esiste una matrice di permutazione $P \in \mathbb{R}^{r \times r}$ e delle matrici diagonali $D_1, \dots, D_d \in \mathbb{R}^{r \times r}$ che soddisfano $D_1 D_2 \cdots D_d = I$ e $U_j = \tilde{U}_j D_j P$, per ogni $j = 1, \dots, d$.

Osservazione 2.0.3. Osserviamo che questa definizione è una specializzazione di quella generale. Nel caso 3-dimensionale, ad esempio scriviamo in coordinate

$$A = \left[\begin{array}{c|c|c} a_1 & \dots & a_r \end{array} \right], \quad B = \left[\begin{array}{c|c|c} b_1 & \dots & b_r \end{array} \right], \quad C = \left[\begin{array}{c|c|c} c_1 & \dots & c_r \end{array} \right].$$

Rappresentiamo $\sigma \in \mathfrak{S}_r$ tramite una matrice P^{-1} di permutazione, e dette

$$D_A^{-1} := \text{diag}(\alpha_1, \dots, \alpha_r), \quad D_B^{-1} := \text{diag}(\beta_1, \dots, \beta_r), \quad D_C^{-1} := \text{diag}(\gamma_1, \dots, \gamma_r),$$

possiamo prendere

$$\tilde{A} := AP^{-1}D_A^{-1} = \left[\begin{array}{c|c|c} \alpha_1 a_{\sigma(1)} & \dots & \alpha_r a_{\sigma(r)} \end{array} \right],$$

e definire in maniera analoga $\tilde{B} := BP^{-1}D_B^{-1}$ e $\tilde{C} := CP^{-1}D_C^{-1}$. Moltiplicando a destra per le matrici inverse troviamo la prima definizione.

2.1 CONVENZIONI

Dato uno spazio vettoriale V su un campo $\mathbb{K}$, lo spazio proiettivo $\mathbb{P}(V)$ è dato da $\pi: V \setminus \{0\} \rightarrow \mathbb{P}(V): v \mapsto [v]$, dove per ogni $v \in V \setminus \{0\}$, il punto $[v]$ denota $\pi(v)$. Poniamo $\pi(V \setminus \{0\} / \sim) =: \mathbb{P}(V)$, dove $v \sim w$ se e solo se esiste $\lambda \in \mathbb{K} \setminus \{0\}$ tale che $v = \lambda w$. Se $V = \mathbb{K}^{n+1}$ indichiamo lo spazio proiettivo standard sul campo $\mathbb{K}$ come $\mathbb{P}^n = \mathbb{P}^n(\mathbb{K}) = \mathbb{P}(\mathbb{K}^{n+1})$. Dato un sottoinsieme $X \subset \mathbb{P}(V)$, il suo cono vettoriale è $\hat{X} = \pi^{-1}(X) \cup \{0\} \subset V$. Lo span lineare di un sottoinsieme $X \subset \mathbb{P}(V)$ è denotato con $\langle X \rangle \subseteq V$.

2.2 IL TEOREMA DI KRUSKAL

Dato un tensore $T \in A \otimes B \otimes C$, vogliamo mostrare che la scrittura

$$(2.2) \quad T = a_1 \otimes b_1 \otimes c_1 + \dots + a_r \otimes b_r \otimes c_r,$$

è essenzialmente unica se i suoi fattori sono “abbastanza” indipendenti.

Osservazione 2.2.1. Una condizione semplice per l'unicità è che T non possa essere ricondotto a una somma di matrici di rango uno, perché accadrebbe quanto descritto nell'Equazione (2.1). Consideriamo ad esempio

$$\begin{aligned} T &= a_1 \otimes b_1 \otimes c_1 + a_1 \otimes b_2 \otimes c_2 + a_3 \otimes b_3 \otimes c_3 + \dots + a_r \otimes b_r \otimes c_r \\ &= a_1 \otimes (b_1 \otimes c_1 + b_2 \otimes c_2) + a_3 \otimes b_3 \otimes c_3 + \dots + a_r \otimes b_r \otimes c_r, \end{aligned}$$

dove ognuno degli insiemi $\{a_i\}$, $\{b_j\}$ e $\{c_k\}$ è formato da elementi linearmente indipendenti. Questa scrittura non è unica a causa del termine

$$a_1 \otimes (b_1 \otimes c_1 + b_2 \otimes c_2)$$

Osservazione 2.2.2. Se consideriamo per l'Equazione (2.2) gli insiemi $\mathcal{S}_A = \{[a_i]\} \subset \mathbb{P}A$, $\mathcal{S}_B = \{[b_i]\} \subset \mathbb{P}B$ e $\mathcal{S}_C = \{[c_i]\} \subset \mathbb{P}C$, allora l'unicità implica che siano formati da r punti distinti.

Definizione 2.2.3 (Posizione generale). Sia W uno spazio vettoriale finito dimensionale e $\mathcal{S} = \{x_1, \dots, x_p\} \subset \mathbb{P}W$ un insieme di punti. Diciamo che i punti di $\mathcal{S}$ sono in 2-posizione generale se nessuna coppia di punti coincide; sono in 3-posizione generale se nessuna terna di punti giace su una retta, e in generale, diremo che

sono in r -posizione generale se nessuna r -upla giace su un sottospazio proiettivo di dimensione $r - 2$ (talvolta detto $(r - 2)$ -piano).

La Figura 2.1 mostra un esempio di punti in posizione generale.




Figura 2.1: Rappresentazione di punti in 3-posizione e 4-posizione generale in uno spazio proiettivo.

Definizione 2.2.4 (Kruskal rank). Il *Kruskal rank* (o k -rango) di un insieme $\mathcal{S} \subset \mathbb{P}W$ è il massimo r tale per cui i punti di $\mathcal{S}$ sono in r -posizione generale. Lo indichiamo con $\mathbf{k}_{\mathcal{S}}$.

Esempio 2.2.5. Considerato il piano illustrato nella Figura 2.1 a destra, i punti $\mathcal{S} = \{q_1, q_2, q_3, q_4\}$ sono sia 2-posizione generale che in 3-posizione generale, quindi il k -rango dell'insieme $\mathcal{S}$ è 3.

Osservazione 2.2.6. Fissata una base per W tale per cui i punti di $\mathcal{S}$ possono essere scritti come colonne di una matrice M (è ben definito a meno di riscalamento), allora $\mathbf{k}_{\mathcal{S}}$ è il massimo intero positivo r tale per cui ogni sottoinsieme di r colonne di M sono vettori linearmente indipendenti. Questa era la definizione originale di Kruskal, e in questo contesto lo indichiamo con $\mathbf{k}_M$.

Osservazione 2.2.7. Dalla definizione segue che $\mathbf{k}_A \leq \text{rank}(A) \leq \min\{m, n\}$ per ogni matrice $A \in \mathbb{R}^{m \times n}$. In particolare, se A è full-rank, $\mathbf{k}_A = \text{rank}(A)$; se invece A ha due colonne linearmente dipendenti, $\mathbf{k}_A \leq 1$.

Possiamo enunciare il Teorema di Kruskal.

Teorema 2.2.8 (Kruskal [41]). Sia $T \in A \otimes B \otimes C$ che ammette decomposizione $T = \sum_{i=1}^r u_i \otimes v_i \otimes w_i$. Siano $\mathcal{S}_A = \{[u_i]\}$, $\mathcal{S}_B = \{[v_i]\}$ e $\mathcal{S}_C = \{[w_i]\}$. Se vale

$$(2.3) \quad r \leq \frac{1}{2}(\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} + \mathbf{k}_{\mathcal{S}_C}) - 1,$$

allora T ha rango r e la sua espressione come tensore di rango r è essenzialmente unica.

Osservazione 2.2.9. Se vale l'Equazione (2.3), segue che $\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}, \mathbf{k}_{\mathcal{S}_C} \geq 2$. Dimostriamolo per $\mathcal{S}_A$, gli altri casi sono analoghi. L'Equazione (2.3) si può riscrivere come

$$2 + 2r \leq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} + \mathbf{k}_{\mathcal{S}_C}.$$

Siccome $\mathbf{k}_{\mathcal{S}}$ è limitato dall'alto dalla cardinalità dell'insieme $\mathcal{S}$, in questo caso abbiamo $\mathbf{k}_{\mathcal{S}_B}, \mathbf{k}_{\mathcal{S}_C} \leq r$, e applicando questa disequazione all'equazione sopra otteniamo,

$$2 + 2r \leq \mathbf{k}_{\mathcal{S}_A} + r + r,$$

cioè $\mathbf{k}_{\mathcal{S}_A} \geq 2$.

Più in generale vale il seguente teorema:

Teorema 2.2.10 (Sidiropoulos e Bro [54]). *Sia $T \in A_1 \otimes A_2 \otimes \cdots \otimes A_d$ che ammette una decomposizione $T = \sum_{i=1}^r u_i^1 \otimes \cdots \otimes u_i^d$. Sia $\mathcal{S}_{A_k} = \{[u_i^k]\}$. Se vale*

$$(2.4) \quad \sum_{k=1}^r \mathbf{k}_{\mathcal{S}_{A_k}} \geq 2r + d - 1,$$

allora T ha rango r e la sua espressione come tensore di rango r è essenzialmente unica.

Osservazione 2.2.11. Osserviamo che nel caso delle matrici l'unicità è verificata solo per $r = 1$, in quanto $T = u \otimes v \in A \otimes B$. Tuttavia, le ipotesi del teorema non sono rispettate perché $\mathcal{S}_A = \{[u]\}, \mathcal{S}_B = \{[v]\}$ e i due insiemi hanno k -rango uno, e

$$\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} = 1 + 1 = 2 \geq 2r + 2 - 1 = 2 + 2 - 1 = 3.$$

Proposizione 2.2.12 (Landsberg [45], §12.5). *Dati degli spazi vettoriali A, B, C di dimensioni $\mathbf{a} = \mathbf{b} = \mathbf{c}$ e un tensore $T \in A \otimes B \otimes C$ di rango multilineare $(\mathbf{a}, \mathbf{a}, \mathbf{a})$. Se T ha rango $\mathbf{a}$, allora la fattorizzazione è unica. In particolare, quando $\mathbf{k}_{\mathcal{S}_A} = \mathbf{k}_{\mathcal{S}_B} = \mathbf{k}_{\mathcal{S}_C} = \mathbf{a}$, la condizione di unicità del teorema di Kruskal si estende a*

$$\mathbf{a} \leq r \leq \frac{1}{2}(\mathbf{a} + \mathbf{a} + \mathbf{a}) - 1 = \frac{3}{2}\mathbf{a} - 1$$

Introduciamo un lemma utile nella dimostrazione della proposizione.

Nuovo!

Lemma 2.2.13. *Nelle ipotesi sopra, se T ha rango multilineare $(\mathbf{a}, \mathbf{a}, \mathbf{a})$, allora gli insiemi $\{a_1, \dots, a_{\mathbf{a}}\}, \{b_1, \dots, b_{\mathbf{b}}\}, \{c_1, \dots, c_{\mathbf{c}}\}$ dati dai fattori della decomposizione CP sono formati da vettori linearmente indipendenti.*

Dimostrazione. Mostriamolo per i vettori $\{a_1, \dots, a_{\mathbf{a}}\}$, per gli altri insiemi segue per simmetria. Consideriamo la scrittura di T in componenti

$$(2.5) \quad T_{ijk} = \sum_{l=1}^{\mathbf{a}} (a_l)_i (b_l)_j (c_l)_k.$$

Per definizione di unfolding troviamo

$$(2.6) \quad (T_{(1)})_{i, \mathbb{L}(j,k)} = \sum_{l=1}^{\mathbf{a}} (a_l)_i (b_l \otimes c_l)_{\mathbb{L}(j,k)}.$$

Dunque $T_{(1)} = U M^{\top}$ dove

$$U = \begin{bmatrix} a_1 & \dots & a_{\mathbf{a}} \end{bmatrix}, \quad V = \begin{bmatrix} b_1 & \dots & b_{\mathbf{b}} \end{bmatrix}, \quad W = \begin{bmatrix} c_1 & \dots & c_{\mathbf{c}} \end{bmatrix},$$

il fatto che sia prodotto di hadamard va motivato?

e $M = B \odot C$ è una matrice $\mathbf{a}^2 \times \mathbf{a}$. Per definizione di rango multilineare e per una disuguaglianza nota sul rango troviamo

$$\mathbf{a} = \text{rank}(T_{(1)}) = \text{rank}(U M^{\top}) \leq \min\{\text{rank}(U), \text{rank}(M)\} \leq \text{rank}(U).$$

Essendo U di taglia $\mathbf{a} \times \mathbf{a}$, necessariamente $\text{rank}(U) = \mathbf{a}$, da cui l'indipendenza lineare. $\square$

Dimostrazione della Proposizione. Se $r = \mathbf{a}$, consideriamo la decomposizione

$$T = a_1 \otimes b_1 \otimes c_1 + \dots + a_{\mathbf{a}} \otimes b_{\mathbf{a}} \otimes c_{\mathbf{a}}$$

Per ogni funzionale $\gamma_j \in C^*$, consideriamo la valutazione

$$T(\gamma_j) = \sum_{i=1}^{\mathbf{a}} \gamma_j(c_i) a_i \otimes b_i = U D_j V^T,$$

dove

$$U = \begin{bmatrix} a_1 & \dots & a_{\mathbf{a}} \end{bmatrix}, \quad D_j = \text{diag}(\gamma_j(c_1), \dots, \gamma_j(c_{\mathbf{a}})), \quad V = \begin{bmatrix} b_1 & \dots & b_{\mathbf{a}} \end{bmatrix}.$$

Osserviamo che se T ha rango multilineare $(\mathbf{a}, \mathbf{a}, \mathbf{a})$, per il Lemma 2.2.13 le matrici U, V sono invertibili, in particolare ma D_j è invertibile solo se $\gamma_j(c_i) \neq 0$ per ogni $i = 1, \dots, \mathbf{a}$. Fissiamo due funzionali $\gamma_1, \gamma_2 \in C^*$ tali che

- (i) Per ogni $j \in \{1, 2\}$, vale $\gamma_j(c_i) \neq 0$ per ogni $i = 1, \dots, \mathbf{a}$, da cui $T(\gamma_j)$ è invertibile.
- (ii) I rapporti $\lambda_i = \frac{\gamma_1(c_i)}{\gamma_2(c_i)}$ sono a due a due distinti.

Per comodità fissiamo $\gamma = \gamma_j$, e mostriamo la (i). Siccome $\{c_1, \dots, c_{\mathbf{a}}\}$ è una base per C , nessuno dei vettori c_i è nullo. Per ogni c_i , consideriamo l'insieme dei funzionali che si annullano con c_i

$$H_i := c_i^\perp = \{\gamma \in C^* \mid \gamma(c_i) = 0\},$$

che forma un iperpiano in C^* (la sua dimensione segue dalla formula della dimensione di un annullatore). Siccome $\mathbb{K}$ è infinito lo spazio C^* non è unione finita di sottospazi propri, allora esiste un funzionale $\gamma \in C^* \setminus \bigcup_{i=1}^{\mathbf{a}} H_i$ non banale. Per questa scelta, si ha che $\gamma(c_i) \neq 0$ per ogni i . Allora la matrice D_j è invertibile, da cui anche $T(\gamma_j)$ lo è, per ogni $j \in \{1, 2\}$. Da cui,

$$\begin{aligned} T(\gamma_1)T(\gamma_2)^{-1} &= (UD_1V^T)(UD_2V^T)^{-1} = UD_1V^TV^{-T}D_2^{-1}U^{-1} \\ &= UD_1D_2^{-1}U^{-1}, \end{aligned}$$

in altre parole, $T(\gamma_1)T(\gamma_2)^{-1}$ è diagonalizzabile con autovettori, dati dalla matrice U , univocamente determinati a meno di permutazione e riscalamento. Siccome tale matrice ha come autovalori λ_i , mostrando la (ii) otteniamo che gli autospazi hanno dimensione uno, da cui la tesi.

A questo punto possiamo mostrare la (ii), ovvero vediamo che i rapporti $\frac{\gamma_1(c_i)}{\gamma_2(c_i)}$ sono distinti. Se per assurdo $\frac{\gamma_1(c_i)}{\gamma_2(c_i)} = \frac{\gamma_1(c_k)}{\gamma_2(c_k)}$ per certi $i, k \in \{1, \dots, \mathbf{a}\}$, si avrebbe che

$$\gamma_1(c_i)\gamma_2(c_k) = \gamma_1(c_k)\gamma_2(c_i).$$

Sfruttando la linearità di γ_1 , troveremmo

$$\gamma_1(c_i\gamma_2(c_k) - c_k\gamma_2(c_i)) = 0.$$

Siccome γ_1 e γ_2 non si annullano sui vettori c_i e c_k , allora $c_i\gamma_2(c_k) - c_k\gamma_2(c_i) \notin \gamma_1^\perp$, quindi necessariamente $c_i\gamma_2(c_k) - c_k\gamma_2(c_i) = 0$, in quanto l'unico elemento fuori da

torna questa
precisazione?

$\gamma_1^\perp$ che viene mandato in zero da γ_1 è il vettore nullo. Ma essendo c_i e c_k linearmente indipendenti, le costanti $\gamma_2(c_k), \gamma_2(c_i)$ sarebbero nulle, che contraddirebbe la (i).

Ripetendo questo ragionamento su A e poi su B otteniamo l'unicità della fattorizzazione. Osserviamo che la stima dell'enunciato segue direttamente dal Teorema di Kruskal. $\square$

Enunciamo il permutation lemma, dimostrato da Kruskal nell'articolo originale, e di fondamentale importanza nella dimostrazione del Teorema di Kruskal.

Lemma 2.2.14 (Permutation lemma). *Siano $\mathcal{S} = \{p_1, \dots, p_r\}$ e $\tilde{\mathcal{S}} = \{q_1, \dots, q_r\}$ due insiemi di punti in $\mathbb{P}W$ a due a due distinti (i.e. tali che $\mathbf{k}_S \geq 2$) e supponiamo che $\langle \tilde{\mathcal{S}} \rangle = W$. Se ogni iperpiano $H \subset \mathbb{P}W$ che contiene almeno $\dim(H) + 1$ punti di $\tilde{\mathcal{S}}$ è tale che $\#(\mathcal{S} \cap H) \geq \#(\tilde{\mathcal{S}} \cap H)$, allora $\mathcal{S} = \tilde{\mathcal{S}}$.*

Refactored!!

Osservazione 2.2.15. Fissata una base per W e rappresentati i punti di $\mathcal{S}$ e $\tilde{\mathcal{S}}$ con due matrici M e $\tilde{M}$, l'ipotesi si può rifrasedare con la formulazione originale. Indichiamo con $\text{nnz}(\cdot)$ il numero di elementi non nulli di un vettore. Poiché $\langle \mathcal{S} \rangle = W$ segue che $\text{rank}(\tilde{M}) = \mathbf{w}$. Ogni vettore $x \in (\mathbb{R}^{\mathbf{w}})^* \setminus \{0\}$ definisce un iperpiano proiettivo $H \subset \mathbb{P}W$, la cui dimensione è $\mathbf{w} - 2$. Le colonne che si annullano nel prodotto $\tilde{M}^\top x$ corrispondono ai punti di $\tilde{\mathcal{S}}$ che soddisfano l'equazione di H . Pertanto, $\#(\tilde{\mathcal{S}} \cap H) = r - \text{nnz}(\tilde{M}^\top x)$. La condizione $\#(\tilde{\mathcal{S}} \cap H) \geq \dim(H) + 1$ si traduce in $r - \text{nnz}(\tilde{M}^\top x) \geq \mathbf{w} - 1$, che equivale a $\text{nnz}(\tilde{M}^\top x) \leq r - \text{rank}(\tilde{M}) + 1$. Da cui la condizione originale: per ogni vettore x tale che $\text{nnz}(\tilde{M}^\top x) \leq r - \text{rank}(\tilde{M}) + 1$, la tesi $\#(\mathcal{S} \cap H) \geq \#(\tilde{\mathcal{S}} \cap H)$ impone che valga $\text{nnz}(M^\top x) \leq \text{nnz}(\tilde{M}^\top x)$.

Definizione 2.2.16 (Concise tensor). Un tensore $T \in A_1 \otimes A_2 \otimes \dots \otimes A_d$ si dice *1-concise* se non esiste un sottospazio proprio $A'_1 \subset A_1$ tale che $T \in A'_1 \otimes A_2 \otimes \dots \otimes A_d$. Similmente, definiamo la *i-conciseness* per $i \in \{2, \dots, d\}$. Un tensore è detto *concise* se è *i-concise* per ogni i .

Osservazione 2.2.17. In altre parole T è concise se non è contenuto in nessun sottospazio proprio $A'_1 \otimes A'_2 \otimes \dots \otimes A'_n \subset A_1 \otimes A_2 \otimes \dots \otimes A_n$. Possiamo pensare a i tensori concise come tensori che usano tutte le dimensioni degli spazi A_i .

Osservazione 2.2.18. Tale proprietà giocherà un ruolo chiave nella dimostrazione del Teorema di Kruskal, dove supporremo che $\langle \mathcal{S}_{A_k} \rangle = A_k$; a questo scopo abbiamo indebolito il permutation lemma con l'ipotesi $\langle \mathcal{S} \rangle = W$ (che non era presente nell'enunciato di Kruskal). La prossima proposizione afferma che tale restrizione è ben posta, ed esclude casi banali dalla dimostrazione del teorema di Kruskal.

Proposizione 2.2.19 (Lunghezza di un tensore concise). *Sia $n > 2$. Sia $T \in A_1 \otimes \cdots \otimes A_d$ di rango r . Diciamo che $T \in A'_1 \otimes \cdots \otimes A'_d$, dove $A'_j \subseteq A_j$ con almeno un'inclusione propria. Allora ogni espressione $T = \sum_{i=1}^{\rho} u_i^1 \otimes \cdots \otimes u_i^d$ con qualche $u_j^s \notin A'_s$ ha $\rho > r$.*

Osservazione 2.2.20. In altre parole, se T non è concise, allora $\rho > r$.

Dimostrazione. Supponiamo per assurdo che $\rho = r$, e consideriamo la scrittura $T = \sum_{j=1}^r u_j^1 \otimes \cdots \otimes u_j^d$. Siccome almeno un'inclusione è stretta, supponiamo senza perdita di generalità che $u_1^1 \notin A'_1$. Allora esiste un funzionale $\alpha \in A_1^*$ tale che $\alpha(A'_1) = 0$ ma $\alpha(u_1^1) \neq 0$. Siccome $T \in A'_1 \otimes \cdots \otimes A'_d$ allora valutando T in α si deve avere che

$$0 = T(\alpha) = \sum_{j=1}^r \alpha(u_j^1)(u_j^2 \otimes \cdots \otimes u_j^d).$$

Siccome $\alpha(u_1^1) \neq 0$, possiamo scrivere il primo addendo della sommatoria come combinazione degli altri, ossia

$$u_1^1 \otimes u_1^2 \otimes \cdots \otimes u_1^d = \sum_{j=2}^r \lambda_j (u_j^2 \otimes \cdots \otimes u_j^d),$$

dove $\lambda_j := -\frac{\alpha(u_j^1)}{\alpha(u_1^1)}$. Sostituendo quest'espressione nell'equazione originale di T , troviamo che

$$\begin{aligned} T &= u_1^1 \otimes \left(\sum_{j=2}^r \lambda_j (u_j^2 \otimes \cdots \otimes u_j^d) \right) + \sum_{j=2}^r u_j^1 \otimes (u_j^2 \otimes \cdots \otimes u_j^d) \\ &= \sum_{j=2}^r (\lambda_j u_1^1 + u_j^1) \otimes u_j^2 \otimes \cdots \otimes u_j^d, \end{aligned}$$

che è una decomposizione di T di rango $r - 1$, che contraddice la minimalità di r , assurdo. $\square$

Per dimostrare il Lemma 2.2.14 abbiamo bisogno di un piccolo risultato insiemistico

Lemma 2.2.21. *Dati tre insiemi A, B e C di cardinalità finita tali che $C \subseteq B$, si ha*

$$\#(A \cap (B \setminus C)) = \#(A \cap B) - \#(A \cap B \cap C).$$

Dimostrazione. Sviluppando

$$A \cap (B \setminus C) = A \cap (B \cap C^c) = (A \cap B) \cap C^c = (A \cap B) \setminus C,$$

da cui

$$\#((A \cap B) \setminus C) = \#(A \cap B) - \#(A \cap B \cap C),$$

dove abbiamo usato che $\#(X \setminus Y) = \#X - \#(X \cap Y)$. $\square$

HO provato a riscrivere l'induzione inversa. È abbastanza chiara così?

Dimostrazione del permutation lemma. Consideriamo la seguente proprietà: i k -piani L che contengono almeno $\dim(L)+1 = k+1$ punti di $\tilde{\mathcal{S}}$, soddisfano $\#(\mathcal{S} \cap L) \geq \#(\tilde{\mathcal{S}} \cap L)$. Osserviamo che per gli 0-piani, ovvero i punti, la proprietà implica la tesi, in quanto per ogni punto $P \in \tilde{\mathcal{S}}$ tale che $1 = \#(\mathcal{S} \cap \{P\}) = \#(\tilde{\mathcal{S}} \cap \{P\})$, allora $\mathcal{S} \cap \{P\} = \tilde{\mathcal{S}} \cap \{P\}$, ovvero $\mathcal{S} = \tilde{\mathcal{S}}$, in quanto i punti di $\mathcal{S}$ sono distinti. Notiamo anche che per ipotesi la proprietà è vera per i $w-2$ -piani, cioè per gli iperpiani. Possiamo quindi dimostrare la tesi assumendo che la proprietà sopra valga per i $(k+1)$ -piani, e mostrando che valga per i k -piani. Tramite un'induzione discendente possiamo partire dagli iperpiani e arrivare fino al caso base, da cui $\mathcal{S} = \tilde{\mathcal{S}}$.

Fissiamo un k -piano L contenente $\mu \geq k+1$ punti di $\tilde{\mathcal{S}}$, e denotiamo con $\{M_\alpha\}$ l'insieme dei piani di dimensione $k+1$ che contengono L e almeno $\mu+1$ elementi di $\tilde{\mathcal{S}}$. È possibile costruire un tale piano M_α prendendo il sottospazio generato da L e un punto di $\tilde{\mathcal{S}}$ non appartenente a L . Osserviamo che $\#\{M_\alpha\} \geq 2$, cioè ci sono almeno due piani distinti contenenti L : se fosse $\#\{M_\alpha\} = 0$, non esisterebbero punti di $\tilde{\mathcal{S}}$ fuori da L , cioè $\mathcal{S} \subset L$, mentre se $\#\{M_\alpha\} = 1$, $\tilde{\mathcal{S}}$ sarebbe contenuto interamente nell'unico k -piano M_α . In ogni caso, $\tilde{\mathcal{S}}$ sarebbe contenuto in un sottospazio di dimensione al più $w-2$, ma ciò è impossibile perché $\langle \tilde{\mathcal{S}} \rangle = W$, quindi $\mathbb{P}W$, che ha dimensione $w-1$, è generato dai punti di $\tilde{\mathcal{S}}$. Dalla costruzione segue inoltre che ogni $(k+1)$ -piano M_α contiene almeno $\mu+1 \geq k+2$ punti di $\tilde{\mathcal{S}}$, quindi applicando l'ipotesi induttiva troviamo

$$(2.7) \quad \#(\tilde{\mathcal{S}} \cap M_\alpha) \leq \#(\mathcal{S} \cap M_\alpha).$$

Osserviamo che

$$(2.8) \quad \#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap (M_\alpha \setminus L)) = r,$$

$$(2.9) \quad \#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap (M_\alpha \setminus L)) \leq r.$$

La prima segue perché ogni punto di $\tilde{\mathcal{S}}$ che non appartiene a L sta esattamente in un piano M_α , mentre la seconda segue perché ogni punto di $\mathcal{S}$ non in L sta in al più un piano M_α . Dal Lemma 2.2.21 otteniamo l'identità (che vale anche per $\tilde{\mathcal{S}}$),




Figura 2.2: Interpretazione geometrica della costruzione nel caso $k = 1$ (L è una retta, e gli M_α sono piani). In questo caso L contiene almeno $\mu \geq k + 1 = 2$ punti di $\tilde{\mathcal{S}}$, e M_α contiene almeno $\mu + 1 \geq k + 2 = 3$ di $\tilde{\mathcal{S}}$; per ipotesi induttiva, $3 \leq \#(\tilde{\mathcal{S}} \cap M_\alpha) \leq \#(\mathcal{S} \cap M_\alpha)$. A priori i punti di $\mathcal{S}$ potrebbero non intersecare L , ma attraverso un conteggio troviamo che $2 \leq \#(\tilde{\mathcal{S}} \cap L) \leq \#(\mathcal{S} \cap L)$.

$$\#(\tilde{\mathcal{S}} \cap (M_\alpha \setminus L)) = \#(\tilde{\mathcal{S}} \cap M_\alpha) - \#(\tilde{\mathcal{S}} \cap M_\alpha \cap L) = \#(\tilde{\mathcal{S}} \cap M_\alpha) - \#(\tilde{\mathcal{S}} \cap L),$$

dove nell'ultimo passaggio abbiamo il contenimento $L \subseteq M_\alpha$. Sostituendola nelle Equazioni (2.8) e (2.9) troviamo

$$\begin{aligned} (1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap M_\alpha) &= r, \\ (1 - \#\{M_\alpha\})\#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha) &\leq r. \end{aligned}$$

Mettendole insieme e applicando l'Equazione (2.7) otteniamo

$$\begin{aligned} (1 - \#\{M_\alpha\})\#(\mathcal{S} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha) &\leq (1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\tilde{\mathcal{S}} \cap M_\alpha) \\ &\leq (1 - \#\{M_\alpha\})\#(\tilde{\mathcal{S}} \cap L) + \sum_{\alpha} \#(\mathcal{S} \cap M_\alpha), \end{aligned}$$

semplificando le sommatorie, e usando che $(1 - \#\{M_\alpha\}) < 0$, troviamo

$$\#(\tilde{\mathcal{S}} \cap L) \leq \#(\mathcal{S} \cap L).$$

□

Introduciamo un ultimo lemma valido in generale:

Lemma 2.2.22. *Sia $T \in A \otimes B$ un tensore di rango r che ammette due espressioni $T = a_1 \otimes b_1 + \dots + a_r \otimes b_r$ e $T = a_1 \otimes b_{\sigma(1)} + \dots + a_r \otimes b_{\sigma(r)}$, dove $\sigma \in \mathfrak{S}_r$ è una permutazione. Allora $\sigma = \text{Id}$.*

Dimostrazione. Riscriviamo T come

$$T = u_1 \otimes b_1 + \dots + u_r \otimes b_r = u_1 \otimes b_{\sigma(1)} + \dots + u_r \otimes b_{\sigma(r)},$$

se e solo se

$$u_1 \otimes (b_{\sigma(1)} - b_1) + \dots + u_r \otimes (b_{\sigma(r)} - b_r) = 0.$$

Da cui, $b_{\sigma(j)} = b_j$ per ogni $j \in \{1, \dots, r\}$, allora $\sigma = \text{Id}$. $\square$

Siamo ora pronti a dimostrare il Teorema 2.2.8.

Dimostrazione del Teorema di Kruskal. Dalla Proposizione 2.2.19 possiamo supporre che T sia concisa, ovvero che A, B, C coincidano con i sottospazi generati da $\tilde{\mathcal{S}}_A, \tilde{\mathcal{S}}_B, \tilde{\mathcal{S}}_C$, rispettivamente. Date quindi due decomposizioni

$$(2.10) \quad T = \sum_{j=1}^r u_j \otimes v_j \otimes w_j = \sum_{j=1}^r \tilde{u}_j \otimes \tilde{v}_j \otimes \tilde{w}_j$$

di lunghezza r , con la prima decomposizione che soddisfa le ipotesi del teorema, vogliamo mostrare che coincidano a meno di permutazione e riscalamento dei fattori. Notiamo che, quando l'unicità della decomposizione di lunghezza r è verificata, il rango di T è r ; infatti, se sopra apparisse una decomposizione di lunghezza $r - 1$, potremmo ricostruirne una di lunghezza r rimpiazzando $\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1$ con $\frac{1}{2}\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1 + \frac{1}{2}\tilde{u}_1 \otimes \tilde{v}_1 \otimes \tilde{w}_1$. Mostriamo prima che $\mathcal{S}_A = \tilde{\mathcal{S}}_A$, $\mathcal{S}_B = \tilde{\mathcal{S}}_B$ e $\mathcal{S}_C = \tilde{\mathcal{S}}_C$. Per simmetria basta mostrare l'ultima affermazione, sfruttando il permutation lemma.

Consideriamo un iperpiano $H \subset \mathbb{P}C$ tale che $\#(\tilde{\mathcal{S}}_C \cap H) \geq c - 1$, allora

$$(2.11) \quad \#(\mathcal{S}_C \cap H) \geq \#(\tilde{\mathcal{S}}_C \cap H),$$

le ipotesi sono garantite dall'Osservazione 2.2.9 e dal fatto che $\langle \tilde{\mathcal{S}}_C \rangle = C$. Definiamo il numero $S := \#(\mathcal{S}_C \not\subset H)$ dei punti di $\mathcal{S}_C$ non contenuti in H , e scomponiamo

$$T = \sum_{j=1}^r u_j \otimes v_j \otimes w_j = \sum_{\sigma=1}^S u_\sigma \otimes v_\sigma \otimes w_\sigma + \sum_{\mu=S+1}^r u_\mu \otimes v_\mu \otimes w_\mu,$$

dove abbiamo riordinato gli indici j affinché i primi S dei $[w_j]$ non stiano in H . L'Equazione (2.11) si può riformulare nel modo seguente

$$\#(\tilde{\mathcal{S}}_C \not\subset H) \geq \#(\mathcal{S}_C \not\subset H) = S,$$

dove abbiamo effettuato le sostituzioni $\#(\mathcal{S}_C \cap H) = r - \#(\mathcal{S}_C \not\subset H)$ e $\#(\tilde{\mathcal{S}}_C \cap H) = r - \#(\tilde{\mathcal{S}}_C \not\subset H)$. Fissiamo un funzionale $h \in \hat{H}^\perp$ non nullo, e consideriamo la valutazione di T in h ,

$$T(h) = \sum_{\sigma=1}^S u_\sigma \otimes v_\sigma h(w_\sigma) \in A \otimes B \simeq \mathbb{R}^{a \times b},$$

dove nessuno dei $h(w_\sigma)$ è nullo. In particolare,

$$\#(\tilde{\mathcal{S}}_C \not\subset H) \geq \text{rank}(T(h)).$$

Rappresentando $T(h)$ in $\mathbb{K}^{a \times b}$ tramite il passaggio alle coordinate, troviamo

$$T(h) = U_S D V_S^*,$$

dove

$$U_S = [u_1 | \dots | u_S] \in \mathbb{K}^{a \times S}, \quad V_S = [v_1 | \dots | v_S] \in \mathbb{K}^{b \times S}, \quad D = \text{diag}(h(w_1), \dots, h(w_S)),$$

in particolare D è di taglia $S \times S$ ed invertibile. Per la disuguaglianza di Sylvester [36, Pag. 12]

$$\begin{aligned} \text{rank}(T(h)) &= \text{rank}(U_S D V_S^*) = \text{rank}(U_S D) + \text{rank}(V_S^*) - S \\ &\geq \dim \langle u_\sigma \rangle_{\sigma=1}^S + \dim \langle v_\sigma \rangle_{\sigma=1}^S - S. \end{aligned}$$

Per definizione di k -rango, valgono $\dim \langle u_\sigma \rangle \geq \min\{S, \mathbf{k}_{S_A}\}$ e $\dim \langle v_\sigma \rangle \geq \min\{S, \mathbf{k}_{S_B}\}$. Mettendo insieme queste ultime stime otteniamo che

$$(2.12) \quad \#(\tilde{\mathcal{S}}_C \not\subset H) \geq \min\{S, \mathbf{k}_{S_A}\} + \min\{S, \mathbf{k}_{S_B}\} - S.$$

Questo concluderebbe se sapessimo che $S \leq \min\{\mathbf{k}_{S_A}, \mathbf{k}_{S_B}\}$. Riscrivendo l'Equazione (2.3) dell'ipotesi, troviamo

$$(2.13) \quad r - \mathbf{k}_{S_C} + 1 \leq \mathbf{k}_{S_A} + \mathbf{k}_{S_B} - r - 1.$$

Siccome $\#(\tilde{\mathcal{S}}_C \cap H) \geq c - 1$, dall'equazione sopra otteniamo

$$\begin{aligned}
 \#(\tilde{\mathcal{S}}_C \not\subset H) &= r - \#(\tilde{\mathcal{S}}_C \cap H) \\
 &\leq r - (c - 1) \\
 (2.14) \quad &\leq r - (\mathbf{k}_{\mathcal{S}_C} - 1) \quad \text{dato che } c - 1 \geq \mathbf{k}_{\mathcal{S}_C} - 1, \\
 &\leq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1.
 \end{aligned}$$

A questo punto possiamo combinare le limitazioni trovate nelle Equazioni (2.12) e (2.14),

$$(2.15) \quad \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1 \geq \#(\tilde{\mathcal{S}}_C \not\subset H) \geq \min\{S, \mathbf{k}_{\mathcal{S}_A}\} + \min\{S, \mathbf{k}_{\mathcal{S}_B}\} - S.$$

Se fosse $S \geq \min\{\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}\}$, avremmo

$$\mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - r - 1 \geq \mathbf{k}_{\mathcal{S}_A} + \mathbf{k}_{\mathcal{S}_B} - S$$

ovvero $-r - 1 \geq -S$ cioè $r + 1 \leq S$, il che è assurdo. Quindi $S \leq \min\{\mathbf{k}_{\mathcal{S}_A}, \mathbf{k}_{\mathcal{S}_B}\}$, e dal permutation lemma segue l'uguaglianza $\mathcal{S}_C = \tilde{\mathcal{S}}_C$.

Supponiamo ora di avere due scritture di T che differiscono da due permutazioni degli indici tramite $\sigma, \tau \in \mathfrak{S}_r$:

$$\begin{aligned}
 T &= u_1 \otimes v_1 \otimes w_1 + \dots + u_r \otimes v_r \otimes w_r \\
 &= u_1 \otimes v_{\sigma(1)} \otimes w_{\tau(1)} + \dots + u_r \otimes v_{\sigma(r)} \otimes w_{\tau(r)}.
 \end{aligned}$$

Se $\sigma = \tau$, possiamo porre $a_j = u_j$, $b_j = v_j \otimes w_j$ e applicare il Lemma 2.2.22.

Se $\sigma \neq \tau$, allora esiste il più piccolo indice $j_0 \in \{1, \dots, r\}$ tale che $\sigma(j_0) =: s_0 \neq t_0 := \tau(j_0)$. Affermiamo che esistano due sottoinsiemi $S, T \subset \{1, \dots, r\}$ con le seguenti proprietà:

- (i) $s_0 \in S, t_0 \in T$,
- (ii) $S \cap T = \emptyset$,
- (iii) $\#S \leq r - \mathbf{k}_{\mathcal{S}_B} + 1$, $\#T \leq r - \mathbf{k}_{\mathcal{S}_C} + 1$, e
- (iv) Esistono due iperpiani $\hat{H}_S \subset B$ e $\hat{H}_T \subset C$ tali che
 - $s_0 \notin \hat{H}_S$ e $t_0 \notin \hat{H}_T$.
 - I sottospazi $\langle v_j \mid j \in S^c \rangle$ e $\langle w_j \mid j \in T^c \rangle$ sono contenuti negli iperpiani $\hat{H}_S$ e $\hat{H}_T$ rispettivamente.

Qui, $S^c = \{1, \dots, r\} \setminus S$. L'idea è costruire due iperpiani $\hat{H}_S$ e $\hat{H}_T$ che separino v_{s_0} da v_{t_0} e w_{s_0} da w_{t_0} come in Figura 2.3, per trovare un funzionale che annulli T , da cui poi trovare un assurdo violando l'ipotesi di Kruskal.

Partiamo da costruire un iperpiano $\hat{H}_T$ che soddisfi la (iv). Fissiamo una base $\mathcal{C}$ di C tale che $\{w_{t_0}, w_{s_0}\} \subset \mathcal{C}$, e definiamo il sottospazio $\hat{H}_T := \langle \mathcal{C} \setminus \{w_{t_0}\} \rangle$ di dimensione $c - 1$. Possiamo riscrivere $\hat{H}_T = \langle w_j \mid j \in T^c \rangle$, dove T^c è l'insieme dei $c - 1$ indici di supporto tali che $t_0 \notin T$. Dalla definizione di k -rango, vale $c \geq k_{S_C}$, dunque $\#T^c \geq k_{S_C} - 1$. Questo assicura che $\#T$ sia strettamente limitata da k_{S_B} , in quanto

$$\#T = r - \#T^c \leq r - k_{S_C} + 1 \leq k_{S_A} + k_{S_B} - r - 1 \leq k_{S_B} - 1.$$

La penultima disuguaglianza segue dall'Equazione (2.13), mentre l'ultima segue da $k_{S_A} \leq r$. Procediamo ora a costruire $\hat{H}_S$. Consideriamo il sottospazio $V_T := \langle v_j \mid j \in T \rangle$, che dalla stima su $\#T$ ha dimensione al più $k_{S_B} - 1$. Osserviamo che $v_{s_0} \notin V_T$; se così non fosse, l'insieme $\{s_0\} \cup T$ conterrebbe al più k_{S_B} vettori, ma il vettore v_{s_0} sarebbe linearmente dipendente rispetto ai vettori $\{v_j \mid j \in T\}$, che contraddirebbe la definizione di k -rango. Da cui, completando il sottospazio $\langle v_j \mid j \in T \rangle$ ad altri vettori in $\pi^{-1}(\mathcal{S}_B)$, possiamo trovare un iperpiano $\hat{H}_S \subset B$ contenente $\langle v_t \mid t \in T \rangle$ ma non v_{s_0} . Sia ora $S^c := \{j \mid v_j \in \hat{H}_S\}$. Similmente a quanto visto per T , valgono $\#S^c \geq k_{S_B} - 1$, dunque $\#S \leq r - k_{S_B} + 1$. Dalla costruzione segue che $T \subseteq S^c$, da cui $S \cap T = \emptyset$. Allora S e T hanno le proprietà desiderate.

la figura va sistemata, lo farò alla fine




Figura 2.3: Rappresentazione della costruzione degli iperpiani $\hat{H}_T \subset C$ e $\hat{H}_S \subset B$ e della separazione degli indici nella dimostrazione del Teorema di Kruskal.

2 Unicità della fattorizzazione CP

La formula delle dimensioni dell'ortogonale assicura che esista un elemento non banale in $\hat{H}_S^\perp \times \hat{H}_S^\perp$, infatti

$$\dim(\hat{H}_S^\perp \times \hat{H}_S^\perp) = \dim(\hat{H}_S^\perp) \dim(\hat{H}_S^\perp) = (\mathbf{b} - (\mathbf{b} - 1))(\mathbf{c} - (\mathbf{c} - 1)) = 1.$$

Notiamo che per costruzione $T|_{\hat{H}_S^\perp \times \hat{H}_T^\perp} = 0$: preso l'unico elemento non zero $(\beta, \gamma) \in \hat{H}_S^\perp \times \hat{H}_T^\perp$, si ha

$$\begin{aligned} 0 = T(\beta, \gamma) &= \sum_{j=1}^r u_j \beta(v_j) \gamma(w_j) \\ &= \sum_{j=1}^r u_j \beta(v_{\sigma(j)}) \gamma(w_{\tau(j)}) = \sum_{j \in \mathcal{J}} u_j \beta(v_{\sigma(j)}) \gamma(w_{\tau(j)}), \end{aligned}$$

dove $\mathcal{J} = \{j \mid \sigma(j) \in S, \tau(j) \in T\} \supseteq \{j \mid \sigma(j) \neq \tau(j)\}$ è non vuoto, in quanto contiene almeno j_0 , e ha cardinalità limitata da $\#S$ e $\#T$. Analizziamo meglio l'espressione sopra. Nel caso della prima sommatoria tutti i termini $\beta(v_j) \gamma(w_j)$ sono nulli. Se così non fosse, esisterebbe un indice j tale per cui $\beta(v_j) \neq 0$ e $\gamma(w_j) \neq 0$, ma ciò accadrebbe, per definizione di annullatore, se e solo se $v_j \notin \hat{H}_S$ (cioè $j \in S$) e $w_j \notin \hat{H}_T$ (cioè $j \in T$), ma ciò accade se e solo se $j \in S \cap T = \emptyset$. Nella seconda riga, similmente, un addendo è non nullo se $v_{\sigma(j)} \notin \hat{H}_S$ e $w_{\tau(j)} \notin \hat{H}_T$, cioè $j \in \mathcal{J}$. Allora esiste una combinazione lineare non banale tra gli elementi u_j per gli indici $j \in \mathcal{J}$, ma $\#\mathcal{J} \leq \min\{\#S, \#T\} \leq \min\{r - \mathbf{k}_{S_B} + 1, r - \mathbf{k}_{S_C} + 1\}$, che è minore di $\mathbf{k}_{S_A}$, che produce l'assurdo, perché per lineare indipendenza e definizione di k -rango, questi dovrebbero essere almeno $\mathbf{k}_{S_A}$. Infatti, se fosse $\mathbf{k}_{S_A} \geq \min\{r - \mathbf{k}_{S_B} + 1, r - \mathbf{k}_{S_C} + 1\}$, si avrebbero

$$r - \mathbf{k}_{S_B} + 1 \geq \mathbf{k}_{S_A},$$

$$r - \mathbf{k}_{S_C} + 1 \geq \mathbf{k}_{S_A}.$$

Sommando le disequazioni troveremmo $2r + 2 \geq \mathbf{k}_{S_A} + \mathbf{k}_{S_B} + \mathbf{k}_{S_A}$, che violerebbe l'ipotesi. Da cui $\sigma = \tau$, che completa la dimostrazione. □

La condizione di Kruskal è sufficiente ma non necessaria. Il seguente risultato fornisce una condizione necessaria ma non sufficiente:

Teorema 2.2.23 (Non unicità CP, Liu e Sidiropoulos [47]). *Dato un tensore $T = \llbracket U_1, \dots, U_d \rrbracket$ tale per cui*

$$\min_j \{ \mathbf{R}(U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1) \} < r,$$

allora la fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$ non è essenzialmente unica.

Osservazione 2.2.24. Nel 1977 Kruskal dimostra l'unicità della fattorizzazione CP nel caso 3-dimensionale con un argomento di 40 pagine [41], di non semplice lettura. La sua idea è stata riadattata da diversi matematici, e attualmente abbiamo due dimostrazioni brevi che sfruttano il permutation lemma, ma che seguono idee diverse. La prima riscrittura, ad opera di Stegeman e Sidiropoulos [58] era 16 pagine, ed è stata di seguito riadattata da Landsberg [45] in un argomento geometrico di poche pagine, che abbiamo presentato in questo elaborato. La seconda rielaborazione, ad opera di Rhodes (circa 9 pagine) in [51] utilizza un approccio diverso, che non discuteremo. Il caso generale, dimostrato da Sidiropoulos e Bro [54] si ottiene (in maniera non ovvia) riconducendosi al caso 3-dimensionale, abbiamo ritenuto più interessante trattare solamente il caso in dimensione bassa.

3

APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA

Aggiornato

L'algoritmo di moltiplicazione matriciale si può esprimere come mappa bilineare che manda due matrici A e B nel prodotto $C = AB$. Possiamo naturalmente rappresentare tale mappa come un tensore T , e quindi cercarne una rappresentazione di rango più basso. Questo dà il vantaggio di valutare le matrici A , B in un algoritmo che dipende dalle entrate di T per ridurre il numero di moltiplicazioni in base al rango di T . Infatti, studiamo gli *algoritmi di moltiplicazione veloce*, ovvero gli algoritmi di moltiplicazione matriciale che impiegano asintoticamente un numero minore di operazioni aritmetiche rispetto all'algoritmo classico, ottenendo un esponente di complessità asintotica minore di 3 per le matrici quadrate. In questo contesto, mostriamo che il rango della forma bilineare dà il numero di moltiplicazioni di un algoritmo, e viceversa. Risulta utile tener traccia del costo ottimale della moltiplicazione ω e dimostrare attraverso il Teorema di Strassen che il rango del tensore può essere messo in corrispondenza con ω . Concludiamo definendo l'algoritmo di Strassen e ricavando un algoritmo approssimato a partire da quello classico, sviluppando la loro fattorizzazione tensoriale e studiando i rispettivi errori algoritmici.

3.1 MAPPE MULTILINEARI E MOLTIPLICAZIONE TRA MATRICI

Definizione 3.1.1 (Moltiplicazione matriciale). Fissati degli interi positivi m, n, p , la moltiplicazione tra due matrici $m \times n$ e $n \times p$ è una mappa bilineare

$$\langle m, n, p \rangle: \mathbb{C}^{m \times n} \times \mathbb{C}^{n \times p} \rightarrow \mathbb{C}^{m \times p}$$
$$(A, B) \mapsto C = AB.$$

Spesso ci riferiremo a $\langle m, n, p \rangle$ chiamandolo “algoritmo”, ad esempio nel contesto degli algoritmi di moltiplicazione veloce.

3 Applicazioni della CP alla complessità aritmetica

Osservazione 3.1.2. La bilinearità della mappa sopra segue immediatamente dalla definizione del prodotto matriciale:

$$(3.1) \quad (AB)_{ij} = \sum_{k=1}^n a_{ik}b_{kj},$$

dove $i = 1, \dots, m$ e $j = 1, \dots, p$.

Osservazione 3.1.3. Possiamo vedere la moltiplicazione tra matrici anche come una forma trilineare

$$\mathbb{C}^{m \times n} \times \mathbb{C}^{n \times p} \times \mathbb{C}^{m \times p} \rightarrow \mathbb{C}$$

$$(A, B, C) \mapsto \text{trace}(ABC)$$

RAPPRESENTAZIONE IN COORDINATE DI UNA FORMA BILINEARE

Consideriamo degli spazi vettoriali U, V, W di dimensioni I, J, K , rispettivamente. Un modo semplice di rappresentare una forma bilineare $\varphi: U \times V \rightarrow W$ come un tensore è farlo partendo dalle slices. Fissato $k \in \{1, \dots, K\}$ e considerata la sua componente k -esima $\varphi_k: U \times V \rightarrow \mathbb{R}$, esiste una matrice $M \in \mathbb{R}^{I \times J}$ tale che $\varphi_k(u, v) = u^\top M v$ per ogni $(u, v) \in \mathbb{R}^I \times \mathbb{R}^J$. Scrivendo ogni componente di

$\varphi = \begin{bmatrix} \varphi_1 \\ \vdots \\ \varphi_K \end{bmatrix}$ in questa forma, otteniamo un tensore $T \in \mathbb{R}^{I \times J \times K}$ tale che le sue fette frontali $T_{:, :, 1}, \dots, T_{:, :, K}$ rappresentano ognuna delle K forme bilineari φ_k , ossia che

$$(3.2) \quad \varphi_k(u, v) = u^\top T_{:, :, k} v = \sum_{i=1}^I \sum_{j=1}^J T_{i,j,k} u_i v_j, \text{ per ogni } k = 1, \dots, K.$$

In forma tensoriale,

$$(3.3) \quad \varphi(u, v) = \begin{bmatrix} \varphi_1(u, v) \\ \vdots \\ \varphi_K(u, v) \end{bmatrix} = \begin{bmatrix} u^\top T_{:, :, 1} v \\ \vdots \\ u^\top T_{:, :, K} v \end{bmatrix} = T \times_1 u^\top \times_2 v^\top.$$

Osservazione 3.1.4. L'algebra multilineare garantisce l'esistenza e l'unicità di T .

Osservazione 3.1.5. Questa procedura si estende anche al caso in cui le entrate di u e v siano oggetti algebrici più complessi di scalari, ad esempio vettori o matrici.

Ricordando che $U^* \otimes V^* \otimes W$ è l'insieme delle forme trilineari da $U \times V \times W^* \rightarrow \mathbb{K}$, possiamo dare un nome all'oggetto sopra.

Definizione 3.1.6 (Tensore strutturale). L'unico tensore $T \in U^* \otimes V^* \otimes W$ associato alla mappa bilineare $\varphi : U \times V \rightarrow W$ è detto *tensore strutturale* di φ .

Osservazione 3.1.7. Con un abuso di notazione tipicamente usato in letteratura [18, 44, 45], nel seguito identificheremo l'algoritmo di moltiplicazione matriciale (come mappa bilineare) con il suo tensore strutturale, denotando entrambi dello stesso simbolo $\langle m, n, p \rangle$, distinguendo l'oggetto in questione laddove creerà ambiguità. Più avanti questa notazione sarà giustificata dalla Proposizione 3.2.3.

3.2 DECOMPOSIZIONE LOW-RANK DI FORME BILINEARI

In § 1.5 abbiamo osservato che le fattorizzazioni low-rank riducono il costo in memoria. Aggiungiamo che questa rappresentazione è anche vantaggiosa per ridurre il calcolo delle operazioni aritmetiche. Per una matrice $M \in \mathbb{R}^{m \times n}$ di rango uno, possiamo scrivere $M = u \otimes v = uv^\top$ per certi $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$; la valutazione $Mx = (uv^\top)x = u(v^\top x)$ ha costo $O(n)$, contro il costo $O(mn)$ del prodotto classico matrice vettore. In generale, se M ha rango R , possiamo scriverla come somma di R matrici di rango uno e per linearità ottenere un costo $O(Rn)$ per Mx . È possibile generalizzare quest'idea per mappe bilineari.

Calcolare la valutazione di una mappa bilineare φ come nell'Equazione (3.2) senza alcuna fattorizzazione di T ha un costo $O(mnp)$, data dal numero di moltiplicazioni necessarie fra gli elementi di u e v con le entrate non nulle di T . Osserveremo che queste operazioni si chiameranno *active multiplications*, in quanto saranno legate alla misura di complessità $L(\varphi)$. In particolare, sarà possibile ridurre le *active multiplications* trovando fattorizzazioni di rango più basso di T .

Definizione 3.2.1 (Bilinear algorithm). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali. Per ogni $i \in \{1, \dots, r\}$, siano $f_i \in U^*, g_i \in V^*, w_i \in W$ tali che

$$\varphi(u, v) = \sum_{i=1}^r f_i(u)g_i(v)w_i,$$

per ogni $u \in U, v \in V$. Allora la r -upla $(f_1, g_1, w_1; \dots; f_r, g_r, w_r)$ viene detta *bilinear computation (algorithm) di lunghezza r per φ* . La lunghezza di più breve algoritmo di calcolo per φ è chiamata *bilinear complexity* o rango di φ , che indichiamo ancora con $\mathbf{R}(\varphi)$.

La prossima proposizione assicura che il rango di una forma bilineare sia dato dal rango CP.

Proposizione 3.2.2. *Fissiamo una forma bilineare φ e denotiamo con T il tensore che la rappresenta. Allora, dalla fattorizzazione CP di un tensore T si ottiene una bilinear computation, e in particolare $\mathbf{R}(\varphi) = \mathbf{R}(T)$.*

Dimostrazione. Data una decomposizione $T = \llbracket U, V, W \rrbracket$ di rango r , dalla Definizione 1.5.1 abbiamo che $T = \sum_{l=1}^r u_l \otimes v_l \otimes w_l$, dove $U \in \mathbb{R}^{I \times r}$, $V \in \mathbb{R}^{J \times r}$, $W \in \mathbb{R}^{K \times r}$. Ricordando che in componenti $T_{i,j,k} = \sum_{l=1}^r u_{il}v_{jl}w_{kl}$, la relazione dell'Equazione (3.2) diventa,

$$\begin{aligned}
 \varphi_k(x, y) &= \sum_{i=1}^I \sum_{j=1}^J T_{ijk} x_i y_j \\
 &= \sum_{i=1}^I \sum_{j=1}^J \sum_{l=1}^r u_{il} v_{jl} w_{kl} x_i y_j \\
 (3.4) \quad &= \sum_{l=1}^r \left(\sum_{i=1}^I u_{il} x_i \right) \cdot \left(\sum_{j=1}^J v_{jl} y_j \right) w_{kl} \\
 &= \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_{kl},
 \end{aligned}$$

per ogni $k = 1, \dots, K$. Mettendo insieme le Equazioni (3.3) e (3.4) troviamo

$$(3.5) \quad \varphi(x, y) = \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_l.$$

Considerando i funzionali $f_l(x) := u_l^\top x$ e $g_l(y) := v_l^\top y$ indotti dal prodotto scalare standard si ha la tesi. □

Quindi valutare φ richiede esattamente $r = \mathbf{R}(T)$ active multiplications (e $O(r)$ addizioni), che sopra evidenziamo con $(\cdot)$. In particolare, il seguente risultato algebrico ci dice che la rappresentazione di una forma bilineare come tensore o come bilinear computation sono identiche. La seconda forma sarà utile per moltiplicare le matrici sfruttando la decomposizione di T .

Proposizione 3.2.3 (Si veda [18], Cap. 14). *Siano U, V e W dei $\mathbb{K}$ -spazi vettoriali. Allora esiste un unico isomorfismo $U^* \otimes V^* \otimes W \rightarrow \{\varphi : U \times V \rightarrow W, \text{ bilineare}\}$ che manda $s \otimes t \otimes w$ nella mappa bilineare $(u, v) \mapsto f(u)g(v)w$.*

3.3 Rappresentazione low-rank del prodotto tra matrici

Osservazione 3.2.4. Grazie a questo isomorfismo, possiamo passare da una bilinear computation

$$\varphi(u, v) = \sum_{i=1}^r f_i(u) g_i(v) w_i,$$

al suo tensore

$$T = \sum_{i=1}^r f_i \otimes g_i \otimes w_i,$$

e viceversa.

3.3 RAPPRESENTAZIONE LOW-RANK DEL PRODOTTO TRA MATRICI

Possiamo applicare il risultato sopra per valutare il prodotto tra matrici con un numero ottimale di operazioni.

Consideriamo due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times p}$ e il loro prodotto $C \in \mathbb{R}^{m \times p}$. Ponendo $x = \text{vec}(A)$ e $y = \text{vec}(B)$, l'Equazione (3.3) diventa

$$(3.6) \quad \text{vec}(C^\top) = \varphi(x, y) = T \times_1 \text{vec}(A)^\top \times_2 \text{vec}(B)^\top,$$

dove tramite le trasposizioni abbiamo fissato l'ordinamento naturale sulle entrate di $\text{vec}(A)$ e $\text{vec}(B)$, e quello inverso su $\text{vec}(C^\top)$. Per costruzione, il tensore $T \in \mathbb{R}^{mn \times np \times mp}$ rappresenta l'algoritmo $\langle m, n, p \rangle$. Scrivendo T tramite la sua decomposizione CP di rango r , l'Equazione (3.5) ci permette di riscrivere l'espressione sopra come una bilinear computation

$$(3.7) \quad \text{vec}(C^\top) = \sum_{l=1}^r (u_l^\top \text{vec}(A)) \cdot (v_l^\top \text{vec}(B)) w_l = \sum_{l=1}^r (f_l \cdot g_l) w_l = \sum_{l=1}^r m_l w_l,$$

Dove abbiamo posto $f_l := f_l(A) := u_l^\top \text{vec}(A)$, $g_l := g_l(B) := v_l^\top \text{vec}(B)$ e $m_l := f_l g_l$.

Questa formula definisce un algoritmo di moltiplicazione veloce $\langle m, n, p \rangle$; spesso nella pratica m, n, p sono più piccoli delle matrici da moltiplicare; in questo caso è possibile dividerle a blocchi e applicare l'algoritmo in maniera ricorsiva, ripetendo la ricorsione fino a raggiungere il caso base. Di seguito giustificheremo meglio questa procedura.

3.4 L'ESPONENTE DELLA MOLTIPLICAZIONE TRA MATRICI

In questo capitolo useremo il seguente modello computazionale con lo scopo di calcolare la complessità di valutare una forma bilineare, che semplifica il calcolo dei costi eliminando le condizioni di branching (e.g. **if-then-else** o **while**) e consentendo l'input da un alfabeto infinito di simboli (come un campo $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$).

Definizione 3.4.1 (Circuito aritmetico). Un *circuito aritmetico* Γ su $\mathbb{K}$ è un grafo diretto, aciclico, finito con vertici di grado entrante 0 o 2 ed esattamente un vertice di grado uscente 0. I vertici di grado entrante 0 sono etichettati con gli elementi di $\mathbb{K} \cup \{x_1, \dots, x_n\}$ e sono detti *inputs*. Quelli di grado entrante 2 sono etichettati con $+$ oppure $\times$ e sono chiamati *gates*. Se il grado uscente di un vertice v è 0, allora v è chiamato un *output gate*. La dimensione di Γ è il numero di archi.




Figura 3.1: Esempio di circuito aritmetico per il polinomio $\varphi(x_1, x_2) = (x_1 + x_2)x_2(x_2 + 1)$.

Definizione 3.4.2 (Funzione costo). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali di dimensione finita. Definiamo la *funzione costo* associata a un circuito aritmetico Γ come

$$C_\Gamma(\varphi) := \text{numero di moltiplicazioni per calcolare } \varphi \text{ sul circuito } \Gamma, \text{ oppure}$$

$$C_\Gamma^{\text{tot}}(\varphi) := \text{numero di addizioni e moltiplicazioni per calcolare } \varphi \text{ sul circuito } \Gamma.$$

Denotiamo con $\mathcal{C}_\varphi$ come l'insieme dei circuiti aritmetici Γ che calcolano φ .

Definizione 3.4.3 (Funzione di complessità aritmetica). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare tra $\mathbb{K}$ -spazi vettoriali di dimensione finita. Definiamo

$$L(\varphi) := \inf_{\Gamma \in \mathcal{C}_\varphi} \{C_\Gamma(\varphi)\} \quad \text{la complessità moltiplicativa di } \varphi, \text{ e}$$

$$L^{\text{tot}}(\varphi) := \inf_{\Gamma \in \mathcal{C}_\varphi} \{C_\Gamma^{\text{tot}}(\varphi)\} \quad \text{la complessità totale di } \varphi.$$

Osservazione 3.4.4. In altre parole, $L(\varphi)$ è il minimo numero di moltiplicazioni non scalari sufficienti a calcolare φ , anche dette *active multiplications*. In maniera analoga, L^{tot} è il minimo numero di moltiplicazioni non scalari e di addizioni sufficienti a calcolare φ .

Consideriamo la forma bilineare $\varphi = \langle n, n, n \rangle$ data dall'Equazione (3.1). Fissato un campo $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, e delle matrici $A, B \in \mathbb{R}^{n \times n}$, denotiamo con

$$(3.8) \quad M_{\mathbb{K}}(n) := L^{\text{tot}}(\langle n, n, n \rangle) = L^{\text{tot}}\left(\left\{\sum_{k=1}^n a_{ik}b_{kj} \mid i, j \in \{1, \dots, n\}\right\}\right)$$

il numero totale di moltiplicazioni aritmetiche sufficienti a calcolare la moltiplicazione di due matrici $n \times n$. Determinare una formula per $M_{\mathbb{K}}(n)$ è lontano dagli strumenti attualmente disponibili. Invece, il problema di approssimare la crescita asintotica della funzione $n \mapsto M_{\mathbb{K}}(n)$ è fattibile; definiamo

Definizione 3.4.5. L'esponente $\omega_{\mathbb{K}}$ di una moltiplicazione matriciale è il numero

$$\omega_{\mathbb{K}} := \inf_{n \in \mathbb{N}} \{\tau \in \mathbb{R} \mid \text{la moltiplicazione tra due matrici in } \mathbb{K}^{n \times n} \\ \text{ha costo } o(n^\tau) \text{ operazioni aritmetiche}\}.$$

In altre parole, $\omega_{\mathbb{K}} = \inf_{n \in \mathbb{N}} \{\tau \in \mathbb{R} \mid M_{\mathbb{K}}(n) = o(n^\tau)\}$.

Osservazione 3.4.6. L'esponente $\omega_{\mathbb{K}}$ rappresenta l'esponente ottimo globale per moltiplicare due matrici. Osserviamo che non dipende dalla taglia n .

Osservazione 3.4.7. La notazione $M_{\mathbb{K}}(h)$ e $\omega_{\mathbb{K}}$ è dovuta alla dipendenza dal campo $\mathbb{K}$. Dato che tratteremo solo $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, spesso scriveremo ω per $\omega_{\mathbb{K}}$.

Aggiunto

Esempio 3.4.8. Per le matrici 2×2 , vale $4 \leq M_{\mathbb{K}}(2) \leq 2^2(4-1) = 12$. Osserveremo che trovare un algoritmo che riduce $M_{\mathbb{K}}(2)$ migliora anche l'esponente.

Teorema 3.4.9 (Schönhage [52]). *L'esponente della moltiplicazione tra matrici è invariante rispetto alle estensioni scalari: se $\mathbb{K} \subset \mathbb{L}$ è un'estensione di campo, allora*

$$\omega_{\mathbb{K}} = \omega_{\mathbb{L}}$$

STIMARE L'ESPONENTE

Un modo elementare di trovare una nuova stima su ω è trovare una scrittura più breve della forma bilineare (o del tensore). La seguente proposizione ci fornisce una prima stima della misura di complessità con il rango di una forma bilineare.

Proposizione 3.4.10 (Strassen, si veda [18], Capitolo 14). *Siano U, V e W dei $\mathbb{K}$ -spazi vettoriali di dimensione finita, e $\varphi : U \times V \rightarrow W$ una mappa bilineare. Allora*

$$L(\varphi) = \text{Lunghezza della più breve bilinear computation per } \varphi.$$

Osservazione 3.4.11. Da questa proposizione segue direttamente che

$$(3.9) \quad L(\varphi) \leq \mathbf{R}(\varphi) \leq 2L(\varphi).$$

Osserviamo che $M_{\mathbb{K}}(n) \leq n^2(2n - 1)$. Siccome il costo computazionale dev'essere almeno pari al numero di entrate della matrice, vale $M_{\mathbb{K}}(n) \geq n^2$, da cui $\omega \in [2, 3]$. Trovare ω è un problema centrale nella teoria della complessità, e si congettura che $\omega = 2$, cioè che il costo delle moltiplicazioni possa essere asintoticamente pari a quello delle addizioni. L'algoritmo naive dimostra che $\omega \leq 3$, mentre il primo miglioramento, dovuto all'algoritmo di Strassen [61] mostra che $\omega \leq \log_2(7) < 2.81$. Il record attuale è $\omega \leq 2.371177$ [3]. Dopo Strassen, nel 1978 i miglioramenti significativi sono stati $\omega \leq 2.7962$ ad opera di [50], poi $\omega \leq 2.7799$ [14] nel 1979, poi $\omega \leq 2.55$ [52], poi $\omega \leq 2.48$ nel 1987 [60], e poi $\omega \leq 2.38$ [22] nel 1989, che potrebbe aver fatto pensare che nel 1990 si sarebbe trovato il bound. Dopo tale miglioramento, l'approssimazione è scesa molto lentamente, fino a scendere sotto $\omega < 2.372$ solo recentemente [2, 32, 59, 64]. Tuttavia, l'avvento dell'Intelligenza Artificiale sta dando un nuovo impulso a questa ricerca (si veda ad esempio AlphaTensor [30]); di recente (agosto 2026) l'utilizzo di strumenti di IA come AlphaEvolve ha stabilito il nuovo record di $\omega \leq 2.371177$ [3]. Sottolineiamo che da un punto di vista pratico, non è detto che le stime ottimali si traducano in algoritmi più veloci o stabili di quello classico, ad esempio l'algoritmo di Strassen, che presenteremo, in molti casi compete con algoritmi con esponente più basso [8, 24].




Figura 3.2: Miglioramenti del limite superiore dell'esponente della moltiplicazione matriciale ω dal 1969 ad oggi. La linea tratteggiata rappresenta il limite superiore $\omega \leq 3$.

3.5 IL RANGO COME MISURA DELLA COMPLESSITÀ

STIMARE LA COMPLESSITÀ NEL CASO GENERALE

Precedentemente abbiamo introdotto gli algoritmi di moltiplicazione dal caso base (indicandolo con $\langle n, n, n \rangle$) senza giustificare come cambia la complessità quando l'algoritmo viene eseguito ricorsivamente. Date due matrici $n^i \times n^i$, possiamo vedere la loro moltiplicazione come il prodotto di matrici $n \times n$ sull'algebra delle matrici $n^{i-1} \times n^{i-1}$, suddividendole in blocchi. Questo dice anche che, se $\mathbf{R}(\langle n, n, n \rangle) \leq r$, allora $\mathbf{R}(\langle n^i, n^i, n^i \rangle) \leq r^i$; infatti, combinando le prossime Proposizioni 3.5.4 e 3.5.5, e usando che il rango è invariante per isomorfismo, troviamo

$$\mathbf{R}(\langle n^i, n^i, n^i \rangle) = \mathbf{R}(\langle n, n, n \rangle^{\otimes i}) \leq \mathbf{R}(\langle n, n, n \rangle)^i \leq r^i,$$

dove

$$\langle n, n, n \rangle^{\otimes i} = \underbrace{\langle n, n, n \rangle \otimes \cdots \otimes \langle n, n, n \rangle}_{i\text{-volte}}.$$

In altre parole, possiamo applicare ricorsivamente l'algoritmo di moltiplicazione veloce, che è disegnato per matrici $n \times n$, per ottenere la moltiplicazione di matrici $n^i \times n^i$ impiegando solo r^i moltiplicazioni. In questo modo possiamo evitare dover fattorizzare il tensore di $\langle n^i, n^i, n^i \rangle$, che sarebbe del grande formato $(n^i)^2 \times (n^i)^2 \times (n^i)^2$.

Se invece $n > n_0$ sono due interi positivi (nei passaggi può essere utile pensare al caso $n_0 = 2$) dato un algoritmo con un caso base fissato $\langle n_0, n_0, n_0 \rangle$ è possibile ottenerne uno per $\langle n, n, n \rangle$ con $n > n_0$, allargando la matrice di taglia $n \times n$ aggiungendo zeri fino a raggiungere la dimensione $n_0^{\lceil \log_{n_0} n \rceil}$, in modo tale che le matrici da moltiplicare siano partizionate in blocchi di taglia divisibile dal caso base. La complessità dipenderà comunque da n_0 e da r , in quanto

$$\begin{aligned} \mathbf{R}(\langle n, n, n \rangle) &\leq \mathbf{R}(\langle n_0^{\lceil \log_{n_0} n \rceil}, n_0^{\lceil \log_{n_0} n \rceil}, n_0^{\lceil \log_{n_0} n \rceil} \rangle) \quad \text{dalla 3.5.3,} \\ &\leq \mathbf{R}(\langle n_0, n_0, n_0 \rangle)^{\lceil \log_{n_0} n \rceil} \quad \text{dalle 3.5.4 e 3.5.5,} \\ &\leq r^{\lceil \log_{n_0} n \rceil} \quad \text{per ipotesi } \mathbf{R}(\langle n, n, n \rangle) \leq r, \\ &\leq r \cdot n^{\log_{n_0} r} \quad \text{usando che } \lceil x \rceil \leq x + 1. \end{aligned}$$

Riassumendo, $\mathbf{R}(\langle n, n, n \rangle) \leq r \cdot n^{\log_{n_0} r}$. Dunque ignorando la costante e applicando l'Equazione (3.15), segue che $\omega \leq \log_{n_0} r$. Abbiamo dimostrato la seguente:

Proposizione 3.5.1. *Se $\mathbf{R}(\langle n, n, n \rangle) \leq r$ per degli interi positivi n, r , allora $n^\omega \leq r$.*

Osservazione 3.5.2. Questo risultato tornerà utile per stimare l'esponente a partire dal tensore strutturale di un algoritmo di moltiplicazione veloce (un modo alternativo per stimarlo è applicare il Master Theorem [23]).

Nei passaggi sopra abbiamo anche osservato che se $n \leq n'$ e dato un algoritmo per n' , possiamo ottenerne uno per n allargando la matrice. Possiamo racchiudere questa proprietà nel seguente risultato:

Proposizione 3.5.3 (Monotonia del rango di un algoritmo). *Il rango di un algoritmo per la moltiplicazione di matrici è monotono crescente rispetto alle loro taglie, ovvero dati due interi positivi $n \leq n'$, allora $\mathbf{R}(\langle n, n, n \rangle) \leq \mathbf{R}(\langle n', n', n' \rangle)$.*

Riportiamo le proposizioni utilizzate per dimostrare la proposizione sopra, dimostrate in [18, Capitoli 14 e 15].

Proposizione 3.5.4. *Siano e, e', h, h', l, l' degli interi positivi. Allora abbiamo*

$$\langle e, h, l \rangle \otimes \langle e', h', l' \rangle \simeq \langle ee', hh', ll' \rangle,$$

cioè le due forme bilineari sono isomorfe.

Proposizione 3.5.5. *Siano φ_1, φ_2 due mappe bilineari. Allora $\mathbf{R}(\varphi_1 \otimes \varphi_2) \leq \mathbf{R}(\varphi_1)\mathbf{R}(\varphi_2)$.*

Dimostrazione. Scriviamo φ_1, φ_2 come bilinear computation:

$$\begin{aligned}\varphi_1(u_1, v_1) &= \sum_{i=1}^{r_1} \alpha_i(u_1) \beta_i(v_1) w_i, \\ \varphi_2(u_2, v_2) &= \sum_{j=1}^{r_2} \gamma_j(u_2) \beta_j(v_2) z_j.\end{aligned}$$

Calcolando il loro prodotto tensoriale,

$$\begin{aligned}(\varphi_1 \otimes \varphi_2)(u_1 \otimes u_2, v_1 \otimes v_2) &= \varphi_1(u_1, v_1) \otimes \varphi_2(u_2, v_2) \\ &= \left(\sum_{i=1}^{r_1} \alpha_i(u_1) \beta_i(v_1) w_i \right) \otimes \left(\sum_{j=1}^{r_2} \gamma_j(u_2) \beta_j(v_2) z_j \right) \\ &= \sum_{i=1}^{r_1} \sum_{j=1}^{r_2} \alpha_i(u_1) \beta_i(v_1) \gamma_j(u_2) \beta_j(v_2) (w_i \otimes z_j),\end{aligned}$$

che è un'espressione di $\varphi_1 \otimes \varphi_2$ come somma di mappe bilineari di rango uno. Per minimalità del rango, segue

$$\mathbf{R}(\varphi_1 \otimes \varphi_2) \leq r_1 r_2 = \mathbf{R}(\varphi_1) \mathbf{R}(\varphi_2).$$

□

IL TEOREMA DI STRASSEN

aggiornato questo paragrafo

Fino a questo punto abbiamo visto che un algoritmo con r moltiplicazioni per matrici $n \times n$ definisce una bilinear computation e dimostra che il rango del tensore associato è $\leq r$. Di conseguenza, dalla Proposizione 3.5.1, un limite superiore per il rango di $\langle n, n, n \rangle$ induce un limite superiore per l'esponente asintotico della moltiplicazione di matrici, ovvero $\omega \leq \log_n \mathbf{R}(\langle n, n, n \rangle)$. Quindi prendendo l'estremo inferiore su tutti i possibili n troviamo che $\omega \leq \inf_n \log_n \mathbf{R}(\langle n, n, n \rangle)$. A questo punto è naturale chiedersi se, ottimizzando su tutte le possibili n , il rango tensoriale è sufficiente a catturare la complessità aritmetica ω ? Il teorema di Strassen risponde in maniera affermativa a questa domanda, mostrando che ω coincide con l'estremo inferiore di queste stime, permettendo così di studiare la complessità di un algoritmo analizzando solamente il rango del tensore strutturale.




Figura 3.3: Circuito aritmetico per la moltiplicazione di matrici 2×2 .

Teorema 3.5.6 (Strassen [61], vedi anche [18] §15.1).

$$\omega = \inf_n \{ \tau \in \mathbb{R} \mid \mathbf{R}(\langle n, n, n \rangle) = O(n^\tau) \}.$$

Ovvero, è possibile moltiplicare due matrici $n \times n$ usando $O(n^{\omega+\varepsilon})$ operazioni aritmetiche se e solo se il rango tensoriale di $\langle n, n, n \rangle$ è $O(n^{\omega+\varepsilon})$.

Introduciamo alcuni strumenti utili a dimostrare questo risultato.

Definizione 3.5.7 (Mappa bilineare concise). Sia $\varphi : U \times V \rightarrow W$ una mappa bilineare. Diremo che φ è *concise* se valgono tutte e tre le condizioni sotto:

- (i) $\text{Ker}_L(\varphi) = \{u \in U \mid \varphi(u, \cdot) = 0\} = \{0\}$,
- (ii) $\text{Ker}_R(\varphi) = \{v \in V \mid \varphi(\cdot, v) = 0\} = \{0\}$,
- (iii) $\text{Im}(\varphi) = \{\varphi(u, v) \mid u \in U, v \in V\} = W$.

Osservazione 3.5.8. Vedendo φ come un elemento di $U^* \otimes V^* \otimes W$ è possibile legare questa definizione alla Definizione ?? per i tensori concise.

Esempio 3.5.9. La mappa bilineare $\langle n, n, n \rangle$ è concise.

Lemma 3.5.10. *Sia $x = (x_0, x_1, x_2, \dots)$ una successione di numeri reali che soddisfa la ricorsione $x_s = ax_{s-1} + cb^s$, per certi numeri reali a, b, c . Allora per ogni $s \geq 0$, vale*

$$x_s = \begin{cases} a^s x_0 + (a^s - b^s) \frac{bc}{a-b} & \text{se } a \neq b, \\ (cs + x_0)a^s & \text{se } a = b. \end{cases}$$

Dimostrazione. Mostriamo la formula per induzione su s . Per $s = 0$ segue direttamente:

$$\begin{aligned} x_1 &= ax_0 + bc, \\ x_2 &= a(ax_0 + bc) + b^2c \\ &= a^2x_0 + (a+b)bc \\ &= \begin{cases} a^2x_0 + (a^2 - b^2) \frac{bc}{a-b} & \text{se } a \neq b, \\ (2c + x_0)a^2 & \text{se } a = b. \end{cases} \end{aligned}$$

Assumiamo la proprietà vera per $n-1$ e mostriamola per n .

Se $a \neq b$,

$$\begin{aligned} x_s &= a \left(a^{s-1}x_0 + (a^{s-1} - b^{s-1}) \frac{bc}{a-b} \right) + b^s c \\ &= a^s x_0 + ((a^{s-1} - b^{s-1})a + b^{s-1}(a-b)) \frac{bc}{a-b} \\ &= a^s x_0 + (a^s - b^s) \frac{bc}{a-b} \end{aligned}$$

Similmente, se $a = b$

$$\begin{aligned} x_s &= (c(s-1) + x_0 + c)a^s \\ &= (cs + x_0)a^s. \end{aligned}$$

□

Dimostrazione del Teorema di Strassen. Dimostriamo che

$$\omega = \inf_n \{ \tau \in \mathbb{R} \mid \mathbf{R}(\langle n, n, n \rangle) = O(n^\tau) \}.$$

Sia θ il lato destro dell'equazione sopra, e per semplicità scriviamo $M(n) := M_{\mathbb{K}}(n)$ e $\omega := \omega_{\mathbb{K}}$. Dall'Equazione (3.9) abbiamo

$$\frac{1}{2} \mathbf{R}(\langle n, n, n \rangle) \leq L(\langle n, n, n \rangle) \leq M(n),$$

per ogni intero $n \geq 1$. Di conseguenza, dalla Definizione 3.4.5 segue $\theta \leq \omega$.

3 Applicazioni della CP alla complessità aritmetica

Mostriamo che $\omega \leq \theta$. Per definizione di θ , per ogni $\varepsilon > 0$ esiste un $n > 1$ tale che

$$(3.10) \quad r := \mathbf{R}(\langle n, n, n \rangle) \leq n^{\theta+\varepsilon}.$$

Dall'Equazione (3.7) esistono dei funzionali $f_\rho, g_\rho \in (\mathbb{K}^{n \times n})^*$ e delle matrici $w_\rho \in \mathbb{K}^{n \times n}$ per $\rho \in \{1, \dots, r\}$ tali che, per ogni $A, B \in \mathbb{K}^{n \times n}$

$$AB = \sum_{\rho=1}^r f_\rho(A) g_\rho(B) w_\rho.$$

Vedendo $\mathcal{A} = \mathbb{K}^{n^i \times n^i}$ come l'algebra delle matrici $n^i \times n^i$, notiamo che i funzionali $f_\rho, g_\rho : \mathbb{K}^{n \times n} \rightarrow \mathbb{K}$ si estendono a funzionali $f_\rho, g_\rho : \mathcal{A}^{n \times n} \rightarrow \mathcal{A}$, sostituendo le entrate scalari con delle matrici. In particolare vale, per ogni $A, B \in \mathcal{A}^{n \times n}$

$$(3.11) \quad AB = \sum_{\rho=1}^r f_\rho(A) g_\rho(B) w_\rho.$$

L'Equazione sopra rappresenta l'algoritmo di moltiplicazione a blocchi tra A e B : infatti abbiamo $\mathcal{A}^{n \times n} = (\mathbb{K}^{n^i \times n^i})^{n \times n} \simeq \mathbb{K}^{n^{i+1} \times n^{i+1}}$, dove l'isomorfismo può essere pensato come la suddivisione di matrici più grandi in matrici a blocchi. Da questo fatto, unito all'Equazione (3.11), si ottiene che

$$(3.12) \quad M(n^{i+1}) \leq rM(n^i) + cn^{2i},$$

dove $c := c(n, r)$ è una costante che dipende sia da n che da r . Questo perché nella formula il prodotto AB , sviluppato come prodotto tra blocchi $n^i \times n^i$ (formalmente, visto come prodotto a coefficienti in $\mathcal{A}$), coinvolge r prodotti e un numero costante di addizioni. Siccome $\langle n, n, n \rangle$ è concise, abbiamo che $r \geq n^2$. Fissando n (e quindi r), risolviamo la ricorsione dell'Equazione (3.12) in funzione di i usando il Lemma 3.5.10 con $a = r$ e $b = n^2$. Analizziamo i due casi.

Se $r > n^2$, abbiamo che

$$\begin{aligned} M(n^i) &= r^i M(1) + (r^i - n^{2i}) \frac{n^2 c}{r - n^2} \\ &= (M(1) + n^2 c) r^i - n^{2i} \frac{n^2 c}{r - n^2}, \end{aligned}$$

da cui,

$$M(n^i) \leq \alpha r^i + \beta n^{2i},$$

dove abbiamo posto $\alpha := M(1) + n^2 c$ e $\beta := -\frac{n^2 c}{r - n^2}$.

Se $r = n^2$, dal Lemma (3.12) abbiamo

$$M(n^i) \leq (cs + M(1))r^i,$$

In entrambi i casi troviamo,

$$(3.13) \quad M(n^i) = O(r^i).$$

Dalla proposizione 3.5.3 segue che M è una successione monotona, per ogni $h \in \mathbb{N} \setminus \{0\}$,

$$(3.14) \quad M(h) \leq M(n^{\lceil \log_n h \rceil}) = O(r^{\log_n h}) = O(h^{\log_n r}) = O(h^{\theta + \varepsilon}),$$

dove la prima uguaglianza segue dall'Equazione 3.5.3, la seconda da una proprietà del logaritmo, e la terza applicando la stima dell'Equazione (3.10). Passando all'inf troviamo $\omega_{\mathbb{K}} \leq \theta$, che completa la dimostrazione. $\square$

Osservazione 3.5.11. Riassumendo, il teorema sopra mette in corrispondenza $\mathbf{R}(\langle n, n, n \rangle)$ (e quindi il numero di active multiplications) con l'esponente asintotico ottimale. Possiamo quindi scrivere

$$(3.15) \quad \omega = \lim_{n \rightarrow +\infty} \log_n(\mathbf{R}(\langle n, n, n \rangle)).$$

3.6 ALGORITMI DI MOLTIPLICAZIONE VELOCE

Osservazione 3.6.1. Di seguito ci limiteremo a studiare prodotti fra matrici quadrate. Per il caso rettangolare, si possono estendere i ragionamenti sopra considerando una rappresentazione di rango r del tensore $\langle m, n, p \rangle$ e scrivendo, attraverso una serie di permutazioni cicliche, la fattorizzazione di $\langle mnp, mnp, mnp \rangle$ di rango r^3 , che produce un algoritmo di complessità $O(n^{\log_{abc} r^3}) = O(n^{3 \log_{abc} r})$. Questo si può vedere tramite la scrittura della moltiplicazione tra matrici come la forma trilineare dell'Osservazione 3.1.3, da cui ne segue l'invarianza del tensore per trasformazioni cicliche,

$$(3.16) \quad \text{trace}(ABC) = \text{trace}(CAB) = \text{trace}(BAC).$$

IL CASO NAIVE


Trattiamo il caso di matrici quadrate con taglie potenze di due (possiamo farlo a meno di passare a una sottomatrice di taglia pari). In questo caso possiamo partizionare le matrici in delle sottomatrici a blocchi 2×2 :

$$\begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix}.$$

Qui è indifferente pensare alle entrate come scalari o come matrici. L'algoritmo naive procede combinando un insieme di otto moltiplicazioni matriciali con quattro addizioni:

$$(3.17) \quad \begin{aligned} m_1 &= a_{11} \cdot b_{11} = s_1 t_1 & m_2 &= a_{12} \cdot b_{21} = s_2 t_2 & m_3 &= a_{11} \cdot b_{12} = s_3 t_3 \\ m_4 &= a_{12} \cdot b_{22} = s_4 t_4 & m_5 &= a_{21} \cdot b_{11} = s_5 t_5 & m_6 &= a_{22} \cdot b_{21} = s_6 t_6 \\ m_7 &= a_{21} \cdot b_{12} = s_7 t_7 & m_8 &= a_{22} \cdot b_{22} = s_8 t_8 \end{aligned}$$

$$\begin{aligned} c_{11} &= m_1 + m_2 = a_{11}b_{11} + a_{12}b_{21}, & c_{12} &= m_3 + m_4 = a_{11}b_{12} + a_{12}b_{22}, \\ c_{21} &= m_5 + m_6 = a_{21}b_{11} + a_{22}b_{21}, & c_{22} &= m_7 + m_8 = a_{21}b_{12} + a_{22}b_{22}. \end{aligned}$$



$$c_{ij} = \sum_{k=1}^2 a_{ik}b_{kj} = a_{i1}b_{1j} + a_{i2}b_{2j}$$

Figura 3.4: Rappresentazione della moltiplicazione di due matrici 2×2 .

Proviamo a scriverlo in forma tensoriale. La sua bilinear computation è

$$C = \sum_{i=1}^8 m_i w_i.$$

Resta solo da assegnare i termini w_i , che in questo caso saranno matrici. Fissiamo la base standard $\{E_{11}, E_{12}, E_{21}, E_{22}\}$ dello spazio delle matrici 2×2 . Scriviamo

$$\begin{aligned} C &= c_{11}E_{11} + c_{12}E_{12} + c_{21}E_{21} + c_{22}E_{22} \\ &= (m_1 + m_2)E_{11} + (m_3 + m_4)E_{12} + (m_5 + m_6)E_{21} + (m_7 + m_8)E_{22} \\ &= \sum_{i=1}^8 m_i w_i, \end{aligned}$$

dove i termini w_i sono determinati dalla scrittura sopra.

Tramite l'isomorfismo della Proposizione 3.2.3, possiamo mappare ogni termine $s_r t_r w_r$ dell'equazione sopra in $s_r \otimes t_r \otimes w_r$ e scrivere il tensore strutturale di $\langle 2, 2, 2 \rangle$ in formato CP (si veda anche la Figura 3.5). Per farlo, identifichiamo i funzionali s_r e t_r con i loro primali a_{ij} e b_{ij} e le matrici w_r con gli elementi c_{ij} .

$$\begin{aligned} \langle 2, 2, 2 \rangle &= a_{11} \otimes b_{11} \otimes c_{11} + a_{12} \otimes b_{21} \otimes c_{11} \\ &\quad + a_{21} \otimes b_{11} \otimes c_{21} + a_{22} \otimes b_{21} \otimes c_{21} \\ &\quad + a_{11} \otimes b_{12} \otimes c_{12} + a_{12} \otimes b_{22} \otimes c_{12} \\ &\quad + a_{21} \otimes b_{12} \otimes c_{22} + a_{22} \otimes b_{22} \otimes c_{22}. \end{aligned} \tag{3.18}$$




Figura 3.5: Decomposizione CP di rango 8 del tensore di moltiplicazione di matrici $\langle 2, 2, 2 \rangle$.

Osserviamo che questo caso base dà luogo a un algoritmo ricorsivo per $n > 2$. Contestualizzando l'Equazione (3.14) del Teorema di Strassen, troviamo che $M(n) \leq O(n^{\log_2 8}) = O(n^3)$.

Nel 1969 Strassen¹ tentò di mostrare che non esistesse un algoritmo più veloce di quello classico. Tramite una serie di riduzioni manuali riuscì a mostrare l'ottimalità su $\mathbb{Z}/2\mathbb{Z}$, ma per $\mathbb{R}$ o $\mathbb{C}$ la tesi si rivelò essere falsa.

L'ALGORITMO DI STRASSEN

L'algoritmo di Strassen è probabilmente l'algoritmo di moltiplicazione veloce più celebre e segue la stessa struttura a blocchi $\langle 2, 2, 2 \rangle$. Riportiamo le equazioni originariamente trovate da Strassen tramite un processo di riduzione.

$$\begin{aligned}
 s_1 &= a_{11} + a_{22} & s_2 &= a_{21} + a_{22} & s_3 &= a_{11} \\
 s_4 &= a_{22} & s_5 &= a_{11} + a_{12} & s_6 &= a_{21} - a_{11} \\
 s_7 &= a_{12} - a_{22} \\
 t_1 &= b_{11} + b_{22} & t_2 &= b_{11} & t_3 &= b_{12} - b_{22} \\
 t_4 &= b_{21} - b_{11} & t_5 &= b_{22} & t_6 &= b_{11} + b_{12} \\
 t_7 &= b_{21} + b_{22}
 \end{aligned}$$

$$\begin{aligned}
 m_r &= s_r t_r, \quad 1 \leq r \leq 7 \\
 (3.19) \quad c_{11} &= m_1 + m_4 - m_5 + m_7 & c_{12} &= m_3 + m_5 \\
 c_{21} &= m_2 + m_4 & c_{22} &= m_1 - m_2 + m_3 + m_6
 \end{aligned}$$

Nella base canonica, la matrice C si scrive come

$$\begin{aligned}
 C &= c_{11}E_{11} + c_{12}E_{12} + c_{21}E_{21} + c_{22}E_{22} \\
 &= (m_1 + m_4 - m_5 + m_7)E_{11} + (m_3 + m_5)E_{12} \\
 &\quad + (m_2 + m_4)E_{21} + (m_1 - m_2 + m_3 + m_6)E_{22} \\
 &= m_1(E_{11} + E_{22}) + m_2(E_{21} - E_{22}) + m_3(E_{12} + E_{22}) \\
 &\quad + m_4(E_{11} + E_{21}) + m_5(-E_{11} + E_{12}) + m_6E_{22} + m_7E_{11} \\
 &= \sum_{r=1}^7 m_r w_r.
 \end{aligned}$$

¹in una comunicazione riportata da Landsberg in [45].

Possiamo anche calcolare gli m_r :

$$\begin{aligned} m_1 &= (a_{11} + a_{22})(b_{11} + b_{22}) \\ m_2 &= (a_{21} + a_{22})b_{11} \\ m_3 &= a_{11}(b_{12} - b_{22}) \\ m_4 &= a_{22}(b_{21} - b_{11}) \\ m_5 &= (a_{11} + a_{12})b_{22} \\ m_6 &= (a_{21} - a_{11})(b_{11} + b_{12}) \\ m_7 &= (a_{12} - a_{22})(b_{21} + b_{22}) \end{aligned}$$

Passando all'isomorfismo, e usando l'identificazione fatta sopra, la bilinear computation si può riscrivere in forma tensoriale come

$$\begin{aligned} \langle 2, 2, 2 \rangle &= (a_{11} + a_{22}) \otimes (b_{11} + b_{22}) \otimes (c_{11} + c_{22}) \\ &+ (a_{21} + a_{22}) \otimes b_{11} \otimes (c_{21} - c_{22}) \\ &+ a_{11} \otimes (b_{12} - b_{22}) \otimes (c_{12} + c_{22}) \\ &+ a_{22} \otimes (-b_{11} + b_{21}) \otimes (c_{21} + c_{11}) \\ &+ (a_{11} + a_{12}) \otimes b_{22} \otimes (-c_{11} + c_{12}) \\ &+ (-a_{11} + a_{21}) \otimes (b_{11} + b_{12}) \otimes c_{22} \\ &+ (a_{12} - a_{22}) \otimes (b_{21} + b_{22}) \otimes c_{11}. \end{aligned}$$

Espandendo i prodotto tensoriali e facendo opportune semplificazioni, possiamo ritrovare il tensore dell'algoritmo classico riportato nell'Equazione (3.18).

Osservazione 3.6.2 (Costo computazionale). Similmente a quanto svolto sopra, troviamo che $M(n) \leq O(n^{\log_2 7}) = O(n^{2.81})$. Inoltre, dalla Proposizione 3.5.1 troviamo che $\omega \leq \log_2 7 < 2.81$.

qui posso mettere $M(n) = O(\log_2 7)$?

Osservazione 3.6.3. L'algoritmo di Strassen non è unico: è possibile riscrivere il tensore sopra in funzione di una costante $t \in \mathbb{R}$ arbitraria. Si veda [45, Pag. 37].

3.7 ALCUNE STIME SULL'ESPONENTE

Ad esempio, l'algoritmo di Strassen [61] mostra che $\mathbf{R}(\langle 2, 2, 2 \rangle) \leq 7$, e come dimostrato da Winograd [65], $\mathbf{R}(\langle 2, 2, 2 \rangle) = 7$, ovvero non è possibile moltiplicare due matrici 2×2 con meno di sette moltiplicazioni. Nei casi diversi da $\langle 2, 2, 2 \rangle$ il problema si complica, e attualmente abbiamo alcune stime più lasche: già per matrici

3×3 , sappiamo solo che $19 \leq \mathbf{R}(\langle 3, 3, 3 \rangle) \leq 23$ [17, 42]; questo caso è ritenuto molto curioso perché esiste un'espressione nota per il tensore, ma è difficile calcolarne il rango. In dimensione più alta la migliore stima dal basso per matrici $n \times n$ è $\frac{5}{2}n^2 - 3n \leq \mathbf{R}(\langle n, n, n \rangle)$ [16]. Si veda [45, Capitolo 11] per una discussione più ampia.

3.8 ALGORITMI APA

Dopo il tentativo di Strassen di dimostrare che l'algoritmo di moltiplicazione standard fosse ottimale, Bini et. Al [14] considerano il seguente algoritmo di moltiplicazione ridotto ottenuto ponendo a zero l'entrata a_{22} di $\langle 2, 2, 2 \rangle$:

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & 0 \end{bmatrix} \cdot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} & a_{21}b_{12} \end{bmatrix}.$$

Facendo alcuni raccoglimenti e sostituendo $a_{22} = 0$, il tensore dell'Equazione (3.18) si riscrive come

$$\begin{aligned} \langle 2, 2, 2 \rangle^{\text{red}} &:= a_{11} \otimes (b_{11} \otimes c_{11} + b_{12} \otimes c_{12}) \\ &\quad + a_{12} \otimes (b_{21} \otimes c_{11} + b_{22} \otimes c_{12}) \\ &\quad + a_{21} \otimes (b_{11} \otimes c_{21} + b_{12} \otimes c_{22}). \end{aligned}$$

Che è somma di sei tensori elementari distinti, quindi $\mathbf{R}(\langle 2, 2, 2 \rangle^{\text{red}}) \leq 6$. Gli autori provarono a cercare un'espressione di rango cinque per $\langle 2, 2, 2 \rangle^{\text{red}}$ numericamente, calcolando

$$\min_{\substack{T \in \mathbb{R}^{n \times n \times n} \\ \mathbf{R}(T)=5}} \|\langle 2, 2, 2 \rangle^{\text{red}} - T\|$$

norma di $\langle 2, 2, 2 \rangle^{\text{red}}$. Il loro computer continuava a produrre tensori T di rango cinque con la norma della differenza che diventava sempre più piccola, ma con coefficienti sempre più grandi. Questo è andato avanti per un po' di tempo, fino a che realizzarono che il codice era giusto, ma quello che sembrava un errore era in realtà una manifestazione del border rank. L'espressione del tensore che stavano cercando era il seguente tensore di rango 5:

$$\langle n, n, n \rangle_t^{\text{red}} = \frac{1}{t} [(I) + (II) - (III) - (IV) + (V)],$$

dove

$$\begin{aligned}
(I) &= (a_{12} + ta_{11}) \otimes (b_{12} + tb_{22} \otimes c_{12}) \\
&= a_{12} \otimes b_{12} \otimes c_{12} + t[a_{12} \otimes b_{22} \otimes c_{12} + a_{11} \otimes b_{12} \otimes c_{12}] + O(t^2) \\
(II) &= (a_{21} + ta_{11}) \otimes b_{11} \otimes (c_{11} + tc_{21}) \\
&= a_{21} \otimes b_{11} \otimes c_{11} + t[a_{21} \otimes b_{11} \otimes c_{21} + a_{11} \otimes b_{11} \otimes c_{11}] + O(t^2) \\
(III) &= a_{12} \otimes b_{12} \otimes ((c_{11} + c_{12}) + tz_{22}) \\
&= a_{12} \otimes b_{12} \otimes c_{11} + a_{12} \otimes b_{12} \otimes c_{12} + t[a_{12} \otimes b_{12} \otimes c_{22}] \\
(IV) &= a_{21} \otimes ((b_{11} + b_{12}) + tb_{21}) \otimes c_{11} \\
&= a_{21} \otimes b_{11} \otimes c_{11} + a_{21} \otimes b_{12} \otimes c_{11} + t[a_{21} \otimes b_{21} \otimes c_{11}] \\
(V) &= (a_{12} + a_{21}) \otimes (b_{12} + tb_{21}) \otimes (c_{11} + tc_{22}) \\
&= a_{12} \otimes b_{12} \otimes c_{11} + a_{21} \otimes b_{12} \otimes c_{11} \\
&\quad + t[a_{12} \otimes (b_{12} + c_{22} + b_{21} \otimes c_{11}) + a_{21} \otimes (b_{12} \otimes c_{22} + b_{21} \otimes c_{11})] + O(t^2)
\end{aligned}$$

In ogni passaggio abbiamo applicato più volte la proprietà distributiva del prodotto tensoriale. Osserviamo che i termini di grado costante in t si cancellano:

$$\begin{aligned}
&a_{12} \otimes (b_{12} \otimes c_{12} - b_{12} \otimes c_{11} - b_{12} \otimes c_{12} + b_{12} \otimes c_{11}) \\
&+ a_{21} \otimes (b_{11} \otimes c_{11} - b_{11} \otimes c_{11} + b_{12} \otimes c_{11} - b_{12} \otimes c_{11}) = 0
\end{aligned}$$

Sommando e raggruppando i termini di grado uno in t troviamo

$$\begin{aligned}
\langle n, n, n \rangle^{\text{red}} &= a_{11} \otimes (b_{11} \otimes c_{11} + b_{12} \otimes c_{12}) + \\
&\quad a_{12} \otimes (b_{21} \otimes c_{11} + b_{22} \otimes c_{12}) + \\
&\quad a_{21} \otimes (b_{11} \otimes c_{21} + b_{12} \otimes c_{22}),
\end{aligned}$$

ovvero il tensore di partenza. Da cui,

$$\begin{aligned}
\langle n, n, n \rangle_t^{\text{red}} - \langle n, n, n \rangle^{\text{red}} &= \frac{1}{t} \left(t \langle n, n, n \rangle_t^{\text{red}} + O(t^2) \right) - \langle n, n, n \rangle^{\text{red}} \\
&= O(t) \xrightarrow[t \rightarrow 0]{} 0
\end{aligned}$$

Abbiamo dimostrato che i tensori approssimanti $\langle n, n, n \rangle_t^{\text{red}}$, di rango 5 convergono ad un tensore di rango 6, cioè che $\underline{R}(\langle n, n, n \rangle_t^{\text{red}}) \leq 5$. Nella pratica, è possibile calcolare il prodotto di due matrici usando il tensore $\langle n, n, n \rangle_t^{\text{red}}$ per una scelta di t maggiore della precisione di macchina, riducendo il numero di moltiplicazioni a

costo di un errore algoritmico che accenneremo in § 3.9.

Il border rank si rivela utilissimo nello studio dell'esponente ω , cioè possiamo sostituire il rango con il border rank nel Teorema 3.5.6:

Teorema 3.8.1 (Bini [14], vedi §3.2).

$$\omega = \inf\{\tau \in \mathbb{R} \mid \underline{\mathbf{R}}(\langle n, n, n \rangle) = O(n^\tau)\}.$$

Possiamo inoltre generalizzare la Proposizione 3.5.1.

Proposizione 3.8.2. *Se $\underline{\mathbf{R}}(\langle n, n, n \rangle) \leq r$ per degli interi positivi n, r , allora $n^\omega \leq r$.*

Riportiamo alcune stime sul border rank riportate in [44, §1]. Per $n = 2$, Landsberg [43] dimostra che $\underline{\mathbf{R}}(\langle 2, 2, 2 \rangle) = \mathbf{R}(\langle 2, 2, 2 \rangle) = 7$. Ci aspetteremmo che per $n > 2$, $\underline{\mathbf{R}}(\langle n, n, n \rangle) < \mathbf{R}(\langle n, n, n \rangle)$, ma la risposta non è così semplice. Per $n = 3$, sappiamo solo che $15 \leq \underline{\mathbf{R}}(\langle 3, 3, 3 \rangle) \leq 20$, mentre per il rango vale $19 \leq \mathbf{R}(\langle 3, 3, 3 \rangle) \leq 23$. In generale, sappiamo che $\mathbf{R}(\langle n, n, n \rangle) \geq 3n^2 - o(n)$ e $\underline{\mathbf{R}}(\langle n, n, n \rangle) \geq 2n^2 - \lceil \log_2(n) \rceil - 1$.

3.9 ERRORE ALGORITMICO

Discutiamo brevemente l'errore algoritmico degli algoritmi di moltiplicazione veloci, rimandando a [6] per ulteriori dettagli. Gli algoritmi di moltiplicazione veloci producono errori numerici più grandi rispetto all'algoritmo classico, dove l'errore in avanti è dato componente per componente, e dipende solo dal prodotto scalare della riga e colonna corrispondente. Questa proprietà è detta *stabilità rispetto alle componenti*. Gli algoritmi veloci, invece, eseguono calcoli che coinvolgono altre entrate della matrice che non appaiono nel prodotto scalare (eventualmente questi contributi si cancellano), dunque gli errori dipendono da proprietà globali delle matrici di input. In gergo, gli algoritmi veloci ² sono detti stabili rispetto alla norma [15, 49], mentre quello classico gode della proprietà detta sopra, che è una caratteristica irraggiungibile per gli algoritmi veloci [49]. Definiamo la *stabilità rispetto alla norma* per il prodotto $C = AB$ dove $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times k}$ come

$$\|\hat{C} - C\| \leq f_{\text{alg}}(n)\|A\|\|B\| + O(\varepsilon^2),$$

dove $\|\cdot\|$ è la norma del massimo, ε è la precisione di macchina, e f_{alg} è una costante polinomiale che dipende dall'algoritmo. Ad esempio, $f_{\text{alg}}(n) = n^2$ per l'algoritmo


²senza ulteriori modifiche, come manipolazione algoritmica per ridurre l'errore di arrotondamento

di moltiplicazione classico, senza alcuna ipotesi sull'ordinamento dei calcoli svolti dal prodotto scalare. Osserviamo che f_{alg} è indipendente dalle matrici di input, e $\|A\|\|B\|$ è indipendente dall'algoritmo.


ANDAMENTO DELL'ERRORE

Per analizzare il comportamento dell'errore algoritmico abbiamo confrontato l'algoritmo $\langle 2, 2, 2 \rangle^{\text{red}}$ con l'algoritmo di Strassen e con la routine di moltiplicazione standard fornita da Intel MKL DGEMM [37] (Math Kernel Library, Double-precision General Matrix Multiply). Gli esperimenti sono stati condotti per dimensioni delle matrici $N = 2^1, \dots, 2^{13} = 8192$ e livelli di ricorsione $L \in \{1, 2, 3\}$. I risultati sono riportati in Figura 3.6.

Chiamiamo $\hat{C}$ il prodotto calcolato dall'algoritmo veloce e C il risultato dell'algoritmo di moltiplicazione standard (in questo caso MKL DGEMM) e studiamo l'andamento dell'errore relativo $\frac{\|\hat{C} - C\|_F}{\|C\|_F}$ all'aumentare della dimensione N . Come mostrato in Figura 3.6a l'algoritmo $\langle 2, 2, 2 \rangle^{\text{red}}$ raggiunge prestazioni elevate grazie all'impiego di sole 5 moltiplicazioni. Tuttavia, come evidenziato in Figura 3.6b, l'accumulo degli errori di arrotondamento nel calcolo di $\hat{C}$, dovuti al parametro ε , porta ad una crescita dell'errore relativo all'aumentare della profondità di ricorsione ($L = 2, 3$).



(a) Prestazioni computazionali (GFLOPS effettivi)



(b) Errore relativo in norma di Frobenius

Figura 3.6: Confronto delle prestazioni computazionali (in GFLOPS effettivi) e dell'errore relativo in norma di Frobenius tra gli algoritmi al variare della dimensione della matrice $N = 2, 4, 8, \dots, 8192$.

4

APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP

migliorato

In questo capitolo esploreremo due applicazioni della decomposizione CP di un tensore a tre indici in due ambiti modellistici, dove avremo modo di applicare il Teorema di Kruskal 2.2.8 e l'algoritmo Alternating Least Squares. Nel primo esperimento il rango non sarà noto a priori e dovremo prima approssimarlo, per poi trovare una decomposizione. Nel secondo conosceremo il rango a priori. In entrambi gli esperimenti sarà necessario risolvere l'ambiguità del riscaldamento e della permutazione dei fattori per preservare il modello reale.

4.1 SPETTROSCOPIA FLUORESCENTE

Nella *spettroscopia fluorescente*, un campione chimico è eccitato e la luce emessa viene misurata a diverse lunghezze d'onda, risultando in una matrice di *eccitazione-emissione* (EEM) di intensità fluorescenti (si veda Figura 4.1). Quando i dati EEM vengono raccolti da diversi campioni, otteniamo un tensore a tre indici. Questi dati si possono utilizzare nella chimica analitica per stimare le concentrazioni e gli spettri dei composti chimici a partire da più miscele.

Nel dettaglio, vengono dati I campioni di soluzioni chimiche, ognuno dei quali contiene diverse sostanze diluite in diverse concentrazioni. Il primo obiettivo è determinare il numero r delle diverse sostanze presenti. Il dataset che analizziamo [1, 39] è composto da una serie di esperimenti riportati da [57], nel quale sono presenti tre sostanze chimiche disciolte nelle soluzioni:

- *Valine-Tyrosine-Valine* (Val-Tyr-Val) - peptide,
- *Tryptophan-Glycine* (Trp-Gly) - peptide,
- *Phenylalanine* (Phe) - aminoacido.

Segnaliamo che i dati sono stati preprocessati dagli autori per riempire i dati mancanti e sostituire le entrate negative, come spiegato in [39].




Figura 4.1: Rappresentazione schematica di uno spettrofotometro per spettroscopia di fluorescenza.

Ogni campione, diciamo il numero i -esimo è successivamente eccitato da una luce in J diverse lunghezze d'onda. Per ogni lunghezza d'onda di eccitazione, viene misurato lo spettro emesso. Diciamo che l'intensità della luce fluorescente emessa è misurata da K diverse lunghezze d'onda. Allora per ogni i otteniamo una matrice $J \times K$ di eccitazione-emissione.

Quindi i dati possono essere rappresentati come un array $I \times J \times K$, scrivibile come

$$T = \sum_{f=1}^r a_f \otimes b_f \otimes c_f,$$

in componenti,

$$T_{ijk} = \sum_{f=1}^r a_{if} b_{jf} c_{kf},$$

dove $a_{i,f}$ è la concentrazione della f -esima sostanza nell' i -esimo campione, $c_{k,f}$ è la frazione di protoni che la f -esima sostanza emette nella lunghezza d'onda k e $b_{j,f}$ è l'intensità della luce incidente alla lunghezza d'onda j moltiplicata per l'assorbimento alla lunghezza d'onda j . Il primo obiettivo è trovare un r tale che ogni f rappresenti una sostanza.

Il dataset analizzato contiene le misurazioni di matrici di eccitazione-emissione (EEM) per 18 campioni, ognuno dei quali consiste in una miscela dei tre composti chimici sopra (Val-Tyr-Val, Trp-Gly e Phe). I dati sono organizzati in un tensore tridimensionale di dimensioni $I \times J \times K = 18 \times 251 \times 21$, corrispondenti rispettivamente ai 18 campioni, alle 251 lunghezze d'onda di emissione (250, 251, ..., 500nm) e alle lunghezze d'onda di eccitazione (210, 215, ..., 310nm). Una rappresentazione

tridimensionale del tensore è mostrata in Figura 4.2, mentre alcune sezioni di matrici di eccitazione-emissione sono visualizzate in Figura 4.3.




Figura 4.2: Rappresentazione tridimensionale del tensore EEM di dimensioni $18 \times 251 \times 21$.

Cerchiamo una fattorizzazione approssimata di $\hat{T}$ con le tecniche descritte nella § 1.10. Fissata una tolleranza ε piccola, applichiamo il procedimento dell’Algoritmo 2. La ricerca di $\hat{T}$ viene ripetuta attraverso una serie di restarts per evitare minimi locali, al termine dei quali viene restituito il tensore che minimizza l’errore relativo ε_{rel} . Nell’articolo originale [57] vengono anche esclusi i tensori che non sono ragionevoli da un punto di vista fisico per rimuovere valori di r troppo piccoli. Per i nostri scopi ci limitiamo a imporre che le quantità fisiche coinvolte (concentrazioni, intensità di emissione ed eccitazione) siano non negative, per cui si scartano le decomposizioni che presentano fattori negativi.

Algorithm 2 Algoritmo di approssimazione del tensore originale.

```

1: for  $i = 1 \dots r$  do
2:   repeat
3:      $\hat{T} \leftarrow \arg \min_{A,B,C} \|T - \llbracket A, B, C \rrbracket\|$  ▷ CP ALS con restarts.
4:   until  $\|T - \hat{T}\| < \varepsilon$ 
5: end for
```

Assumiamo ora che il rango ottimale r sia stato determinato attraverso l’euristica discussa in § 1.7. Siccome i valori di r sono relativamente piccoli, a meno di piccole perturbazioni, l’espressione di $\hat{T}$ come somma di elementi di rango uno sarà unica grazie al Teorema di Kruskal 2.2.8. Quindi, decomponendo $\hat{T}$, possiamo recuperare la concentrazione di ognuna delle r sostanze in ogni soluzione, determinando i vettori a_f così come lo spettro delle eccitazioni ed emissioni determinando i vettori b_f . La Figura 4.5 mostra i fattori calcolati e il confronto con le concentrazioni reali delle tre sostanze, arrestando CP ALS quando la differenza dell’errore relativo tra due iterazioni susseguenti è minore di 10^{-4} . Nel grafico sono tracciati i fattori a_f, b_f, c_f della decomposizione CP, dove ogni riga $f = 1, 2, 3$ rappresenta una sostanza diversa (scritta in sottoimpressione). Ad esempio, la componente a_1 sono le barre blu nella




Figura 4.3: Profili d'intensità di emissione-eccitazione del tensore EEM. I profili rappresentano le matrici EEM e corrispondono alle fette orizzontali del tensore, ordinate dall'alto ($T_{1,:,:}$) al basso ($T_{18,:,:}$). Ogni fetta è etichettata a destra con le concentrazioni dei tre composti chimici (Val-Tyr-Val/Trp-Gly/Phe), e copre 21 lunghezze d'onda d'eccitazione per 251 lunghezze d'onda di emissione.




Figura 4.4: Errore relativo al variare del rango della decomposizione approssimante. Il rango ottimale selezionato è $r = 3$, corrispondente al superamento della tolleranza target $\varepsilon = 0.05$. Osserviamo che la precisione non varia di molto all'aumentare di r .

prima sottofigura in alto a sinistra, dove notiamo che i primi due fattori di a_1 sono nulli, che significa che la componente non è presente nei primi due campioni. Nella colonna centrale in alto denotiamo le componenti individuali di b_1 , che sono 256, con dei punti. Il terzo fattore c_1 è rappresentato nella figura in alto a destra. Analogamente la seconda riga descrive i fattori a_2, b_2, c_2 e la terza a_3, b_3, c_3 . Nel calcolo della fattorizzazione abbiamo dovuto riscaldare i fattori del tensore ottenuto da ALS per mantenere i valori fedeli al tensore originale. Inoltre abbiamo permutato i fattori con un algoritmo simile a quello che descriveremo nella § 4.2.

Serve precisare meglio?




Figura 4.5: Fattori della decomposizione CP non negativa a rango $r = 3$ del tensore EEM. I diagrammi a barre a sinistra confrontano i profili di concentrazione calcolati con le concentrazioni effettive delle tre sostanze (Val-Tyr-Val, Trp-Gly, Phe).

4.2 BLIND SOURCE SEPARATION

Immaginiamo una stanza affollata in cui diverse persone parlano contemporaneamente, mentre alcuni microfoni sparsi per la sala che registrano le conversazioni. Poiché i microfoni catturano solo la sovrapposizione delle singole voci, l'obiettivo è elaborare le registrazioni per isolare la voce di ogni singola persona. Questo scenario è noto nell'analisi di segnali come *blind source separation*.

In questa sezione studieremo un problema simile utilizzando la decomposizione CP. In particolare, ci concentreremo su un'applicazione nel campo delle telecomunicazioni wireless nota come *blind deconvolution* nel modello *direct-sequence code-division multiple access* (DS-CDMA) [26, 45, 55] che riadattiamo in questa sezione.

Per semplicità supponiamo che R utenti mandino dei messaggi a I antenne. I messaggi arrivano mischiati, e l'obiettivo è recuperare i segnali individuali e le posizioni degli utenti.




Figura 4.6: $R = 3$ sorgenti inviano segnali a $I = 2$ antenne.

L'utente r -esimo trasmette il messaggio in un vettore di $s_r = [s_{1r}, \dots, s_{Kr}]^T \in \mathbb{R}^K$, dove le entrate sono numeri reali random. Ci sono I antenne che ricevono i segnali. Quando i segnali arrivano all' i -esima antenna, il segnale ha subito distorsione nella sua intensità e fase (anche detta *fading/gain*), quindi ciò che viene ricevuto dall'antenna i -esima sono le IK quantità $a_{ir}s_{kr}$, dove a_{ir} è il fading/gain tra l'utente r e l'antenna i .

In questo scenario si riceve un tensore (matrice) $T \in \mathbb{C}^{I \times K}$ di rango R di entrate

$$T_{ik} = \sum_{r=1}^R a_{ir}s_{kr}.$$

L'obiettivo sarebbe recuperare i segnali s_r , per $1 \leq r \leq R$ da questa matrice decomponendola come somma di matrici di rango uno. Sfortunatamente, questa decomposizione non è mai unica quando $R > 1$. Per aggirare il problema, vengono introdotti dei “codici” per “diffondere” il segnale che ogni utente invia per ottenere un tensore a tre indici che avrà generalmente una decomposizione unica.¹

Facciamo le seguenti ipotesi sulla trasmissione dei segnali: la trasmissione avviene in linea d'aria, seguendo la strada più breve (secondo la distanza euclidea) senza incontrare ostacoli; i simboli inviati arrivano in maniera ordinata senza sovrapposizione (esempio $s_{k,r}$ allo stesso tempo di $s_{k+1,r}$). Questi comportamenti sono noti in letteratura come ICI (*interchip interference*) e ISI (*intersignal interference*). Inoltre i segnali non subiscono rumore e non vengono memorizzati.

Per recuperare s_r e a_{ir} , l' r -esimo utente introduce una ridondanza in termini di codice chiamata *spreading sequence* che è fissata per ogni utente, diciamo $c_r = [c_{1r}, \dots, c_{Jr}]^\top$. Vengono trasmesse simultaneamente J quantità $[s_{kr}c_{1r}, \dots, s_{kr}c_{Jr}]$, chiamate *chips* al tempo k , dove in ogni entrata rappresenta la trasmissione del simbolo s_{kr} su una frequenza diversa. La trasmissione totale sopra JK unità di tempo dell'utente r -esimo sono le JK chips $c_{jr}s_{kr}$, $1 \leq j \leq J$, $1 \leq k \leq K$ (qui J è anche detto *spreading gain*). L'antenna i -esima riceve le JK quantità $\sum_r a_{ir}c_{jr}s_{kr}$, per $1 \leq j \leq J$, $1 \leq k \leq K$, dove, come sopra, a_{ir} sono i fading/gain tra l'utente r e l'antenna i . In totale, viene ricevuto un tensore $T \in \mathbb{C}^{I \times J \times K}$ di rango R scrivibile in componenti come

$$(4.1) \quad T_{ijk} = \sum_{r=1}^R a_{ir}c_{jr}s_{kr},$$

o in generale,

$$T = \sum_{r=1}^R a_r \otimes c_r \otimes s_r.$$

In altre parole, $T = \llbracket S, C, A \rrbracket$. L'obiettivo è recuperare i segnali s_r , per $1 \leq r \leq R$ da questo tensore, cioè la matrice S . Per farlo abbiamo bisogno che la scrittura sia essenzialmente unica. Per il Teorema di Kruskal 2.2.8 questa decomposizione è unica se

$$\mathbf{k}_A + \mathbf{k}_B + \mathbf{k}_C \geq 2(R + 1).$$

Per costruzione [26] le matrici A e C sono di k -rango pieno con probabilità 1, mentre

¹Tale spreading è comune nelle telecomunicazioni, e.g. della ridondanza è introdotta per compensare gli errori causati dalla corruzione dei segnali durante la trasmissione.

se i simboli trasmessi s_{Kr} appartengono ad un alfabeto finito, c'è possibilità che S non sia di k -rango pieno—c'è una possibilità che le sequenze di utenti diversi possano essere uguali, ma questo è poco probabile per dataset più grandi. Quindi nella pratica assumiamo che S sia di k -rango pieno. Questo significa che il numero di utenti che possono essere processati simultaneamente si può considerare limitato come

$$(4.2) \quad \min\{I, R\} + \min\{J, R\} + \min\{K, R\} \geq 2(R + 1).$$

Il calcolo di T avviene con l'Algoritmo ALS 1.

Osservazione 4.2.1. Una limitazione di questo modello è che in ambito industriale spesso ci sono poche antenne e meno utenti, quindi si perde l'unicità.

ESPERIMENTO NUMERICO

Consideriamo lo scenario dove $R = 4$ utenti vogliono inviare messaggi di $K = 100$ simboli a $I = 5$ antenne, con un fattore di spreading $J = 16$. Generiamo dei tensori

$$T_\sigma = T_{\text{clean}} + W_\sigma \in \mathbb{R}^{I \times J \times K}$$

dove W_σ è un tensore di rumore gaussiano con entrate in $\mathcal{N}(0, \sigma)$ e T_{clean} è un tensore generato in formato denso a partire dalla decomposizione $T_{\text{clean}} = \llbracket A, C, S \rrbracket$. L'esperimento consiste in recuperare la posizione degli R utenti conoscendo la posizione delle antenne (la matrice A). Per farlo dobbiamo calcolare le matrici S e C , sfruttando la decomposizione CP al variare del rumore σ nella Tabella 4.1.

Tabella 4.1: Livelli di rumore gaussiano applicati al tensore $T_\sigma = T_{\text{clean}} + W_\sigma$, con relativo rapporto segnale-rumore (SNR) e corrispondente scenario fisico di trasmissione.

Rumore	σ	SNR _{dB}	Scenario fisico
σ_0	0,0000	∞ dB	Assenza di rumore
σ_1	0,0173	16,5 dB	Segnale ottimo
σ_2	0,0403	9,1 dB	Segnale buono
σ_3	0,0691	4,4 dB	Segnale debole
σ_4	0,1037	0,9 dB	Segnale quasi assente
σ_5	0,1382	-1,6 dB	Fortissime interferenze

- Matrice delle antenne $A \in \mathbb{R}^{I \times R}$: generiamo le posizioni delle antenne p_i e degli utenti u_r nel quadrato $[0, L]^2$, dove L è un generico intero positivo,

per $i = 1, \dots, I$ e $r = 1, \dots, R$. Le entrate di A sono $a_{ir} := \frac{1}{\|p_i - u_r\|_2}$, dove assumiamo che $\|p_i - u_r\|_2 > 0$ (gli utenti non si trovano sulle antenne).

- Matrice dei simboli $S \in \mathbb{R}^{K \times R}$ con entrate s_{kr} secondo la distribuzione gaussiana standard $\mathcal{N}(0, 1)$.
- Matrice delle sequenze di spreading $C \in \{-1, 1\}^{J \times R}$: contiene i codici casuali assegnati a ciascuna delle R sorgenti, dove $c_{jr} = -1$ o $c_{jr} = 1$ con uguale probabilità.

L'Algoritmo ALS 1 produce un tensore approssimante $\hat{T} = \llbracket \hat{A}, \hat{C}, \hat{S} \rrbracket$ unico a meno di permutazione e riscalamento dei fattori: per i valori scelti, l'Equazione 4.2 è verificata in senso stretto. In questa applicazione è importante recuperare l'ordine dei fattori—altrimenti un utente finirebbe per trovarsi sulla posizione di un altro utente. Descriviamo ad alto livello il procedimento per recuperare la permutazione originale. Indichiamo con (a_r, c_r, s_r) i fattori di T e con $(\hat{a}_r, \hat{c}_r, \hat{s}_r)$ i fattori di $\hat{T}$.

1. Calcoliamo correlazione tra ogni colonna $\hat{a}_k$ e a_r tramite $\rho_{kr} := \frac{\hat{a}_k^\top a_r}{\|\hat{a}_k\|_2 \cdot \|a_r\|_2}$.
2. Costruiamo la matrice dei costi $M \in \mathbb{R}^{R \times R}$ di entrate $M_{kr} = 1 - |\rho_{kr}|$.
3. Troviamo una permutazione ottima $\pi^* \in \mathfrak{S}_R$ che realizza

$$\min_{\pi \in \mathfrak{S}_R} \sum_{r=1}^R M_{\pi(r), r}.$$

4. Calcoliamo il cambio di segno tramite $\xi_r := \text{sign}(\hat{a}_{\pi^*(r)}^\top a_r) \in \{-1, 1\}$.
5. Permutiamo e riscaliamo $\hat{A}$ e $\hat{S}$ applicando $\xi_r \hat{A}_{:, \pi^*(r)}$ e $\xi_r \hat{S}_{:, \pi^*(r)}$, rispettivamente.

RISULTATI

Nel contesto definito sopra, denotiamo gli utenti reali $r \in \{1, \dots, R\}$ con dei quadrati e gli utenti recuperati con degli omini dello stesso colore. Inizialmente verifichiamo che in assenza di rumore l'utente recuperato combaci con l'utente reale, come illustrato in Figura 4.7. Inoltre verifichiamo che ciò funzioni per diverse disposizioni degli utenti e delle antenne in Figura 4.8. Di seguito, generiamo più tensori T_σ al variare di σ nella Tabella 4.1 e osserviamo quanto gli utenti recuperati si discostano dall'utente originale. In Figura 4.9 osserviamo i comportamenti tipici di deriva al

crescere del rumore. Infine, la Figura 4.10 mostra ulteriori esecuzioni dell'algoritmo su sei configurazioni spaziali differenti.




Figura 4.7: Stima della posizione degli utenti e delle antenne in assenza di rumore. I quadrati trasparenti indicano le posizioni reali degli utenti U_r , gli omini indicano le posizioni stimate $\hat{U}_r$, i triangoli scuri indicano le antenne a_i , e le circonferenze tratteggiate indicano le distanze stimate dalle antenne.




Figura 4.8: Stima della posizione degli utenti e delle antenne in sei esperimenti indipendenti con diverse disposizioni spaziali di antenne e sorgenti in assenza di rumore.


Deriva della Localizzazione degli Utenti sotto Rumore Gaussiano ($R=4$, $I=5$)

Figura 4.9: Deriva della localizzazione degli utenti sotto sei livelli crescenti di rumore gaussiano $(\sigma_0, \dots, \sigma_5)$ per un singolo esperimento. Gli omini numerati da 1 a 5 indicano le posizioni stimate al crescere del livello di rumore.



Figura 4.10: Deriva della localizzazione degli utenti sotto rumore gaussiano per sei esperimenti indipendenti (disposizioni spaziali differenti), mostrando i comportamenti tipici di deriva al crescere del livello di rumore σ_l .

ACRONIMI

ALS	Alternating Least Squares
APA	Arbitrary Precision Approximating
BSS	Blind Source Separation
CP	Canonical Polyadic Decomposition
DS-CDMA	Direct-Sequence Code-Division Multiple Access
EEM	Excitation-Emission Matrix
ICI	Interchip Interference
ISI	Intersignal Interference
SNR	Signal-to-Noise Ratio
SVD	Singular Value Decomposition

GLOSSARIO

$A_1 \otimes \cdots \otimes A_d$	Spazio vettoriale del prodotto tensoriale di d spazi
$\langle m, n, p \rangle$	Tensore o mappa bilineare della moltiplicazione di matrici di dimensioni $(m \times n)$ e $(n \times p)$
$\langle T_1, T_2 \rangle$	Prodotto scalare tra tensori
$\mathbf{R}(T)$	Border rank di un tensore
$\llbracket A_1, \dots, A_d \rrbracket$	Notazione di Kruskal per la decomposizione CP
$\ T\ _F$	Norma di Frobenius di un tensore o matrice
$\mathrm{GL}_n(\mathbb{K})$	Gruppo generale lineare delle matrici $n \times n$ invertibili su $\mathbb{K}$
$*$	Prodotto di Hadamard (elemento per elemento)
$\mathbb{K}$	Campo scalare generico ($\mathbb{R}$ o $\mathbb{C}$)
$\mathbf{k}_A$	Kruskal rank (k -rango) della matrice A
$\boxtimes$	Prodotto di Kronecker tra matrici
$\odot$	Prodotto di Khatri-Rao (Kronecker colonna per colonna)
$\mathbf{R}_{\text{multilin}}(T)$	Rango multilineare (tupla dei ranghi delle matricizzazioni)
$\mathbb{N}, \mathbb{Z}, \mathbb{Q}, \mathbb{R}, \mathbb{C}$	Insiemi dei numeri naturali, interi, razionali, reali e complessi
$[n]$	Insieme degli indici $\{1, 2, \dots, n\}$
ω	Esponente di complessità della moltiplicazione tra matrici
$\mathbf{R}(T), \text{rank}(M)$	Rango tensoriale o rango matriciale
$\mathfrak{S}_n$	Gruppo simmetrico su n elementi
T	Tensore di ordine d
$T_{(\ell)}$	Matricizzazione (ℓ -esimo unfolding) del tensore T
$\otimes$	Prodotto tensoriale o esterno (outer product)
$A^\top$	Matrice trasposta
$T_{:, :, k}, T_{:, j, k}$	Slice e fibra di un tensore
$\times_n$	Prodotto tensore-matrice lungo il modo n
$U^\perp$	Annullatore / complemento ortogonale del sottospazio U
V^*	Spazio duale dello spazio vettoriale V
$\text{vec}(M)$	Vettorizzazione di una matrice o tensore

BIBLIOGRAFIA

1. E. Acar, E. E. Papalexakis, G. Gürdeniz, M. A. Rasmussen, A. J. Lawaetz, M. Nilsson, e R. Bro. «Structure-Revealing Data Fusion». *BMC Bioinformatics* 15:1, 2014, p. 239. DOI: [10.1186/1471-2105-15-239](https://doi.org/10.1186/1471-2105-15-239).
2. J. Alman, R. Duan, V. V. Williams, Y. Xu, Z. Xu, e R. Zhou. «More asymmetry yields faster matrix multiplication». *Computing Research Repository (arXiv)*, 2024. arXiv:2404.16349.
3. J. Alman, V. Vassilevska Williams et al. «Improving the matrix multiplication exponent with modern optimization and AlphaEvolve». *arXiv preprint*, 2026.
4. M. Astrid e S.-I. Lee. «Cp-decomposition with tensor power method for convolutional neural networks compression». In: *2017 IEEE International Conference on Big Data and Smart Computing (BigComp)*. IEEE. 2017, pp. 115–118.
5. M. Atkinson e N. Stephens. «On the maximal multiplicative complexity of a family of bilinear forms». *Linear Algebra and its applications* 27, 1979, pp. 1–8.
6. G. Ballard, A. R. Benson, A. Druinsky, B. Lipshitz, e O. Schwartz. «Improving the numerical stability of fast matrix multiplication». *SIAM Journal on Matrix Analysis and Applications* 37:4, 2016, pp. 1382–1418.
7. G. Ballard e T. G. Kolda. *Tensor Decompositions for Data Science*. Cambridge University Press, 2025. URL: <https://tensortextbook.com>.
8. A. R. Benson e G. Ballard. «A Framework for Practical Parallel Fast Matrix Multiplication». *CoRR* abs/1409.2908, 2014. arXiv: [1409.2908](https://arxiv.org/abs/1409.2908). URL: <http://arxiv.org/abs/1409.2908>.
9. J. M. F. ten Berge. «Simplicity and typical rank results for three-way arrays». *Psychometrika* 76:1, 2011, pp. 3–12. DOI: [10.1007/s11336-010-9193-1](https://doi.org/10.1007/s11336-010-9193-1).
10. J. M. F. ten Berge. «The typical rank of tall three-way arrays». *Psychometrika* 65:4, 2000, pp. 525–532. DOI: [10.1007/BF02296342](https://doi.org/10.1007/BF02296342).

11. J. M. F. ten Berge e H. A. L. Kiers. «Simplicity of core arrays in three-way principal component analysis and the typical rank of $p \times q \times 2$ arrays». *Linear Algebra and its Applications* 294:1–3, 1999, pp. 169–179. DOI: [10.1016/S0024-3795\(99\)00057-9](https://doi.org/10.1016/S0024-3795(99)00057-9).
12. J. M. F. ten Berge, N. D. Sidiropoulos, e R. Rocci. «Typical rank and INDSCAL dimensionality for symmetric three-way arrays of order $I \times 2 \times 2$ or $I \times 3 \times 3$ ». *Linear Algebra and its Applications* 388, 2004, pp. 363–377. DOI: [10.1016/j.laa.2004.03.009](https://doi.org/10.1016/j.laa.2004.03.009).
13. J. M. F. ten Berge e A. Stegeman. «Symmetry transformations for square sliced three-way arrays, with applications to their typical rank». *Linear Algebra and its Applications* 418:1, 2006, pp. 215–224. DOI: [10.1016/j.laa.2006.02.002](https://doi.org/10.1016/j.laa.2006.02.002).
14. D. Bini. «Relations between exact and approximate bilinear algorithms. Applications». *Calcolo* 17:1, 1980, pp. 87–97. DOI: [10.1007/bf02575865](https://doi.org/10.1007/bf02575865). URL: <https://doi.org/10.1007/bf02575865>.
15. D. Bini e G. Lotti. «Stability of fast algorithms for matrix multiplication». *Numerische Mathematik* 36:1, 1980, pp. 63–72.
16. M. Bläser. «A $(5/2)n^2$ -Lower Bound for the Multiplicative Complexity of $n \times n$ -Matrix Multiplication». In: *Proceedings of the 18th Annual Symposium on Theoretical Aspects of Computer Science*. STACS '01. Springer-Verlag, Berlin, Heidelberg, 2001, pp. 99–109. ISBN: 3540416951.
17. M. Bläser. «On the complexity of the multiplication of matrices of small formats». *Journal of Complexity* 19:1, 2003, pp. 43–60. ISSN: 0885-064X. DOI: [https://doi.org/10.1016/S0885-064X\(02\)00007-9](https://doi.org/10.1016/S0885-064X(02)00007-9). URL: <https://www.sciencedirect.com/science/article/pii/S0885064X02000079>.
18. P. Bürgisser, M. Clausen, e M. A. Shokrollahi. *Algebraic complexity theory*. Vol. 315. Springer Science & Business Media, 2013.
19. F. Calamante, M. Mørup, e L. K. Hansen. «Defining a local arterial input function for perfusion MRI using independent component analysis». *Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine* 52:4, 2004, pp. 789–797.
20. J. D. Carroll e J.-J. Chang. «Analysis of individual differences in multidimensional scaling via an N-way generalization of “Eckart-Young” decomposition». *Psychometrika* 35:3, 1970, pp. 283–319.

21. V. Choulakian. «Some properties of the PARAFAC model». *Journal of Chemometrics* 24:7–8, 2010, pp. 483–490. DOI: [10.1002/cem.1310](https://doi.org/10.1002/cem.1310).
22. D. Coppersmith e S. Winograd. «Matrix multiplication via arithmetic progressions». *Journal of Symbolic Computation* 9:3, 1990. Computational algebraic complexity editorial, pp. 251–280. ISSN: 0747-7171. DOI: [https://doi.org/10.1016/S0747-7171\(08\)80013-2](https://doi.org/10.1016/S0747-7171(08)80013-2). URL: <https://www.sciencedirect.com/science/article/pii/S0747717108800132>.
23. T. H. Cormen, C. E. Leiserson, R. L. Rivest, e C. Stein. *Introduction to algorithms*. MIT press, 2022.
24. P. D’Alberto. *Strassen’s Matrix Multiplication Algorithm Is Still Faster*. 2023. arXiv: [2312.12732](https://arxiv.org/abs/2312.12732) [cs.MS]. URL: <https://arxiv.org/abs/2312.12732>.
25. L. DeLathauwer. «A Link between the Canonical Decomposition in Multilinear Algebra and Simultaneous Matrix Diagonalization». *SIAM Journal on Matrix Analysis and Applications* 28:3, 2006, pp. 642–666. DOI: [10.1137/040608830](https://doi.org/10.1137/040608830). eprint: <https://doi.org/10.1137/040608830>. URL: <https://doi.org/10.1137/040608830>.
26. L. DeLathauwer e A. de Baynast. «Blind deconvolution of DS-CDMA signals by means of decomposition in rank-(1, L, L) terms». *IEEE Transactions on Signal Processing* 56:4, 2008, pp. 1562–1571.
27. A. Defendi. *bachelor-thesis: Experiments Project*. <https://github.com/defending1/bachelor-thesis/tree/master/sandbox/experiments>. 2026.
28. A. Defendi. *fast-matmul: Rust Port*. <https://github.com/defending1/fast-matmul>. 2026.
29. C. Eckart e G. Young. «The approximation of one matrix by another of lower rank». *Psychometrika* 1:3, 1936, pp. 211–218.
30. A. Fawzi, M. Balog, A. Huang, T. Hubert, B. Romera-Paredes, M. Barekatain, A. Novikov, F. J. R. Ruiz, J. Schrittwieser, G. Swirszcz et al. «Discovering faster matrix multiplication algorithms with reinforcement learning». *Nature* 610:7930, 2022, pp. 47–53.
31. S. Friedland. «On the generic rank of 3-tensors». *Linear Algebra and its Applications* 436:3, 2012, pp. 478–497. DOI: [10.1016/j.laa.2011.08.031](https://doi.org/10.1016/j.laa.2011.08.031).

32. F. L. Gall. «Powers of Tensors and Fast Matrix Multiplication». *CoRR* abs/1401.7714, 2014. arXiv: [1401.7714](https://arxiv.org/abs/1401.7714). URL: <http://arxiv.org/abs/1401.7714>.
33. W. Hackbusch e B. N. Khoromskij. «Tensor-product approximation to multidimensional integral operators and Green’s functions». *SIAM journal on matrix analysis and applications* 30:3, 2008, pp. 1233–1253.
34. R. A. Harshman e M. E. Lundy. «Uniqueness proof for a family of models sharing features of Tucker’s three-mode factor analysis and PARAFAC/CANDECOMP». *Psychometrika* 61:1, 1996, pp. 133–154.
35. J. Håstad. «Tensor rank is NP-complete». In: *International colloquium on automata, languages, and programming*. Springer. 1989, pp. 451–460.
36. R. A. Horn e C. R. Johnson. *Matrix analysis*. Cambridge university press, 2012.
37. Intel Corporation. *Intel® oneAPI Math Kernel Library Reference Manual*. Intel Corporation. Santa Clara, CA, 2024. URL: <https://www.intel.com/content/www/us/en/developer/tools/oneapi/onemkl.html>.
38. J. JáJá. «Optimal evaluation of pairs of bilinear forms». *SIAM Journal on Computing* 8:3, 1979, pp. 443–462. DOI: [10.1137/0208037](https://doi.org/10.1137/0208037).
39. T. G. Kolda. *EEM Tensor Dataset*. https://gitlab.com/tensors/tensor_data_eem. Accesso: 25 agosto 2026. 2021.
40. J. B. Kruskal. «Rank, decomposition, and uniqueness for 3-way and N -way arrays». In: *Multiway and Random Data Analysis*. A cura di R. Coppi e S. Bolasco. North-Holland, 1989, pp. 7–18.
41. J. B. Kruskal. «Three-way arrays: rank and uniqueness of trilinear decompositions, with application to arithmetic complexity and statistics». *Linear Algebra and its Applications* 18:2, 1977, pp. 95–138. ISSN: 0024-3795. DOI: [https://doi.org/10.1016/0024-3795\(77\)90069-6](https://doi.org/10.1016/0024-3795(77)90069-6). URL: <https://www.sciencedirect.com/science/article/pii/0024379577900696>.
42. J. D. Laderman. «A noncommutative algorithm for multiplying 3×3 matrices using 23 multiplications». *Bulletin of the American Mathematical Society* 82:1, 1976, pp. 126 –128.
43. J Landsberg. «The border rank of the multiplication of 2×2 matrices is seven». *Journal of the American Mathematical Society* 19:2, 2006, pp. 447–459.

44. J.M. Landsberg. «Geometry and complexity theory». *NSF Award Number 1405348. Directorate for Mathematical and Physical Sciences* 14:1405348, 2015, p. 5348.
45. J.M. Landsberg. *Tensors: geometry and applications*. Vol. 128. American Mathematical Soc., 2011.
46. X. Li, S. Lin, S. Yan, e D. Xu. «Discriminant locally linear embedding with high-order tensor data». *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)* 38:2, 2008, pp. 342–352.
47. X. Liu e N.D. Sidiropoulos. «Cramér-Rao lower bounds for low-rank decomposition of multidimensional arrays». *IEEE Transactions on Signal Processing* 49:9, 2001, pp. 2074–2086.
48. G.W. McNeice e A.G. Jones. «Multisite, multifrequency tensor decomposition of magnetotelluric data». *Geophysics* 66:1, 2001, pp. 158–173.
49. W. Miller. «Computational complexity and numerical stability». In: *Proceedings of the sixth annual ACM symposium on Theory of computing*. 1974, pp. 317–322.
50. V.Y. Pan. «Strassen’s algorithm is not optimal trilinear technique of aggregating, uniting and canceling for constructing fast algorithms for matrix operations». In: *19th Annual Symposium on Foundations of Computer Science (sfcs 1978)*. 1978, pp. 166–176. DOI: [10.1109/SFCS.1978.34](https://doi.org/10.1109/SFCS.1978.34).
51. J.A. Rhodes. *A concise proof of Kruskal’s theorem on tensor decomposition*. 2009. arXiv: [0901.1796](https://arxiv.org/abs/0901.1796) [math.RA]. URL: <https://arxiv.org/abs/0901.1796>.
52. A. Schönhage. «Partial and Total Matrix Multiplication». *SIAM Journal on Computing* 10:3, 1981, pp. 434–455. DOI: [10.1137/0210032](https://doi.org/10.1137/0210032). eprint: <https://doi.org/10.1137/0210032>. URL: <https://doi.org/10.1137/0210032>.
53. T. Schultz e H.-P. Seidel. «Estimating crossing fibers: A tensor decomposition approach». *IEEE Transactions on Visualization and Computer Graphics* 14:6, 2008, pp. 1635–1642.
54. N.D. Sidiropoulos e R. Bro. «On the uniqueness of multilinear decomposition of N-way arrays». *Journal of Chemometrics: A Journal of the Chemometrics Society* 14:3, 2000, pp. 229–239.

55. N.D. Sidiropoulos, G.B. Giannakis, e R. Bro. «Blind PARAFAC receivers for DS-CDMA systems». *IEEE Transactions on Signal Processing* 48:3, 2000, pp. 810–823.
56. V. de Silva e L.-H. Lim. *Tensor rank and the ill-posedness of the best low-rank approximation problem*. 2008. arXiv: [math/0607647](https://arxiv.org/abs/math/0607647) [math.NA]. URL: <https://arxiv.org/abs/math/0607647>.
57. A.K. Smilde, R. Bro, P. Geladi et al. *Multi-way analysis with applications in the chemical sciences*. Vol. 396. Wiley Chichester, 2004.
58. A. Stegeman e N.D. Sidiropoulos. «On Kruskal’s uniqueness condition for the Candecomp/Parafac decomposition». *Linear Algebra and its Applications* 420:2, 2007, pp. 540–552. ISSN: 0024-3795. DOI: <https://doi.org/10.1016/j.laa.2006.08.010>. URL: <https://www.sciencedirect.com/science/article/pii/S0024379506003855>.
59. A. Stothers. «On the complexity of matrix multiplication». Tesi di dott. Edinburgh, UK: University of Edinburgh, 2010. URL: <https://ed.ac.uk>.
60. V. STRASSEN. «Relative bilinear complexity and matrix multiplication.» *Journal für die reine und angewandte Mathematik* 1987:375-376, 1987, pp. 406–443. DOI: [doi:10.1515/crll.1987.375-376.406](https://doi.org/10.1515/crll.1987.375-376.406). URL: <https://doi.org/10.1515/crll.1987.375-376.406>.
61. V. Strassen. «Gaussian elimination is not optimal». *Numer. Math.* 13:4, 1969, pp. 354–356. ISSN: 0029-599X. DOI: [10.1007/BF02165411](https://doi.org/10.1007/BF02165411). URL: <https://doi.org/10.1007/BF02165411>.
62. T. Sumi, T. Sakata, e M. Miyazaki. «Typical ranks for $m \times n \times (m-1)n$ tensors with $m \leq n$ ». *Linear Algebra and its Applications* 438:2, 2013, pp. 953–958. DOI: [10.1016/j.laa.2011.08.009](https://doi.org/10.1016/j.laa.2011.08.009).
63. L.R. Tucker. «Implications of factor analysis of three-way matrices for measurement of change». *Problems in measuring change* 15:122-137, 1963, p. 3.
64. V.V. Williams. *Breaking the Coppersmith-Winograd barrier*. Manuscript available at <http://theory.stanford.edu/~virgi/matrixmult-f.pdf>. 2011.
65. S. Winograd. «On multiplication of 2×2 matrices». *Linear Algebra and its Applications* 4:4, 1971, pp. 381–388. ISSN: 0024-3795. DOI: [https://doi.org/10.1016/0024-3795\(71\)90009-7](https://doi.org/10.1016/0024-3795(71)90009-7). URL: <https://www.sciencedirect.com/science/article/pii/0024379571900097>.