

Canonical Polyadic Decomposition and applications

A minimal, modern L^AT_EX package for typesetting your thesis

by

Alberto Defendi (with the help of many others!)

A document submitted in partial fulfillment of the requirements for the degree of

Technical Report

at

MISKATONIC UNIVERSITY

ABSTRACT

Scientific documents often use L^AT_EX for typesetting. While numerous packages and templates exist, it makes sense to create a new one. Just because.

INDICE

I	LA FATTORIZZAZIONE CP	3
1.1	Tensori	3
1.2	La fattorizzazione CP	8
1.2.1	Rango CP	9
1.2.2	Il problema del border rank	9
1.2.3	Operazioni nel formato CP	10
1.2.4	Costruzione del tensore in formato denso	10
1.2.5	Unicità della fattorizzazione CP	10
1.2.6	Calcolo della fattorizzazione CP	11
2	APPLICAZIONI DELLA CP	13
2.1	Rappresentare forme bilineari tramite tensori	13
2.2	Il master method	14
2.3	Moltiplicazione ricorsiva di matrici	15
	ACRONIMI	17
	GLOSSARIO	19
	BIBLIOGRAFIA	21

INTRODUZIONE

I LA FATTORIZZAZIONE CP

I.1 TENSORI

Definizione 1.1.1. Denotiamo l'insieme dei numeri naturali da 1 a $n \in \mathbb{N}$ come $[n] = \{1, \dots, n\}$, e il prodotto cartesiano tra $[n]$ e $[m]$ come $[n] \otimes [m] = \{(i, j) : i \in [n], j \in [m]\}$.


Definizione 1.1.2. Un *tensor* $\mathcal{X}$ di ordine d è un array multidimensionale con entrate definite sul campo $\mathbb{K}$, che denotiamo come $\mathcal{X} \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$. Indicizziamo gli elementi di un tensore come $\mathcal{X}(i_1, i_2, \dots, i_d)$, dove $(i_1, i_2, \dots, i_d) \in [n_1] \otimes [n_2] \otimes \dots \otimes [n_d]$.

Definizione 1.1.3 (Prodotto di Kroneker). Date due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{p \times q}$, il loro prodotto di Kroneker è la matrice

$$C = A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{R}^{mp \times nq}, \text{ dove } c_{kl} = a_{ij}b_{nl},$$

dove $\alpha = L^*(i, k) = L(k, i)$ e $\beta = L^*(j, l) = L(l, j)$

Definizione 1.1.4 (Tensor slice). Dato $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ chiamiamo slice (o fetta) di $\mathcal{X}$ ogni matrice ottenuta da $\mathcal{X}$ fissando tutti gli indici tranne due. Le slices ottenute fissando gli ultimi $d - 2$ indici sono dette frontal slices.



Usare emph quando si introduce un termine nuovo, inserire tabella notazione all'inizio

ADD: Esempi di tensori. Tra cui il tensore che indica (quello del prodotto di matrici)

riscrivere con L^* . Vedi definizione nelle note

Definizione fibre

Definizione 1.1.5 (Ordinamento naturale). L'ordinamento naturale (natural ordering) su $[n_1] \otimes \dots \otimes [n_d]$ è la mappa biunivoca

$$\begin{aligned} \mathbb{L}: [n_1] \otimes \dots \otimes [n_d] &\rightarrow \left[\prod_{j=1}^d n_j \right] \\ (i_1, i_2, \dots, i_d) &\mapsto 1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1) = 1 + \sum_{j=1}^d s_j(i_j - 1), \end{aligned}$$

dove $s_j = n_1 \dots n_{j-1} = \prod_{b=1}^{j-1} n_b$ è detto passo j -esimo. L'inversa di $\mathbb{L}$ è data dalla mappa

$$\begin{aligned} \mathbb{L}^{-1}: \left[\prod_{j=1}^d n_j \right] &\rightarrow [n_1] \otimes \dots \otimes [n_d] \\ l &\mapsto \left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor \right) \end{aligned}$$

Osservazione 1.1.6. La mappa $\mathbb{L}$ ha come inversa $\mathbb{L}^{-1}$, sono anche chiamate linearizzazione e tensorizzazione degli indici, rispettivamente, in quanto permettono di passare da un indice tensoriale a uno lineare, e viceversa.

Dimostrazione. Segue direttamente dalla definizione di $\mathbb{L}$ e dalle proprietà del modulo, infatti,

$$\begin{aligned} \mathbb{L}^{-1}(\mathbb{L}(i_1, i_2, \dots, i_d)) &= \mathbb{L}^{-1}(1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1)) \\ &= \left(1 + \left\lfloor \frac{\sum_{j=1}^d s_j(i_j - 1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{\sum_{j=1}^d s_j(i_j - 1) \bmod (n_d s_d)}{s_d} \right\rfloor \right) \\ &= \left(1 + \left\lfloor \sum_{j=1}^d \frac{s_j}{s_1} (i_j - 1) \bmod (n_1 s_1) \right\rfloor, \dots, 1 + \left\lfloor \sum_{j=1}^d \frac{s_j}{s_d} (i_j - 1) \bmod (n_d s_d) \right\rfloor \right) \\ &= (i_1, i_2, \dots, i_d), \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $s_j = \prod_{k=1}^d n_k$ e il fatto che $[x] = 0$ per ogni $x \in [0, 1)$. Viceversa,

$$\begin{aligned} \mathbb{L}(\mathbb{L}^{-1}(l)) &= \mathbb{L}\left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor\right) = \\ &= 1 + s_1 \left(\left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor \right) + \dots + s_d \left(\left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor \right) \end{aligned}$$

missing end


□

Analogamente alle matrici, i tensori vengono salvati in memoria come vettori, risulta quindi naturale definire la seguente operazione

Definizione 1.1.7. Dato un tensore $\mathcal{X}$, possiamo definire l'operazione che trasforma un tensore in vettore, tramite la mappa di vettorizzazione

$$\text{vec}: \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d} \rightarrow \mathbb{R}^{\prod_{j=1}^d n_j}$$

$$\mathcal{X} \mapsto x$$



dove $x_l = \mathcal{X}(\mathbb{L}^{-1}(l; n_1, n_2, \dots, n_d))$.

In molte situazioni risulta comodo disporre gli elementi di un tensore in una matrice. Uno dei modi per farlo è utilizzare le matricizzazioni, anche dette *unfoldings*.

Definizione 1.1.8 (Mode- k unfolding). Il *mode- k unfolding* di un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ è la matrice $X_{(k)} \in \mathbb{R}^{n_k \times \prod_{j \neq k} n_j}$ le cui colonne sono mode- k fibers ordinate seguendo l'ordine naturale su $[n_1] \otimes \dots \otimes [n_{k-1}] \otimes [n_{k+1}] \otimes \dots \otimes [n_d]$. In particolare si ha

$$\mathcal{X}(i, j) = \mathcal{X}(i_1, \dots, i_{k-1}, i, i_{k+1}, \dots, i_d), \text{ con } j = \mathbb{L}(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d).$$




Figura 1.1: Schema delle matricizzazioni di un tensore.

Dal punto di vista computazionale è utile introdurre la seguente operazione

Definizione 1.1.9 (Reshape). Definiamo l'operatore di *reshape* come l'operazione che cambia le dimensioni di un array multidimensionale, senza alterarne le dimensioni e mantenendo l'ordine

refrasare un poco per renderla più leggibile

delle entrate. Formalmente, fissati $d, d' \in \mathbb{N}$ e un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$, per ogni $m_1, \dots, m_{d'}$ tali che $\prod_{i=1}^{d'} m_i = \prod_{j=1}^d n_j$, il tensore $\mathcal{Y} = \text{RESHAPE}(\mathcal{X}, m_1 \times \dots \times m_{d'}) \in \mathbb{R}^{m_1 \times \dots \times m_{d'}}$ è definito come

$$\mathcal{Y}(i_1, \dots, i_{d'}) = \mathcal{X}(j_1, \dots, j_d),$$

per ogni $(i_1, \dots, i_{d'}), (j_1, \dots, j_d)$ tali che $\mathbb{L}(i_1, \dots, i_{d'}; m_1 \times \dots \times m_{d'}) = \mathbb{L}(j_1, \dots, j_d; n_1 \times \dots \times n_d)$.

Osservazione 1.1.10. L'insieme dei tensori $\mathbb{R}^{n_1 \times \dots \times n_d}$ forma un $\mathbb{R}$ -spazio vettoriale, dotato del prodotto scalare euclideo, con le operazioni

- Addizione: $(\mathcal{X}_1 + \mathcal{X}_2)(i_1, \dots, i_d) = \mathcal{X}_1(i_1, \dots, i_d) + \mathcal{X}_2(i_1, \dots, i_d)$.
- Moltiplicazione per scalare: Per ogni $\alpha \in \mathbb{R}$, $\alpha(\mathcal{X}(i_1, \dots, i_d)) = (\alpha\mathcal{X})(i_1, \dots, i_d)$
- Prodotto scalare: $\langle \mathcal{X}_1, \mathcal{X}_2 \rangle = \text{vec}(\mathcal{X}_1)^\top \text{vec}(\mathcal{X}_2)$
- Norma: $\|\text{vec}(\mathcal{X})\|$

Definizione 1.1.11 (Prodotto esterno). Dati dei vettori $v^{(1)} \in \mathbb{R}^{n_1}, \dots, v^{(d)} \in \mathbb{R}^{n_d}$, loro prodotto esterno, anche detto prodotto tensore, è il tensore

$$\mathcal{X} = v^{(1)} \circ v^{(2)} \circ \dots \circ v^{(d)} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d},$$

tale che la sua scrittura in componenti è

$$\mathcal{X}(i_1, i_2, \dots, i_d) = v_{i_1}^{(1)} v_{i_2}^{(2)} \dots v_{i_d}^{(d)} = \prod_{j=1}^d v_{i_j}^{(j)}.$$

Lemma 1.1.12 (Legame tra il prodotto esterno e il prodotto di Kroneker). *Dato un tensore $\mathcal{X} = v^{(1)} \circ \dots \circ v^{(d)}$, allora*

- (i) $\text{vec}(\mathcal{X}) = v^{(d)} \otimes \dots \otimes v^{(1)}$
- (ii) $X_{(k)} = v^{(k)} \left(v^{(d)} \otimes \dots \otimes v^{(k-1)} \otimes v^{(k+1)} \otimes \dots \otimes v^{(1)} \right)^\top$
- (iii) $X_{(\mathcal{R} \times \mathcal{C})} = (v^{(n)} \otimes \dots \otimes v^{(n_1)}) (v^{(c_{d-\beta})} \otimes \dots \otimes v^{(c_1)})^\top$, dove $\mathcal{R} = \{n_1, \dots, n_\beta\}$ e $\mathcal{C} = \{c_1, \dots, c_{d-\beta}\}$.

Dimostrare

Dimostrazione.

□

Osservazione 1.1.13. Tutte le matricizzazioni di un prodotto esterno hanno rango 1.

In molte situazioni è utile moltiplicare un tensore con una matrice, ma purtroppo le dimensioni non combaciano. La seguente definizione risolve il problema facendo agire la matrice la matrice lungo il modo k -esimo di un tensore, e si chiama.

Definizione 1.1.14 (Prodotto nel modo k). Il *prodotto nel modo k* di un tensore $\mathfrak{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ con una matrice $U \in \mathbb{R}^{r \times n_k}$ è un tensore

$$\mathfrak{Y} = \mathfrak{X} \times_k U \in \mathbb{R}^{n_1 \times \dots \times n_{k-1} \times r \times n_{k+1} \times \dots \times n_d} \text{ con } Y_{(k)} = UX_{(k)}.$$

In componenti, $\mathfrak{Y}(i_1, \dots, i_{k-1}, \alpha, i_{k+1}, \dots, i_d) = \sum_{i_k=1}^d \mathfrak{X}(i_1, i_2, \dots, i_d) U_{\alpha, i_k}$.

Lemma 1.1.15. Siano $A \in \mathbb{K}^{m \times n}$, $B \in \mathbb{K}^{m \times n}$ ed $X \in \mathbb{K}^{n \times m}$. Allora

$$\text{vec}(AXB) = (B^\top \otimes A) \text{vec}(X)$$

Dimostrazione. Scrivendo $B = [b_1, \dots, b_n]$ ed $X = [x_1, \dots, x_n]$, la k -esima colonna di AXB è

$$(AXB)_{:,k} = AXb_k = A \sum_{i=1}^m x_i b_{i,k} = [b_{1,k}A, \dots, b_{n,k}A] \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix} = ([b_{1,k}, \dots, b_{n,k}] \otimes A) \text{vec}(X).$$

Impilando insieme le colonne otteniamo che

$$\text{vec}(AXB) = \begin{bmatrix} (AXB)_{:,1} \\ (AXB)_{:,2} \\ \vdots \\ (AXB)_{:,n} \end{bmatrix} = \begin{bmatrix} b_1^\top \otimes A \\ b_2^\top \otimes A \\ \vdots \\ b_n^\top \otimes A \end{bmatrix} \text{vec}(X) = (B^\top \otimes A) \text{vec}(X).$$

□

Proposizione 1.1.16. Dato un tensore $\mathfrak{X} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ e delle matrici $U \in \mathbb{R}^{m_1 \times n_1}$, $V \in \mathbb{R}^{m_1 \times n_2}$ e $W \in \mathbb{R}^{m_3 \times n_3}$. Sono fatti equivalenti:

$$(i) \mathfrak{Y} = \mathfrak{X} \times_1 U \times_2 V \times_3 W \in \mathbb{R}^{m_1 \times m_2 \times m_3}.$$

$$(ii) \text{vec}(\mathfrak{Y}) = (W \otimes V \otimes U) \cdot \text{vec}(\mathfrak{X}).$$

$$(iii) Y_{(1)} = UX_{(1)}(W \otimes V)^\top.$$

$$(iv) Y_{(2)} = VX_{(2)}(W \otimes U)^\top.$$

$$(v) Y_{(3)} = WX_{(3)}(V \otimes U)^\top.$$

Dimostrazione. (1) $\iff$ (2) Mostriamo che $\text{vec}(\mathfrak{X} \times_1 U) = (I \otimes I \otimes U) \text{vec}(\mathfrak{X})$.

(2) $\iff$ (4) Conversely, assume statement 2 holds. Thus...

□

Proposizione 1.1.17. Siano $A \in \mathbb{R}^{m \times p}$ e $B \in \mathbb{R}^{n \times q}$. Allora,

$$A \otimes B = P(B \otimes A)Q^\top,$$

dove P e Q sono matrici di permutazione (m, n) - e (p, q) - perfect shuffle, rispettivamente.

Dimostrazione.

□

Potremmo
riadattare:
THE VEC-
PERMUTATION
MATRIX, THE
VEC OPERA-
TOR AND
KRONECKER
PRODUCTS: A
REVIEW

Short introduzio-
ne che legghi caso
matriciale con
tensoriale.

1.2 LA FATTORIZZAZIONE CP

Definizione 1.2.1 (Canonical Polyadic Decomposition (CP)). Diciamo che un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ ammette una decomposizione CP di rango $r \in \mathbb{N}$ se esistono delle matrici $U_1, \dots, U_d$ tali che $U_b = [u_1^{(b)} \mid \dots \mid u_r^{(b)}] \in \mathbb{R}^{n_b \times r}$ tali per cui valgono le seguenti condizioni equivalenti:

$$(i) \quad \mathcal{X} = \sum_{j=1}^r u_j^{(1)} \circ \dots \circ u_j^{(d)} = \sum_{i=1}^r \bigcirc_{b=1}^d u_j^{(b)}.$$

$$(ii) \quad \text{vec}(\mathcal{X}) = \sum_{j=1}^r u_j^{(d)} \otimes \dots \otimes u_j^{(1)} = \sum_{i=1}^r \bigotimes_{b=d}^1 u_j^{(b)}.$$

$$(iii) \quad \mathcal{X}(i_1, i_2, \dots, i_d) = \sum_{j=1}^r U_1(i_1, j) U_2(i_2, j) \dots U_d(i_d, j) = \sum_{j=1}^r \prod_{b=1}^d U_b(i_b, j).$$

In tal caso, scriviamo $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$.

Definizione 1.2.2. Il *rango CP* di un tensore $\mathcal{X}$ è il minimo intero $r \in \mathbb{Z}_{\geq 0}$ tale per cui $\mathcal{X}$ ammette una decomposizione CP di rango r , e lo denotiamo con $\text{rank}(\mathcal{X}) = r$.

Osservazione 1.2.3 (Risparmio in memoria della CP). La fattorizzazione CP di un tensore $\mathcal{X}$ di rango r permette di ridurre notevolmente il costo di memorizzazione del tensore, in quanto richiede $O((n_1 + \dots + n_d)r) \ll O(\prod_{i=1}^d n_i)$.

Esempio polino-
mio semisep +
altro es

Definizione 1.2.4 (Prodotto Khatri-Rao). Date due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$, il loro *prodotto Khatri-Rao* è dato da

$$C = A \odot B = [a_1 \otimes b_1 \mid \dots \mid a_r \otimes b_r] \in \mathbb{R}^{(mn) \times r}, \quad (1.1)$$

dove a_j e b_j indicano la j -esima colonna di A e B , rispettivamente, e la matrice C si lascia scrivere in componenti come $C_{k,l} = A_{i,l} B_{j,l}$, dove $\mathbb{L}^*(i, j) = \mathbb{L}(j, i) = k$.

Osservazione 1.2.5. Calcolare il prodotto di Khatri-Rao di due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$ ha un costo in memoria di $O(mn \cdot r)$.

1.2.1 RANGO CP

Proposizione 1.2.6. Sia $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ un tensore che ammette fattorizzazione $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$, e sia $r_j = \text{rank}(X_{(j)})$ il rango dell'unfolding $X_{(j)}$, con $j = 1, \dots, d$. Allora vale che

$$\max_{j=1, \dots, d} (r_j) \leq \text{rank}(\mathcal{X}) \leq \min_{j=1, \dots, d} \left(\prod_{i \neq j} r_i \right) \quad (1.2)$$

Dimostrazione. La minorazione segue direttamente dalla scrittura delle

□

1.2.2 IL PROBLEMA DEL BORDER RANK

Esempio 1.2.7. Consideriamo dei vettori $a_1, a_2 \in \mathbb{R}^m$, $b_1, b_2 \in \mathbb{R}^n$ e $c_1, c_2 \in \mathbb{R}^p$ vettori linearmente indipendenti. Definiamo il tensore

$$\mathcal{X} = a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_1 + a_2 \circ b_1 \circ c_1, \quad (1.3)$$

e notiamo che $\text{rank}(\mathcal{X}) = 3$ dato che non può essere scomposto come somma di tensori più semplici. Consideriamo la successioni di tensori

$$\mathcal{Y}_\varepsilon = \frac{1}{\varepsilon} (a_1 + \varepsilon a_2) \circ (b_1 + \varepsilon b_2) \circ (c_1 + \varepsilon c_2) - \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_1, \text{ con } \varepsilon \in \mathbb{R}, \quad (1.4)$$

che essendo combinazione lineare di due tensori di rango uno, ha rango 2. Vediamo che $\lim_{\varepsilon \rightarrow 0} \mathcal{Y}_\varepsilon = \mathcal{X}$, da cui segue che l'insieme dei tensori di rango 3 non è chiuso. Espandendo i termini dell'Equazione 1.4 tramite la proprietà distributiva del prodotto esterno,


$$\begin{aligned} \mathcal{Y}_\varepsilon &= \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_2 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_1 + a_2 \circ b_1 \circ c_1 \\ &\quad + \varepsilon (a_2 \circ b_2 \circ c_1 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_2 + a_2 \circ b_2 \circ c_2) - \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_1 \\ &= \mathcal{X} + \varepsilon (a_2 \circ b_2 \circ c_1 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_2 + a_2 \circ b_2 \circ c_2) \end{aligned} \quad (1.5)$$

Quindi $\mathcal{Y}_\varepsilon - \mathcal{X} \rightarrow 0$.

Questo motiva la seguente definizione:

Definizione 1.2.8 (Border rank). Dato un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$, il suo border rank è la quantità

$$\underline{\text{rank}}(\mathcal{X}) = \min \{ r \in \mathbb{N} \mid \exists \mathcal{Y} \in \mathbb{R}^{n_1 \times \dots \times n_d} \text{ t.c } \text{rank}(\mathcal{Y}) = r, \|\mathcal{X} - \mathcal{Y}\| < \varepsilon \}.$$



Se serve, versione
per unfoldings
generalizzati

I.2.3 OPERAZIONI NEL FORMATO CP

Lemma 1.2.9. Dato un tensore $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$, vale $\text{vec}(\mathcal{X}) = (U_d \odot U_{d-1} \odot \dots \odot U_1)1_r$, dove $1_r = [1, \dots, 1]^\top$.

Dimostrazione. Segue dall'identità

$$\begin{aligned} \text{vec}(\mathcal{X}) &= \sum_{b=1}^r u_b^{(d)} \otimes \dots \otimes u_b^{(1)} = [u_1^{(d)} \otimes \dots \otimes u_1^{(1)} \mid \dots \mid u_r^{(d)} \otimes \dots \otimes u_r^{(1)}]1_r \\ &= (U_d \odot U_{d-1} \odot \dots \odot U_1)1_r. \end{aligned}$$

□

I.2.4 COSTRUZIONE DEL TENSORE IN FORMATO DENSO

I.2.5 UNICITÀ DELLA FATTORIZZAZIONE CP

Definizione 1.2.10 (Essenziale unicità CP). Una fattorizzazione CP di rango r di un tensore $\mathcal{X} \llbracket U_1, \dots, U_d \rrbracket$ è *essenzialmente unica* se, per ogni altra fattorizzazione $\mathcal{X} = \llbracket \tilde{U}_1, \dots, \tilde{U}_d \rrbracket$ di rango r , esiste una matrice di permutazione $P \in \mathbb{R}^{r \times r}$ e delle matrici diagonali $D_1, \dots, D_d \in \mathbb{R}^{r \times r}$ che soddisfano $D_1 D_2 \dots D_d = I$ e $U_j = \tilde{U}_j D_j P$, per ogni $j = 1, \dots, d$.

Definizione 1.2.11 (k -rango). Data $A \in \mathbb{R}^{m \times n}$, il suo k -rango è il massimo $k \in \mathbb{N}$ tale che ogni scelta di k colonne in A comprende colonne linearmente indipendenti. Lo denoteremo con il simbolo $\text{rank}_k(A)$.

Osservazione 1.2.12. Dalla definizione segue che $\text{rank}_k(A) \leq \text{rank}(A)$ per ogni matrice $A \in \mathbb{R}^{m \times n}$. In particolare, se A è full-rank, $\text{rank}_k(A) = \text{rank}(A)$; se invece A ha due colonne linearmente dipendenti, $\text{rank}_k(A) \leq 1$.

Teorema 1.2.13 (Kruskal 3D, Sidiropoulos e Bro). *Una fattorizzazione CP di un tensore $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$ di rango r è essenzialmente unica se*

$$\sum_{j=1}^d \text{rank}_k(U_j) \geq 2r + d - 1.$$

La condizione di Kruskal è sufficiente ma non necessaria. Il seguente risultato fornisce una condizione necessaria ma non sufficiente:

Teorema 1.2.14. *Dato un tensore $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$ tale per cui $\min_j \{ \text{rank}(U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1) \} < r$, allora la fattorizzazione $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$ non è essenzialmente unica.*

1.2.6 CALCOLO DELLA FATTORIZZAZIONE CP

Trattiamo il problema di trovare la migliore approssimazione con rango CP r di un dato tensore. Studiamo il caso $d = 3$. Dato $\mathcal{X} \in \mathbb{R}^{m \times n \times p}$ cerchiamo una fattorizzazione $\llbracket A, B, C \rrbracket$ con $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ e $C \in \mathbb{R}^{p \times r}$ cercando di risolvere il problema ai minimi quadrati

$$\min_{A, B, C} \|\mathcal{X} - \llbracket A, B, C \rrbracket\|^2. \quad (1.6)$$

Tale problema può essere mal posto per quanto detto sul border rank. Inoltre si tratta di un problema non convesso (esistono molti minimi locali) e dato che ogni tensore ha rappresentazioni CP multiple. why?

ALTERNATING LEAST-SQUARES

Considero

$$\|\mathcal{X} - \llbracket A, B, C \rrbracket\|^2 = \|X_{(1)} - A(C \odot B)^\top\|_F^2 = \|(C \odot B)A^\top - X_{(1)}^\top\|_F^2,$$

ovvero un problema lineare ai minimi quadrati dove l'incognita è una matrice A . La soluzione può essere espressa in termini delle equazioni normali why?

$$(C \odot B)^\top (C \odot B) A^\top = (C \odot B)^\top X_{(1)}^\top,$$

se e solo se, usando il lemma lemma KRP HA-Damard

$$(C^\top C \star B^\top B) A^\top = (C \odot B)^\top X_{(1)}^\top.$$

1 La fattorizzazione CP

La matrice $Z = \mathbb{R}^{r \times r}$ è semidefinita positiva, e quando è positiva definita (accade se $C \odot B$ è full-rank possiamo risolvere con la fattorizzazione di Cholesky il sistema)

$$AZ = X_{(1)}(C \odot B) = M \quad (1.7)$$

vEdi fogli per
calcolo costo

2 APPLICAZIONI DELLA CP

2.1 RAPPRESENTARE FORME BILINEARI TRAMITE TENSORI

Conoscere il rango CP di tensori che rappresentano applicazioni multilineari può rivelare informazioni sulla complessità asintotica e fornire algoritmi con complessità ottimale per la loro valutazione. Proviamo a formulare il problema: dall'algebra lineare sappiamo che data una forma bilineare $b : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}$, esiste una matrice $M \in \mathbb{R}^{m \times n}$ tale che $b(u, v) = u^\top M v$ per ogni $(u, v) \in \mathbb{R}^m \times \mathbb{R}^n$. Notiamo che un insieme di p forme bilineari, o equivalentemente una funzio-

ne bilineare $b = \begin{bmatrix} b_1 \\ \vdots \\ b_p \end{bmatrix} : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}^p$ si può rappresentare tramite un tensore $\mathcal{X} \in \mathbb{R}^{m \times n \times p}$ tale

È chiaro se si chiama ancora b?

che le sue slice frontali rappresentino ognuna delle p forme bilineari, ossia che

$$b_k(u, v) = u^\top \mathcal{X}(:, :, k) v = \sum_{i=1}^m \sum_{j=1}^n \mathcal{X}(i, j, k) u_i v_j, \text{ per ogni } k = 1, \dots, p. \quad (2.1)$$

Da cui,

$$b(u, v) = \begin{bmatrix} b_1(u, v) \\ \vdots \\ b_p(u, v) \end{bmatrix} = \mathcal{X} \times_1 u^\top \times_2 v^\top. \quad (2.2)$$

Osservazione 2.1.1. Questa procedura si estende anche al caso in cui le entrate di u e v siano oggetti algebrici più complessi di scalari, ad esempio vettori o matrici.

Osservazione 2.1.2 (Active multiplications). Scrivere una forma bilineare come nell'Equazione 2.1 evidenzia il numero di moltiplicazioni necessarie fra gli elementi di u e v . Queste sono dette *active multiplications* e corrispondono al numero di elementi non nulli di $\mathcal{X}$. Poiché ci aspettiamo che il costo delle active multiplications sia quello che determini la complessità di valutare $b(u, v)$, cerchiamo di minimizzarne il numero cercando fattorizzazioni CP di $\mathcal{X}$.

Se abbiamo $\mathcal{X} = \llbracket A, B, C \rrbracket$ con $\text{rank}(\mathcal{X}) = r$, dalla Definizione 1.2.1 abbiamo che $\mathcal{X} = \sum_{l=1}^r a_l \circ b_l \circ c_l$, o in componenti, $\mathcal{X}(i, j, k) = \sum_{l=1}^r a_{il} b_{jl} c_{kl}$. Inserendo questa relazione nella Equazione 2.1 troviamo,

$$\begin{aligned}
 b_k(u, v) &= \left(\left(\sum_{i=1}^r a_i \circ b_i \circ c_i \right) x_1 u^\top x_2 v^\top \right)_k = \left(\sum_{l=1}^r (a_l \circ b_l \circ c_l) x_1 u^\top x_2 v^\top \right)_k \\
 &= \sum_{i=1}^m \sum_{j=1}^n \sum_{l=1}^r a_{il} b_{jl} c_{kl} u_i v_j = \sum_{l=1}^r \left(\sum_{i=1}^m a_{il} u_i \right) \cdot \left(\sum_{j=1}^n b_{jl} v_j \right) c_{kl} = \sum_{l=1}^r (a_l^\top u) \cdot (b_l^\top v) c_{kl},
 \end{aligned} \tag{2.3}$$

per ogni $k = 1, \dots, p$. Mettendo insieme le Equazioni 2.2 e 2.3 troviamo

$$b(u, v) = \sum_{l=1}^r (a_l^\top u) \cdot (b_l^\top v) c_l.$$

Espandere discussione dall'articolo

Quindi valutare b richiede esattamente r active multiplications, che evidenziamo con $(\cdot)$.

2.2 IL MASTER METHOD

Introduciamo brevemente un metodo per risolvere relazioni ricorsive definite per ricorrenza, detto *master method*. I lettori più interessati possono trovare una trattazione più dettagliata sul libro [1].

Il master method si usa per risolvere ricorrenze della forma

$$T(n) = aT\left(\frac{n}{b}\right) + f(n), \tag{2.4}$$

dove $a \geq 1$ e $b > 1$ sono costanti e $f(n)$ è una funzione asintoticamente positiva. La ricorrenza 2.4 descrive il tempo di esecuzione di un algoritmo che divide un problema di dimensione n in a sottoproblemi, ognuno di dimensione $\frac{n}{b}$. Gli a sottoproblemi vengono risolti ricorsivamente in tempo $T(\frac{n}{b})$, e la funzione $f(n)$ rappresenta il costo di dividere il problema e ricombinare la ricorsione di ogni sottoproblema.

Indichiamo con O e Ω la stima superiore e inferiore, rispettivamente, e con Θ la stima stretta.

Teorema 2.2.1 (Master theorem). *Siano $a \geq 1$ e $b > 1$ delle costanti, sia $f(n)$ una funzione e definiamo $T(n)$ sugli interi nonnegativi dalla ricorrenza*

$$T(n) = aT\left(\frac{n}{b}\right) + f(n),$$

dove con $\frac{n}{b}$ indichiamo sia $\lfloor \frac{n}{b} \rfloor$ o $\lceil \frac{n}{b} \rceil$. Allora $T(n)$ ha le seguenti soglie asintotiche:

1. Se $f(n) = O(n^{\log_b a - \varepsilon})$ per qualche $\varepsilon > 0$, allora $T(n) = \Theta(n^{\log_b a})$.
2. Se $f(n) = \Theta(n^{\log_b a})$ allora $T(n) = \Theta(n^{\log_b a} \log n)$.

3. If $f(n) = \Omega(n^{\log_b a + \varepsilon})$ per qualche costante $\varepsilon > 0$, e se $af(\frac{n}{b}) < cf(n)$ per qualche costante $c < 1$ e ogni n sufficientemente grande, allora $T(n) = \Theta(f(n))$.

Esempio 2.2.2. Nel caso dell'algoritmo naive la ricorrenza ha la forma $a = 8$, $b = 2$ e $f(n) = \Theta(n^2)$, ovvero

$$T(n) = 8T(\frac{n}{2}) + \Theta(n^2).$$

Siccome $n^{\log_b a} = n^{\log_2 8} = n^3$, che è polinomialmente più grande di $f(n)$, ovvero $f(n) = O(n^{3-\varepsilon})$ per $\varepsilon = 1$, dal caso 1 di 2.2.1 segue che $T(n) = \Theta(n^3)$.

2.3 MOLTIPLICAZIONE RICORSIVA DI MATRICI

Possiamo rappresentare la moltiplicazione tra matrici come una funzione bilineare, quindi come un tensore.

Lemma 2.3.1 (Rappresentazione del prodotto matriciale). *Per ogni coppia di matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times p}$, esiste un tensore $\mathcal{X} \in ?$ tale che il prodotto $C = AB \in \mathbb{R}^{m \times p}$ si scrive come $\mathcal{X} \times_1 \text{vec}(A) \times_2 \text{vec}(B) = \text{vec}(C)$.*

finire

Dimostrazione. Dalla definizione di prodotto di matrice, $C_{ij} =$

□

Brief motivation

Notazione: Indichiamo con $\langle m, n, p \rangle$ il prodotto tra due matrici di taglia $m \times n$ e $n \times p$.

Trattiamo prima il caso di matrici quadrate con taglie potenze di due. Discuteremo di seguito come trattare il caso generale. In questo caso possiamo partizionare le matrici in delle sottomatrici a blocchi 2×2 :

$$\begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \cdot \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}.$$

L'algoritmo naive procede combinando un insieme di otto moltiplicazioni matriciali con quattro addizioni:

$$\begin{aligned} M_1 &= A_{11} \cdot B_{11} & M_2 &= A_{12} \cdot B_{21} & M_3 &= A_{11} \cdot B_{12} \\ M_4 &= A_{12} \cdot B_{22} & M_5 &= A_{21} \cdot B_{11} & M_6 &= A_{22} \cdot B_{21} \\ M_7 &= A_{21} \cdot B_{12} & M_8 &= A_{22} \cdot B_{22} \\ C_{11} &= M_1 + M_2 & C_{12} &= M_3 + M_4 \\ C_{21} &= M_5 + M_6 & C_{22} &= M_7 + M_8 \end{aligned}$$

ACRONIMI

PCA	Principal component analysis
SNF	Smith normal form
TDA	Topological data analysis

GLOSSARIO

$\text{\LaTeX}$	A document preparation system
$\mathbb{R}$	The set of real numbers

BIBLIOGRAFIA

1. T. H. Cormen, C. E. Leiserson, R. L. Rivest, e C. Stein. *Introduction to algorithms*. MIT press, 2022.