

UNIVERSITÀ DI PISA

DIPARTIMENTO DI MATEMATICA

Corso di Laurea Triennale in Matematica

Tensor Canonical Polyadic Decomposition and the Complexity of Matrix Multiplication

Tesi di Laurea Triennale


Relatore:

Prof. Leonardo Robol

Candidato:

Alberto Defendi

ANNO ACCADEMICO 2025/2026




SOMMARIO


La decomposizione CP (Canonical Polyadic Decomposition) di rango r di un tensore è la sua scomposizione nella somma di r tensori di rango uno, una generalizzazione naturale della decomposizione di matrici. Oltre ad avere un'importanza teorica nel calcolo tensoriale, è uno strumento utile in molte aree scientifiche: per citarne alcune, spettroscopia, *signal processing*, neurologia e analisi dei dati. In molte di queste applicazioni l'unicità della fattorizzazione è una proprietà fondamentale per rappresentare fedelmente le componenti di sistemi complessi—si pensi al problema di modellare i neuroni di un sistema nervoso tramite un tensore per studiarne gli impulsi, noto come *blind source separation*.

Il primo obiettivo è dimostrare l'unicità della fattorizzazione CP sotto opportune ipotesi. Questo risultato, originariamente dimostrato da Kruskal nel 1977 attraverso il concetto di Kruskal rank, è stato di recente semplificato seguendo la dimostrazione originale, usando strumenti geometrici. Inoltre, osserveremo alcune peculiarità teoriche che distinguono i tensori dalle matrici, ponendo le basi per l'utilizzo del calcolo tensoriale nella teoria della complessità.

Successivamente, applicheremo questi strumenti al problema della complessità della moltiplicazione tra matrici: in quanto mappa bilineare, il prodotto matriciale può essere rappresentato tramite un tensore tre indici, e poi messo in corrispondenza con un algoritmo per valutare il prodotto in funzione delle entrate del tensore. Introduciamo la nozione di complessità aritmetica del prodotto tra matrici per definire l'esponente asintotico ω , che ne misura la complessità ottimale. Tale quantità sarà messa in corrispondenza con il rango CP di un tensore tramite il Teorema di Strassen. Come corollario, ridurre lo studio della complessità ai tensori, anziché all'analisi diretta delle equazioni algebriche, semplifica notevolmente la ricerca di algoritmi più efficienti; una sfida aperta da decenni, dall'algoritmo di Strassen (del 1970), fino alle recenti scoperte guidate dall'intelligenza artificiale.


Infine, l'analisi verrà estesa dagli algoritmi di moltiplicazione esatti agli algoritmi approssimati (APA), introdotti da Bini et al. In questo contesto emerge il fenomeno topologico del border rank, per il quale una successione di tensori di rango inferiore può convergere a un tensore di rango superiore. Dal punto di vista algoritmico, ciò si traduce nella possibilità di approssimare la moltiplicazione esatta tramite una successione di algoritmi con costo computazionale inferiore. Di conseguenza, il rango tensoriale può essere sostituito con il border rank nel calcolo di ω , permettendo di ottenere stime asintotiche più accurate, al prezzo di un errore algoritmico arbitrariamente piccolo.






INDICE

1	LA FATTORIZZAZIONE CP	3
1.1	Tensori	3
1.2	Rango tensoriale	4
1.3	Ordinamenti	5
1.4	La fattorizzazione CP	9
1.5	Slices, fibers e unfoldings	11
1.6	Il problema del rango	16
1.7	Il teorema del rango	21
1.8	Ricostruzione del tensore in formato denso	24
1.9	Calcolo della fattorizzazione CP	24
2	APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP	27
2.1	Spettroscopia fluorescente	27
2.2	Blind deconvolution di segnali	33
	ACRONIMI	37
	GLOSSARIO	39
	BIBLIOGRAFIA	41





INTRODUZIONE

I tensori sono oggetti che modellano molti esperimenti in un numero disparato di aree scientifiche. Decomporli in oggetti più facili da analizzare Studieremo la *canonical polyadic decomposition*, nota anche come PARAFAC, per “parallel factor analysis”, CANDECOMP, per “canonical decomposition”, e *CP decomposition*, il quale nome potrebbe o come acronimo della combinazione di CANDECOMP e PARAFAC.

Le decomposizioni di tensori occorrono in numerose aree scientifiche. Alcune di queste sono: nell’ambito medico della psicomatria è stata impiegata per studiare gli impulsi cerebrali [311, 71, 158], in particolare nel trovare l’area del cervello di un paziente in cui è in atto una crisi epilettica, o la diagnosi e gestione di ictus.; sempre nella medicina, nell’interpretare la immagini di risonanze magnetiche (MRI); vedi ad esempio e relative reference. Nella geofisica, ad esempio l’interpretazione di data magnetotellurica per strutture regionali a una e due dimensioni, ad esempio in ...e le reference all’interno (wtf?). Nell’analisi numerica. *si può ridurre allo studio di funzioni semiseparabili?* Grazie alla convergenza delle serie di Fourier nello spazio delle funzioni $f : \mathbb{R}^n \rightarrow \mathbb{R}$ misurabili secondo la norma euclidea $L^2(\mathbb{R}^n)$, si ha $L^2(\mathbb{R}^n) = L^2(\mathbb{R}) \otimes \cdots \otimes L^2(\mathbb{R})$, e spesso vengono approssimate funzioni di n variabili da una somma finita di prodotti di funzioni in una variabile, generalizzando la separazione di variabili. Si veda ...


source, add reference


- In geophysics; for example the interpretation of magnetotelluric data for one-dimensional and two-dimensional regional structures; see, e.g., [335] and the references therein.
- In interpreting magnetic resonance imaging (MRI); see, e.g., [284, 125], and the references therein. One such use is in determining the location in the brain that is causing epileptic seizures in a patient. Another is the diagnosis and management of strokes.

Questo elaborato si sviluppa con la seguente struttura:

Nel capitolo 1, introdurremo i tensori e i relativi spazi. Definiremo la fattorizzazione CP e dei relativi metodi di calcolo. Discuteremo alcune loro caratteristiche fondamentali che li differenziano dalle matrici.

Nel capitolo 2 dimostreremo il Teorema di Kruskal, che afferma l’unicità della





scrittura della fattorizzazione CP di un tensore sotto opportune ipotesi, discutendo alcuni casi di non unicità.

Nel capitolo 3 sposteremo il focus allo studio della complessità della moltiplicazione matriciale, studiando gli *algoritmi di moltiplicazione veloci* dal punto di vista della decomposizione CP.


Nel capitolo 4 presenteremo alcune applicazioni modellistiche della CP, presentando due esperimenti numerici: il recupero della concentrazione di sostanze chimiche in un composto (*spettroscopia fluorescente*) e l'analisi di segnali (*cocktail party problem*).


Le principali fonti di questo lavoro sono TENSORB e LANDSBERG^{1,2}.

cite

Come descritto da Landsberg, nell'ambito del calcolo tensoriale avviene uno “scontro di culture”, dove confluiscono risultati teorici trovati dagli studiosi delle applicazioni scientifiche (e.g., psicometria, chemiometria, neurologia), analisti numerici, teorici della complessità e geometri algebrici.

Credits: cite ballard E Kolda per aver ispirato molte figure. Librerie numeriche.





1 LA FATTORIZZAZIONE CP

1.1 TENSORI

In questo elaborato lavoriamo in $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$, e denotiamo gli spazi vettoriali, che assumeremo sempre finiti, con le lettere A, B, C, V, W e A_j , e le dimensioni con le lettere $\mathbf{a}, \mathbf{b}, \mathbf{c}$, etc. Dati dei vettori $v_1, \dots, v_p \in V$, l'insieme $\langle v_1, \dots, v_p \rangle \subseteq V$ denota lo span lineare di $v_1, \dots, v_p$. Indichiamo con $V^* = \{f : V \rightarrow \mathbb{K} \mid f \text{ lineare}\}$ lo *spazio duale* dello spazio V , e per ogni $\alpha \in V^*$, denotiamo con $\alpha^\perp = \{v \in V \mid \alpha(v) = 0\}$ l'*annullatore* di α . Similmente, dato un sottospazio vettoriale $U \subseteq V$, definiamo l'annullatore di U come $U^\perp = \{\alpha \in V^* \mid \alpha(u) = 0, \forall u \in U\}$.

Definizione 1.1.1 (Mappe trilineari). Siano U, V, W spazi vettoriali di dimensione finita su un campo $\mathbb{K}$. Una *forma bilineare* è una mappa $\varphi : U \times V \rightarrow W$ lineare in ogni componente, in altre parole tale che $f(u, \cdot)$ e $f(\cdot, v)$ sono lineari per ogni $u \in U$ e $v \in V$. Quando $W = \mathbb{K}$ la chiameremo *forma bilineare*.


In generale, dati degli spazi vettoriali $A_1, \dots, A_n$ di dimensione finita, definiamo le forme n -multilineari come applicazioni $\varphi : A_1 \times \dots \times A_n \rightarrow \mathbb{K}$ lineari in ognuna delle n componenti, e data una forma n -multilineare $\varphi : A_1 \times A_2 \times \dots \times A_n$ è possibile costruire una mappa $n - 1$ lineare $A_1 \times A_2 \times \dots \times A_{n-1} \rightarrow \mathbb{K}$.


Definizione 1.1.2 (Tensore). Definiamo lo spazio dei *tensori* $A_1 \otimes A_2 \otimes \dots \otimes A_n$ come l'insieme delle forme n -multilineari $\varphi : A_1^* \times A_2^* \times \dots \times A_n^* \rightarrow \mathbb{K}$.

Osservazione 1.1.3 (Spazio standard). Sfruttando l'identificazione canonica $\mathbb{K}^m \otimes \mathbb{K}^n \simeq \mathbb{K}^{m \times n}$ (o più in generale $\mathbb{K}^{n_1} \otimes \mathbb{K}^{n_2} \otimes \dots \otimes \mathbb{K}^{n_d} \simeq \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$) possiamo dare una definizione di tensore operativamente utile in molti contesti del calcolo tensoriale, dove spesso è più conveniente lavorare nello spazio standard $\mathbb{R}^{n_1 \times \dots \times n_d}$.

Definizione 1.1.4 (Tensore in coordinate). Un *tensore in coordinate* T di ordine d è un array multidimensionale con entrate definite sul campo $\mathbb{K}$, che denotiamo come $T \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$. Indicizziamo gli elementi di un tensore come $T_{i_1, i_2, \dots, i_d}$.

Usare emph
quando si in-
troduce un ter-
mine nuovo,
inserire tabella
notazione all'i-
nizio





Osservazione 1.1.5. Per la ragione sopra, spesso chiameremo tensore anche l'oggetto sopra scrivendo semplicemente $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$.

Osservazione 1.1.6. Dato $T \in A \otimes B \otimes C$, possiamo sempre passare da un tensore nello spazio $A \otimes B \otimes C$ a un tensore in $\mathbb{R}^{a \times b \times c}$ così: fissate delle basi $\{e_i\}, \{g_j\}, \{h_k\}$ di A, B, C rispettivamente, possiamo scrivere $T = \sum_{ijk} T_{ijk} e_i \otimes g_j \otimes h_k$. Al variare degli indici, T_{ijk} descrive un array tridimensionale ("a forma di parallelepipedo") in $\mathbb{R}^{a \times b \times c}$, che chiamiamo ancora T .

Osservazione 1.1.7. Siccome per ogni spazio vettoriale V , vale $V \otimes \mathbb{K} \simeq V$, un tensore $T \in \mathbb{K}^{m \times n \times 1}$ è una matrice $m \times n$, e più in generale un tensore $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_{d-1} \times 1}$ è un tensore di dimensione $n_1 \times n_2 \times \dots \times n_{d-1}$.

Scrivere

Esempio 1.1.8. (Tensori che rappresentano applicazioni multilineari)

ADD: Esempi di tensori. Tra cui il tensore che indica (quello del prodotto di matrici)

Osservazione 1.1.9. L'insieme dei tensori $\mathbb{R}^{n_1 \times \dots \times n_d}$ forma un $\mathbb{R}$ -spazio vettoriale, dotato del prodotto scalare euclideo, con le operazioni


- Addizione: $(T_1 + T_2)(i_1, \dots, i_d) = T_1(i_1, \dots, i_d) + T_2(i_1, \dots, i_d)$.
- Moltiplicazione per scalare: Per ogni $\alpha \in \mathbb{R}$, $\alpha(T(i_1, \dots, i_d)) = (\alpha T)(i_1, \dots, i_d)$.
- Prodotto scalare: $\langle T_1, T_2 \rangle = \text{vec}(T_1)^\top \text{vec}(T_2)$.
- Norma: $\|\text{vec}(T)\| = \sqrt{\sum_{i_1=1}^{n_1} \sum_{i_2=1}^{n_2} \dots \sum_{i_d=1}^{n_d} (T_{i_1, i_2, \dots, i_d})^2}$.


1.2 RANGO TENSORIALE

Definizione 1.2.1 (Tensore di rango uno). Dati $a_1 \in A_1, a_2 \in A_2, \dots, a_d \in A_d$, definiamo un *tensore di rango uno* come un elemento $a_1 \otimes a_2 \otimes \dots \otimes a_n \in A_1 \otimes A_2 \otimes \dots \otimes A_n$ tale che $a_1 \otimes \dots \otimes a_d(\beta_1, \dots, \beta_n) = \beta_1(a_1)\beta_2(a_2) \dots \beta_d(a_d)$.

Operativamente, dati due vettori $u = [u_1, \dots, u_m]^\top \in \mathbb{R}^m$ e $v = [v_1, \dots, v_n]^\top \in \mathbb{R}^n$, possiamo calcolare il prodotto tensore come

$$u \otimes v = uv^\top = \begin{bmatrix} u_1 v_1 & u_1 v_2 & \dots & u_1 v_n \\ u_2 v_1 & u_2 v_2 & \dots & u_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ u_m v_1 & u_m v_2 & \dots & u_m v_n \end{bmatrix} \in \mathbb{R}^{m \times n}.$$





In più dimensioni, presi $a_1 \in \mathbb{R}^{n_1}, \dots, a_n \in \mathbb{R}^{n_n}$, il loro prodotto tensore è

$$(1.1) \quad T = a^{(1)} \otimes a^{(2)} \otimes \dots \otimes a^{(d)} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$$

tale che la sua scrittura in componenti è

$$(1.2) \quad T_{i_1, i_2, \dots, i_d} = a_{i_1}^{(1)} v_{i_2}^{(2)} \dots v_{i_d}^{(d)}$$

Questo ci permette di definire la seguente quantità fondamentale:

Definizione 1.2.2 (Rango di un tensore). Il rango di un tensore $T \in A_1 \otimes A_2 \otimes \dots \otimes A_n$ è il minimo intero positivo r tale che T si può scrivere come somma di tensori di rango uno, e scriviamo $\mathbf{R}(T) = r$.

1.3 ORDINAMENTI

Introduciamo alcuni ingredienti utili a definire la fattorizzazione CP.

Sposta sotto
ordinamento

Definizione 1.3.1 (Prodotto di Kroneker). Date due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{p \times q}$, il loro prodotto di Kroneker è la matrice

$$C = A \boxtimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{R}^{mp \times nq}, \text{ dove } c_{kl} = a_{ij}b_{nl},$$


dove $\alpha = \mathbb{L}^*(i, k) = \mathbb{L}(k, i)$ e $\beta = \mathbb{L}^*(j, l) = \mathbb{L}(l, j)$


Osservazione 1.3.2. Dalla definizione di prodotto di Kroneker, segue che

$$\text{rank}(A \boxtimes B) = \text{rank}(A) \text{rank}(B).$$

Un modo per dimostrarlo è considerare le decomposizioni ai valori singolari (SVD) di $A = U \Sigma V^*$ e $B = U' \Sigma' V'^*$, e calcolare

$$\begin{aligned} A \boxtimes B &= (U \Sigma V^*) \boxtimes (U' \Sigma' V'^*) \\ &= (U \boxtimes U') (\Sigma \boxtimes \Sigma') (V^* \boxtimes V'^*), \end{aligned}$$





dove la seconda uguaglianza segue dalla proprietà $(AC \boxtimes BD) = (A \boxtimes B)(C \boxtimes D)$ del prodotto di Kroneker. Siccome le matrici U, U' e V, V' sono ortogonali (e quindi invertibili), anche $U \boxtimes U'$ e $V^* \boxtimes V'^*$ sono ortogonali. Quindi

$$\text{rank}(A \boxtimes B) = \text{rank}(\Sigma \boxtimes \Sigma') = \text{rank}(\Sigma) \text{rank}(\Sigma') = \text{rank}(A) \text{rank}(B).$$

Osservazione 1.3.3 (Prodotto di Kroneker come vettorizzazione del prodotto tensore). Dati due vettori $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$, il loro prodotto di Kroneker si può vedere come vettorizzazione del prodotto vettore, ossia

$$(1.3) \quad \text{vec}(v \otimes u) = \text{vec} \begin{pmatrix} v_1 u_1 & v_1 u_2 & \dots & v_1 u_m \\ v_2 u_1 & v_2 u_2 & \dots & v_2 u_m \\ \vdots & \vdots & \ddots & \vdots \\ v_n u_1 & v_n u_2 & \dots & v_n u_m \end{pmatrix} = [u_1 v \mid u_2 v \mid \dots \mid u_m v] = u \boxtimes v$$

Notiamo che tale operazione scambia l'ordine tra i vettori.

Breve motivazione dell'ordinamento naturale

Definizione 1.3.4 (Ordinamento naturale). *L'ordinamento naturale (o natural ordering) sull'insieme $[n_1] \times \dots \times [n_d]$ è la mappa biunivoca*

$$\mathbb{L}: [n_1] \times \dots \times [n_d] \rightarrow \left[\prod_{j=1}^d n_j \right]$$


$$(i_1, i_2, \dots, i_d) \mapsto 1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1) = 1 + \sum_{j=1}^d s_j(i_j - 1),$$


dove i coefficienti s_j sono chiamati *passi j-esimi* e sono definiti come $s_1 = 1$ e $s_{j+1} = n_1 \cdots n_j = \prod_{h=1}^j n_h = s_j n_j$, per ogni $j \in [d-1]$. L'inversa di $\mathbb{L}$ è data dalla mappa

$$\mathbb{L}^{-1}: \left[\prod_{j=1}^d n_j \right] \rightarrow [n_1] \times \dots \times [n_d]$$

$$l \mapsto \left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor \right).$$

Le mappe $\mathbb{L}$ e $\mathbb{L}^{-1}$ sono l'una l'inversa dell'altra, e sono anche dette linearizzazione e tensorizzazione degli indici, rispettivamente, in quanto permettono di passare da un indice tensoriale a uno lineare, e viceversa.





Buona definizione. Segue direttamente dalla definizione di $\mathbb{L}$ e dalle proprietà del modulo. Infatti, detto $\alpha = \mathbb{L}(i_1, i_2, \dots, i_d)$, vale che

$$\mathbb{L}^{-1}(\alpha) = (i_1, i_2, \dots, i_d),$$

in quanto

$$\begin{aligned} (\mathbb{L}^{-1}(\alpha))_h &= 1 + \left\lfloor \frac{\sum_{i=1}^d s_j(i_j - 1) \pmod{n_h s_h}}{s_h} \right\rfloor \\ &= 1 + \left\lfloor \sum_{i=1}^d \frac{s_j}{s_1} (i_j - 1) \pmod{n_h s_h} \right\rfloor \\ &= i_h \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $s_j = n_1 n_2 \cdots n_j$ e il fatto che $\lfloor x \rfloor = 0$ per ogni $x \in [0, 1)$. Viceversa, chiamato $\beta := \mathbb{L}^{-1}(l)$, dove

$$\beta_h = 1 + \left\lfloor \frac{(l - 1) \pmod{n_h s_h}}{s_h} \right\rfloor$$

dimostriamo che

$$\mathbb{L}(\beta) = l.$$

in quanto

$$\begin{aligned} \mathbb{L}(\beta) &= \mathbb{L}(\beta_1, \dots, \beta_d) = \\ &= 1 + \sum_{h=1}^d s_1 \left(\left\lfloor \frac{(l - 1) \pmod{n_h s_h}}{s_h} \right\rfloor \right) \end{aligned}$$

□


FINIRE


Esempio 1.3.5. È utile visualizzare il caso 3–dimensionale: fissato un tensore $T \in \mathbb{R}^{m \times n \times p}$ indicizzato con (i, j, k) , abbiamo che $s_1 = 1, s_2 = m$ e $s_3 = mn$, dunque

$$\mathbb{L}(i, j, k) = 1 + (i - 1) + m(j - 1) + mn(k - 1) = i + m(j - 1) + mn(k - 1),$$

mentre l'inversa è

$$\mathbb{L}^{-1}(i, j, k) = \left(\lfloor (l - 1) \pmod{m} \rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mn}}{m} \right\rfloor, 1 + \left\lfloor \frac{(l - 1) \pmod{mnp}}{mn} \right\rfloor \right).$$





Definizione 1.3.6 (Reverse ordering). *L'ordinamento inverso* sull'insieme $[n_1] \times \dots \times [n_d]$ è la mappa biunivoca

$$\mathbb{L}^*: [n_1] \times \dots \times [n_d] \rightarrow \left[\prod_{j=1}^d n_j \right]$$

$$(i_1, i_2, \dots, i_d) \mapsto 1 + \sum_{j=1}^d s_j^* (i_j - 1),$$

dove $s_d^* = 1$ e $s_{j-1}^* = \prod_{h=j}^d n_h = s_j^* n_j$, per $j = d, \dots, 2$. La sua inversa è la mappa


$$(\mathbb{L}^*)^{-1}: \left[\prod_{j=1}^d n_j \right] \rightarrow [n_1] \times \dots \times [n_d]$$

$$l \mapsto \left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1^*)}{s_1^*} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d^*)}{s_d^*} \right\rfloor \right)$$


.


Esempio 1.3.7. Nel caso di un tensore $T \in \mathbb{R}^{m \times n \times p}$, i passi sono $s_3^* = 1$, $s_2^* = p$ e $s_1^* = np$.

Osservazione 1.3.8. I passi determinano l'ordine di percorrenza del tensore nelle definizioni di $\mathbb{L}$ e $\mathbb{L}^*$.



Analogamente alle matrici, i tensori vengono salvati in memoria come vettori, risulta quindi naturale definire la seguente operazione






Definizione 1.3.9. Dato un tensore T , possiamo definire l'operazione che trasforma un tensore in vettore, tramite la mappa di vettorizzazione

$$\text{vec}: \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d} \rightarrow \mathbb{R}^{\prod_{j=1}^d n_j}$$

$$T \mapsto x$$



dove $x_l = T(\mathbb{L}^{-1}(l; n_1, n_2, \dots, n_d))$.

Osservazione 1.3.10. L'operatore di trasposizione per matrici induce l'ordinamento inverso sulla vettorizzazione. Consideriamo ad esempio il caso 2×2 :

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad A^\top = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix} \implies \text{vec}(A) = \begin{bmatrix} a_{11} \\ a_{21} \\ a_{12} \\ a_{22} \end{bmatrix}, \quad \text{vec}(A^\top) = \begin{bmatrix} a_{11} \\ a_{12} \\ a_{21} \\ a_{22} \end{bmatrix}.$$


Nel caso matriciale si usa riferirsi all'ordine naturale come *column-major* e a quello inverso come *row-major*, specialmente nel contesto dei linguaggi di programmazione.


Check

1.4 LA FATTORIZZAZIONE CP

Introduciamo una scrittura di un tensore in tensori elementari, utile a risolvere i seguenti problemi che affronteremo nei prossimi capitoli.

Il problema inverso del rango: Dato un intero positivo r , nel caso matriciale è, in linea teorica, un problema semplice costruire una matrice di rango r ; mentre dal punto di vista computazionale, esistono algoritmi polinomiali per approssimare il rango. Nel caso dei tensori, il problema è difficile su entrambi i fronti. Nella teoria, trovare un tensore di un certo rango è come trovare un ago in un pagliaio; nella pratica, approssimare il tensore, o il rango, è numericamente difficile. Questo complica la risoluzione di molti problemi che possono essere modellati tramite tensori, come vedremo ad esempio nel Capitolo ??.





Risparmio computazionale: Cerchiamo una decomposizione di rango basso di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ per ridurre il costo di rappresentazione in memoria e delle operazioni algebriche che lo convolgono. Nel caso matriciale, data una matrice $X \in \mathbb{R}^{n_1 \times n_2}$ di rango r , possiamo scrivere

$$X = UV^\top = [u_1 | \dots | u_r] [v_1 | \dots | v_r]^\top = u_1 v_1^\top + \dots + u_r v_r^\top = u_1 \otimes v_1 + \dots + u_r \otimes v_r,$$

per certe matrici $U \in \mathbb{R}^{n_1 \times r}$ e $V \in \mathbb{R}^{n_2 \times r}$. Questo tipo di decomposizione è vantaggioso in termini di memoria: infatti

$$\text{vec}(X) = v_1 \boxtimes u_1 + \dots + v_r \boxtimes u_r,$$

quindi memorizzare U e V costa $O((n_1 + n_2)r)$ invece che $O(n_1 n_2)$. Vorremmo quindi riadattare questa decomposizione per memorizzare T con costo $O((n_1 + \dots + n_d)r)$ invece che $O(n_1 \dots n_d)$. Tuttavia, generalizzare questa decomposizione a più dimensioni ha numerosi ostacoli.

discorso unicità

ref to ostacoli

Definizione 1.4.1 (Canonical Polyadic Decomposition (CP)). Dati degli spazi vettoriali $A_1 \otimes \dots \otimes A_d$ e dei vettori $\{u_1^t, \dots, u_{n_t}^t\} \subset A_t$, diciamo che un tensore $T \in A_1 \otimes \dots \otimes A_d$ ammette una *decomposizione CP* di rango $r \in \mathbb{N}$ se si può scrivere come

$$T = u_1^1 \otimes u_1^2 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes u_r^2 \otimes \dots \otimes u_r^d.$$

serve ipotesi sui vettori?


Osservazione 1.4.2. Siccome $A_1 \otimes \dots \otimes A_n$ è generato da elementi di rango uno, è sempre possibile decomporre un tensore in formato CP.


Osservazione 1.4.3 (Canonical Polyadic Decomposition (CP)). La decomposizione CP in $\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è data da delle matrici $U_1, \dots, U_d$ tali che $U_t = [u_1^t | \dots | u_r^t] \in \mathbb{R}^{n_t \times r}$ tali per cui

$$T = u_1^1 \otimes u_1^2 \otimes \dots \otimes u_1^d + \dots + u_r^1 \otimes u_r^2 \otimes \dots \otimes u_r^d \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}.$$

In tal caso, scriveremo $T = \llbracket U_1, \dots, U_d \rrbracket$.

Osservazione 1.4.4. Possiamo riferirci alla CP sia come decomposizione (data dalla somma dei termini di rango uno) oppure come fattorizzazione (data dai fattori $U_1, \dots, U_d$).





Osservazione 1.4.5. Fissando la notazione sopra, la fattorizzazione CP si può scrivere nelle seguenti formulazioni equivalenti:

- (i) $T = \sum_{j=1}^r u_j^1 \otimes \cdots \otimes u_j^d.$
- (ii) $\text{vec}(T) = \sum_{j=1}^r u_j^d \boxtimes \cdots \boxtimes u_j^1.$
- (iii) $T_{i_1, i_2, \dots, i_d} = \sum_{j=1}^r U_1(i_1, j) U_2(i_2, j) \cdots U_d(i_d, j).$

la 3 non torna

Sources/Chapter1/figures/cp.pdf

Figura 1.1: Fattorizzazione CP di un tensore $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{n \times m \times p}$, dove i vettori a_l, b_l, c_l indicano le colonne l -esime di A, B, C .

Osservazione 1.4.6 (Risparmio in memoria della CP). La fattorizzazione CP di un tensore T di rango r permette di ridurre notevolmente il costo di memorizzazione, in quanto richiede $O((n_1 + \dots + n_d)r) \ll O(\prod_{i=1}^d n_i)$.


1.5 SLICES, FIBERS E UNFOLDINGS


Cambiare

Definizione 1.5.1 (Tensor slice). Dato $T \in \mathbb{R}^{n_1 \times n_2 \times \cdots \times n_d}$ chiamiamo *slice* (o *fetta*) di T ogni matrice ottenuta da T fissando tutti gli indici tranne due. Le slices ottenute fissando gli ultimi $d-2$ indici sono dette *frontal slices*. Nel caso $d=3$ si identificano tutte le possibili slices (Figura 1.2):

Definizione 1.5.2 (Mode- k fiber). Dato un tensore $T \in \mathbb{R}^{n_1 \times \cdots \times n_d}$ chiamiamo *fibers* i vettori ottenuti fissando tutti gli indici tranne uno. Quando l'indice libero di variare è il k -esimo lo chiamiamo *mode- k fiber*. Nel caso $d=3$ denotiamo le fibre come fibre colonna $x_{:jk}$ (mode-1), fibre riga $x_{i:k}$ (mode-2) e fibre tubo $x_{ij:}$ (mode-3), come illustrato in Figura 1.3.

In molte situazioni risulta comodo disporre gli elementi di un tensore in una matrice. Uno dei modi per farlo è utilizzare le matricizzazioni, anche dette *unfoldings*.







Sources/Chapter1/figures/slices.pdf

Figura 1.2: Slices di un tensore di ordine 3: fette orizzontali $X_{i::}$ (mode-1), laterali $X_{:j:}$ (mode-2) e frontali $X_{::k}$ (mode-3).

Sources/Chapter1/figures/fibers.pdf

Figura 1.3: Fibre di un tensore di ordine 3: fibre colonna $x_{:jk}$ (mode-1), riga $x_{i:k}$ (mode-2) e tubo $x_{ij:}$ (mode-3).





Definizione 1.5.3 (Mode- k unfolding). Il *mode- k unfolding* di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ è la matrice $\mathbf{T}_{(k)} \in \mathbb{R}^{n_k \times \prod_{j \neq k} n_j}$ le cui colonne sono mode- k fibers ordinate seguendo l'ordine naturale su $\underline{n}_1 \times \dots \times \underline{n}_{k-1} \times \underline{n}_{k+1} \times \dots \times \underline{n}_d$. In particolare si ha

$$(\mathbf{T}_{(k)})_{i,j} = T_{i_1, \dots, i_{k-1}, i, i_{k+1}, \dots, i_d}, \text{ con } j = \mathbb{L}(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d).$$

Osservazione 1.5.4. Possiamo pensare all'unfolding nel modo k come a rimappare l'indice i_k sulle righe e l'indice $(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d)$ sulle colonne.

Sources/Chapter1/figures/fibers_unfolding.pdf


Figura 1.4: Fibre e matricizzazioni nei tre modi per un tensore del terzo ordine.


Esempio 1.5.5 (De Lathauwer [10]). Consideriamo il tensore T di taglia $2 \times 2 \times 2$ definito da

$$a_{111} = -a_{121} = 3, \quad a_{211} = -a_{221} = 6, \quad a_{112} = -a_{122} = 1, \quad a_{212} = -a_{222} = 2.$$

I vettori dei modi 1, 2 e 3 sono le colonne delle matrici

$$\mathbf{T}_{(1)} = \begin{bmatrix} 3 & -3 & 1 & -1 \\ 6 & -6 & 2 & -2 \end{bmatrix}, \quad \mathbf{T}_{(2)} = \begin{bmatrix} 3 & 6 & 1 & 2 \\ -3 & -6 & -1 & -2 \end{bmatrix}, \quad \mathbf{T}_{(3)} = \begin{bmatrix} 3 & 6 & -3 & -6 \\ 1 & 2 & -1 & -2 \end{bmatrix},$$





rispettivamente. Il tensore ha rango uno perché si può decomporre come

$$T = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -1 \end{bmatrix} \otimes \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Pensando la terza dimensione nel verso entrante al foglio, possiamo riassumere i passaggi svolti per fattorizzare T , dove è stata applicata più volte la definizione di prodotto tensore:

c'è un typo!

`./Sources/Chapter1/figures/cp_example.pdf`

`Sources/Chapter1/figures/unfoldings.pdf`

Figura 1.5: Schema delle matricizzazioni e vettorizzazione di un tensore.

L'operazione di unfolding permette anche di catturare il suo rango (matriciale) lungo ogni direzione:

anche def land-
sberg


Definizione 1.5.6 (Rango multilineare). Il *rango multilineare* o *multirank* di un tensore $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è la d -upla $(r_1, r_2, \dots, r_d)$, dove $r_k = \text{rank } \mathbf{T}_{(k)}$, per ogni $k \in \{1, \dots, d\}$. Lo denotiamo con $\mathbf{R}_{\text{multilin}}(T)$.


Dal punto di vista computazionale è utile introdurre la seguente operazione

refrasare un po-
co per renderla
più leggibile

Definizione 1.5.7 (Reshape). Definiamo l'operatore di *reshape* come l'operazione riarrangia il tensore senza alterarne le dimensioni e mantenendo l'ordine delle entrate. Formalmente, fissati $d, d' \in \mathbb{N}$ e un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$, per ogni $m_1, \dots, m_{d'}$ tali che $\prod_{i=1}^{d'} m_i = \prod_{j=1}^d n_j$, il tensore $\mathbf{Y} = \text{RESHAPE}(T, m_1 \times \dots \times m_{d'}) \in \mathbb{R}^{m_1 \times \dots \times m_{d'}}$ è definito come

$$\mathbf{Y}(i_1, \dots, i_{d'}) = T(j_1, \dots, j_d),$$





per ogni $(i_1, \dots, i_{d'}, (j_1, \dots, j_d)$ tali che $\mathbb{L}(i_1, \dots, i_{d'}; m_1 \times \dots \times m_{d'}) = \mathbb{L}(j_1, \dots, j_d; n_1 \times \dots \times n_d)$.

Osservazione 1.5.8. Un reshape ha costo nullo perché non si spostano celle di memoria, ma si eseguono solo operazioni di indici. Questa proprietà vale in particolare per tutte le strutture dati (vettori, matrici, tensori) $\tilde{T}$ tali che $\text{vec}(\tilde{T}) = \text{vec}(T)$.

Osservazione 1.5.9. L'unfolding sul primo modo ha costo nullo, in quanto $\mathbf{T}_{(1)} = \text{RESHAPE}(T, n_1 \times \prod_{j=2}^d n_j)$, cioè

$$\mathbf{T}_{(1)} = \left[T_{:, \dots, :, 1} \mid \dots \mid T_{:, \dots, :, n_d} \right] \in \mathbb{R}^{n_1 \times \prod_{j=2}^d n_j}.$$

Osservazione 1.5.10. Per $k > 1$, formare l'unfolding $\mathbf{T}_{(k)}$ ha un costo non banale, in particolare $\text{vec}(\mathbf{T}_{(k)}) \neq \text{vec}(T)$.

Se $k = d$, l'unfolding $\mathbf{T}_{(d)} = \begin{bmatrix} \text{vec}(T_{:, \dots, :, 1})^\top \\ \vdots \\ \text{vec}(T_{:, \dots, :, n_d})^\top \end{bmatrix}$, e in particolare vale $\text{vec}(\mathbf{T}_{(d)}^\top) =$

$\text{vec}(T)$. Quindi calcolare la trasposta dell'ultimo unfolding non costa nulla.

Lemma 1.5.11 (Vettorizzazione e unfolding di un tensore di rango uno). *Dato un tensore $T = v^1 \otimes \dots \otimes v^d$, allora*

(i) $\text{vec}(T) = v^d \boxtimes \dots \boxtimes v^1$.

(ii) $\mathbf{T}_{(k)} = v^k (v^d \boxtimes \dots \boxtimes v^{k-1} \boxtimes v^{k+1} \boxtimes \dots \boxtimes v^1)^\top$.

In particolare, tutte le matricizzazioni di un prodotto esterno hanno rango 1.


Dimostrazione. La (i) segue applicando più volte l'Osservazione 1.3.3. Dimostriamo la (ii). Per definizione di tensore di rango uno (1.2) la scrittura in componenti di T è


$$T_{i_1, \dots, i_d} = v_{i_1}^1 \dots v_{i_d}^d = v_{i_k}^k \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right).$$

Preso $u = v^d \boxtimes \dots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \dots \boxtimes v^1$, osserviamo che la sua componente j -esima è il prodotto fra parentesi, ovvero $u_j = \left(\prod_{\substack{m=1 \\ m \neq k}}^d v_{i_m}^m \right)$. A questo punto, per definizione di unfolding abbiamo $(\mathbf{T}_{(k)})_{i_k, j} = v_{i_k}^k u_j$, da cui

$$\mathbf{T}_{(k)} = v^k u^\top = v^k (v^d \boxtimes \dots \boxtimes v^{k+1} \boxtimes v^{k-1} \boxtimes \dots \boxtimes v^1)^\top.$$

□





In molte situazioni è utile moltiplicare un tensore con una matrice, ma purtroppo le dimensioni non combaciano. La seguente definizione risolve il problema facendo agire la matrice la matrice lungo il modo k -esimo di un tensore, e si chiama.

Definizione 1.5.12 (Prodotto nel modo k). Il *prodotto nel modo k* di un tensore $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ con una matrice $U \in \mathbb{R}^{r \times n_k}$ descrive l'azione di U sulla k -esima coordinata di T . Formalmente, è un tensore

$$Y = T \times_k U \in \mathbb{R}^{n_1 \times \dots \times n_{k-1} \times r \times n_{k+1} \times \dots \times n_d} \text{ con } \mathbf{Y}_{(k)} = U \mathbf{T}_{(k)}.$$

In componenti, $Y_{i_1, \dots, i_{k-1}, \alpha, i_{k+1}, \dots, i_d} = \sum_{i_k=1}^d T(i_1, i_2, \dots, i_d) U_{\alpha, i_k}$.

Esempio polinomio semisep + altro es

1.6 IL PROBLEMA DEL RANGO

In più dimensioni il problema di calcolare il rango, e una fattorizzazione CP di un tensore si complicano notevolmente rispetto al caso matriciale. Ci sono molte domande aperte riguardo al rango, ad esempio non si ha una risposta generale (a differenza del caso matriciale) a domande del tipo:

1. Qual'è il massimo rango possibile per un tensore di dimensione $n_1 \times \dots \times n_d$?
2. Quali sono i ranghi *tipici*, ovvero quelli ottenuti con probabilità non nulla quando si genera un tensore di entrate casuali?

Per capire il motivo, discutiamo alcune caratteristiche dei tensori che rendono complesso il “problema del rango”.


BORDER RANK

Nel caso delle matrici, una successione di matrici di rango r converge sempre a una matrice di rango $\leq r$. Per i tensori possono accadere dei “salti”, in altre parole, la varietà dei tensori di un rango fissato r non è chiusa¹, ad esempio, un tensore di rango 2 può convergere ad uno di rango 3, come mostra il prossimo esempio. Questo inconveniente teorico ha risvolti interessanti che vedremo nella § ??.


Esempio 1.6.1. Consideriamo dei vettori $a_1, a_2 \in \mathbb{R}^m$, $b_1, b_2 \in \mathbb{R}^n$ e $c_1, c_2 \in \mathbb{R}^p$ vettori linearmente indipendenti. Definiamo il tensore

$$(1.4) \quad T = a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1,$$

¹Non precisiamo la topologia, per una discussione formale si vedano [18, 19].



non mi piace



e notiamo che $\mathbf{R}(T) = 3$ dato che non può essere scomposto come somma di tensori più semplici. Consideriamo la successioni di tensori

$$(1.5) \quad T_\varepsilon = \frac{1}{\varepsilon}(a_1 + \varepsilon a_2) \otimes (b_1 + \varepsilon b_2) \otimes (c_1 + \varepsilon c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1, \text{ con } \varepsilon \in \mathbb{R},$$

che essendo combinazione lineare di due tensori di rango uno, ha rango 2. Vediamo che $\lim_{\varepsilon \rightarrow 0} T_\varepsilon = T$, da cui segue che l'insieme dei tensori di rango 3 non è chiuso. Espandendo i termini dell'Equazione (1.5) tramite la proprietà distributiva del prodotto esterno,

$$(1.6) \quad \begin{aligned} \mathbf{y}_\varepsilon &= \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_1 + a_2 \otimes b_1 \otimes c_1 \\ &\quad + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) - \frac{1}{\varepsilon}a_1 \otimes b_1 \otimes c_1 \\ &= T + \varepsilon(a_2 \otimes b_2 \otimes c_1 + a_1 \otimes b_1 \otimes c_2 + a_1 \otimes b_2 \otimes c_2 + a_2 \otimes b_2 \otimes c_2) \end{aligned}$$

Quindi $T_\varepsilon - T \rightarrow 0$.

Questo motiva la seguente definizione:

Definizione 1.6.2 (Border rank). Un tensore T ha *border rank* r se è limite di una successione di tensori di rango r , ma non è limite di una successione di tensori di rango s , per ogni $s < r$. Lo denoteremo con il simbolo $\underline{\mathbf{R}}(T)$.

Osservazione 1.6.3. $\mathbf{R}(T) \geq \underline{\mathbf{R}}(T)$.

Osservazione 1.6.4. In altri termini, se $T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$, il suo border rank è la quantità


$$\underline{\mathbf{R}}(T) = \min\{r \in \mathbb{N} \mid \exists T' \in \mathbb{R}^{n_1 \times \dots \times n_d} \text{ tale che } \mathbf{R}(T') = r, \|T - T'\| < \varepsilon\}.$$

Il border rank ammette anche la seguente interpretazione geometrica:


COSTO COMPUTAZIONALE

Calcolare il costo di una fattorizzazione CP usando un algoritmo esatto è NP-Hard [14]. Non solo; il problema di trovare un tensore approssimante di un certo rango è computazionalmente difficile. In altre parole, la miglior approssimazione di rango r è data da dei vettori $x_i \in \mathbb{R}^{n_1}, y_i \in \mathbb{R}^{n_2}, \dots, z_i \in \mathbb{R}^{n_d}$, per $i = 1, \dots, r$ che minimizzano

$$\|A - x_1 \otimes y_1 \otimes \dots \otimes z_1 - \dots - x_r \otimes y_r \otimes \dots \otimes z_r\|$$



Disegno interpretazione geometrica (landsberg pg 38)



oppure, in altre parole un tensore B dato da una fattorizzazione CP, che realizza

$$\min_{\text{rank}(B) \leq r} \|A - B\|.$$

Qui $\|\cdot\|$ denota una norma fissata su $\mathbb{R}^{n_1 \times \dots \times n_d}$. Quando $d = 2$, il problema è risolto per norme invarianti per trasformazioni unitarie su $\mathbb{R}^{m \times n}$ dal teorema di Eckart-Young-Mirsky [12]: se

$$A = U\Sigma V^* = \sum_{i=1}^{\text{rank}(A)} \sigma_i u_i \otimes v_i, \quad \sigma_i \geq \sigma_{i+1},$$

è la decomposizione ai valori singolari di A (anche detta SVD), allora la migliore approssimazione di rango r è data dai primi r termini della somma. Sfortunatamente, generalizzare questo risultato in più dimensioni è ritenuto molto difficile (o impossibile) [21].

Nella pratica esistono diverse euristiche per calcolare il rango. Una di queste è scegliere come rango il più piccolo r che minimizza l'errore relativo rispetto al rango $r - 1$. Per un tensore a 3 indici, l'*errore relativo* è definito in questo modo:

$$(1.7) \quad \varepsilon_{\text{rel}} = \frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} = \frac{\left(\sum_{i,j,k} (t_{ijk} - \sum_{l=1}^r a_{il} b_{jl} c_{kl})^2\right)^{\frac{1}{2}}}{\left(\sum_{i,j,k} t_{ijk}^2\right)^{\frac{1}{2}}}.$$

RANGO MASSIMO


Nel caso di una matrice $m \times n$, il suo rango massimo è $\min\{m, n\}$. Per un tensore, il *rango massimo* è definito come il massimo dei ranghi realizzabili per dei tensori $T \in \mathbb{R}^{n_1 \times \dots \times n_d}$ di una certa taglia fissata. In altre parole,

$$\mathbf{R}_{\max}(\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}) = \max\{\mathbf{R}(T) \mid T \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}\}.$$

Sfortunatamente, ad eccezione di alcuni casi speciali, i ranghi massimi per la maggior parte dei tensori di ordine superiore sono sconosciuti. I casi speciali in cui il rango massimo è noto sono elencati nella Tabella 1.1. Il primo risultato per tensori di dimensione $2 \times m \times n$ implica, ad esempio, che un tensore di taglia $2 \times 2 \times 2$ ha un rango massimo pari a 3.

È inoltre possibile derivare un limite superiore debole per il rango massimo:

se lasci verifica-
lo






Tabella 1.1: Ranghi massimi tensoriali noti. L'ordine delle dimensioni non modifica il rango, quindi le taglie sono ordinate dalla più piccola alla più grande (tratta da Ballard e Kolda [3, Tabella 16.1]).

Taglia tensore	Rango massimo	Fonte
$2 \times m \times n$ ($m \leq n$)	$m + \min\{m, \lfloor n/2 \rfloor\}$	JáJá [15]; Kruskal [17]
$3 \times 3 \times 3$	5	Kruskal [17]
$3 \times 7 \times 7$	8	Atkinson e Stephens [2]
$2 \times 4 \times 4$	6	ten Berge [5]

$$(1.8) \quad R_{\max}(\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}) \leq \min_k \prod_{\substack{\ell=1 \\ \ell \neq k}}^d n_\ell = \frac{\prod_{k=1}^d n_k}{\max_k n_k}.$$

RANGO TIPICO

Mentre le matrici random hanno rango massimo con probabilità uno², per un tensore di un formato fissato potrebbe esserci più di un rango con probabilità positiva. Questo fenomeno è noto come *rango tipico*.

Sia $\mathcal{D}(n_1, n_2, \dots, n_d)$ una distribuzione di probabilità continua sullo spazio dei tensori $\mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ (un esempio sono i tensori a entrate gaussiane).

Definizione 1.6.5. Il *rango tipico* (o *rango generico*) di un tensore $T \in \mathbb{K}^{n_1 \times \dots \times n_d}$ è l'insieme dei ranghi che occorrono con probabilità non nulla, rispetto ad ogni distribuzione continua $\mathcal{D}(n_1, n_2, \dots, n_d)$ sull'insieme di tali tensori. In formule,


$$\mathbf{R}_{\text{typical}} = \{r \mid P(\mathbf{R}(T) = r, T \sim \mathcal{D}(n_1, \dots, n_d)) > 0\}.$$


Mentre per le matrici il rango tipico è unico e coincide con il massimo rango possibile, per i tensori di ordine superiore a due. In particolare su $\mathbb{R}$ possono coesistere più ranghi tipici, mentre su $\mathbb{C}$ il rango tipico è sempre unico. La Tabella 1.2 riassume i principali risultati noti in letteratura, tratti da Ballard e Kolda [3, p. 276, Tabella 16.2]. Per verificare questi risultati, abbiamo implementato un esperimento numerico. Selezionando alcuni formati, abbiamo generato dei tensori casuali con entrate estratte indipendentemente sia da una distribuzione normale standard $\mathcal{N}(0, 1)$ sia da una distribuzione uniforme $\mathcal{U}(-1, 1)$. Il rango di ciascun tensore è stato stimato usando l'algoritmo ALS su un campione di 200 tensori, facendo 120 restarts e

rewrite and verify

ref

²L'idea è presa una matrice con entrate estratte da una distribuzione di probabilità continua, il determinante è un polinomio le cui indeterminate sono le entrate della matrice. Il luogo di zeri di questo polinomio ha misura di Lebesgue nulla, quindi integrando la densità di probabilità sul luogo di zeri dà probabilità nulla. La tesi si ha passando al complementare.





un numero massimo di 500 iterazioni, interrompendo una volta raggiunto un errore relativo inferiore a 10^{-5} . La distribuzione empirica dei ranghi riportata in Figura 1.6 mostra che la distribuzione delle entrate (normale o uniforme) non altera l'insieme dei ranghi tipici e produce frequenze empiriche analoghe.





Figura 1.6: Distribuzione empirica dei ranghi per tensori casuali reali di formato $2 \times 2 \times 2$, $3 \times 3 \times 2$, $3 \times 3 \times 3$ e $3 \times 3 \times 5$ con entrate estratte da distribuzioni Normali $\mathcal{N}(0, 1)$ ed Uniformi $\mathcal{U}(-1, 1)$ (istogrammi affiancati).


Tabella 1.2: Ranghi tipici noti sul campo reale $\mathbb{R}$ per tensori di dimensione $m \times n \times p$ con $2 \leq m \leq n \leq p$ (adattata da Ballard e Kolda [3, Tabella 16.2]).

Formato ($m \times n \times p$)	Rango tipico	Fonte
$2 \times n \times n$	$\{n, n + 1\}$	ten Berge, Kiers [6]
$3 \times 3 \times 3$	5	ten Berge, Stegeman [8]
$3 \times 3 \times 5$	$\{5, 6\}$	ten Berge, Sidiropoulos, Rocci [7]
$3 \times 4 \times 8$	$\{8, 9\}$	Sumi et al. [23]
$3 \times 5 \times 9$	$\{9, 10\}$	Choulakian [9]; ten Berge [4]
$4 \times 4 \times 12$	$\{12, 13\}$	Friedland [13]
$m \times n \times n(m - 1)$ ($m > 2$, n dispari)	$n(m - 1)$	ten Berge [5]
$m \times n \times p$ ($n(m - 1) < p < mn$)	p	ten Berge, Kiers [6]; ten Berge [5]
$m \times n \times p$ ($p \geq mn$)	mn	ten Berge, Kiers [6]; ten Berge [5]

DIPENDENZA DAL CAMPO BASE

Nel caso matriciale ogni matrice $m \times n$ a entrate reali ha lo stesso rango se visto come elemento di $\mathbb{R}^{m \times n}$ o di $\mathbb{C}^{m \times n}$, per i tensori questo è falso. Consideriamo il seguente esempio:





Esempio 1.6.6 (De Silva e Lim [21]). Scriviamo $z_k = x_k + iy_k$ e $\bar{z}_k = x_k - iy_k$, allora

$$(1.9) \quad \begin{aligned} & \frac{1}{2}(\bar{z}_1 \otimes z_2 \otimes \bar{z}_3 + z_1 \otimes \bar{z}_2 \otimes z_3) \\ &= x_1 \otimes x_2 \otimes x_3 + x_1 \otimes y_2 \otimes y_3 - y_1 \otimes x_2 \otimes y_3 + y_1 \otimes y_2 \otimes x_3. \end{aligned}$$

Chiamando $I = \bar{z}_1 \otimes z_2 \otimes \bar{z}_3$ e $II = z_1 \otimes \bar{z}_2 \otimes z_3$, usando la proprietà distributiva e la trilinearità del prodotto tensore,

$$\begin{aligned} I &= (x_1 - iy_1) \otimes (x_2 + iy_2) \otimes (x_3 - iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 - ix_1 \otimes x_2 \otimes y_3 + ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 - iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 - iy_1 \otimes y_2 \otimes y_3, \\ II &= (x_1 + iy_1) \otimes (x_2 - iy_2) \otimes (x_3 + iy_3) \\ &= x_1 \otimes x_2 \otimes x_3 + ix_1 \otimes x_2 \otimes y_3 - ix_1 \otimes y_2 \otimes x_3 \\ &\quad + x_1 \otimes y_2 \otimes y_3 + iy_1 \otimes x_2 \otimes x_3 - y_1 \otimes x_2 \otimes y_3 \\ &\quad + y_1 \otimes y_2 \otimes x_3 + iy_1 \otimes y_2 \otimes y_3. \end{aligned}$$

L'espressione sopra segue calcolando $\frac{1}{2}(I + II)$.

1.7 IL TEOREMA DEL RANGO


Data la complessità del problema del rango possiamo stimarlo rango con la seguente proposizione, dalla quale intuimmo che non sarà semplice trovare stime del rango di un tensore—queste spesso coinvolgono tecniche algebrico-combinatorie avanzate. Vedremo alcuni esempi di queste stime nella Sezione ??.


Definiamo un'operazione utile tra le colonne di due matrici, che sarà utile a dimostrare il risultato di questa sezione.

Definizione 1.7.1 (Prodotto Khatri-Rao). Date due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$, il loro *prodotto Khatri-Rao* è dato da

$$(1.10) \quad C = A \odot B = [a_1 \boxtimes b_1 \mid \dots \mid a_r \boxtimes b_r] \in \mathbb{R}^{(mn) \times r},$$

dove a_j e b_j indicano la j -esima colonna di A e B , rispettivamente, e la matrice C si lascia scrivere in componenti come $C_{kl} = A_{il}B_{jl}$, dove $\mathbb{L}^*(i, j) = \mathbb{L}(j, i) = k$.





Osservazione 1.7.2. Il prodotto $A \odot B$ è sottomatrice di $A \boxtimes B$, in quanto una colonna k -esima della prima è del tipo $a_k \boxtimes b_k$, mentre per la seconda è $[a_{1k}B, \dots, a_{mk}B]^\top$; quindi possiamo ottenere la prima matrice selezionando alcune colonne della seconda.

Osservazione 1.7.3. Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$, il prodotto Khatri-Rao

$$U_d \odot U_{d-1} \odot \dots \odot U_1$$

ha come colonna r -esima $u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$, in altre parole, è la rappresentazione matriciale dell'insieme $\{u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1\}_{r=1, \dots, d}$ formato dagli addendi della decomposizione $\text{vec}(T) = \sum_{r=1}^R u_r^d \boxtimes u_r^{d-1} \boxtimes \dots \boxtimes u_r^1$. In particolare, vale

$$\begin{aligned} \text{vec}(T) &= \sum_{h=1}^r u_h^d \boxtimes \dots \boxtimes u_h^1 = \left[u_1^d \boxtimes \dots \boxtimes u_1^1 \mid \dots \mid u_r^d \boxtimes \dots \boxtimes u_r^1 \right]^\top \mathbf{1}_r \\ &= (U_d \odot U_{d-1} \odot \dots \odot U_1) \mathbf{1}_r. \end{aligned}$$

Osservazione 1.7.4. Calcolare il prodotto di Khatri-Rao di due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$ ha un costo in memoria di $O(mnr)$.

Lemma 1.7.5. *Data una fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket \in \mathbb{R}^{n_1 \times \dots \times n_d}$, essa ha come unfoldings*

$$\mathbf{T}_{(j)} = U_j (U_d \odot U_{d-1} \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)^\top,$$


per ogni $j = 1, \dots, d$.


Dimostrazione. Scrivendo le matricizzazioni di $T = \sum_{h=1}^r u_h^1 \otimes \dots \otimes u_h^d$, dove i vettori $u_1^j, \dots, u_r^j$ rappresentano le colonne della matrice U_j , troviamo che

$$\begin{aligned} \mathbf{T}_{(j)} &= \sum_{h=1}^r u_h^j \left(u_h^d \boxtimes \dots \boxtimes u_h^{j+1} \boxtimes u_h^{j-1} \boxtimes \dots \boxtimes u_h^1 \right)^\top \\ &= U_j \left[u_1^d \boxtimes \dots \boxtimes u_1^1 \mid \dots \mid u_r^d \boxtimes \dots \boxtimes u_r^1 \right]^\top \\ &= U_j (U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)^\top, \end{aligned}$$

dove nel primo passaggio abbiamo applicato la Proposizione 1.5.11 su ogni addendo di rango uno. $\square$

Esempio 1.7.6. Se $T = \llbracket A, B, C \rrbracket$, allora segue che $\mathbf{T}_{(1)} = A(C \odot B)^\top$.





Proposizione 1.7.7 (Teorema del rango). *Sia $T \in \mathbb{R}^{n_1 \times \cdots \times n_d}$ un tensore che ammette fattorizzazione $T = \llbracket U_1, \dots, U_d \rrbracket$, e sia $r_j = \text{rank}(\mathbf{T}_{(j)})$ il rango dell'unfolding $\mathbf{T}_{(j)}$ con $j = 1, \dots, d$. Allora vale che*

$$(1.11) \quad \max_{j=1, \dots, d} (r_j) \leq \mathbf{R}(T) \leq \min_{j=1, \dots, d} \left(\prod_{i \neq j} r_i \right)$$

Dimostrazione. Fissato $r = \mathbf{R}(T)$, la minorazione segue direttamente dal fatto che ogni unfolding $\mathbf{T}_{(j)}$ è una matrice di taglia $n_j \times r$. Mostriamo la maggiorazione, assumendo senza perdita di generalità che $\mathbf{R}(T) \leq \prod_{i=2}^d r_i$. Consideriamo la vettorizzazione

$$(1.12) \quad \text{vec}(T) = \sum_{k=1}^r u_k^d \boxtimes \cdots \boxtimes u_k^2 \boxtimes u_k^1.$$

Allora l'insieme

$$\left\{ u_k^d \boxtimes \cdots \boxtimes u_k^2 \right\}_{k=1, \dots, r}$$

è formato da vettori linearmente indipendenti. Se così non fosse, esisterebbe un indice k_0 , che possiamo supporre $k_0 = 1$ a meno di riordinamento degli indici k , tale per cui

$$(1.13) \quad u_1^d \boxtimes \cdots \boxtimes u_1^2 = \sum_{h=2}^r c_h (u_h^d \boxtimes \cdots \boxtimes u_h^2),$$


che sostituita nella Equazione (1.12) porta alla seguente decomposizione:


$$\begin{aligned} \text{vec}(T) &= \sum_{k=2}^r u_k^d \boxtimes \cdots \boxtimes u_k^2 \boxtimes u_k^1 + \left(\sum_{k=2}^r c_k (u_k^d \boxtimes \cdots \boxtimes u_k^2) \right) \boxtimes u_1^1 \\ &= \sum_{k=2}^r \left(u_k^d \boxtimes \cdots \boxtimes u_k^2 \right) \boxtimes (u_k^1 + c_k u_1^1), \end{aligned}$$

che ha rango $r - 1$, contraddicendo la minimalità di r . Dal Lemma 1.7.5 possiamo scrivere

$$\mathbf{T}_{(1)} = U_1(U_d \odot \cdots \odot U_2)^\top.$$

Dalla lineare indipendenza appena dimostrata, e dall'Osservazione 1.7.3 segue che $\mathbf{R}(U_d \odot \cdots \odot U_2) = r$. Applicando l'Osservazione 1.7.2 a più fattori, $U_d \odot \cdots \odot$





U_r è sottomatrice di $U_d \boxtimes \cdots \boxtimes U_2$. Siccome il rango del prodotto di Kroneker è moltiplicativo (Osservazione 1.3.2) troviamo

$$r \leq \text{rank}(U_d \boxtimes \cdots \boxtimes U_2) = r_2 \cdots r_d.$$

Ripetendo l'argomento per gli altri unfoldings si ha la tesi. $\square$

Osservazione 1.7.8. Una conseguenza immediata di questo teorema è che T ha rango uno se e solo se $\mathbf{R}_{\text{multilin}}(T) = 1$, cioè se e solo se $\mathbf{R}(\mathbf{T}_{(j)}) = 1$ per ogni j . In generale vale che, se $\mathbf{R}(T) = r$, allora $\mathbf{R}_{\text{multilin}}(T) \leq r$, ma non il viceversa.

ho cercato un
esempio non è
semplice verifi-
care

1.8 RICOSTRUZIONE DEL TENSORE IN FORMATO DENSO

In alcune situazioni è utile scrivere il tensore fattorizzato in modo esplicito, ad esempio per valutare l'errore di approssimazione (1.7) o generare numericamente un tensore. Un modo conveniente di farlo è il seguente. Data una fattorizzazione $T = \llbracket A, B, C \rrbracket \in \mathbb{R}^{m \times n \times p}$ di rango r , dato che $\text{vec}(T) = (C \odot B \odot A)\mathbf{1}_r$, saremmo tentati di formare la matrice $C \odot B \odot A$ e moltiplicarla per il vettore di tutti uni $\mathbf{1}_r$, ma questa matrice ha più entrate del risultato finale. L'approccio vincente è considerare $\mathbf{T}_{(1)} = A(C \odot B)^\top$ dato dalla Proposizione 1.7.5, e studiare il sistema


$$\begin{cases} R = C \odot B, \\ Y = AR^\top, \\ T = \text{RESHAPE}(Y, m \times n \times p). \end{cases}$$


Il risultato intermedio $R \in \mathbb{R}^{np \times r}$ ha costo $O(npr)$, mentre formare Y costa $O(mnpr)$. Dato che l'unfolding è sul modo uno, non abbiamo bisogno di permutazioni.

1.9 CALCOLO DELLA FATTORIZZAZIONE CP

Trattiamo il problema di trovare la migliore approssimazione con rango r di un dato tensore. Studiamo il caso $d = 3$ per semplicità di notazione. Dato $T \in \mathbb{R}^{m \times n \times p}$ cerchiamo una fattorizzazione $\llbracket A, B, C \rrbracket$ con $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ e $C \in \mathbb{R}^{p \times r}$ cercando di risolvere il problema ai minimi quadrati

$$(\mathcal{P}) \quad \min_{A, B, C} \|T - \llbracket A, B, C \rrbracket\|^2.$$





Tale problema può essere mal posto per quanto detto sul border rank. Inoltre si tratta di un problema non convesso (esistono molti minimi locali); inoltre un tensore può avere fattorizzazioni CP multiple.

Definizione 1.9.1 (Prodotto di Hadamard). Date due matrici $A, B \in \mathbb{R}^{m \times n}$, il loro *prodotto di Hadamard* è il loro prodotto elemento per elemento, e si indica con la matrice $C = A * B$ con entrate $C_{ij} = a_{ij}b_{ij}$.

Lemma 1.9.2. Date delle matrici $A \in \mathbb{R}^{m \times r}, B \in \mathbb{R}^{n \times r}, C \in \mathbb{R}^{m \times s}, D \in \mathbb{R}^{n \times s}$, vale

$$(A \odot B)^\top (C \odot D) = (A^\top C) * (B^\top D).$$

Dimostrazione. Basta osservare che la matrice

$$(A \odot B)^\top (C \odot D) = \begin{bmatrix} a_1^\top \boxtimes b_1^\top \\ \vdots \\ a_r^\top \boxtimes b_r^\top \end{bmatrix} \left[c_1 \boxtimes d_1 \mid \dots \mid c_s \boxtimes d_s \right].$$

array ticker
brackets $\boxtimes$

ha come entrata (i, j) l'elemento $(a_i^\top c_j)(b_i^\top d_j)$, che corrisponde all'entrata (i, j) di $(A^\top C) * (B^\top D)$. $\square$

ALTERNATING LEAST-SQUARES

Nonostante la funzione obbiettivo dell'Equazione (P) non sia convessa, essa è convessa nelle singole variabili. Ovvero, fissando B e C , ottimizzare solo su A significa risolvere un problema ai minimi quadrati lineare

$$(1.14) \quad \|T - \llbracket A, B, C \rrbracket\|^2 = \|\mathbf{T}_{(1)} - A(C \odot B)^\top\|_F^2 = \|(C \odot B)A^\top - \mathbf{T}_{(1)}^\top\|_F^2,$$


dove l'incognita è una matrice. Nel primo passaggio abbiamo applicato la Proposizione 1.7.5 per ridurci a un problema ai minimi quadrati matriciale. La soluzione può essere espressa in termini delle equazioni normali


why?

$$(C \odot B)^\top (C \odot B)A^\top = (C \odot B)^\top \mathbf{T}_{(1)}^\top,$$

se e solo se, usando il Lemma 1.9.2

$$(1.15) \quad (C^\top C * B^\top B)A^\top = (C \odot B)^\top \mathbf{T}_{(1)}^\top$$





Sia $Z := C^\top C * B^\top B \in \mathbb{R}^{r \times r}$. Osserviamo che calcolare Z ha costo $O((n+p)r^2)$.

motiva

Inoltre Z è semidefinita positiva, e quando $C \odot B$ è full-rank è positiva definita: in tal caso possiamo risolvere con la fattorizzazione di Cholesky il sistema

$$(1.16) \quad AZ = \mathbf{T}_{(1)}(C \odot B) = M,$$

verifica

con costo $O(r^2m + r^3)$

verificare (aggiungerebbe un paragrafetto)

L'idea dell'algoritmo ALS è di minimizzare ciclicamente la funzione obiettivo dell'Equazione (1.14), prima al variare di A , poi B e poi C . Ognuno dei problemi dati dall'Equazione ha costo $O(mnpr)$. Riassumiamo questo schema nell'Algoritmo 1, dove in ogni passaggio riscaldiamo la fattorizzazione CP come $\llbracket AD_A, BD_B, CD_C \rrbracket$ con delle matrici tali che $D_A D_B D_C = I_r$ per riscaldare le colonne dei due fattori fissati in modo che abbiano norma unitaria.


Algorithm 1 Schema dell'algoritmo ALS.


Input: Tensore T di rango r , tolleranza ε .

- 1: Generiamo B e C in modo casuale.
 - 2: Normalizziamo le colonne di B .
 - 3: **repeat**
 - 4: Normalizziamo le colonne di C .
 - 5: $A \leftarrow \arg \min_A \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 6: Normalizziamo le colonne di A .
 - 7: $B \leftarrow \arg \min_B \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 8: Normalizziamo le colonne di B .
 - 9: $C \leftarrow \arg \min_C \|T - \llbracket A, B, C \rrbracket\|^2$.
 - 10: **until** $\frac{\|T - \llbracket A, B, C \rrbracket\|}{\|T\|} > \varepsilon$.
-

Osservazione 1.9.3. Dato che in genere non si sa il valore ottimo del problema $(\mathcal{P})$, arrestiamo l'algoritmo quando sta "stagnando", ovvero quando l'errore relativo fra due iterazioni successive diminuisce meno di un dato fattore.

Osservazione 1.9.4. Nel caso di T matrice, il fattore $C = I$ e nel caso T ha rango $r = 1$, l'algoritmo diventa il metodo delle potenze, in quanto l'Equazione (1.15) degenera in $a \leftarrow T \frac{b}{\|b\|^2}$ e $b \leftarrow T^\top \frac{a}{\|a\|^2}$, mentre per T di rango $r > 1$ diventa il metodo dei sottospazi: $A \leftarrow TB(B^\top B)^{-1}$ e $B \leftarrow T^\top A(A^\top A)^{-1}$.





2 APPLICAZIONI MODELLISTICHE DELLA DECOMPOSIZIONE CP

In questo capitolo esploreremo due applicazioni della decomposizione CP di un tensore a tre indici in due ambiti modellistici, dove avremo modo di applicare il Teorema di Kruskal ?? e l'algoritmo Alternating Least Squares. Nel primo esperimento il rango non sarà noto a priori e dovremo prima approssimarlo, per poi trovare una decomposizione. Nel secondo conosceremo il rango a priori.

cambia titolo

why eccitation-emission matrices hanno rango 1?

improve

2.1 SPETTROSCOPIA FLUORESCENTE

Nella *spettroscopia fluorescente*, un campione chimico è eccitato (e.g. tramite una luce), e la luce che viene emessa viene misurata a diverse lunghezze d'onda, risultando in una matrice di *eccitazione-emissione* (EEM) di intensità fluorescenti (si veda Figura 2.1). Quando i dati EEM vengono raccolti da diversi campioni, otteniamo un tensore a tre indici. Questi dati si possono utilizzare nella chimica analitica per stimare le concentrazioni e gli spettri dei composti chimici a partire da più miscele.





Figura 2.1: Rappresentazione schematica di uno spettrofotometro per spettroscopia di fluorescenza.



Nel dettaglio, vengono dati I campioni di soluzioni chimiche, ognuno dei quali contiene diverse sostanze diluite in diverse concentrazioni. Il primo obiettivo è determinare il numero r delle diverse sostanze presenti. Il dataset che analizziamo [1, 16] è composto da una serie di esperimenti riportati da [22], nel quale sono presenti ci sono tre sostanze chimiche disciolte nelle soluzioni:

- *Valine-Tyrosine-Valine* (Val-Tyr-Val) - peptide,
- *Tryptophan-Glycine* (Trp-Gly) - peptide,
- *Phenylalanine* (Phe) - amino acid.

Segnaliamo che i dati sono stati preprocessati dagli autori per riempire i dati mancanti e sostituire le entrate negative, come spiegato in [16].

Ogni campione, diciamo il numero i -esimo è successivamente eccitato da una luce in J diverse lunghezze d'onda. Per ogni lunghezza d'onda di eccitazione, viene misurato lo spettro emesso. Diciamo che l'intensità della luce fluorescente emessa è misurata da K diverse lunghezze d'onda. Allora per ogni i otteniamo una matrice $J \times K$ di eccitazione-emissione.

Quindi i dati possono essere rappresentati come un array $I \times J \times K$, scrivibile come


$$T = \sum_{f=1}^r a_f \otimes b_f \otimes c_f,$$

in componenti,

$$T_{ijk} = \sum_{f=1}^r a_{if} b_{jf} c_{kf},$$

dove $a_{i,f}$ è la concentrazione della f -esima sostanza nell' i -esimo campione, $c_{k,f}$ è la frazione di protoni che la f -esima sostanza emette nella lunghezza d'onda k e $b_{j,f}$ è l'intensità della luce incidente alla lunghezza d'onda j moltiplicata per l'assorbimento alla lunghezza d'onda j . Il primo obiettivo è trovare un r tale che ogni f rappresenti una sostanza.

Il dataset analizzato contiene le misurazioni di matrici di eccitazione-emissione (EEM) per 18 campioni, ognuno dei quali consiste in una miscela dei tre composti chimici sopra (Val-Tyr-Val, Trp-Gly e Phe). I dati sono organizzati in un tensore tridimensionale di dimensioni $I \times J \times K = 18 \times 251 \times 21$, corrispondenti rispettivamente ai campioni, alle lunghezze d'onda di emissione (da 250 a 500 nm) e alle lunghezze d'onda di eccitazione (da 210 a 310 nm). Una rappresentazione tridi-



mentionale del tensore è mostrata in figura 2.2, mentre alcune sezioni di matrici di eccitazione-emissione sono visualizzate in figura 2.3.

Sources/Chapter4/figures/piled_tensor.pdf

Figura 2.2: Rappresentazione tridimensionale del tensore EEM di dimensioni $18 \times 251 \times 21$.


Cerchiamo una fattorizzazione approssimata di $\hat{T}$ con le tecniche descritte nella § 1.9. Fissata una tolleranza ε piccola, applichiamo il procedimento dell’Algoritmo 2. La ricerca di $\hat{T}$ viene ripetuta attraverso una serie di restarts per evitare minimi locali, al termine dei quali viene restituito il tensore che minimizza l’errore relativo ε_{rel} . Nell’articolo originale [22] vengono anche esclusi i tensori che non sono ragionevoli da un punto di vista fisico per rimuovere valori di r troppo piccoli. Per i nostri scopi ci limitiamo a imporre che le quantità fisiche coinvolte (concentrazioni, intensità di emissione ed eccitazione) siano non negative, per cui si scartano le decomposizioni che presentano fattori negativi.

Algorithm 2 Algoritmo di approssimazione del tensore originale.

```

1: for  $i = 1 \dots r$  do
2:   repeat
3:      $\hat{T} \leftarrow \arg \min_{A,B,C} \|T - \llbracket A, B, C \rrbracket\|$  ▷ CP ALS con restarts.
4:   until  $\|T - \hat{T}\| < \varepsilon$ 
5: end for
```

Assumiamo ora che il rango ottimale r sia stato determinato attraverso l’euristica discussa in § 1.6. Siccome i valori di r sono relativamente piccoli, a meno di piccole perturbazioni, l’espressione di $\hat{T}$ come somma di elementi di rango uno sarà unica grazie al Teorema di Kruskal ???. Quindi, decomponendo $\hat{T}$, possiamo recuperare la concentrazione di ognuna delle r sostanze in ogni soluzione, determinando i vettori a_f così come lo spettro delle eccitazioni ed emissioni determinando i vettori b_f . La figura 2.5 mostra i fattori calcolati e il confronto con le concentrazioni reali delle tre sostanze, arrestando CP ALS quando la differenza dell’errore relativo tra due iterazioni susseguenti è minore di 10^{-4} . Nel grafico sono tracciati i fattori a_f, b_f, c_f della decomposizione CP, dove ogni riga $f = 1, 2, 3$ rappresenta una sostanza diversa (scritta in sottoimpressione). Ad esempio, la componente a_1 sono le barre blu nella







Figura 2.3: Profili d'intensità di emissione-eccitazione del tensore EEM. I profili corrispondono alle fette orizzontali del tensore, ordinate dall'alto ($T_{1,:,:}$) al basso ($T_{18,:,:}$) Visualizzazione di alcune matrici di eccitazione-emissione (EEM) per diversi campioni. Ogni profilo è etichettato a destra con le concentrazioni dei tre composti chimici (Val-Tyr-Val/Trp-Gly/Phe). Ogni profilo copre 21 lunghezze d'onda di eccitazione (210-215-310 nm) da 251 lunghezze d'onda di emissione (350-251-500nm)








Figura 2.4: Errore relativo al variare del rango della decomposizione approssimante. Il rango ottimale selezionato è $r = 3$, corrispondente al superamento della tolleranza target $\varepsilon = 0.05$. Osserviamo che la precisione non varia di molto all'aumentare di r .


prima sottofigura in alto a sinistra, dove notiamo che i primi due fattori di a_1 sono nulli, che significa che la componente non è presente nei primi due campioni. Nella colonna centrale in alto denotiamo le componenti individuali di b_1 , che sono 256, con dei punti. Il terzo fattore c_1 è rappresentato nella figura in alto a destra.






Sources/Chapter4/figures/eem_model.pdf

Figura 2.5: Fattori della decomposizione CP non negativa a rango $r = 3$ del tensore EEM. I diagrammi a barre a sinistra confrontano i profili di concentrazione calcolati con le concentrazioni effettive delle tre sostanze (Val-Tyr-Val, Trp-Gly, Phe).





2.2 BLIND DECONVOLUTION DI SEGNALI

Nel *problema del cocktail party* un insieme di persone si trova in una stanza a parlare. Ci sono diversi ricevitori impostati che registrano le conversazioni: non singolarmente ma tutte insieme, sovrapposte. L'obiettivo è recuperare cosa ogni persona sta dicendo. Questo "unmixing" si può ottenere usando la decomposizione CP. Questo problema è noto nell'analisi di segnali come *blind deconvolution*, utilizzata nel campo delle telecomunicazioni nel modello wireless *direct-sequence code-division multiple access* (DS-CDMA) [11, 19, 20] che riadattiamo in questa sezione.

Per semplicità supponiamo che R utenti mandino dei messaggi a I antenne. I messaggi arrivano mischiati, e l'obiettivo è recuperare i segnali individuali e le posizioni di utenti e antenne.

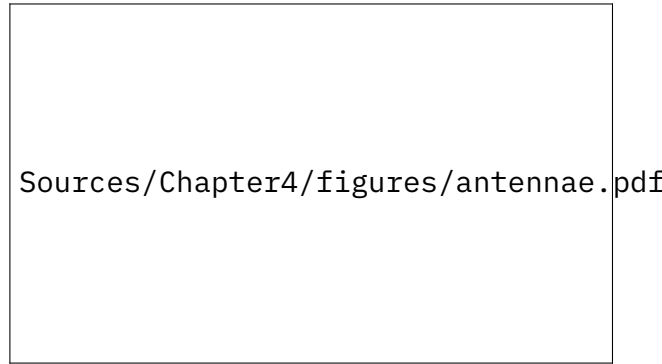



Figura 2.6: $R = 3$ sorgenti inviano segnali a $I = 2$ antenne.

L'utente r -esimo trasmette il messaggio in un vettore di $s_r = [s_{1r}, \dots, s_{Kr}]^T \in \mathbb{R}^K$, dove le entrate sono numeri reali random. Ci sono I antenne che ricevono i segnali. Quando i segnali arrivano all' i -esima antenna, il segnale è stato soggetto a distorsione nell'intensità e fase (anche detta *fading/gain*), quindi ciò che viene ricevuto dall'antenna i -esima sono le IK quantità $a_{ir}s_{kr}$, dove a_{ir} è il fading/gain tra l'utente r e l'antenna i .

In questo scenario si riceve un tensore $T \in \mathbb{C}^{I \times K}$ di rango R di entrate

$$T_{ik} = \sum_{r=1}^R a_{ir}s_{kr}.$$

L'obiettivo sarebbe recuperare i segnali s_r , per $1 \leq r \leq R$ da questo tensore (matrice) decomponendole come matrici di rango uno. Sfortunatamente, questa decomposizione non è mai unica quando $R > 1$. Per aggirare il problema, vengono introdotti



dei “codici” per “diffondere” il segnale che ogni utente invia per ottenere un tensore a tre indici che avrà generalmente una decomposizione unica.¹

Facciamo le seguenti ipotesi sulla trasmissione dei segnali: la trasmissione avviene in linea d’aria, seguendo la strada più breve (secondo la distanza euclidea) senza incontrare ostacoli; i simboli inviati arrivano in maniera ordinata senza sovrapposizione (esempio $s_{k,r}$ allo stesso tempo di $s_{k+1,r}$). Questi comportamenti sono noti in letteratura come ICI (*interchip interference*) e ISI (*intersignal interference*). Inoltre i segnali non subiscono rumore e non vengono memorizzati (serve?).

Per recuperare s_r e a_{ir} , l’ r -esimo utente introduce una ridondanza in termini di codice chiamata *spreading sequence* che è fissata per ogni utente, diciamo $c_r = [c_{1r}, \dots, c_{Jr}]^T$. Il simbolo s_{kr} è trasmesso su molteplici frequenze; come risultato, vengono trasmesse simultaneamente J quantità $[s_{kr}c_{1r}, \dots, s_{kr}c_{Jr}]$, chiamate *chips* al tempo k . La trasmissione totale sopra JK unità di tempo dell’utente r -esimo sono le JK chips $c_{jr}s_{kr}$, $1 \leq j \leq J$, $1 \leq k \leq K$ (qui J è anche detto *spreading gain*). L’antenna i -esima riceve le JK quantità $\sum_r a_{ir}c_{jr}s_{kr}$, per $1 \leq j \leq J$, $1 \leq k \leq K$, dove, come sopra, a_{ir} sono i fading/gain tra l’utente r e l’antenna i . In totale, viene ricevuto un tensore $T \in \mathbb{C}^{I \times J \times K}$ di rango R scrivibile in componenti come

$$(2.1) \quad T_{ijk} = \sum_{r=1}^R a_{ir}c_{jr}s_{kr},$$

o in generale,


$$T = \sum_{r=1}^R a_r \otimes c_r \otimes s_r.$$

In altre parole, $T = \llbracket S, C, A \rrbracket$. L’obiettivo è recuperare i segnali s_r , per $1 \leq r \leq R$ da questo tensore, cioè la matrice S . Per farlo abbiamo bisogno che la scrittura sia essenzialmente unica. Per il Teorema di Kruskal ?? questa decomposizione è unica se

$$\mathbf{k}_A + \mathbf{k}_B + \mathbf{k}_C \geq 2(R + 1).$$

Per costruzione [11] le matrici A e C sono di k -rango pieno con probabilità 1, mentre se i simboli trasmessi s_{Kr} appartengono ad un alfabeto finito, c’è possibilità che S non sia di k -rango pieno—c’è una possibilità che le sequenze di utenti diversi possano essere uguali, ma questo è poco probabile per dataset più grandi. Quindi nella pratica assumiamo che S sia di k -rango pieno. Questo significa che il numero

¹Tale spreading è comune nelle telecomunicazioni, e.g. della ridondanza è introdotta per compensare gli errori causati dalla corruzione dei segnali durante la trasmissione.





di utenti che possono essere processati simultaneamente si può considerare limitato come

$$\min\{I, R\} + \min\{J, R\} + \min\{K, R\} \geq 2(R + 1).$$

Il recupero di T avviene con l'algoritmo ALS, fissando le matrici A, C e facendo variare la matrice S , minimizzando la funzione


$$\|T - \sum_{r=1}^R s_r \otimes c_r \otimes a_r\|^2 = \sum_{i,j,k} |t_{ijk} - \sum_{r=1}^R s_{ir} c_{jr} a_{kr}|^2.$$






ACRONIMI


ALS	Alternating Least Squares
APA	Arbitrary Precision Approximating
CP	Canonical Polyadic Decomposition
SVD	Singular Value Decomposition






GLOSSARIO


$\text{\LaTeX}$	A document preparation system
$\mathbb{R}$	The set of real numbers







BIBLIOGRAFIA


1. E. Acar, E. E. Papalexakis, G. Gürdeniz, M. A. Rasmussen, A. J. Lawaetz, M. Nilsson, e R. Bro. «Structure-Revealing Data Fusion». *BMC Bioinformatics* 15:1, 2014, p. 239. DOI: [10.1186/1471-2105-15-239](https://doi.org/10.1186/1471-2105-15-239).
2. M. Atkinson e N. Stephens. «On the maximal multiplicative complexity of a family of bilinear forms». *Linear Algebra and its applications* 27, 1979, pp. 1–8.
3. G. Ballard e T. G. Kolda. *Tensor Decompositions for Data Science*. Cambridge University Press, 2025. URL: <https://tensortextbook.com>.
4. J. M. F. ten Berge. «Simplicity and typical rank results for three-way arrays». *Psychometrika* 76:1, 2011, pp. 3–12. DOI: [10.1007/s11336-010-9193-1](https://doi.org/10.1007/s11336-010-9193-1).
5. J. M. F. ten Berge. «The typical rank of tall three-way arrays». *Psychometrika* 65:4, 2000, pp. 525–532. DOI: [10.1007/BF02296342](https://doi.org/10.1007/BF02296342).
6. J. M. F. ten Berge e H. A. L. Kiers. «Simplicity of core arrays in three-way principal component analysis and the typical rank of $p \times q \times 2$ arrays». *Linear Algebra and its Applications* 294:1–3, 1999, pp. 169–179. DOI: [10.1016/S0024-3795\(99\)00057-9](https://doi.org/10.1016/S0024-3795(99)00057-9).
7. J. M. F. ten Berge, N. D. Sidiropoulos, e R. Rocci. «Typical rank and INDSCAL dimensionality for symmetric three-way arrays of order $I \times 2 \times 2$ or $I \times 3 \times 3$ ». *Linear Algebra and its Applications* 388, 2004, pp. 363–377. DOI: [10.1016/j.laa.2004.03.009](https://doi.org/10.1016/j.laa.2004.03.009).
8. J. M. F. ten Berge e A. Stegeman. «Symmetry transformations for square sliced three-way arrays, with applications to their typical rank». *Linear Algebra and its Applications* 418:1, 2006, pp. 215–224. DOI: [10.1016/j.laa.2006.02.002](https://doi.org/10.1016/j.laa.2006.02.002).
9. V. Choulakian. «Some properties of the PARAFAC model». *Journal of Chemometrics* 24:7–8, 2010, pp. 483–490. DOI: [10.1002/cem.1310](https://doi.org/10.1002/cem.1310).





10. L. DeLathauwer. «A Link between the Canonical Decomposition in Multilinear Algebra and Simultaneous Matrix Diagonalization». *SIAM Journal on Matrix Analysis and Applications* 28:3, 2006, pp. 642–666. DOI: [10.1137/040608830](https://doi.org/10.1137/040608830). eprint: <https://doi.org/10.1137/040608830>. URL: <https://doi.org/10.1137/040608830>.
11. L. DeLathauwer e A. de Baynast. «Blind deconvolution of DS-CDMA signals by means of decomposition in rank-(1, L, L) terms». *IEEE Transactions on Signal Processing* 56:4, 2008, pp. 1562–1571.
12. C. Eckart e G. Young. «The approximation of one matrix by another of lower rank». *Psychometrika* 1:3, 1936, pp. 211–218.
13. S. Friedland. «On the generic rank of 3-tensors». *Linear Algebra and its Applications* 436:3, 2012, pp. 478–497. DOI: [10.1016/j.laa.2011.08.031](https://doi.org/10.1016/j.laa.2011.08.031).
14. J. Håstad. «Tensor rank is NP-complete». In: *International colloquium on automata, languages, and programming*. Springer, 1989, pp. 451–460.
15. J. JáJá. «Optimal evaluation of pairs of bilinear forms». *SIAM Journal on Computing* 8:3, 1979, pp. 443–462. DOI: [10.1137/0208037](https://doi.org/10.1137/0208037).
16. T.G. Kolda. *EEM Tensor Dataset*. https://gitlab.com/tensors/tensor_data_eem. Accesso: 25 agosto 2026. 2021.
17. J.B. Kruskal. «Rank, decomposition, and uniqueness for 3-way and N -way arrays». In: *Multiway and Random Data Analysis*. A cura di R. Coppi e S. Bolasco. North-Holland, 1989, pp. 7–18.
18. J.M. Landsberg. «Geometry and complexity theory». *NSF Award Number 1405348. Directorate for Mathematical and Physical Sciences* 14:1405348, 2015, p. 5348.
19. J.M. Landsberg. *Tensors: geometry and applications*. Vol. 128. American Mathematical Soc., 2011.
20. N.D. Sidiropoulos, G.B. Giannakis, e R. Bro. «Blind PARAFAC receivers for DS-CDMA systems». *IEEE Transactions on Signal Processing* 48:3, 2000, pp. 810–823.
21. V. de Silva e L.-H. Lim. *Tensor rank and the ill-posedness of the best low-rank approximation problem*. 2008. arXiv: [math/0607647](https://arxiv.org/abs/math/0607647) [math.NA]. URL: <https://arxiv.org/abs/math/0607647>.





22. A.K. Smilde, R. Bro, P. Geladi et al. *Multi-way analysis with applications in the chemical sciences*. Vol. 396. Wiley Chichester, 2004.
23. T. Sumi, T. Sakata, e M. Miyazaki. «Typical ranks for $m \times n \times (m-1)n$ tensors with $m \leq n$ ». *Linear Algebra and its Applications* 438:2, 2013, pp. 953–958.
DOI: 10.1016/j.laa.2011.08.009.

