

Canonical Polyadic Decomposition and applications

A minimal, modern L^AT_EX package for typesetting your thesis

by

Alberto Defendi (with the help of many others!)

A document submitted in partial fulfillment of the requirements for the degree of

Technical Report

at

MISKATONIC UNIVERSITY

ABSTRACT

Scientific documents often use L^AT_EX for typesetting. While numerous packages and templates exist, it makes sense to create a new one. Just because.

INDICE

I	LA FATTORIZZAZIONE CP	3
1.1	Tensori	3
1.2	La fattorizzazione CP	9
1.3	Rango CP	10
1.4	Il problema del border rank	10
1.5	Operazioni nel formato CP	11
1.6	Costruzione del tensore in formato denso	12
1.7	Unicità della fattorizzazione CP	12
1.8	Calcolo della fattorizzazione CP	13
2	APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA	15
2.1	Rappresentare forme bilineari tramite tensori	15
2.2	Il master method	16
2.3	Moltiplicazione ricorsiva di matrici	17
	ACRONIMI	19
	GLOSSARIO	21
	BIBLIOGRAFIA	23

INTRODUZIONE

I LA FATTORIZZAZIONE CP

I.1 TENSORI

Definizione 1.1.1. Denotiamo l'insieme dei numeri naturali da 1 a $n \in \mathbb{N}$ come $[n] = \{1, \dots, n\}$, e il prodotto cartesiano tra $[n]$ e $[m]$ come $[n] \otimes [m] = \{(i, j) : i \in [n], j \in [m]\}$.

Osservazione 1.1.2. Un tensore $\mathcal{X} \in \mathbb{R}^{m \times n \times 1}$ è una matrice $m \times n$, e più in generale un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ è un tensore di dimensione $n_1 \times n_2 \times \dots \times n_d$.

Definizione 1.1.3. Un *tensore* $\mathcal{X}$ di ordine d è un array multidimensionale con entrate definite sul campo $\mathbb{K}$, che denotiamo come $\mathcal{X} \in \mathbb{K}^{n_1 \times n_2 \times \dots \times n_d}$. Indicizziamo gli elementi di un tensore come $\mathcal{X}(i_1, i_2, \dots, i_d)$, dove $(i_1, i_2, \dots, i_d) \in [n_1] \otimes [n_2] \otimes \dots \otimes [n_d]$.

Osservazione 1.1.4. Per array intendiamo un arrangiamento di elementi di $\mathbb{K}$ secondo gli indici $(i_1, i_2, \dots, i_d) \in [n_1] \otimes [n_2] \otimes \dots \otimes [n_d]$. Trattare la buona definizione dei tensori dal punto di vista algebrico esula dallo scopo del presente lavoro, tuttavia il lettore interessato a una visione algebrica più ampia, può guardare.

Definizione 1.1.5 (Prodotto di Kroneker). Date due matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{p \times q}$, il loro prodotto di Kroneker è la matrice

$$C = A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \dots & a_{1n}B \\ a_{21}B & a_{22}B & \dots & a_{2n}B \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1}B & a_{m2}B & \dots & a_{mn}B \end{bmatrix} \in \mathbb{R}^{mp \times nq}, \text{ dove } c_{kl} = a_{ij}b_{nl},$$

dove $\alpha = \mathbb{L}^*(i, k) = \mathbb{L}(k, i)$ e $\beta = \mathbb{L}^*(j, l) = \mathbb{L}(l, j)$


Definizione 1.1.6 (Tensor slice). Dato $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ chiamiamo slice (o fetta) di $\mathcal{X}$ ogni matrice ottenuta da $\mathcal{X}$ fissando tutti gli indici tranne due. Le slices ottenute fissando gli ultimi $d - 2$ indici sono dette frontal slices.

Usare emph quando si introduce un termine nuovo, inserire tabella notazione all'inizio

Cita landberg o Hackbush)

ADD: Esempi di tensori. Tra cui il tensore che indica (quello del prodotto di matrici)

riscrivere con $\mathbb{L}^*$. Vedi definizione nelle note



Definizione 1.1.7 (Ordinamento naturale). L'ordinamento naturale (natural ordering) su $[n_1] \otimes \dots \otimes [n_d]$ è la mappa biunivoca

$$\mathbb{L}: [n_1] \otimes \dots \otimes [n_d] \rightarrow \left[\prod_{j=1}^d n_j \right]$$

$$(i_1, i_2, \dots, i_d) \mapsto 1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1) = 1 + \sum_{j=1}^d s_j(i_j - 1),$$

dove $s_j = n_1 \dots n_{j-1} = \prod_{b=1}^{j-1} n_b$ è detto passo j -esimo. L'inversa di $\mathbb{L}$ è data dalla mappa

$$\mathbb{L}^{-1}: \left[\prod_{j=1}^d n_j \right] \rightarrow [n_1] \otimes \dots \otimes [n_d]$$

$$l \mapsto \left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor \right)$$

. Le mappe $\mathbb{L}$ e $\mathbb{L}^{-1}$ sono l'una l'inversa dell'altra, e sono anche dette linearizzazione e tensorizzazione degli indici, rispettivamente, in quanto permettono di passare da un indice tensoriale a uno lineare, e viceversa.

Buona definizione. Segue direttamente dalla definizione di $\mathbb{L}$ e dalle proprietà del modulo, infatti,

$$\begin{aligned} \mathbb{L}^{-1}(\mathbb{L}(i_1, i_2, \dots, i_d)) &= \mathbb{L}^{-1}(1 + s_1(i_1 - 1) + \dots + s_d(i_d - 1)) \\ &= \left(1 + \left\lfloor \frac{\sum_{j=1}^d s_j(i_j - 1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{\sum_{j=1}^d s_j(i_j - 1) \bmod (n_d s_d)}{s_d} \right\rfloor \right) \\ &= \left(1 + \left\lfloor \frac{\sum_{j=1}^d \frac{s_j}{s_1}(i_j - 1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{\sum_{j=1}^d \frac{s_j}{s_d}(i_j - 1) \bmod (n_d s_d)}{s_d} \right\rfloor \right) \\ &= (i_1, i_2, \dots, i_d), \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $s_j = \prod_{k=1}^d n_k$ e il fatto che $[x] = 0$ per ogni $x \in [0, 1)$. Viceversa,

$$\begin{aligned} \mathbb{L}(\mathbb{L}^{-1}(l)) &= \mathbb{L}\left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor\right) = \\ &= 1 + s_1 \left\lfloor \frac{(l-1) \bmod (n_1 s_1)}{s_1} \right\rfloor + \dots + s_d \left\lfloor \frac{(l-1) \bmod (n_d s_d)}{s_d} \right\rfloor \end{aligned}$$

□

FINIRE

Esempio 1.1.8. È utile visualizzare il caso 3-dimensionale: fissato un tensore $\mathfrak{X} \in \mathbb{R}^{m \times n \times p}$ indicizzato con (i, j, k) , abbiamo che $s_1 = 1$, $s_2 = m$ e $s_3 = mn$, dunque

$$\mathbb{L}(i, j, k) = 1 + (i-1) + m(j-1) + mn(k-1) = i + m(j-1) + mn(k-1),$$

mentre l'inversa è

$$\mathbb{L}^{-1}(i, j, k) = \left(\lfloor (l-1) \bmod (m) \rfloor, 1 + \left\lfloor \frac{(l-1) \bmod (mn)}{m} \right\rfloor, 1 + \left\lfloor \frac{(l-1) \bmod (mnp)}{mn} \right\rfloor \right).$$

Definizione 1.1.9 (Reverse ordering). *L'ordinamento inverso* su $[n_1] \otimes [n_2] \otimes \dots \otimes [n_d]$ è la mappa biunivoca

$$\begin{aligned} \mathbb{L}^* : [n_1] \otimes \dots \otimes [n_d] &\rightarrow \left[\prod_{j=1}^d n_j \right] \\ (i_1, i_2, \dots, i_d) &\mapsto 1 + \sum_{j=1}^d s_j^* (i_j - 1), \end{aligned}$$

dove $s_j^* = \prod_{b=j+1}^d n_b$. La sua inversa è la mappa

$$\begin{aligned} (\mathbb{L}^*)^{-1} : \left[\prod_{j=1}^d n_j \right] &\rightarrow [n_1] \otimes \dots \otimes [n_d] \\ l &\mapsto \left(1 + \left\lfloor \frac{(l-1) \bmod (n_1 s_1^*)}{s_1^*} \right\rfloor, \dots, 1 + \left\lfloor \frac{(l-1) \bmod (n_d s_d^*)}{s_d^*} \right\rfloor \right) \end{aligned}$$


Osservazione 1.1.10. La definizione differisce dall'ordinamento naturale solamente dalla definizione dei passi s_j .

Analogamente alle matrici, i tensori vengono salvati in memoria come vettori, risulta quindi naturale definire la seguente operazione

Definizione 1.1.11. Dato un tensore $\mathcal{X}$, possiamo definire l'operazione che trasforma un tensore in vettore, tramite la mappa di vettorizzazione

$$\text{vec}: \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d} \rightarrow \mathbb{R}^{\prod_{j=1}^d n_j}$$

$$\mathcal{X} \mapsto x$$



dove $x_l = \mathcal{X}(\mathbb{L}^{-1}(l; n_1, n_2, \dots, n_d))$.

In molte situazioni risulta comodo disporre gli elementi di un tensore in una matrice. Uno dei modi per farlo è utilizzare le matricizzazioni, anche dette *unfoldings*.

Definizione 1.1.12 (Mode- k unfolding). Il *mode- k unfolding* di un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ è la matrice $\mathbf{X}_{(k)} \in \mathbb{R}^{n_k \times \prod_{j \neq k} n_j}$ le cui colonne sono mode- k fibers ordinate seguendo l'ordine naturale su $[n_1] \otimes \dots \otimes [n_{k-1}] \otimes [n_{k+1}] \otimes \dots \otimes [n_d]$. In particolare si ha

$$\mathcal{X}(i, j) = \mathcal{X}(i_1, \dots, i_{k-1}, i, i_{k+1}, \dots, i_d), \text{ con } j = \mathbb{L}(i_1, \dots, i_{k-1}, i_{k+1}, \dots, i_d).$$




Figura 1.1: Schema delle matricizzazioni di un tensore.

refrasare un poco
per renderla più
leggibile

Dal punto di vista computazionale è utile introdurre la seguente operazione

Definizione 1.1.13 (Reshape). Definiamo l'operatore di *reshape* come l'operazione che cambia le dimensioni di un array multidimensionale, senza alterarne le dimensioni e mantenendo l'ordine

delle entrate. Formalmente, fissati $d, d' \in \mathbb{N}$ e un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$, per ogni $m_1, \dots, m_{d'}$ tali che $\prod_{i=1}^{d'} m_j = \prod_{j=1}^d n_j$, il tensore $\mathcal{Y} = \text{RESHAPE}(\mathcal{X}, m_1 \times \dots \times m_{d'}) \in \mathbb{R}^{m_1 \times \dots \times m_{d'}}$ è definito come

$$\mathcal{Y}(i_1, \dots, i_{d'}) = \mathcal{X}(j_1, \dots, j_d),$$

per ogni $(i_1, \dots, i_{d'}), (j_1, \dots, j_d)$ tali che $\mathbb{L}(i_1, \dots, i_{d'}; m_1 \times \dots \times m_{d'}) = \mathbb{L}(j_1, \dots, j_d; n_1 \times \dots \times n_d)$.

Osservazione 1.1.14. L'insieme dei tensori $\mathbb{R}^{n_1 \times \dots \times n_d}$ forma un $\mathbb{R}$ -spazio vettoriale, dotato del prodotto scalare euclideo, con le operazioni

- Addizione: $(\mathcal{X}_1 + \mathcal{X}_2)(i_1, \dots, i_d) = \mathcal{X}_1(i_1, \dots, i_d) + \mathcal{X}_2(i_1, \dots, i_d)$.
- Moltiplicazione per scalare: Per ogni $\alpha \in \mathbb{R}$, $\alpha(\mathcal{X}(i_1, \dots, i_d)) = (\alpha\mathcal{X})(i_1, \dots, i_d)$
- Prodotto scalare: $\langle \mathcal{X}_1, \mathcal{X}_2 \rangle = \text{vec}(\mathcal{X}_1)^\top \text{vec}(\mathcal{X}_2)$
- Norma: $\|\text{vec}(\mathcal{X})\|$

Definizione 1.1.15 (Prodotto esterno). Dati dei vettori $v^{(1)} \in \mathbb{R}^{n_1}, \dots, v^{(d)} \in \mathbb{R}^{n_d}$, loro prodotto esterno, anche detto prodotto tensore, è il tensore

$$\mathcal{X} = v^{(1)} \circ v^{(2)} \circ \dots \circ v^{(d)} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d},$$

tale che la sua scrittura in componenti è

$$\mathcal{X}(i_1, i_2, \dots, i_d) = v_{i_1}^{(1)} v_{i_2}^{(2)} \dots v_{i_d}^{(d)} = \prod_{j=1}^d v_{i_j}^{(j)}.$$

Lemma 1.1.16 (Legame tra il prodotto esterno e il prodotto di Kroneker). *Dato un tensore $\mathcal{X} = v^{(1)} \circ \dots \circ v^{(d)}$, allora*

$$(i) \text{vec}(\mathcal{X}) = v^{(d)} \otimes \dots \otimes v^{(1)}$$

$$(ii) X_{(k)} = v^{(k)} \left(v^{(d)} \otimes \dots \otimes v^{(k-1)} \otimes v^{(k+1)} \otimes \dots \otimes v^{(1)} \right)^\top$$

$$(iii) X_{(\mathcal{R} \times \mathcal{C})} = (v^{(r_\delta)} \otimes \dots \otimes v^{(r_1)}) (v^{(c_{d-\delta})} \otimes \dots \otimes v^{(c_1)})^\top, \text{ dove } \mathcal{R} = \{r_1, \dots, r_\delta\} \text{ e } \mathcal{C} = \{c_1, \dots, c_{d-\delta}\}.$$

Dimostrazione.

□

Dimostrare

Osservazione 1.1.17. Tutte le matricizzazioni di un prodotto esterno hanno rango 1.

In molte situazioni è utile moltiplicare un tensore con una matrice, ma purtroppo le dimensioni non combaciano. La seguente definizione risolve il problema facendo agire la matrice la matrice lungo il modo k -esimo di un tensore, e si chiama.

Definizione 1.1.18 (Prodotto nel modo k). Il *prodotto nel modo k* di un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ con una matrice $U \in \mathbb{R}^{r \times n_k}$ è un tensore

$$\mathcal{Y} = \mathcal{X} \times_k U \in \mathbb{R}^{n_1 \times \dots \times n_{k-1} \times r \times n_{k+1} \times \dots \times n_d} \text{ con } Y_{(k)} = UX_{(k)}.$$

In componenti, $\mathcal{Y}(i_1, \dots, i_{k-1}, \alpha, i_{k+1}, \dots, i_d) = \sum_{i_k=1}^d \mathcal{X}(i_1, i_2, \dots, i_d) U_{\alpha, i_k}$.

Lemma 1.1.19. Siano $A \in \mathbb{K}^{m \times n}$, $B \in \mathbb{K}^{m \times n}$ ed $X \in \mathbb{K}^{n \times m}$. Allora

$$\text{vec}(AXB) = (B^\top \otimes A) \text{vec}(X)$$

Dimostrazione. Scrivendo $B = [b_1, \dots, b_n]$ ed $X = [x_1, \dots, x_m]$, la k -esima colonna di AXB è

$$(AXB)_{:,k} = AXb_k = A \sum_{i=1}^m x_i b_{i,k} = [b_{1,k}A, \dots, b_{m,k}A] \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix} = ([b_{1,k}, \dots, b_{m,k}] \otimes A) \text{vec}(X).$$

Impilando insieme le colonne otteniamo che

$$\text{vec}(AXB) = \begin{bmatrix} (AXB)_{:,1} \\ (AXB)_{:,2} \\ \vdots \\ (AXB)_{:,n} \end{bmatrix} = \begin{bmatrix} b_1^\top \otimes A \\ b_2^\top \otimes A \\ \vdots \\ b_n^\top \otimes A \end{bmatrix} \text{vec}(X) = (B^\top \otimes A) \text{vec}(X).$$

□

Proposizione 1.1.20. Dato un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times n_3}$ e delle matrici $U \in \mathbb{R}^{m_1 \times n_1}$, $V \in \mathbb{R}^{m_1 \times n_2}$ e $W \in \mathbb{R}^{m_3 \times n_3}$. Sono fatti equivalenti:

$$(i) \mathcal{Y} = \mathcal{X} \times_1 U \times_2 V \times_3 W \in \mathbb{R}^{m_1 \times m_2 \times m_3}.$$

$$(ii) \text{vec}(\mathcal{Y}) = (W \otimes V \otimes U) \cdot \text{vec}(\mathcal{X}).$$

$$(iii) Y_{(1)} = UX_{(1)}(W \otimes V)^\top.$$

$$(iv) Y_{(2)} = VX_{(2)}(W \otimes U)^\top.$$

$$(v) Y_{(3)} = WX_{(3)}(V \otimes U)^\top.$$

Dimostrazione. (1) $\iff$ (2) Mostriamo che $\text{vec}(\mathcal{X} \times_1 U) = (I \otimes I \otimes U) \text{vec}(\mathcal{X})$.

(2) $\iff$ (4) Conversely, assume statement 2 holds. Thus...

□

Proposizione 1.1.21. Siano $A \in \mathbb{R}^{m \times p}$ e $B \in \mathbb{R}^{n \times q}$. Allora,

$$A \otimes B = P(B \otimes A)Q^\top,$$

dove P e Q sono matrici di permutazione (m, n) - e (p, q) - perfect shuffle, rispettivamente.

Dimostrazione.

ADD

□

1.2 LA FATTORIZZAZIONE CP

Cerchiamo una decomposizione di rango basso di un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ per ridurre il costo di rappresentazione in memoria e delle operazioni algebriche che lo coinvolgono. Nel caso matriciale, data una matrice $X \in \mathbb{R}^{n_1 \times n_2}$ di rango r , possiamo scrivere

$$X = UV^\top = [u_1 | \dots | u_r][v_1 | \dots | v_r]^\top = u_1 v_1^\top + \dots + u_r v_r^\top = u_1 \circ v_1 + \dots + u_r \circ v_r,$$

per certe matrici $U \in \mathbb{R}^{n_1 \times r}$ e $V \in \mathbb{R}^{n_2 \times r}$. Questo tipo di decomposizione è vantaggioso in termini di memoria: infatti

$$\text{vec}(X) = v_1 \otimes u_1 + \dots + v_r \otimes u_r,$$

quindi memorizzare U e V costa $O((n_1 + n_2)r)$ invece che $O(n_1 n_2)$. Vorremmo quindi riadattare questa decomposizione per memorizzare $\mathcal{X}$ con costo $O((n_1 + \dots + n_d)r)$ invece che $O(n_1 \dots n_d)$. Tuttavia, generalizzare questa decomposizione a più dimensioni ha numerosi ostacoli.

ref to ostacoli

Definizione 1.2.1 (Canonical Polyadic Decomposition (CP)). Diciamo che un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$ ammette una *decomposizione CP* di rango $r \in \mathbb{N}$ se esistono delle matrici $U_1, \dots, U_d$ tali che $U_b = [u_1^{(b)} | \dots | u_r^{(b)}] \in \mathbb{R}^{n_b \times r}$ tali per cui valgono le seguenti condizioni equivalenti:

$$(i) \quad \mathcal{X} = \sum_{j=1}^r u_j^{(1)} \circ \dots \circ u_j^{(d)} = \sum_{i=1}^r \bigcirc_{b=1}^d u_j^{(b)}.$$

$$(ii) \quad \text{vec}(\mathcal{X}) = \sum_{j=1}^r u_j^{(d)} \otimes \dots \otimes u_j^{(1)} = \sum_{i=1}^r \bigotimes_{b=d}^1 u_j^{(b)}.$$

$$(iii) \quad \mathcal{X}(i_1, i_2, \dots, i_d) = \sum_{j=1}^r U_1(i_1, j) U_2(i_2, j) \dots U_d(i_d, j) = \sum_{j=1}^r \prod_{b=1}^d U_b(i_b, j).$$

In tal caso, scriviamo $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$.

Definizione 1.2.2. Il *rango CP* di un tensore $\mathcal{X}$ è il minimo intero $r \in \mathbb{Z}_{\geq 0}$ tale per cui $\mathcal{X}$ ammette una decomposizione CP di rango r , e lo denotiamo con $\text{rank}(\mathcal{X}) = r$.

Osservazione 1.2.3 (Risparmio in memoria della CP). La fattorizzazione CP di un tensore $\mathcal{X}$ di rango r permette di ridurre notevolmente il costo di memorizzazione del tensore, in quanto richiede $O((n_1 + \dots + n_d)r) \ll O(\prod_{i=1}^d n_i)$.

Definizione 1.2.4 (Prodotto Khatri-Rao). Date due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$, il loro *prodotto Khatri-Rao* è dato da

$$C = A \odot B = [a_1 \otimes b_1 \mid \dots \mid a_r \otimes b_r] \in \mathbb{R}^{(mn) \times r}, \quad (1.1)$$

dove a_j e b_j indicano la j -esima colonna di A e B , rispettivamente, e la matrice C si lascia scrivere in componenti come $C_{k,l} = A_{i,l}B_{j,l}$, dove $\mathbb{L}^*(i, j) = \mathbb{L}(j, i) = k$.

Osservazione 1.2.5. Calcolare il prodotto di Khatri-Rao di due matrici $A \in \mathbb{R}^{m \times r}$ e $B \in \mathbb{R}^{n \times r}$ ha un costo in memoria di $O(mn \cdot r)$.

1.3 RANGO CP

Proposizione 1.3.1. Sia $\mathcal{X} \in \mathbb{R}^{n_1 \times \dots \times n_d}$ un tensore che ammette fattorizzazione $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$, e sia $r_j = \text{rank}(X_{(j)})$ il rango dell'unfolding $X_{(j)}$, con $j = 1, \dots, d$. Allora vale che

$$\max_{j=1, \dots, d} (r_j) \leq \text{rank}(\mathcal{X}) \leq \min_{j=1, \dots, d} \left(\prod_{i \neq j} r_i \right) \quad (1.2)$$

Dimostrazione. La minorazione segue direttamente dalla scrittura delle

□

Nel caso matriciale, possiamo calcolare il rango di una matrice A usando la decomposizione

motivare?

SVD $U\Sigma V^*$, ma nel caso multidimensionale calcolare il rango è un problema NP-hard.

1.4 IL PROBLEMA DEL BORDER RANK

Esempio 1.4.1. Consideriamo dei vettori $a_1, a_2 \in \mathbb{R}^m$, $b_1, b_2 \in \mathbb{R}^n$ e $c_1, c_2 \in \mathbb{R}^p$ vettori linearmente indipendenti. Definiamo il tensore

$$\mathcal{X} = a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_1 + a_2 \circ b_1 \circ c_1, \quad (1.3)$$

e notiamo che $\text{rank}(\mathcal{X}) = 3$ dato che non può essere scomposto come somma di tensori più semplici. Consideriamo la successioni di tensori

$$\mathcal{Y}_\varepsilon = \frac{1}{\varepsilon} (a_1 + \varepsilon a_2) \circ (b_1 + \varepsilon b_2) \circ (c_1 + \varepsilon c_2) - \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_1, \text{ con } \varepsilon \in \mathbb{R}, \quad (1.4)$$

che essendo combinazione lineare di due tensori di rango uno, ha rango 2. Vediamo che $\lim_{\varepsilon \rightarrow 0} \mathcal{Y}_\varepsilon = \mathcal{X}$, da cui segue che l'insieme dei tensori di rango 3 non è chiuso. Espandendo i termini dell'Equazione 1.4 tramite la proprietà distributiva del prodotto esterno,


$$\begin{aligned} \mathcal{Y}_\varepsilon &= \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_2 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_1 + a_2 \circ b_1 \circ c_1 \\ &\quad + \varepsilon(a_2 \circ b_2 \circ c_1 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_2 + a_2 \circ b_2 \circ c_2) - \frac{1}{\varepsilon} a_1 \circ b_1 \circ c_1 \quad (1.5) \\ &= \mathcal{X} + \varepsilon(a_2 \circ b_2 \circ c_1 + a_1 \circ b_1 \circ c_2 + a_1 \circ b_2 \circ c_2 + a_2 \circ b_2 \circ c_2) \end{aligned}$$

Quindi $\mathcal{Y}_\varepsilon - \mathcal{X} \rightarrow 0$.

Questo motiva la seguente definizione:

Definizione 1.4.2 (Border rank). Dato un tensore $\mathcal{X} \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_d}$, il suo border rank è la quantità

$$\text{rank}(\mathcal{X}) = \min\{r \in \mathbb{N} \mid \exists \mathcal{Y} \in \mathbb{R}^{n_1 \times \dots \times n_d} \text{ t.c. } \text{rank}(\mathcal{Y}) = r, \|\mathcal{X} - \mathcal{Y}\| < \varepsilon\}.$$



1.5 OPERAZIONI NEL FORMATO CP

Lemma 1.5.1. Dato un tensore $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$, vale $\text{vec}(\mathcal{X}) = (U_d \odot U_{d-1} \odot \dots \odot U_1) 1_r$, dove $1_r = [1, \dots, 1]^\top$.

Dimostrazione. Segue dall'identità

$$\begin{aligned} \text{vec}(\mathcal{X}) &= \sum_{b=1}^r u_b^{(d)} \otimes \dots \otimes u_b^{(1)} = [u_1^{(d)} \otimes \dots \otimes u_1^{(1)} \mid \dots \mid u_r^{(d)} \otimes \dots \otimes u_r^{(1)}] 1_r \\ &= (U_d \odot U_{d-1} \odot \dots \odot U_1) 1_r. \end{aligned}$$

□

Se serve, versione
per unfoldings
generalizzati

1.6 COSTRUZIONE DEL TENSORE IN FORMATO DENSO

1.7 UNICITÀ DELLA FATTORIZZAZIONE CP

Definizione 1.7.1 (Essenziale unicità CP). Una fattorizzazione CP di rango r di un tensore $\mathcal{X}[[U_1, \dots, U_d]]$ è *essenzialmente unica* se, per ogni altra fattorizzazione $\mathcal{X} = [[\tilde{U}_1, \dots, \tilde{U}_d]]$ di rango r , esiste una matrice di permutazione $P \in \mathbb{R}^{r \times r}$ e delle matrici diagonali $D_1, \dots, D_d \in \mathbb{R}^{r \times r}$ che soddisfano $D_1 D_2 \dots D_d = I$ e $U_j = \tilde{U}_j D_j P$, per ogni $j = 1, \dots, d$.

Definizione 1.7.2 (k -rango). Data $A \in \mathbb{R}^{m \times n}$, il suo k -rango è il massimo $k \in \mathbb{N}$ tale che ogni scelta di k colonne in A comprende colonne linearmente indipendenti. Lo denoteremo con il simbolo $\text{rank}_K(A)$.


Osservazione 1.7.3. Dalla definizione segue che $\text{rank}_K(A) \leq \text{rank}(A)$ per ogni matrice $A \in \mathbb{R}^{m \times n}$. In particolare, se A è full-rank, $\text{rank}_K(A) = \text{rank}(A)$; se invece A ha due colonne linearmente dipendenti, $\text{rank}_K(A) \leq 1$.

Veniamo ora al risultato nella sua forma più generale, dimostrato da Sidiropoulos e Bro [2].

Teorema 1.7.4 (Kruskal 3D, Sidiropoulos e Bro). Una fattorizzazione CP di un tensore $\mathcal{X} = [[U_1, \dots, U_d]]$ di rango r è *essenzialmente unica* se

$$\sum_{j=1}^d \text{rank}_K(U_j) \geq 2r + d - 1.$$

Mostriamo prima il caso $d = 3$. Per semplicità, consideriamo l'enunciato sopra rinominando $\mathcal{X} = [[A, B, C]]$, e mostriamo che $\text{rank}_K(A) + \text{rank}_K(B) + \text{rank}_K(C) \geq 2r + 2$.



Per il caso $d = 4$ introduciamo il seguente lemma:

Lemma 1.7.5 (K -rango del prodotto di Khatri-Rao). Consideriamo $A = [a_1 \mid \dots \mid a_r] \in \mathbb{C}^{m \times p}$ e $B = [b_1 \mid \dots \mid b_r] \in \mathbb{C}^{n \times p}$. Allora, se $\text{rank}_K(A) \geq 1$ e $\text{rank}_K(B) \geq 1$ vale che

$$\text{rank}_K(A \odot B) \geq \min(\text{rank}_K(A) + \text{rank}_K(B) - 1, r),$$

Chiedere se questa notazione del rank_K va bene

Chiarire se $\mathbb{K}$ può essere $\mathbb{R}$ o $\mathbb{C}$

mentre se almeno una tra A o B ha K -rango nullo, vale

$$\text{rank}_K(A \odot B) = 0.$$

Dimostrazione. Assumiamo a meno di scambiare le due matrici che $\text{rank}_K(A)$ sia nullo. Ciò equivale a dire che A contiene almeno una colonna nulla, da cui per la Definizione 1.1.5 il prodotto $A \odot B$ avrà almeno una colonna nulla, da cui $\text{rank}_K(A \odot B) = 0$.

Mostriamo la prima stima procedendo per assurdo. Consideriamo l'insieme

$$S = \inf \{s \in \mathbb{N} \mid b_{i_1} \otimes a_{i_1}, \dots, b_{i_s} \otimes a_{i_s} \text{ sono colonne linearmente indipendenti di } A \odot B\}.$$

Se $S = -\infty$, ossia non è possibile estrarre alcuna collezione di colonne linearmente indipendenti da $A \odot B$, poniamo $S = d + 1$ e $\text{rank}_K(B \odot A) = S - 1$. □

Finire appena
finisci di capire

La condizione di Kruskal è sufficiente ma non necessaria. Il seguente risultato fornisce una condizione necessaria ma non sufficiente:

Teorema 1.7.6. *Dato un tensore $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$ tale per cui $\min_j \{\text{rank}(U_d \odot \dots \odot U_{j+1} \odot U_{j-1} \odot \dots \odot U_1)\} < r$, allora la fattorizzazione $\mathcal{X} = \llbracket U_1, \dots, U_d \rrbracket$ non è essenzialmente unica.*

1.8 CALCOLO DELLA FATTORIZZAZIONE CP

Trattiamo il problema di trovare la migliore approssimazione con rango CP r di un dato tensore. Studiamo il caso $d = 3$. Dato $\mathcal{X} \in \mathbb{R}^{m \times n \times p}$ cerchiamo una fattorizzazione $\llbracket A, B, C \rrbracket$ con $A \in \mathbb{R}^{m \times r}$, $B \in \mathbb{R}^{n \times r}$ e $C \in \mathbb{R}^{p \times r}$ cercando di risolvere il problema ai minimi quadrati

$$\min_{A, B, C} \|\mathcal{X} - \llbracket A, B, C \rrbracket\|^2. \quad (1.6)$$

Tale problema può essere mal posto per quanto detto sul border rank. Inoltre si tratta di un problema non convesso (esistono molti minimi locali) e dato che ogni tensore ha rappresentazioni CP multiple.

why?

ALTERNATING LEAST-SQUARES

Considero

$$\|\mathcal{X} - \llbracket A, B, C \rrbracket\|^2 = \|\mathbf{X}_{(1)} - A(C \odot B)^\top\|_F^2 = \|(C \odot B)A^\top - \mathbf{X}_{(1)}^\top\|_F^2,$$

ovvero un problema lineare ai minimi quadrati dove l'incognita è una matrice A . La soluzione può essere espressa in termini delle equazioni normali

why?

1 La fattorizzazione CP

$$(C \odot B)^\top (C \odot B) A^\top = (C \odot B)^\top X_{(1)}^\top,$$

lemma KRP HA-Damard

se e solo se, usando il lemma

$$(C^\top C * B^\top B) A^\top = (C \odot B)^\top X_{(1)}^\top.$$

La matrice $Z = \mathbb{R}^{r \times r}$ è semidefinita positiva, e quando è positiva definita (accade se $C \odot B$ è full-rank possiamo risolvere con la fattorizzazione di Cholesky il sistema)

$$AZ = X_{(1)}(C \odot B) = M \tag{1.7}$$

vEdi fogli per calcolo costo

2 APPLICAZIONI DELLA CP ALLA COMPLESSITÀ ARITMETICA

2.1 RAPPRESENTARE FORME BILINEARI TRAMITE TENSORI

Conoscere il rango CP di tensori che rappresentano applicazioni multilineari può rivelare informazioni sulla complessità asintotica e fornire algoritmi con complessità ottimale per la loro valutazione. Proviamo a formulare il problema: dall'algebra lineare sappiamo che data una forma bilineare $b : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}$, esiste una matrice $M \in \mathbb{R}^{m \times n}$ tale che $b(x, y) = x^\top M y$ per ogni $(x, y) \in \mathbb{R}^m \times \mathbb{R}^n$. Notiamo che un insieme di p forme bilineari, o equivalentemente una funzione

bilineare $b = \begin{bmatrix} b_1 \\ \vdots \\ b_p \end{bmatrix} : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}^p$ si può rappresentare tramite un tensore $\mathcal{X} \in \mathbb{R}^{m \times n \times p}$ tale che

È chiaro se si chiama ancora b ?

le sue slice frontali rappresentino ognuna delle p forme bilineari, ossia che

$$b_k(x, y) = x^\top \mathcal{X}(:, :, k) y = \sum_{i=1}^m \sum_{j=1}^n \mathcal{X}(i, j, k) x_i y_j, \text{ per ogni } k = 1, \dots, p. \quad (2.1)$$

Da cui,

$$b(x, y) = \begin{bmatrix} b_1(x, y) \\ \vdots \\ b_p(x, y) \end{bmatrix} = \mathcal{X} \times_1 x^\top \times_2 y^\top. \quad (2.2)$$

Osservazione 2.1.1. Questa procedura si estende anche al caso in cui le entrate di x e y siano oggetti algebrici più complessi di scalari, ad esempio vettori o matrici.

Osservazione 2.1.2 (Active multiplications). Scrivere una forma bilineare come nell'Equazione 2.1 evidenzia il numero di moltiplicazioni necessarie fra gli elementi di x e y . Queste sono dette *active multiplications* e corrispondono al numero di elementi non nulli di $\mathcal{X}$. Poiché ci aspettiamo che il costo delle active multiplications sia quello che determini la complessità di valutare $b(x, y)$, cerchiamo di minimizzarne il numero cercando fattorizzazioni CP di $\mathcal{X}$.

Data una decomposizione $\mathcal{X} = \llbracket U, V, W \rrbracket$ di rango r , dalla Definizione 1.2.1 abbiamo che $\mathcal{X} = \sum_{l=1}^r u_l \circ v_l \circ w_l$, o in componenti, $\mathcal{X}(i, j, k) = \sum_{l=1}^r u_{il} v_{jl} w_{kl}$. Inserendo questa relazione

nella Equazione 2.1 troviamo,

$$\begin{aligned} b_k(x, y) &= \left(\left(\sum_{l=1}^r u_l \circ v_l \circ w_l \right) x_1 x^\top x_2 y^\top \right)_k = \left(\sum_{l=1}^r (u_l \circ v_l \circ w_l) x_1 x^\top x_2 y^\top \right)_k \\ &= \sum_{i=1}^m \sum_{j=1}^n \sum_{l=1}^r u_{il} v_{jl} w_{kl} x_i y_j = \sum_{l=1}^r \left(\sum_{i=1}^m u_{il} x_i \right) \cdot \left(\sum_{j=1}^n v_{jl} y_j \right) w_{kl} = \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_{kl}, \end{aligned} \quad (2.3)$$

per ogni $k = 1, \dots, p$. Mettendo insieme le Equazioni 2.2 e 2.3 troviamo

$$b(x, y) = \sum_{l=1}^r (u_l^\top x) \cdot (v_l^\top y) w_l.$$

Espandere discussione dall'articolo

Quindi valutare b richiede esattamente r active multiplications, che evidenziamo con $(\cdot)$.

2.2 IL MASTER METHOD

Introduciamo brevemente un metodo per risolvere relazioni ricorsive definite per ricorrenza, detto *master method*. I lettori più interessati possono trovare una trattazione più dettagliata sul libro [1]. Il master method si usa per risolvere ricorrenze della forma

$$T(n) = aT\left(\frac{n}{b}\right) + f(n), \quad (2.4)$$

dove $a \geq 1$ e $b > 1$ sono costanti e $f(n)$ è una funzione asintoticamente positiva. La ricorrenza 2.4 descrive il tempo di esecuzione di un algoritmo che divide un problema di dimensione n in a sottoproblemi, ognuno di dimensione $\frac{n}{b}$. Gli a sottoproblemi vengono risolti ricorsivamente in tempo $T(\frac{n}{b})$, e la funzione $f(n)$ rappresenta il costo di dividere il problema e ricombinare la ricorsione di ogni sottoproblema.

Indichiamo con O e Ω la stima superiore e inferiore, rispettivamente, e con Θ la stima stretta.

Teorema 2.2.1 (Master theorem). *Siano $a \geq 1$ e $b > 1$ delle costanti, sia $f(n)$ una funzione e definiamo $T(n)$ sugli interi nonnegativi dalla ricorrenza*

$$T(n) = aT\left(\frac{n}{b}\right) + f(n),$$

dove con $\frac{n}{b}$ indichiamo sia $\lfloor \frac{n}{b} \rfloor$ o $\lceil \frac{n}{b} \rceil$. Allora $T(n)$ ha le seguenti soglie asintotiche:

1. Se $f(n) = O(n^{\log_b a - \varepsilon})$ per qualche $\varepsilon > 0$, allora $T(n) = \Theta(n^{\log_b a})$.
2. Se $f(n) = \Theta(n^{\log_b a})$ allora $T(n) = \Theta(n^{\log_b a} \log n)$.

3. If $f(n) = \Omega(n^{\log_b a + \varepsilon})$ per qualche costante $\varepsilon > 0$, e se $af(\frac{n}{b}) < cf(n)$ per qualche costante $c < 1$ e ogni n sufficientemente grande, allora $T(n) = \Theta(f(n))$.

Esempio 2.2.2. Nel caso dell'algoritmo naive la ricorrenza ha la forma $a = 8$, $b = 2$ e $f(n) = \Theta(n^2)$, ovvero

$$T(n) = 8T(\frac{n}{2}) + \Theta(n^2).$$

Siccome $n^{\log_b a} = n^{\log_2 8} = n^3$, che è polinomialmente più grande di $f(n)$, ovvero $f(n) = O(n^{3-\varepsilon})$ per $\varepsilon = 1$, dal caso 1 di 2.2.1 segue che $T(n) = \Theta(n^3)$.

2.3 MOLTIPLICAZIONE RICORSIVA DI MATRICI

Possiamo rappresentare la moltiplicazione tra matrici come una funzione bilineare, quindi come un tensore.

Lemma 2.3.1 (Rappresentazione del prodotto matriciale). *Per ogni coppia di matrici $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times p}$, esiste un tensore $\mathfrak{X} \in ?$ tale che il prodotto $C = AB \in \mathbb{R}^{m \times p}$ si scrive come $\mathfrak{X} \times_1 \text{vec}(A)^\top \times_2 \text{vec}(B)^\top = \text{vec}(C)^\top$.*

finire

Dimostrazione. Dalla definizione di prodotto di matrice, $C_{ij} =$

□

Brief motivation

Notazione: Indichiamo con $\langle m, n, p \rangle$ il prodotto tra due matrici di taglia $m \times n$ e $n \times p$.

Trattiamo prima il caso di matrici quadrate con taglie potenze di due. Discuteremo di seguito come trattare il caso generale. In questo caso possiamo partizionare le matrici in delle sottomatrici a blocchi 2×2 :

$$\begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \cdot \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}.$$

L'algoritmo naive procede combinando un insieme di otto moltiplicazioni matriciali con quattro addizioni:

$$\begin{aligned} M_1 &= A_{11} \cdot B_{11} & M_2 &= A_{12} \cdot B_{21} & M_3 &= A_{11} \cdot B_{12} \\ M_4 &= A_{12} \cdot B_{22} & M_5 &= A_{21} \cdot B_{11} & M_6 &= A_{22} \cdot B_{21} \\ M_7 &= A_{21} \cdot B_{12} & M_8 &= A_{22} \cdot B_{22} \\ C_{11} &= M_1 + M_2 & C_{12} &= M_3 + M_4 \\ C_{21} &= M_5 + M_6 & C_{22} &= M_7 + M_8 \end{aligned}$$

ACRONIMI

PCA	Principal component analysis
SNF	Smith normal form
TDA	Topological data analysis

GLOSSARIO

$\text{\LaTeX}$	A document preparation system
$\mathbb{R}$	The set of real numbers

BIBLIOGRAFIA

1. T. H. Cormen, C. E. Leiserson, R. L. Rivest, e C. Stein. *Introduction to algorithms*. MIT press, 2022.
2. N. D. Sidiropoulos e R. Bro. «On the uniqueness of multilinear decomposition of N-way arrays». *Journal of Chemometrics: A Journal of the Chemometrics Society* 14:3, 2000, pp. 229–239.